

MAESTRÍA EN ANALÍTICA APLICADA
FACULTAD DE INGENIERÍA

Diseño e implementación de un modelo de *nowcasting* elección-agnóstico para la intención de voto aplicado a elecciones locales en Colombia 2023

Juan Sotelo Aguilar

DIRECTOR
PhD. Miguel Uribe Laverde
Universidad de La Sabana

AÑO ACADÉMICO 2026

A María José, mi familia y quienes creyeron en esto antes de que yo mismo creyera.

Índice general

Resumen	1
Abstract	1
1 Introducción	1
1.1 Motivación del problema	1
1.2 Estado del arte: de los modelos paramétricos al SOMEN-DC	2
1.3 Hipótesis de trabajo	5
1.4 Estructura del documento	6
2 Pregunta de investigación	7
2.1 Pregunta principal	7
2.2 Preguntas derivadas	7
3 Marco conceptual	8
3.1 <i>Nowcasting</i> electoral y predicción con redes sociales	8
3.1.a Definición de <i>nowcasting</i> en contexto electoral	8
3.2 Modelos elección-agnósticos: definición y ventajas	8
3.3 Interacciones digitales como <i>proxy</i> de intención de voto	9
3.3.a La hipótesis Tumasjan	9
3.3.b Interacciones absolutas vs. dominancia relativa	9
3.4 El problema del histórico de interacciones	10
4 Objetivos	10
4.1 Objetivo general	10
4.2 Objetivos específicos	10
5 Metodología	11
5.1 Definición formal del problema	11
5.1.a Definición de la elección	11
5.1.b Definición de la intención de voto y los resultados	11
5.1.c Definición formal de las publicaciones y su comportamiento temporal	12
5.1.d Definición del problema	12
5.2 Diseño general del proceso	13
5.3 Etapa 1 - Bolivia: Replicación del SOMEN-DC y prueba de concepto	14
5.3.a Caso de estudio y recolección de datos	14
5.3.b Preparación de datos y variable objetivo	14
5.3.c Evaluación de modelos	15
5.4 Etapa 2 - Costa Rica: Modelado del crecimiento de interacciones	16
5.4.a El problema estructural	16

5.4.b	Recolección y validación del panel	16
5.4.c	Análisis de la persistencia de interacciones	17
5.4.d	Selección y calibración del modelo Weibull	17
5.4.e	Validación: precisión en la estimación del total final	18
5.4.f	Función de reconstrucción histórica	19
5.5	Etapla 3 - Colombia: Construcción del dataset y modelado	21
5.6	Modelado predictivo	22
5.6.a	Modelo de regresión	22
5.6.b	Modelo de clasificación binaria	22
6	Resultados	23
6.1	Resultados de Bolivia (Etapla 1)	23
6.2	Resultados de Costa Rica (Etapla 2)	25
6.3	Resultados de Colombia (Etapla 3)	26
6.4	Síntesis: contribuciones al estado del arte	27
7	Impacto esperado	27
7.1	Impacto académico	27
7.2	Impacto práctico	28
7.3	Limitaciones y trabajo futuro	28
8	Conclusiones	29
8.1	Respuesta a la pregunta de investigación	29
8.2	Lecciones aprendidas	30
8.3	Próximos pasos	30
	Bibliografía	31

Resumen

En Latinoamérica, las encuestas electorales son la única herramienta disponible para el seguimiento de la intención de voto durante una campaña activa. Este trabajo propone y valida una metodología alternativa para estimar la intención de voto que no depende de encuestas, es elección-agnóstica y puede replicarse con herramientas comerciales accesibles.

Palabras clave: nowcasting electoral, redes sociales, machine learning, Colombia, elecciones locales, elección-agnóstico.

Abstract

In Latin America, electoral polls are the only available tool for tracking voting intention during an active campaign. This work proposes and validates an alternative methodology to estimate voting intention that does not rely on polls, is election-agnostic, and can be replicated with accessible commercial tools. Using social media interactions from candidates' official profiles as the primary signal, and a Weibull growth model for historical interaction reconstruction, the study demonstrates that relative dominance of a candidate's digital engagement is a statistically significant predictor of electoral outcomes in Colombian local elections ($\rho > 0.46, p < 2 \times 10^{-7}$).

Keywords: electoral nowcasting, social media, machine learning, Colombia, local elections, election-agnostic model, Weibull growth.

1

Introducción

1.1. Motivación del problema

La industria global de investigación de mercados y opinión pública, que incluye el pronóstico electoral, alcanzó 153.000 millones de dólares en 2024, un crecimiento del 8 % frente al año anterior, según *ESOMAR* (2025), la asociación mundial del sector. En Colombia, la misma industria facturó 743.058 millones de pesos en 2024 (equivalentes a aproximadamente 208.000 dólares a la tasa de cambio de mayo de 2026), con un crecimiento del 1 % frente al año anterior, según la *Asociación Colombiana de Empresas de Investigación de Mercados y Opinión Pública* (ACEI, 2025).

Este crecimiento contrasta con el de los mercados alternativos de pronóstico: plataformas como *Polymarket* y *Kalshi* registraron en conjunto cerca de 60.000 millones de dólares en volumen de operaciones en los primeros meses de 2026, superando ya el total de 2025, y se proyecta que alcancen un billón de dólares anuales para 2030, según estimaciones de Bernstein Research (Giangiulio, 2026). Esta divergencia sugiere que la demanda por información predictiva sobre resultados futuros crece a un ritmo que las encuestas tradicionales no están capturando.

A pesar de su ubicuidad, las encuestas electorales en Colombia enfrentan profundos retos estructurales que se han agudizado recientemente. La dificultad logística de abarcar territorios extensos, la alta tasa de no respuesta y los elevados costos operativos limitan la frecuencia y el tamaño muestral de los estudios, especialmente en elecciones locales.

A estos problemas estructurales se suma un nuevo marco regulatorio que ha tensionado aún más el sector: la **Ley 2494 de 2025**, que estableció requisitos metodológicos estrictos para la elaboración y publicación de encuestas electorales, incluyendo una veda de publicación que interrumpió el flujo de información entre julio y noviembre de 2025 (Congreso de la República de Colombia, 2025).

La aplicación práctica de esta norma generó tal nivel de fricción entre el *Consejo Nacional Electoral* (CNE) y las firmas encuestadoras, que la consultora española GAD3 suspendió definitivamente sus mediciones en el país en mayo de 2026, argumentando que la interpretación de la Comisión Técnica exige demostrar condiciones de muestreo que “ninguna metodología demoscópica puede satisfacer en la práctica” (GAD3, 2026).

La norma, al invalidar encuestas telefónicas, paneles digitales y métodos mixtos en favor de encuestas presenciales domiciliarias, encareció operativamente el sector y concentró el mercado en pocas firmas con suficiente capacidad económica para operar en campo en todo el territorio nacional (Ríos Giraldo, 2026). En este panorama, resulta cada vez más urgente desarrollar herramientas de pronóstico electoral que no dependan exclusivamente de encuestas y que aprovechen fuentes alternativas de datos masivos.

1.2. Estado del arte: de los modelos paramétricos al SOMEN-DC

La capacidad de anticipar resultados electorales ha sido un reto persistente para la ciencia política desde los años setenta, cuando surgieron los primeros modelos predictivos formales en Estados Unidos y el Reino Unido. Los trabajos pioneros de Sigelman (1979) y Whiteley (1979) demostraron que la popularidad presidencial medida meses antes de una elección era un predictor estadísticamente significativo del resultado electoral, abriendo la puerta a una tradición de modelos formales de pronóstico que hasta entonces era prácticamente inexistente en la ciencia política.

Esta tradición evolucionó rápidamente hacia arquitecturas econométricas más sofisticadas. Mughan (1987) comparó tres modelos simples de pronóstico para elecciones generales en el Reino Unido, concluyendo que las variables macroeconómicas, en particular el desempleo y la aprobación gubernamental, ofrecían mayor poder predictivo que los indicadores de popularidad aislados. Por su parte, Sanders (1991) desarrolló un modelo de función de popularidad para el gobierno británico que incorporaba condiciones económicas y eventos políticos exógenos, anticipando el resultado de las elecciones generales con seis meses de antelación. Durante los años noventa y la primera década del siglo XXI, estos modelos alcanzaron su madurez técnica, apoyándose en herramientas de series de

tiempo como VAR y ARMA. En el contexto del Reino Unido, (Lewis-Beck et al. (2004)) formularon un modelo de economía política que explicaba más del 80 % de la varianza en el apoyo gubernamental usando solo tres variables: aprobación del gobierno, inflación y el número de términos consecutivos en el poder. En paralelo, Norpoth (2004) propuso una perspectiva dinámica que modelaba el retorno del voto al equilibrio histórico mediante un proceso autorregresivo AR(1), demostrando que el partido ganador tiende a perder aproximadamente la mitad de su ventaja en la siguiente elección. En varios ciclos electorales, estos modelos superaban en precisión a las propias encuestadoras.

Sin embargo, desde aproximadamente 2015, la capacidad predictiva de estos enfoques se deterioró de forma pronunciada. En el Reino Unido, ningún modelo establecido logró anticipar la mayoría conservadora de ese año (Stegmaier et al., 2023); un año después, los mismos enfoques fallaron en predecir la victoria de Donald Trump, el Brexit y la salida del Reino Unido de la Unión Europea (K. Brito et al., 2024; Stegmaier et al., 2023). Esta crisis generalizada no fue accidental: Kennedy et al. (2018) documentaron, en una evaluación exhaustiva encargada por la Asociación Americana de Investigación de Opinión Pública (AAPOR), que los sondeos de 2016 sobreestimaron sistemáticamente el apoyo a Hillary Clinton debido a sesgos de no-respuesta diferencial, especialmente entre votantes de Trump sin estudios universitarios. A esto se sumaron los cambios estructurales en la comunicación política propiciados por las redes sociales (Tucker et al., 2018) y la creciente fragmentación y polarización de los electorados (Barberá, 2020), que volvieron menos predecibles los comportamientos que los modelos paramétricos habían aprendido a capturar.

La crisis impulsó a los investigadores a explorar fuentes de datos alternativas. El auge del *Big Data* y las plataformas digitales abrió una nueva línea de investigación: usar las huellas digitales de los ciudadanos como covariables en tiempo real para el pronóstico electoral. El estudio seminal de Tumasjan et al. (2010) sobre las elecciones federales alemanas de 2009 fue el primer trabajo de referencia en este campo. Analizando más de 104.000 *tweets* publicados en las semanas previas a la elección, los autores encontraron que el simple volumen de menciones de cada partido replicaba el resultado electoral con un error absoluto medio de apenas 1,65 %, comparable al de las encuestadoras tradicionales. Más allá de la predicción, Tumasjan et al. demostraron que los perfiles de sentimiento de los mensajes correspondían a las posiciones políticas reales de los partidos, y que las menciones conjuntas de dos partidos reflejaban las alianzas políticas existentes. Esta hipótesis, que la atención digital equivale a capital político, abrió una década de investigación intensa.

No obstante, la promesa inicial no se sostuvo en la replicación sistemática. Skoric et al. (2020), en un meta-análisis de 74 estudios publicados entre 2007 y 2018, encontraron que las predicciones basadas en redes sociales quedaban en promedio por debajo de los *benchmarks* de la encuesta tradicional, con alta varianza entre estudios y sin convergencia metodológica. Sus resultados mostraron que las predicciones basadas únicamente en análisis de sentimiento léxico no superaban a las basadas en características estructurales de red, y que la combinación de ambas, usando aprendizaje automático, producía los mejores resultados ($MAE = 2,14 \%$; $R^2 = 0,818$). K. Brito et al. (2024), en una revisión crítica de doce años de investigación, formalizaron el problema: el enfoque de *Twitter* solo, basado en volumen de menciones o sentimiento, no rinde mejor que el azar, con tasas de acierto de entre el 50 % y el 63 %. Los autores identificaron cinco causas estructurales

de este fracaso: la imposibilidad de encuestar representativamente a través de Twitter, la dependencia de decisiones arbitrarias de recolección, los cambios constantes en el ecosistema de plataformas, la falta de datos históricos comparables, y la repetición de los errores metodológicos de las *straw polls* anteriores a 1936. El problema de fondo es metodológico: rastrear millones de publicaciones abiertas es costoso, ruidoso y difícilmente replicable fuera de entornos universitarios con infraestructura computacional avanzada (Skoric et al., 2020).

La respuesta más sofisticada a estos problemas llegó desde Brasil. K. d. S. Brito y Adeodato (2020) propusieron un cambio fundamental de paradigma: en lugar de rastrear lo que la ciudadanía dice sobre los candidatos, menciones abiertas, *hashtags*, sentimiento, el modelo analiza exclusivamente lo que la ciudadanía hace con el contenido que los propios candidatos publican en sus perfiles oficiales. Combinando datos de Facebook, Twitter e Instagram de las elecciones presidenciales de Brasil (2018) y Estados Unidos (2016) con encuestas tradicionales como variable objetivo, entrenaron redes neuronales tipo MLP que superaron estadísticamente a las encuestadoras en Brasil, donde los candidatos son muchos y las encuestas son pocas, y fueron competitivos en Estados Unidos. Este enfoque fue posteriormente sistematizado por K. Brito y Adeodato (2022), quienes analizaron más de 67.000 publicaciones de candidatos presidenciales en Argentina, Brasil, Colombia y México (2018–2019), demostrando que las métricas de *engagement* por publicación, en particular los *likes* por *post* en Instagram, correlacionaban fuertemente con el resultado electoral ($r = 0,75\text{--}0,98$), mientras que el número absoluto de publicaciones presentaba correlación nula o negativa.

El conjunto de estas contribuciones se formalizó en el marco **SOMEN-DC** (*Social Media Electoral Nowcasting During Campaign*), desarrollado por K. Brito y Adeodato (2023) en la Universidad Federal de Pernambuco. El modelo propone un proceso de cinco pasos, comprensión del evento, recolección de datos, preparación, modelado y evaluación, y una estrategia de ejecución continua (DC) que permite emitir predicciones diarias durante la campaña. Usando datos de más de 65.000 publicaciones y 195 encuestas de cuatro países latinoamericanos, los ensambles de redes neuronales (MLP y GRNN) entrenados con métricas de *engagement* y encuestas como etiquetas alcanzaron errores absolutos medios frecuentemente inferiores a 3 puntos porcentuales, dentro del umbral histórico de las encuestadoras.

Sin embargo, el SOMEN-DC presenta tres limitaciones estructurales que este trabajo busca superar:

1. **Techo encuestocéntrico.** Al usar las encuestas como variable objetivo de entrenamiento, el modelo no puede superar la capacidad predictiva de las propias encuestas. Es, en esencia, un replicador sofisticado de sondeos: aprende a imitar la señal de las encuestas a partir de datos digitales, sin acceso a una fuente de verdad independiente.
2. **Dependencia de infraestructura costosa.** El modelo requiere *scraping* continuo desde el inicio de la campaña para registrar la evolución temporal de las interacciones, acceso que los autores originales tenían a través de servicios institucionales de la Universidad Federal de Pernambuco, hoy inasequibles o inexistentes para la mayoría de investigadores independientes.
3. **No transferibilidad.** Los pesos aprendidos son válidos exclusivamente para la elección en que se entrenaron. Cada nueva contienda exige repetir desde cero el ciclo

completo de recolección y entrenamiento, sin posibilidad de acumular aprendizaje entre elecciones o de generalizar patrones entre contextos electorales distintos.

Estas tres limitaciones definen el espacio de contribución de esta tesis.

1.3. Hipótesis de trabajo

El punto de partida conceptual de este proyecto es la hipótesis seminal formulada por Tumasjan et al. (2010), quienes postulan que el volumen de actividad digital de un candidato en plataformas de redes sociales funciona como un estimador de su capital electoral subyacente. Esta intuición ha encontrado respaldo empírico consistente en contextos distintos al original: K. Brito y Adeodato (2022) demostraron que las métricas de *engagement* por publicación en los perfiles oficiales de candidatos presidenciales en Argentina, Brasil, Colombia y México correlacionan fuertemente con el resultado electoral ($r = 0,75-0,98$), mientras que las interacciones absolutas o el volumen de publicaciones presentan correlaciones nulas o negativas.

No obstante, existe un argumento estructural en contra de esta hipótesis que merece atención explícita: la penetración de las redes sociales no es aleatoria. La probabilidad de que un ciudadano tenga presencia activa en redes sociales depende de factores económicos, geográficos y culturales, lo que introduce un sesgo sistemático si se asume que la audiencia digital de un candidato representa fielmente a su electorado potencial (Skoric et al., 2020). Sin embargo, este argumento pierde fuerza en la medida en que la cobertura digital se aproxima a la universalidad. Según DataReportal (2025), el 70,4 % de la población colombiana usa redes sociales al cierre de 2025, cifra que creció en 1,6 millones de personas solo en 2024, con Facebook, TikTok, YouTube, Instagram y LinkedIn alcanzando al 89,3 %, 93,0 %, 74,4 %, 52,3 % y 44,4 % de los adultos colombianos, respectivamente. Significativamente, X/Twitter, la plataforma que concentra la mayor parte de la literatura de predicción electoral con redes sociales, solo alcanza al 12,0 % de los adultos en Colombia, lo que compromete estructuralmente cualquier modelo que dependa exclusivamente de esa fuente.

Formulación del problema

Considérese una elección de ganador único para un cargo ejecutivo ; alcalde, gobernador o presidente con un conjunto finito de C candidatos competitivos $\mathcal{C} = \{c_1, c_2, \dots, c_C\}$. Para cada candidato c_i , se observa un vector de características digitales:

$$\mathbf{x}_i \in \mathbb{R}^d \tag{1.1}$$

construido a partir de las interacciones acumuladas en sus publicaciones de redes sociales durante una ventana de n días previos a la jornada electoral. Este vector puede incluir interacciones totales, *engagement* por publicación, dominancia relativa respecto al total de interacciones de la elección, entre otras métricas.

La hipótesis central de este trabajo postula que existe una función:

$$f : \mathbb{R}^d \rightarrow [0, 1]^C \tag{1.2}$$

tal que $f(\mathbf{x}_i)$ aproxima la cuota de voto esperada del candidato c_i , con la restricción natural de que las predicciones sumen a la unidad sobre todos los candidatos de la misma elección:

$$\sum_{i=1}^C f(\mathbf{x}_i) = 1 \quad (1.3)$$

La contribución metodológica de este trabajo respecto a la literatura previa reside en el mecanismo de aprendizaje de f . En los modelos existentes, incluyendo el SOMEN-DC (K. Brito & Adeodato, 2023), esta función se aprende de forma independiente para cada elección, usando las encuestas de intención de voto como variable objetivo. En el modelo propuesto, f se aprende sobre un conjunto de M elecciones históricas $\mathcal{E} = \{e_1, e_2, \dots, e_M\}$, usando directamente el resultado electoral como fuente de verdad. Esto tiene dos implicaciones fundamentales: primero, elimina la dependencia de encuestas en cualquier etapa del proceso; segundo, permite que los parámetros aprendidos capturen patrones que son comunes entre elecciones, la relación estructural entre tracción digital y respaldo electoral, y no los detalles particulares de una campaña en específico. Una vez entrenada, f puede aplicarse a una elección nueva $e_{M+1} \notin \mathcal{E}$ sin necesidad de datos de entrenamiento adicionales, lo que constituye la propiedad de **elección-agnosticismo** que da nombre al modelo.

Bajo este marco, el modelo opera recibiendo como *input* el vector $\mathbf{x}_i$ de interacciones digitales de cada candidato, calculado sobre una ventana de n días previos a la jornada electoral. El *output* es un vector $\hat{\mathbf{y}} \in [0, 1]^C$ donde cada componente $\hat{y}_i = f(\mathbf{x}_i)$ representa la cuota de voto estimada para el candidato c_i , respondiendo a la pregunta: *si las elecciones ocurrieran hoy, ¿Qué porcentaje de los votantes apoyaría a cada candidato?*

1.4. Estructura del documento

Para abordar esta hipótesis, la investigación se estructuró a través de tres etapas empíricas que guían la organización de este documento. El **Capítulo 2** define formalmente la pregunta de investigación y los interrogantes derivados. El **Capítulo 3** presenta el marco conceptual, explorando la literatura sobre *nowcasting* electoral y la viabilidad de los modelos elección-agnósticos. Seguidamente, el **Capítulo 4** detalla los objetivos del estudio.

El **Capítulo 5** desarrolla la metodología, dividida en las tres fases del proyecto:

- **Bolivia (Prueba de concepto):** Donde se replica el modelo SOMEN-DC para evaluar empíricamente sus limitaciones.
- **Costa Rica (Modelado de crecimiento):** Enfocada en resolver el problema del registro histórico mediante la calibración matemática de la curva de crecimiento de las interacciones.
- **Colombia (Construcción y modelado final):** Donde se compila el *dataset* elección-agnóstico de elecciones locales (2023) y se entrenan los algoritmos de clasificación y regresión.

Finalmente, el **Capítulo 6** expone los resultados obtenidos en cada fase, mientras que los **Capítulos 7 y 8** discuten el impacto esperado de la herramienta, sus limitaciones inherentes y las conclusiones definitivas del estudio.

2

Pregunta de investigación

Para abordar las limitaciones metodológicas previamente expuestas relativas a la dependencia de las encuestas y la imposibilidad de transferir los modelos de *nowcasting* a nuevas elecciones, esta investigación se estructura alrededor de un interrogante central y una serie de preguntas derivadas que guían el diseño empírico del estudio.

2.1. Pregunta principal

La inquietud fundamental que motiva este trabajo se sintetiza en la siguiente pregunta de investigación:

*¿Es posible diseñar e implementar un modelo de nowcasting de la intención de voto que sea **elección-agnóstico**, es decir, cuyos parámetros se entrenen con datos de múltiples elecciones simultáneas y sean transferibles a contiendas no vistas, que no dependa en ninguna etapa de encuestas de opinión pública, y que pueda aplicarse con precisión a elecciones locales en Colombia utilizando únicamente señales extraídas de interacciones en redes sociales?*

Esta pregunta desafía el paradigma establecido en la literatura (representado por modelos como el SOMEN-DC), buscando independizar por completo el pronóstico de las encuestas y evaluar si las huellas digitales por sí solas contienen suficiente información estructural para estimar el apoyo político en un ecosistema electoral altamente fragmentado como el colombiano.

2.2. Preguntas derivadas

Para dar respuesta a la pregunta principal de manera secuencial y estructurada, el estudio plantea cuatro preguntas de investigación derivadas, cada una asociada a un desafío metodológico o empírico específico:

1. **Sobre la capacidad predictiva intrínseca de la red:** ¿Las interacciones en redes sociales de los candidatos (volumen de *likes*, comentarios, visualizaciones, etc.) tienen un poder predictivo estadísticamente significativo sobre el resultado electoral real en el contexto latinoamericano?
2. **Sobre la viabilidad de la reconstrucción de series temporales:** Dado que las plataformas digitales no almacenan un registro público del historial de interacciones de una publicación, ¿Es posible reconstruir matemáticamente la curva de crecimiento de las interacciones de publicaciones pasadas sin haber realizado *scraping* en tiempo real durante la campaña original?
3. **Sobre la selección de características (feature engineering):** Entre las múltiples señales disponibles, ¿Qué tipo de métricas digitales resultan más informativas para el

pronóstico electoral: el volumen absoluto de interacciones de un candidato, su *dominancia relativa* en comparación con sus contrincantes, o su capacidad para generar tracción tardía en los últimos días de la campaña?

4. **Sobre la escalabilidad y el tipo de modelado:** Considerando las limitaciones en el tamaño de muestra de elecciones históricas viables para estudio, ¿Con cuántos ejemplos de entrenamiento es estadísticamente factible y robusto entrenar un modelo de **clasificación** (predecir quién gana) versus un modelo de **regresión** (predecir el porcentaje exacto de votos)?

3

Marco conceptual

3.1. *Nowcasting* electoral y predicción con redes sociales

3.1.a. Definición de *nowcasting* en contexto electoral

En ciencia política, *nowcasting* (pronóstico del presente) designa una estimación cuantitativa de “lo que pasaría si la elección se celebrara hoy”. Se diferencia del *forecasting* clásico (predicción a futuro) en que el *nowcasting* busca modelar el estado actual y latente del electorado mediante actualizaciones continuas y en tiempo real, basándose en un modelo cuyos parámetros estructurales se mantienen fijos mientras varían las covariables observadas Lewis-Beck y Tien, 2014; Lewis-Beck et al., 2011.

La primera formulación formal aplicada a elecciones nacionales se consolidó con los modelos *proxy*. Por ejemplo, en el Reino Unido, Lewis-Beck et al. (2011) modelaron el voto del oficialismo a partir de indicadores adelantados, como la aprobación del gobierno, medida con meses de antelación. En épocas más recientes, con el auge del *Big Data*, la literatura empírica se ha volcado al uso de redes sociales como fuente masiva de covariables en tiempo real, transformando el *nowcasting* en una herramienta de minería de datos dinámicos Skoric et al., 2020.

Desde el estudio seminal de Tumasjan et al. (2010), múltiples autores han explorado arquitecturas híbridas. Trabajos recientes como los de K. Brito y Adeodato (2022, 2023) han sofisticado la técnica combinando recolección de datos durante la campaña (*During Campaign*) y modelos de aprendizaje automático (*Machine Learning*) aplicados a Latinoamérica. Sin embargo, estas aplicaciones mantienen una dependencia crítica: el entrenamiento constante frente a encuestas tradicionales.

3.2. Modelos elección-agnósticos: definición y ventajas

Un modelo **elección-agnóstico** es aquel que se entrena utilizando datos conjuntos de múltiples elecciones simultáneamente, con el propósito de aprender reglas de decisión y pesos paramétricos que representen patrones de comportamiento electoral universales

(o regionalmente consistentes), de modo que sean directamente transferibles a elecciones no vistas.

Formalmente, sea $\mathcal{E} = \{e_1, e_2, \dots, e_M\}$ un conjunto de M elecciones históricas diferentes (por ejemplo, alcaldías de distintas ciudades). El objetivo es aprender una función predictiva:

$$f : \mathbb{R}^d \rightarrow [0, 1] \quad (3.1)$$

tal que $\hat{y}_{i,m} = f(\mathbf{x}_{i,m})$, donde $\mathbf{x}_{i,m}$ es el vector de características de d dimensiones (interacciones digitales, tasas de crecimiento, dominancia) del candidato i en la elección m , y $\hat{y}_{i,m}$ es la cuota de voto estimada o la probabilidad de victoria.

La principal ventaja matemática y operativa de este enfoque frente a arquitecturas específicas de campaña como el SOMEN-DC K. Brito y Adeodato, 2023 radica en su escalabilidad e independencia. Al abstraer la función f sobre M elecciones, el modelo se desacopla de la necesidad de contar con datos de encuestas como variable dependiente, utilizando directamente los resultados electorales finales como *ground truth*. Asimismo, elimina la dependencia de infraestructura de *scraping* en tiempo real, pues la predicción sobre una elección nueva $\mathcal{E}_{new}$ requiere únicamente extraer los vectores $\mathbf{x}_{new}$ y procesarlos a través del modelo pre-entrenado.

3.3. Interacciones digitales como *proxy* de intención de voto

3.3.a. La hipótesis Tumasjan

El uso de señales digitales como estimador político se sustenta empíricamente en el trabajo fundacional de Tumasjan et al. (2010) sobre las elecciones federales alemanas de 2009. Estos autores demostraron que el simple conteo volumétrico de *tweets* que mencionan a un partido refleja fielmente el resultado electoral, logrando un error absoluto medio (MAE) de 1.65 %. Esta hipótesis sugiere que la atención (reflejada en interacciones y contenido generado) equivale a capital político en la arena digital.

3.3.b. Interacciones absolutas vs. dominancia relativa

Si bien el volumen absoluto de interacciones (por ejemplo, el total de *likes*) ofrece una señal importante, presenta ruido debido a la heterogeneidad de los distritos electorales y la presencia de cuentas atípicamente virales. Para mitigar esto, este estudio introduce y prioriza la métrica de **dominancia relativa**: el porcentaje de interacciones que acumula un candidato sobre el total de interacciones generadas por todos los candidatos competitivos dentro de su misma ciudad o distrito.

Los análisis exploratorios sobre las elecciones locales colombianas de 2023 presentados en este trabajo confirman que la dominancia relativa es significativamente más informativa que el volumen absoluto. La correlación de Spearman entre la dominancia relativa en interacciones y la cuota de voto real alcanza $\rho > 0.46$ con $p < 2 \times 10^{-7}$.

No obstante, se deben reconocer las limitaciones intrínsecas de este *proxy*. Las redes sociales son ecosistemas permeables a la actividad no inorgánica (bots, manipulación coordinada), sesgos demográficos propios de las plataformas y la existencia de candidatos que, por su condición de figuras públicas o *influencers*, generan tracción digital

desproporcionada a su verdadera viabilidad electoral.

3.4. El problema del histórico de interacciones

Uno de los mayores desafíos para entrenar modelos predictivos retrospectivos es la opacidad temporal de los datos en redes sociales. Plataformas como Facebook, Twitter/X y TikTok muestran únicamente el total acumulado de interacciones de una publicación en el instante en que es consultada (hoy). No guardan ni exponen públicamente la curva histórica de crecimiento; por lo tanto, es imposible observar directamente cuántos *likes* tenía una publicación específicamente el día anterior a las elecciones, un dato crucial para el *nowcasting*.

Para sortear este obstáculo metodológico, este trabajo propone modelar matemáticamente la curva de crecimiento acumulado de las interacciones utilizando una distribución de Weibull con parámetro de desplazamiento (*offset*):

$$F(t) = 1 - e^{-k \cdot (t+t_0)^\alpha} \quad (3.2)$$

donde t es el tiempo transcurrido (en días) desde la publicación; k es el parámetro de escala que determina la velocidad general de acumulación; α es el parámetro de forma que captura la rápida deceleración típica del consumo de contenido en redes (decaimiento exponencial); y t_0 modela la asimetría temporal inicial, capturando la explosión masiva de interacciones que ocurre en las primeras horas antes de que t se convierta en 1 día.

Al calibrar estos parámetros (k, α, t_0) de forma diferenciada para cada plataforma, es posible proyectar la curva $F(t)$ hacia el pasado y estimar con alta fidelidad las métricas que tenía cualquier publicación histórica en la víspera electoral.

4 Objetivos

4.1. Objetivo general

Diseñar e implementar un modelo de *nowcasting* de la intención de voto en elecciones locales colombianas que sea elección-agnóstico, no dependa de encuestas, use únicamente interacciones en redes sociales de los perfiles oficiales de los candidatos, y pueda replicarse con herramientas comerciales accesibles.

4.2. Objetivos específicos

1. **OE1.** Replicar y evaluar empíricamente el modelo SOMEN-DC en la segunda vuelta presidencial de Bolivia (octubre de 2025).
2. **OE2.** Modelar el crecimiento temporal de las interacciones en redes sociales usando varios modelos de forma comparativa.

3. **OE3.** Construir un *dataset* de entrenamiento elección-agnóstico con datos de las elecciones locales colombianas de 2023.
4. **OE4.** Entrenar y evaluar modelos de clasificación y regresión del resultado electoral.
5. **OE5.** Documentar las condiciones de viabilidad metodológica del modelo propuesto y documentar sus limitaciones.

5

Metodología

5.1. Definición formal del problema

5.1.a. Definición de la elección

Definimos una elección, llamada **elección agnóstica** como e donde $e \in E$ y E es el conjunto de todas las elecciones agnósticas que cumplen los siguientes requisitos:

- Es un proceso competitivo no determinístico definido como la participación de dos o más candidatos con posibilidades reales de ganar y condiciones equitativas (Kayser y Lindstädt, 2015).
- Tiene por ganador a un único candidato por elección $c_{ganador,e} \in C_e$ con C_e siendo el conjunto de candidatos para la elección e .
- El candidato ganador $c_{ganador,e}$ es aquel que obtuvo más votos entre las opciones posibles de la elección e .
- Se desarrolla en un periodo de tiempo acotado $t \in [t_0, t_f]$, con t_0 y t_f siendo el inicio y fin de la campaña, que sería el día anterior a la elección.
- Se mide mediante los votos de los electores $v_e \in V_e$, siendo V_e el conjunto de todos los electores de la elección e .
- Todos los candidatos del universo de elecciones E tienen cuentas oficiales de un conjunto de redes sociales R con $r \in R$ y publican activamente en ellas para el momento t_0 . En el ejercicio de Bolivia y Costa Rica estas fueron Facebook, TikTok, X/Twitter e Instagram mientras que para Colombia se omitió Instagram.

5.1.b. Definición de la intención de voto y los resultados

Definimos la intención de voto como el número de votantes v_e que, en un momento t , escogerían al candidato c_e . Esta es una variable subyacente, ya que no todos los votantes tienen definido su voto desde el t_0 , algunos no van a votar o pueden hacerlo en blanco. Las encuestas son estimadores de esta misma variable, pero dado que esta variable solo toma un valor definido el día de las elecciones, no podemos usar una metodología clásica de series de tiempo para modelar la evolución temporal de la intención de voto. Por lo tanto,

modelamos la relación entre los vectores de métricas de redes sociales de los candidatos desde una cantidad de días antes de la elección y el valor que sabemos que toma la intención de voto el día de las elecciones.

La elección e tiene una intención de voto asociada, representada por un vector $i_e \in I_e$, donde I_e es el conjunto de intenciones de voto para la elección e . Este vector está compuesto por una secuencia de intenciones de voto, una por cada candidato, ordenadas de forma idéntica al vector de candidatos C_e . Es decir, $i_e = (i_{e,c_1}, i_{e,c_2}, \dots, i_{e,c_{|C_e|}})$, donde i_{e,c_j} es la intención de voto del candidato c_j para la elección e . Esta intención de voto para el candidato c_e se calcula como su número de votos porcentual obtenido en la elección e , es decir:

$$i_{e,c_j} = \frac{v_{e,c_j}}{v_e}$$

donde v_{e,c_j} es el número de votos del candidato c_j para la elección e y v_e es el número total de votos para cualquiera de los candidatos de la elección e , es decir $\sum_{j=1}^{|C_e|} v_{e,c_j} = 1$. Es muy importante denotar que esta suma NO incluye votos nulos, en blanco o similares.

Dadas estas condiciones, tenemos que una elección de estas características es un evento que es posible acotar a métricas comparables del conjunto de elecciones sin importar su número de candidatos. De esta forma, pasamos a definir como funcionan las publicaciones, interacciones e intención de voto.

5.1.c. Definición formal de las publicaciones y su comportamiento temporal

Partimos de una publicación cualquiera, es decir un elemento p , de un candidato c_e , en una fecha t , en una red social r_j , es decir, un $p_{e,c,r,t}$, que simplificamos a $p_i \forall i \in I$ para un momento de recolección de información t . Esta publicación posee un conjunto de características que permite su comparación con otras publicaciones:

- Fecha de publicación t_{pub}
- Fecha de recolección de información t_{rec}
- Vector de interacciones a fecha de recolección: me gusta, compartir, comentar, guardar, etc. $x_{i,t_{rec}}$

Este trabajo parte de la idea fundamental que el conjunto de vectores x_i para un candidato c tiene algún tipo y nivel de correlación con su intención de voto $i_{e,c}$ y es lo que el trabajo busca modelar. Este vector puede ser apoyado por otras variables microfundamentadas, como la relación gobierno/oposición, variables económicas, entre otras.

Este vector de interacciones $x_{i,t_{rec}}$ posee una propiedad importante y es que es acumulativo. Con muy notables excepciones causadas por intervención de la plataforma o del candidato, las interacciones de una publicación no caen, por lo que para un momento t , podemos decir que los elementos del vector $x_{i,t}$ son monótonamente no decrecientes. Por lo tanto el vector de interacciones se puede modelar mediante una función $f_j(t_{pub}, t_{rec}, x_i)$ para cada red social, que modela el crecimiento de las interacciones de una publicación a lo largo del tiempo, donde t está en días desde la fecha de publicación.

5.1.d. Definición del problema

Con estos elementos contruidos, postulamos la existencia de una función que tenga como *input* un vector de características de las interacciones en redes sociales junto con

otras variables de un conjunto $\mathcal{C}_e$ de candidatos y que tenga como *output* la intención de voto de los candidatos, como porcentaje del total de los votos a candidatos válidos. Dicho en notación matemática, este trabajo busca encontrar:

$$\mathbf{i}_e = f(\mathbf{x}_e, \mathbf{c}_e, t_{rec}, \mathcal{C}_e) \quad (5.1)$$

Donde:

- $i_{e,c}$ es la intención de voto del candidato c para la elección e .
- $x_{e,c}$ es el vector de características de las interacciones en redes sociales del candidato c para la elección e .
- $c_{e,c}$ es el vector de características del candidato c para la elección e .
- t_{rec} es la fecha de recolección de información.
- $\mathcal{C}_e$ es el conjunto de candidatos para la elección e .

Y esta función debería de tener un conjunto de características tales que la hagan una alternativa viable para la toma de decisiones en campaña, con una relación costo/calidad similar o mejor a las encuestas. Entre estas: ser elección agnóstica, funcionar independiente del número de candidatos y tener un costo inferior al de una encuesta.

Para poder construir esta función se vuelve necesario solucionar un conjunto de problemas:

- **P1** *¿El modelo SOMEN-DC es replicable con herramientas comerciales no-académicas?*
- **P2** *¿Cómo se comporta el modelo SOMEN-DC ante un cambio en su lógica de recolección de datos?*
- **P3** *¿Cómo se puede construir un conjunto de datos de entrenamiento para este problema?*
- **P4** *¿Cómo se puede convertir este modelo en una herramienta de nowcasting electoral si es un problema de corte transversal más que un problema de serie de tiempo?*

Para resolver estas preguntas se hizo necesario realizar los tres ejercicios definidos en el trabajo; la elección presidencial de Segunda Vuelta en Bolivia del 2025, de Primera Vuelta en Costa Rica del 2026 y las Elecciones locales de Colombia en el 2023. El ejercicio de Bolivia ayudó a solucionar las preguntas P1 y P2, mientras que el ejercicio de Costa Rica y de Colombia ayudó a solucionar la pregunta P3. Por último, la pregunta P4 se puede resolver con los resultados del ejercicio con la Segunda Vuelta de las Elecciones presidenciales en Colombia en el 2026.

5.2. Diseño general del proceso

La arquitectura metodológica de esta investigación está estructurada como un proceso secuencial dividido en cuatro etapas empíricas. La Etapa 1 corresponde a una prueba de concepto en Bolivia para replicar y evidenciar los problemas estructurales del modelo SOMEN-DC base. La Etapa 2 aborda el problema de la asimetría de la información temporal, calibrando un modelo de crecimiento matemático en Costa Rica, la Etapa 3 consolida el modelo elección-agnóstico en las Elecciones Locales en Colombia en el 2023 y el modelo aplicado a predicción continua se aplica en la Segunda Vuelta de la Elección presidencial de Colombia de 2026.

5.3. Etapa 1 - Bolivia: Replicación del SOMEN-DC y prueba de concepto

5.3.a. Caso de estudio y recolección de datos

Para confirmar empíricamente las limitaciones inherentes a la literatura de *nowcasting* dependiente de encuestas, se planteó un caso de estudio replicando la metodología SOMEN-DC en el contexto de la segunda vuelta presidencial de Bolivia (programada para el 19 de octubre de 2025). Esta contienda polarizada entre Rodrigo Paz Pereira y Jorge “Tuto” Quiroga representó un escenario ideal de prueba por ser una elección presidencial en un país Latinoamericano no tratado por los autores (Brito y Andeoato) en su producción científica. El resultado real proyectado para el estudio determinó a Paz como ganador con el 54.53 % frente al 45.47 % de Quiroga.

Se definió como ventana temporal retrospectiva 180 días (del 18 de mayo al 18 de octubre de 2025). Para extraer los datos se usaron herramientas como Apify operando como *scrapers* web y Make.com como orquestador lógico, programados para extraer diariamente las interacciones a las 10:00 p.m. hora de La Paz de las cuentas oficiales de ambos candidatos en Facebook, Twitter/X, Instagram y TikTok. Los datos crudos se agregaron a nivel diario, garantizando continuidad temporal al imputar con cero (0) aquellos días sin publicaciones. El procesamiento incluyó el cálculo de promedios de interacción por publicación (ej. *likes* por post) para medir tanto el volumen bruto como la calidad del *engagement*, consolidando un vector final de 24 características explicativas numéricas en un *dataset* de 308 registros independientes.

5.3.b. Preparación de datos y variable objetivo

El preprocesamiento de la información digital fue exhaustivo para lidiar con el ruido de las redes sociales. Primero, se aplicó una estandarización intra-plataforma mediante puntajes Z (*z-scores*) para equiparar el peso relativo de redes con distintos niveles de masividad. Seguidamente, se normalizaron de forma independiente los indicadores numéricos de cada candidato a una escala [0, 1] utilizando escalado *Min-Max*, y para mitigar la alta variabilidad diaria inherente a las publicaciones, se aplicó un filtro de suavizado temporal consistente en una media móvil de dos períodos (*window=2*).

La generación de la variable dependiente o variable objetivo (*IntencionVotoReal*) es uno de los pasos más críticos. Se extrajeron los resultados de 14 encuestas de diversas firmas (Ipsos Ciesmori, SPIE, Captura Consulting y Ciemcorp) divulgadas durante la ventana de análisis. Los porcentajes declarados fueron normalizados matemáticamente para que la intención de ambos contendientes sumara estrictamente 1 (o 100 %). Posteriormente, se ancló el último valor de la serie temporal al resultado electoral real del día de los comicios y se generó una serie de tiempo diaria ininterrumpida utilizando métodos de interpolación lineal matemática.

El modelo de entrenamiento (*train*) consumió únicamente los datos abarcados desde la primera hasta la última encuesta pública, reservando la porción final para la ventana de proyección predictiva (*pred*) hasta el día cero de las elecciones. Con este corte, las normalizaciones de validación (*StandardScaler*) se calibraron rigurosamente sobre el conjunto de entrenamiento para imposibilitar fugas de información futura (*data leakage*).

5.3.c. Evaluación de modelos

Siguiendo la arquitectura original, se entrenaron y evaluaron múltiples topologías algorítmicas bajo un esquema determinista de aprendizaje supervisado, comparando algoritmos lineales versus no lineales y validando el impacto de la reducción de dimensionalidad (*Principal Component Analysis*, PCA). El portafolio de modelos evaluados incluyó Regresión Lineal Clásica, Redes Neuronales de Regresión Generalizada (GRNN) ajustando el σ mediante la mediana de las distancias euclidianas, y Perceptrón Multicapa con *Backpropagation* (MLP-BP) configurado con capas ocultas de 48 y 24 neuronas, función de activación *ReLU*, optimizador Adam y una tasa de aprendizaje iterativo. Adicionalmente, las salidas predictivas de las redes neuronales fueron filtradas con medias móviles exponenciales algorítmicas (β asimétrico dependiendo del cambio de tendencia) para suavizar la intención predictiva final.

El modelo con mejor desempeño predictivo resultó ser el ensemble MLP-BP acoplado con PCA, tal como se observa de manera suavizada en la Figura 5.1, alcanzando un Error Absoluto Medio (MAE) de 0.0279 y un Error Porcentual Absoluto Medio (MAPE) aproximado del 5.1 %. Este resultado superó considerablemente el *baseline* trivial basado en tomar simplemente el valor de la última encuesta disponible antes de la elección (cuyo MAE en el caso del candidato Paz fue del 0.1803). Cabe destacar que los modelos estrictamente lineales fracasaron sistemáticamente en el ajuste (presentando MAEs entre 0.29 y 0.31), confirmando empíricamente que la relación entre el volumen de interacciones digitales y la tracción en las encuestas exhibe dinámicas fuertemente no lineales.




Figura 5.1: Series de tiempo de la evolución de la intención de voto utilizando el modelo MLP-BP con PCA.

Los resultados de esta primera etapa confirmaron de manera concluyente los problemas teóricos del SOMEN-DC señalados en la hipótesis: la dependencia estructural de las encuestas para el entrenamiento, el altísimo costo logístico de mantener infraestructura de *scraping* continuo y, más grave aún, la imposibilidad de extrapolar los pesos de la red neuronal a una nueva elección (no generalizabilidad).

5.4. Etapa 2 - Costa Rica: Modelado del crecimiento de interacciones

5.4.a. El problema estructural

Para construir un modelo generalizable a partir de M elecciones pasadas se requiere observar datos históricos. Sin embargo, las plataformas digitales únicamente muestran el total acumulado de interacciones en la fecha actual de la consulta: si se rasparan datos en 2026 sobre una elección de 2023, sería imposible saber cuántas interacciones se habían acumulado el día de la elección y cuántas corresponden a tráfico residual o póstumo generado tras conocerse los resultados. Para resolver esto, es necesario estimar una curva teórica de crecimiento de interacciones que permita reconstruir el estado del post en cualquier momento pasado.

5.4.b. Recolección y validación del panel

Se recolectaron datos con una cadencia de extracción **diaria** durante un período de **30 días**: los 15 días previos a la primera vuelta presidencial del 2 de febrero de 2026 y los 15 días posteriores. Esta ventana simétrica garantizó capturar tanto el pico de actividad de campaña como la curva de decaimiento posterior, cubriendo así el ciclo de vida completo de las publicaciones más recientes. El proceso abarcó **cuatro plataformas** (Facebook, Instagram, TikTok y Twitter/X) y **4 candidatos presidenciales**.

Durante la validación de integridad se detectó que Twitter presentaba ausencia masiva de identificadores de publicación (*postIds*). Para solucionar esto, se generaron identificadores únicos calculando un hash MD5 sobre el contenido textual de cada *tweet*, permitiendo agrupar correctamente las observaciones longitudinales de una misma publicación. Se documentaron 765 publicaciones únicas de Facebook, 603 de Instagram, 344 de TikTok y 210 de Twitter/X.

La estandarización temporal se realizó calculando el **Día Relativo**: el tiempo transcurrido en días desde la fecha de publicación hasta el momento de extracción, siendo el día de publicación el Día 0. Sobre el panel bruto se observó el denominado **Sesgo de Composición**: cuando publicaciones de crecimiento rápido alcanzan su máximo y dejan de observarse, el promedio global cae artificialmente porque solo permanecen en la muestra las publicaciones con crecimiento más lento. Para corregirlo, se aplicó:

- **Forzado monótono** (*cummax*): las interacciones solo pueden crecer o mantenerse, nunca bajar.
- **Interpolación lineal**: los días sin observación dentro del período de vida de un *post* se rellenan por interpolación entre los puntos conocidos.
- **Forward Fill**: si un post alcanza el 100 % y deja de observarse, su valor se mantiene en los días siguientes para no deprimir el promedio.
- **Normalización a fracción**: las interacciones absolutas se convierten en fracción del máximo observado ($\in [0, 1]$), haciendo comparables publicaciones de distinto volumen.

Tras aplicar estos filtros, se retuvieron las publicaciones con al menos dos observaciones y con máximo alcanzado en el Día 3 o posterior. El resultado final del panel fue de

1,922 publicaciones únicas (765 de Facebook, 603 de Instagram, 344 de TikTok y 210 de Twitter/X, que suman exactamente 1,922), generando **19,439 pares** (día, fracción) aptos para el modelado.

5.4.c. Análisis de la persistencia de interacciones

El primer objetivo del análisis fue cuantificar cuánto tiempo persiste la actividad de una publicación y si la candidata ganadora mostraba un patrón diferente al resto. Se aplicaron pruebas T de una muestra para cada Día Relativo: el crecimiento es estadísticamente significativo ($p < 0,0001$) hasta el día 10, pero desde una perspectiva empírica se vuelve marginal a partir del día 5–7 ($< 2\%$ diario). Esto justifica que una ventana de 14 días previos a la jornada de votación es suficiente y robusta para capturar el *engagement* relevante de una publicación.

La Figura 5.2 compara la curva promedio de interacciones acumuladas (estabilizada con *Forward Fill*) de la candidata ganadora Laura Fernández versus el promedio del resto de candidatos. Ambas curvas exhiben una forma de saturación prácticamente idéntica: en los primeros 2–3 días se acumula más del 80% del total de interacciones, y a partir del Día 7 ambas han alcanzado el 100% para fines prácticos. Esta convergencia morfológica confirma que los factores de crecimiento orgánico son propiedades de la plataforma, no del candidato, validando el supuesto de estacionariedad del modelo y que el resultado electoral no altera la forma de la curva.




Figura 5.2: Porcentaje de interacciones acumuladas por Día Relativo (curvas estabilizadas): Laura Fernández, candidata ganadora (línea dorada continua), vs. promedio del resto de candidatos (línea azul discontinua). Ambas curvas son morfológicamente indistinguibles, lo que confirma que el patrón de crecimiento es una propiedad de la plataforma y no del candidato.

5.4.d. Selección y calibración del modelo Weibull

Para modelar la curva de crecimiento acumulado de interacciones se evaluaron tres familias de funciones: exponencial simple, logística y Weibull con *offset* temporal t_0 . La

función exponencial simple $F(t) = 1 - e^{-kt}$ fue descartada porque no incorpora el retardo inicial de activación que exhiben las publicaciones de Facebook (cuyo pico de distribución de contenido ocurre horas después de publicado, no de forma inmediata). La curva logística fue descartada porque su punto de inflexión simétrico obligaría a fijar artificialmente la mitad del crecimiento en un día específico, algo que no se observa en los datos. La distribución Weibull con *offset*:

$$F(t; k, \alpha, t_0) = 1 - e^{-k(t+t_0)^\alpha} \quad (5.2)$$

fue seleccionada por tres razones: (i) está acotada en $[0, 1]$, lo que la hace matemáticamente compatible con la fracción de interacciones acumuladas; (ii) el parámetro de forma α le permite ajustar curvas cóncavas o convexas según el comportamiento empírico de cada plataforma; y (iii) el *offset* t_0 captura el retardo real de distribución del algoritmo de cada red sin necesidad de trasladar manualmente el eje temporal.

Los parámetros k (escala), α (forma) y t_0 (retardo) se calibraron por plataforma mediante optimización no lineal por mínimos cuadrados (*curve_fit*), ensayando múltiples puntos de partida para evitar mínimos locales. Los parámetros óptimos se presentan en la Tabla 5.1.

Cuadro 5.1: Parámetros Weibull calibrados por plataforma y bondad de ajuste (R^2) sobre el panel de fracciones.

Plataforma	k	α	t_0 [días]	t_0 [horas]	R^2
Facebook	0.9480	0.8230	1.93	46h	0.351
Instagram	1.1369	0.5210	0.04	1h	0.403
TikTok	1.3272	0.5124	0.79	19h	0.351
Twitter/X	1.4453	1.1422	0.26	6h	0.691

Los R^2 del panel resultan matemáticamente bajos en Facebook y TikTok. Un análisis de descomposición de varianza reveló que la varianza *intra-publicación* (ruido de medición dentro de un mismo *post*: hora de publicación, viralidad puntual, algoritmo de la plataforma) representa el 66.8 % de la varianza total, frente al 29.2 % de varianza *inter-publicaciones* (diferencias entre publicaciones distintas). Esto implica que un R^2 bajo es matemáticamente irreducible para cualquier modelo de curva promedio, y que el modelo captura correctamente la forma global de la curva. El diagnóstico se ilustra en la Figura 5.3: la mediana de las fracciones se concentra rápidamente cerca del 100 % (72 % en el día 0, 87 % al día 1, 98 % al día 3), pero la dispersión es alta en los primeros días, reflejando la heterogeneidad entre publicaciones.

La Figura 5.4 muestra el ajuste del modelo Weibull para cada plataforma. Cada panel presenta la mediana empírica (puntos negros), el rango intercuartílico empírico (área azul) y la curva del modelo calibrado (roja). Twitter/X exhibe el mejor ajuste ($R^2 = 0.691$) dado que sus publicaciones alcanzan el 100 % muy rápidamente y con poca dispersión.

5.4.e. Validación: precisión en la estimación del total final

Dado que el objetivo no es ajustar curvas sino reconstruir el total final de interacciones a partir de una observación parcial, la métrica de evaluación relevante es el **Error Porcentual Absoluto Mediano** (MAPE) entre el total estimado $\hat{N} = n_t/F(t)$ y el total real N observado al final del período. La Tabla 5.2 resume estos errores por plataforma y día de




Figura 5.3: Distribución de la fracción acumulada de interacciones ($n_t/n_{\text{máx}}$) por Día Relativo, sobre el panel completo de 1,922 publicaciones. La línea roja muestra la mediana: en el Día 0 ya se acumula el 72 % del total final; al Día 3, el 98 %. La dispersión en los días iniciales refleja la heterogeneidad entre publicaciones, razón por la que el R^2 global es bajo pero el modelo promedio es válido.




Figura 5.4: Ajuste del modelo Weibull con *offset* temporal por plataforma. Puntos negros: mediana empírica. Área azul: rango intercuartílico (IQR) empírico. Curva roja: modelo calibrado. Los parámetros k , α y t_0 de cada plataforma se detallan en la Tabla 5.1.

observación.

Cuadro 5.2: MAPE mediano (%) en la estimación del total final de interacciones, por plataforma y día de observación.

Plataforma	Día 0	Día 1	Día 2	Día 3	Día 7
Facebook	11.27 %	6.92 %	3.73 %	2.12 %	0.32 %
Instagram	64.77 %	20.72 %	15.67 %	12.06 %	3.76 %
TikTok	25.36 %	14.20 %	8.35 %	5.94 %	2.29 %
Twitter/X	56.37 %	11.09 %	2.55 %	0.38 %	0.00 %

La Figura 5.5 muestra visualmente estos resultados. En el panel izquierdo se observa que el MAPE decae exponencialmente con el día de observación: a partir del Día 3, todos los modelos, excepto Instagram, se ubican por debajo del umbral de referencia del 20 %. El panel derecho ilustra la distribución completa del error al Día 3, mostrando que la gran mayoría de las publicaciones se estima con alta precisión. Instagram presenta el MAPE más alto en días tempranos debido a la fuerte concentración de interacciones en las primeras horas, que el modelo no captura completamente con el *offset* $t_0 = 0.04$ días.

5.4.f. Función de reconstrucción histórica

Con los parámetros calibrados, se implementó una función de reconstrucción que, dada la fecha de publicación, las interacciones observadas en un día t y la plataforma, estima el




Figura 5.5: Evaluación de la precisión proyectiva del modelo Weibull. **Izquierda:** MAPE mediano por plataforma y día de observación; la línea discontinua marca el 20 % de referencia. **Derecha:** distribución del error por publicación al Día 3. A partir del Día 3, Facebook, TikTok y Twitter/X alcanzan errores medianos inferiores al 12 %.

total final de interacciones y genera la curva diaria completa. Formalmente, el total final estimado es:

$$\hat{N} = \frac{n_t}{F(t; k, \alpha, t_0)} \quad (5.3)$$

donde n_t son las interacciones observadas en el Día t y $F(t; k, \alpha, t_0) = 1 - e^{-k(t+t_0)^\alpha}$ es la fracción acumulada predicha por el modelo. La Figura 5.6 muestra dos ejemplos concretos: una publicación de Facebook con un total final conocido de 50,000 interacciones, y una publicación de Instagram con 43,000 interacciones observadas parcialmente en el Día 10. El modelo reconstruye la curva de interacciones nuevas por día (barras azules) y el porcentaje acumulado (línea roja), permitiendo inferir el estado histórico de cualquier publicación en cualquier momento pasado.




Figura 5.6: Ejemplos de reconstrucción histórica de interacciones con el modelo Weibull calibrado. **Izquierda:** publicación de Facebook con 50,000 interacciones totales conocidas; el modelo distribuye las interacciones nuevas por día (barras) y la fracción acumulada (curva roja). **Derecha:** publicación de Instagram con 43,000 interacciones medidas el Día 10; el modelo infiere el total final y reconstruye la curva completa.

Los parámetros k , α y t_0 de las cuatro plataformas, junto con los MAPE por día de observación, se exportaron en un archivo de configuración que es consumido directamente por la etapa de construcción del *dataset* de Colombia (Etapa 3), garantizando consistencia

entre las dos fases del estudio.

5.5. Etapa 3 - Colombia: Construcción del dataset y modelado

Con la solución temporal formalizada, la tercera etapa se concentró en la construcción del *dataset* de entrenamiento masivo. Se estableció un protocolo riguroso de diseño para capturar información exclusiva de las campañas de las elecciones locales de alcaldías en Colombia de octubre de 2023. Se definió un universo geográfico abarcando las 33 ciudades más pobladas de Colombia, procediendo a compilar interacciones generadas estrictamente en la ventana de 14 días previos a los comicios.

Por políticas y restricciones agresivas de la API *Graph* impuestas corporativamente por Meta en sus versiones recientes, Instagram tuvo que ser excluido de la extracción sistematizada. Por tanto, la adquisición de datos de fuentes abiertas iteró sobre tres infraestructuras concurrentes automatizadas a través de un *pipeline* (*scripts* ‘*scrapping_general.py*’ y ‘*unificar_redes.py*’): Playwright para automatización de navegadores ocultos (*headless*) contra la interfaz web de Twitter/X (con restricción de hasta 50 *tweets* por actor); y consultas de alto rendimiento hacia la API privada no documentada de TikTok y las colecciones indexadas de Facebook a través de *Apify*.

Para asegurar la validez inferencial, se aplicaron filtros de exclusión: solo ingresaron al *dataset* actores políticos con más de 10,000 votos confirmados en los escrutinios finales. Se excluyeron deliberadamente dos ciudades, la capital Bogotá (debido al sesgo de representatividad por el perfil de *influencer* de Gustavo Bolívar, cuya masiva tracción general superaba demográficamente la esfera meramente local) y Piedecuesta (debido a que la candidatura ganadora enfrentó problemas legales que resultaron en la desaparición intencional de sus perfiles y rastros de campaña). En casos anómalos como el de Santa Marta, donde la candidatura de mayor votación enfrentó revocatoria legal posterior, el estudio consideró ganador computacional al actor con mayor volumen bruto de votos consignados, para preservar la correlación con la intención ciudadana.

Tras los filtros geográficos y de calidad de datos documentados en el análisis exploratorio preliminar (‘*analisis_exploratorio.ipynb*’), el universo hábil final consolidó 5,776 publicaciones únicas distribuidas a través de las tres infraestructuras monitoreadas (2,511 en Facebook, 2,346 en Twitter/X y 919 en TikTok). Estas entradas correspondieron a un censo final de 328 candidatos repartidos a través de 31 ciudades competitivas. Sobre los 112 candidatos que superaban la barrera estadística de los 10,000 votos (cuya cobertura digital era altísima, con 92.6 % de ellos poseyendo publicaciones de red activas en el archivo), los análisis paramétricos confirmaron tempranamente la existencia de señal predictiva: las interacciones totales medias evidenciaban que los ganadores promediaban 44,252 frente a 28,011 de los perdedores, y las pruebas U de Mann-Whitney validaban una superioridad de *engagement* medio por publicación estadísticamente significativa para un 95 % de confianza ($p = 0.0481$). De manera asilada, un pronosticador empírico básico (*baseline*) asumiendo que el ganador fuera siempre aquel con mayor volumen nominal habría acertado en el 57.58 % de las jurisdicciones municipales.

La integración operativa del modelo de crecimiento de la Etapa 2 se ejecutó a través de la rutina ‘*Reconstruccion_Panel_Historico.ipynb*’. Aplicando los parámetros k , α estáticos y derivando el t_0 dinámico en función del lapso transcurrido desde la creación particular de cada post, la red reconstruyó la matriz histórica produciendo un *super-dataset* vali-

dado de 5,776 instancias por 340 campos numéricos (representando las permutaciones correspondientes a 11 subclases de métricas y sus rezagos o sumatorias acumuladas en plazos iterativos de 30 días escalables). Las calibraciones documentales confirmaron que la monotonidad de las curvas sintéticas era impecable (cumplimiento en 5,776 de 5,776 ensayos) y el factor de error mediano inyectado sobre las estimaciones finales se situaba matemáticamente en un 0.000 % absoluto para proyecciones convergentes en el día 14.

5.6. Modelado predictivo

La etapa terminal concentró los análisis econométricos y heurísticos bajo dos grandes paradigmas clásicos de la Inteligencia Artificial.

5.6.a. Modelo de regresión

El enfoque predictivo continuo ('Modelo_Predictivo_Electoral.ipynb') pretendía encontrar un mapeo directo para estimar la magnitud escalar porcentual de votos. Con un tensor de entrenamiento reducido dimensionalmente (112 individuos por 84 variables explicativas macro), las optimizaciones se condujeron aplicando el protocolo analítico de validación cruzada dejando uno fuera (*Leave-One-Out Cross-Validation*, LOO-CV) para mitigar correlaciones espaciales endógenas. Las arquitecturas de Vectores de Soporte Regresivo (SVR) provistas de *kernel* radial (RBF) lograron los mejores comportamientos topográficos, pero exhibieron resultados mediocres de inferencia (Error Absoluto Medio de 15.22 puntos porcentuales de desviación por estimación y una varianza explicada o R^2 irrisoria del 0.054). La saturación matemática diagnosticó enfáticamente un sobreajuste estructural de la red; la abundancia masiva de variables intervinientes no era asimilable para el pequeño volumen de observaciones empíricas. Se desestimó este enfoque, por ahora, como una ruta viable a corto plazo.

5.6.b. Modelo de clasificación binaria

Tras constatar la asimetría matricial, el análisis se reconceptualizó sobre el paradigma probabilístico discreto ('Clasificacion_Binaria_Electoral.ipynb'), simplificando la tarea del algoritmo a una función discriminatoria simple: adivinar el ganador o vencedor absoluto por distrito (*¿quién gana?*). El hiperplano se centró en priorizar masivamente el constructo analítico de la **dominancia relativa** como entrada primordial. Con un balance de clases nativo de 24.1 % (casos positivos, victoriosos) versus 75.9 % (casos negativos), los clasificadores de Regresión Logística Penalizada (LOO-CV) dominaron ampliamente, registrando niveles de *Accuracy* ponderado de 0.812 y coeficientes AUC-ROC de 0.770, traduciéndose en pronósticos asertivos para el 59.3 % de las municipalidades (16 aciertos en 27 contiendas).

Aunque estas mediciones confirman irreprochablemente que el capital político latente sí se manifiesta y decodifica a través de las interacciones sociales (la señal existe y el ruido no la silencia estadísticamente), un heurístico ingenuo (*baseline*) estipulado al comienzo de la experimentación, pronosticar ciegamente a favor del postulante con el mayor indicador bruto acumulado de *dominancia_engagement* en el ecosistema municipal, ostentaba un nivel de predicción efectiva del 70.4 % (19 aciertos de 27). Por ende, el algoritmo no pudo rebasar este techo estadístico debido a la falta de masa crítica de entrenamiento y

volumen electoral comparado en los rangos analíticos; con mayores tamaños y adiciones de contiendas iteradas, la profundidad topológica se revelaría.

6

Resultados

6.1. Resultados de Bolivia (Etapa 1)

La replicación del enfoque de *nowcasting* electoral basado en encuestas sobre la segunda vuelta presidencial boliviana (Paz vs. Quiroga, octubre de 2025) arrojó resultados mixtos que confirmaron las limitaciones estructurales de este paradigma y justificaron el viraje metodológico hacia la Etapa 2.

Datos y configuración experimental

Se construyó un *dataset* de 308 observaciones diarias (26 columnas de características) que combinaba métricas diarias de interacción, *posts*, *likes*, *shares* y comentarios, de Facebook, Instagram, TikTok y Twitter/X para ambos candidatos. La variable objetivo fue la intención de voto real interpolada a partir de las encuestas publicadas entre la primera y la última medición demoscópica disponible. El resultado real del 19 de octubre de 2025 fue: **Paz: 54.53 %**, **Quiroga: 45.47 %**.

Comparativa de modelos

Se evaluaron seis modelos (más el *baseline* de última encuesta) sobre su predicción en el día de elecciones. La Tabla 6.1 resume las métricas para el candidato Paz (el ganador), que son las más relevantes para la predicción. La Figura 6.1 ilustra la evolución temporal del mejor modelo.

Cuadro 6.1: Métricas de predicción en el día de elecciones - candidato Paz (real: 54.53 %).

Modelo	Predicción Paz	MAE	MAPE	RMSE
Baseline (última encuesta)	36.50 %	0.1803	33.1 %	0.1803
Regresión Lineal	24.85 %	0.2968	54.4 %	0.2968
Regresión Lineal + PCA	23.38 %	0.3115	57.1 %	0.3115
MLP-BP	46.91 %	0.0762	14.0 %	0.0762
MLP-BP + PCA	51.74 %	0.0279	5.1 %	0.0279
GRNN	34.67 %	0.1986	36.4 %	0.1986
GRNN + PCA	34.48 %	0.2005	36.8 %	0.2005

El modelo **MLP-BP + PCA** fue el único que superó al *baseline*: predijo un 51.74 % para Paz (error absoluto de solo 2.79 puntos porcentuales frente al resultado real de 54.53 %), mejorando más de seis veces al estimador inercial de última encuesta (MAE = 0.1803). Los

modelos de regresión lineal fallaron de manera categórica, incluso invirtiendo el resultado (prediciendo a Quiroga como ganador con 75.15 %), lo que confirma que la relación entre interacciones digitales e intención de voto no es lineal. El GRNN quedó sistemáticamente “atascado” sobreestimando a Quiroga durante toda la serie temporal (véase Figura 6.1).




Figura 6.1: Evolución diaria de la intención de voto estimada por el modelo MLP-BP+PCA (líneas continuas) vs. la intención de voto real interpolada desde encuestas (líneas discontinuas) para Paz (verde) y Quiroga (rojo). Las líneas verticales punteadas marcan la fecha de publicación de cada encuesta. El modelo captura la tendencia ascendente de Paz en las últimas semanas, aunque con alta varianza diaria.

Limitaciones estructurales identificadas

A pesar del resultado numérico del MLP-BP+PCA, el análisis reveló tres falencias críticas que desaconsejaron continuar esta ruta:

1. **Falta de generalización:** Los pesos y la topología de la red neuronal son específicos de este evento electoral. No existe mecanismo para transferir el aprendizaje a otra contienda sin reentrenamiento completo, haciendo el modelo irrepetible.
2. **Ceguera ante giros súbitos:** Los cambios de favorabilidad ocurridos en la última semana de campaña, cuando Paz remontó significativamente en las encuestas, no fueron capturados por las métricas de interacciones acumuladas. El modelo operó con un rezago estructural irrecuperable.
3. **Disociación de la señal TikTok:** Un análisis de importancia de variables identificó que la dinámica de viralidad de TikTok operaba en un plano desacoplado del resto de plataformas. Los picos de interacción en TikTok inyectaban varianza espuria en momentos en que la intención de voto real permanecía estacionaria, degradando la señal agregada.

Un experimento adicional con *lag features* (memorias de 1, 2 y 3 días) y ponderación temporal exponencial (mayor peso a días recientes) buscó dotar al modelo de capacidad

para detectar cambios de tendencia. Si bien este enfoque redujo el sesgo en períodos de alta actividad, amplificó el ruido diario y no logró resolver la inestabilidad en los días de elección. Estos hallazgos consolidaron la decisión de redirigir el enfoque hacia un modelo de clasificación binaria multi-elección, agnóstico a las dinámicas específicas de un único evento.

6.2. Resultados de Costa Rica (Etapa 2)

El modelado paramétrico del crecimiento de interacciones resolvió satisfactoriamente el obstáculo estructural que impide explotar registros históricos sin infraestructura activa de extracción. El panel de 30 días (15 antes y 15 después del día de elecciones), recogido con cadencia diaria sobre las cuatro plataformas hegemónicas, produjo **1,922 publicaciones válidas** y **19,439 observaciones** con las que se calibraron los parámetros del modelo Weibull.

Morfología del crecimiento: ganadores y no ganadores

Un hallazgo central del análisis es que la **curva de crecimiento acumulado de interacciones es morfológicamente idéntica entre la candidata ganadora y el resto de los competidores** (véase Figura 5.2 en la sección de metodología). En ambos grupos, más del 80 % de las interacciones totales se acumulan en los primeros 2–3 días desde la publicación, y a partir del Día 7 la curva es prácticamente plana. Las pruebas T día a día confirman que el crecimiento es estadísticamente significativo ($p < 0,0001$) hasta el Día 10, pero empíricamente irrelevante ($< 2\%$ diario) a partir del Día 5–7.

Este resultado tiene una implicación metodológica crítica: **el patrón de crecimiento orgánico es una propiedad de la plataforma, no del candidato ni del resultado electoral**. Esto valida el supuesto de estacionariedad del modelo Weibull y permite aplicar los mismos parámetros calibrados en Costa Rica 2026 para reconstruir históricamente las interacciones de cualquier otra elección.

Precisión proyectiva del modelo Weibull

Los parámetros calibrados (k, α, t_0) para cada plataforma se detallan en la Tabla 5.1. La evaluación de precisión se realizó simulando el escenario real de uso: tomando la medición de un día t y estimando el total final como $\hat{N} = n_t / F(t; k, \alpha, t_0)$. Los resultados del MAPE mediano se resumen en la Tabla 5.2 y se visualizan en la Figura 5.5.

Los hallazgos son formidables en la mayoría de las plataformas. Al observar una publicación en su **Día 3**:

- **Facebook**: MAPE mediano de **2.12 %** - prácticamente sin error desde el día 3.
- **TikTok**: MAPE mediano de **5.94 %** - muy por debajo del umbral de referencia del 20 %.
- **Twitter/X**: MAPE mediano de **0.38 %** - error casi nulo; las publicaciones de Twitter se saturan en horas.
- **Instagram**: MAPE mediano de **12.06 %** - el más alto, explicado por la extrema concentración de interacciones en las primeras horas (offset $t_0 = 0.04$ días = 1 hora).

En términos globales, entre el 89 % y el 99 % de las publicaciones (según la plataforma) se estiman con un error inferior al 20 % al observarlas en el Día 3. A partir del **Día 7**, el error mediano cae por debajo del 4 % en todas las plataformas.

Función de reconstrucción histórica

Con los parámetros calibrados se implementó y validó la **función de reconstrucción histórica** (véase Figura 5.6), que dado el total de interacciones observado en un día t y la plataforma, genera la curva diaria completa de interacciones nuevas e infiere el estado del post en cualquier fecha pasada. No se documentaron violaciones de monotonicidad (una publicación nunca pierde interacciones al retroceder en el tiempo), y el error mediano inyectado a la serie temporal en el Día 14 pre-elección es matemáticamente cero para Facebook y Twitter/X.

6.3. Resultados de Colombia (Etapa 3)

La evaluación del ecosistema digital de las elecciones de alcaldes 2023 sobre las 31 ciudades competitivas colombianas confirmó irrevocablemente la hipótesis fundacional del estudio empírico: las interacciones en redes sociales sí albergan una señal predictiva real y cuantificable sobre el comportamiento en urnas.

Las pruebas no paramétricas de distribución confirmaron que, en promedio, los candidatos ganadores movilizaron más interacciones globales y poseían un *engagement* marginal por post significativamente más alto ($p < 0.05$) que el resto de contendientes derrotados de sus respectivos tarjetones. Más profundamente, la experimentación estableció un paradigma de extracción de características: la **dominancia relativa** de la conversación digital en el territorio superó con creces al volumen nominal de interacciones como predictor de éxito, logrando índices de correlación monótona de Spearman superiores a 0.46.

Frente a la escalabilidad de modelado en escasez de datos (112 muestras), los resultados fueron contrastantes. El abordaje de **regresión lineal / no-lineal** para adivinar márgenes porcentuales exactos de voto fracasó categóricamente (el máximo techo explicativo o pseudo- R^2 alcanzado fue apenas del 0.118), indicando que el espacio dimensional es excesivamente grande y ruidoso frente a la disponibilidad de observaciones.

Por el contrario, la **clasificación probabilística discreta** (resolver quién es el ganador binario del certamen en cada ciudad) exhibió una convergencia parcial y funcional. Los modelos de ensamble superaron métricas conservadoras con tasas de aciertos ponderadas del 59.3 % en adivinar correctamente el mapa político regional de ganadores por capitales. No obstante, las arquitecturas entrenadas no lograron desbancar al heurístico analítico puro (*baseline*): simplemente asignar como ganador determinista al candidato que en solitario concentró la mayor dominancia de *engagement* en su respectiva ciudad reportó una tasa de acierto del 70.4 %. La señal existe intrínsecamente en el vector espacial, pero la reducida cardinalidad de la matriz actual imposibilita que una red compleja de aprendizaje automatizado abstraiga patrones topológicos multidimensionales que le permitan abatir una simple regla algorítmica descriptiva.

6.4. Síntesis: contribuciones al estado del arte

Los hallazgos empíricos y los desarrollos técnicos documentados a lo largo de este estudio confluyen en cuatro contribuciones sustanciales al dominio de la analítica política y los modelos predictivos heterodoxos:

1. **Elección-Agnosticismo Empírico:** Se establece una ruta metodológica viable (demostrada a través de la clasificación binaria basada en la métrica transversal de dominancia relativa) para romper la asimetría temporal del SOMEN-DC, permitiendo entrenar algoritmos con observaciones de múltiples contiendas de alcaldías paralelas simultáneamente y abstraer reglas de decisión exportables.
2. **Total Independencia Demoscópica:** A diferencia de la inmensa mayoría de la literatura contemporánea en estimación digital electoral, este esquema sustituye la obligatoriedad de usar encuestas como variable dependiente, anclando directamente su optimización sobre la variable *ground truth* universal: el escrutinio final.
3. **Restaurador Temporal de Series (Modelo Weibull):** Se introduce y formaliza una arquitectura matemática de interpolación capaz de retrotraer variables acumulativas hacia instantes en el pasado. Esto soluciona drásticamente el que quizás sea el mayor obstáculo técnico para la investigación retrospectiva de dinámicas digitales, facultando a los analistas a poblar *datasets* de series temporales históricas partiendo exclusivamente de un raspado actual estático, sin requerir despliegues preventivos costosos.
4. **Democratización del Pipeline:** Se desmitifica la barrera logística del analfabetismo algorítmico, comprobando la total escalabilidad y operatividad de la solución utilizando, de principio a fin, una orquestación ligera ensamblada con herramientas de mercado genéricas (*Make*, *Apify*, API oficiales, librerías *Headless*), demostrando que la predicción y monitoreo algorítmico no es una tecnología que deba residir exclusivamente bajo el control de infraestructuras corporativas, gubernamentales o institucionales avanzadas.

7

Impacto esperado

7.1. Impacto académico

Esta investigación aspira a realizar una aportación fundacional a la literatura de ciencia de datos políticos y estudios electorales cuantitativos en América Latina. A nivel epistemológico, este trabajo documenta la primera metodología estructurada de *nowcasting* electoral elección-agnóstica e independiente de encuestas conceptualizada e implementada para el entorno político altamente fragmentado de Colombia.

Metodológicamente, la formalización matemática del **modelo de crecimiento Weibull** constituye un artefacto científico de exportación. Al proporcionar un marco matemático capaz de reconstruir la evolución temporal de la tracción digital sin depender de registros en tiempo real, el estudio libera a futuras investigaciones académicas de la obligación

logística de desplegar sensores de recopilación con meses de antelación al evento electoral de interés.

Adicionalmente, se efectúa una contribución transversal al debate global sobre la viabilidad de la predicción electoral mediante redes sociales, delineando claramente las fronteras de escala empírica: delimitando la inviabilidad estructural de las arquitecturas de regresión volumétrica en escenarios de escasez dimensional (muestras menores a 200 casos), al tiempo que valida matemáticamente la *dominancia relativa* como el estimador heurístico más robusto en elecciones subnacionales.

7.2. Impacto práctico

En una dimensión operativa, el principal aporte aplicativo es la materialización de un sistema orquestado de pronóstico y monitoreo de extremado bajo costo. Al demostrarse la reproducibilidad absoluta del ecosistema metodológico empleando herramientas comerciales de extracción *off-the-shelf* (como *Apify* o integradores *no-code* como *Make.com*) y prescindiendo por completo de servidores y arquitecturas universitarias dedicadas, la investigación democratiza el análisis de datos políticos complejos.

Este avance abre la puerta para que medios de comunicación regionales, laboratorios de veeduría ciudadana y pequeñas firmas de consultoría estratégica desplieguen capacidades de inteligencia electoral en tiempo real. En el mediano plazo, estas técnicas se proyectan como la alternativa natural y costo-eficiente frente a los oligopolios demoscópicos, especialmente en otras naciones de Latinoamérica donde la carencia de encuestas sistemáticas o la desconfianza pública en sus resultados exigen métodos de estimación paralelos transparentes y auditables.

7.3. Limitaciones y trabajo futuro

La honestidad intelectual obliga a delimitar las fallas orgánicas y los confines de aplicabilidad del estudio. En primer lugar, la calibración de la matriz temporal Weibull, si bien fue exhaustiva a nivel micro de publicaciones, descansó sobre el comportamiento macro de una única elección (Costa Rica 2026). Asumir universalidad conductual exige una validación prospectiva replicando la medición longitudinal sobre certámenes demográficamente disímiles para confirmar la estabilidad inter-elecciones de los parámetros de forma y escala.

En segundo lugar, por determinaciones corporativas restrictivas de la compañía Meta, Instagram quedó excluido del *dataset* colombiano; esta omisión representa una pérdida incalculable de la fotografía generacional y el consumo audiovisual de una gran franja del electorado joven. Asimismo, tanto el modelo de dominancia heurística como los ensambles algorítmicos probaron ser estructuralmente vulnerables a perfiles políticos con audiencias atípicas (como lo demostró la exclusión forzosa del candidato *influencer* Gustavo Bolívar), revelando que las masas críticas interdepartamentales contaminan la medición estrictamente local. Todo esto sin ignorar que el conteo volumétrico peca de ceguera ante la calidad y veracidad de la interacción: las arquitecturas modeladas no están equipadas actualmente para ponderar el efecto adverso o positivo de interacciones manufacturadas artificialmente (granjas de *bots*, perfiles inorgánicos o *astroturfing*).

Por lo tanto, la agenda de ****trabajo futuro**** a desprender de esta investigación es rica y expansiva. Se priorizará escalar el conjunto de datos integrando eventos asimétricos (elecciones legislativas departamentales) y otras geografías de la región andina; investigar el desempeño matricial de agregar ventanas temporales de memoria (*lagged variables*); desarrollar clasificadores semánticos que depuren la señal descartando la actividad inorgánica artificial; e incorporar en el plano explicativo covariables estructuradas *offline* (indicadores económicos territoriales y clima de opinión en la prensa tradicional). Inmediatamente, la prioridad empírica definitiva será la confrontación longitudinal ciega del clasificador binario entrenado contra los resultados de las próximas elecciones territoriales en Colombia del año 2027.

8

Conclusiones

8.1. Respuesta a la pregunta de investigación

Este documento se originó a partir de una inquietud central: evaluar si era metodológicamente posible diseñar un modelo de *nowcasting* electoral elección-agnóstico y emancipado de las encuestas para el complejo entorno local colombiano. A la luz de los hallazgos empíricos, la respuesta global es afirmativa con matices estructurales: el modelo es conceptual y operativamente posible, pero su techo predictivo actual está condicionado por el volumen histórico de entrenamiento.

En primer lugar, se demostró irrefutablemente que las interacciones ciudadanas en plataformas sociales **tienen un poder predictivo real** sobre el comportamiento del electorado colombiano. Las pruebas no paramétricas arrojaron diferencias significativas ($p < 0.05$) entre ganadores y perdedores, y la correlación de rango cruzó un umbral robusto de Spearman $\rho > 0.46$. No obstante, la experimentación también comprobó que, frente a un problema de alta varianza como una elección fragmentada, la señal extraída aislada de la red sin covariables de apoyo es ruidosa e insuficiente para dictar sentencias determinísticas absolutas a nivel nacional.

En segundo término, la viabilidad del modelo descansaba sobre la premisa de la **reconstrucción temporal**. Las pruebas sobre el panel de control validaron que la interpolación matemática mediante distribuciones de Weibull es excepcionalmente precisa (inyectando errores menores al 20 % en más del 89 % del material muestral observado tempranamente). En consecuencia, un marco analítico elección-agnóstico se ha consolidado como un enfoque empírico viable y robusto: el modelo puede abstraer y aplicar reglas universales. Sin embargo, para que las arquitecturas topológicas (como redes neuronales o ensambles complejos) logren trascender el desempeño del algoritmo *baseline* trivial basado en dominancia relativa, se torna imperativo inyectar iteraciones masivas de eventos históricos en la matriz de aprendizaje.

8.2. Lecciones aprendidas

A lo largo del desarrollo computacional y la revisión estadística del proyecto, se decantaron lecciones críticas para la práctica del *nowcasting* digital en el sur global:

- **La supremacía de la dominancia relativa:** Quedó evidenciado que el ecosistema de campaña funciona como un juego de suma cero territorial. La posición de un candidato relativa a la conversación local de su ciudad (*share of voice*) es una métrica inmensamente superior al volumen absoluto de interacciones, pues este último es susceptible de distorsiones poblacionales y mediáticas inherentes a las dinámicas atípicas de los perfiles públicos masivos.
- **El paradigma de clasificación:** Frente a matrices limitadas por la escasez de datos subnacionales etiquetados, plantear la predicción como un problema de clasificación probabilística discreta (*¿quién se lleva la elección?*) probó ser cualitativamente más realista y convergente que pretender establecer márgenes porcentuales directos (*¿cuánto saca?*) a través de regímenes de regresión.
- **El abismo de la última semana:** El obstáculo empírico más resistente para las métricas agregativas continúa siendo el giro coyuntural tardío. La explosión de interacciones preexistentes oculta frecuentemente las volatilidades sutiles de la opinión pública suscitadas por eventos, escándalos o alianzas que acontecen en los tres días anteriores al evento de urnas.
- **Autonomía computacional:** La comprobación de un ciclo de vida completo de análisis —desde la orquestación y el *scraping* (*Make.com*, *Playwright*, API de X, *Apify*) hasta la proyección asintótica y el modelado matricial— probó que este *pipeline* analítico complejo es enteramente ejecutable desde laboratorios comerciales e independientes que operen con un coste logístico nominal o nulo.

8.3. Próximos pasos

La natural prolongación de este cuerpo de investigación consiste en llevar la experimentación a la fase de masificación de datos, integrando *datasets* de contiendas asimétricas de más naciones de América Latina y diferentes marcos temporales, apuntalando así el tamaño de las muestras para destrabar el uso de aprendizaje profundo. Inminentemente, se hace obligatoria la recalibración inter-regional del modelo Weibull, así como el rediseño dimensional para inyectar vectores categóricos de sentimiento. La culminación de este esfuerzo empírico se cristalizará durante la apertura de las urnas de las próximas elecciones territoriales en Colombia de 2027, las cuales fungirán como el juez definitivo ciego (*out-of-time sample*) sobre el cual se medirá, bajo estricto rigor metodológico ex-ante, la madurez proyectiva de la inteligencia desarrollada.

Bibliografía

- ACEI. (2025). Perspectivas de la Industria de Investigación de Mercados en Colombia 2025 [Asociación Colombiana de Empresas de Investigación de Mercados y Opinión Pública].
- Barberá, P. (2020). Social Media, Echo Chambers, and Political Polarization. En N. Persily & J. A. Tucker (Eds.), *Social Media and Democracy: The State of the Field and Prospects for Reform*. Cambridge University Press. <https://www.researchgate.net/publication/343996442>
- Brito, K., & Adeodato, P. J. L. (2022). Measuring the performances of politicians on social media and the correlation with major Latin American election results. *Government Information Quarterly*, 39(4), 101745. <https://doi.org/10.1016/j.giq.2022.101745>
- Brito, K., & Adeodato, P. J. L. (2023). Machine learning for predicting elections in Latin America. *Government Information Quarterly*, 40(2), 101782. <https://doi.org/10.1016/j.giq.2022.101782>
- Brito, K., Silva Filho, T., & Adeodato, P. J. L. (2024). Stop trying to predict elections only with Twitter: There are other data. *Government Information Quarterly*, 41(1), 101899. <https://doi.org/10.1016/j.giq.2023.101899>
- Brito, K. d. S., & Adeodato, P. J. L. (2020). Predicting Brazilian and U.S. Elections with Machine Learning and Social Media Data. *Proceedings of the 2020 International Joint Conference on Neural Networks (IJCNN)*.
- Congreso de la República de Colombia. (2025). Ley 2494 de 2025, por la cual se regula la elaboración, publicación y divulgación de encuestas electorales [Diario Oficial de Colombia].
- DataReportal. (2025, noviembre). Digital 2026: Colombia [Datos de octubre 2025. Publicado por Kepios / We Are Social / Meltwater]. <https://datareportal.com/reports/digital-2026-colombia>
- ESOMAR. (2025). *Global Market Research 2025*. ESOMAR. <https://esomar.org/publications/global-market-research-2025>
- GAD3. (2026, mayo). Comunicado: Suspensión de publicación de encuestas electorales en Colombia. <https://www.lasillavacia.com/en-vivo/por-ley-mordaza-gad3-suspende-publicacion-de-encuestas-en-colombia/>
- Giangiulio, D. (2026, abril). Prediction Markets: On Pace for \$1 Trillion by 2030 [Citado en CNBC, 14 de abril de 2026]. <https://www.cnbc.com/2026/04/14/prediction-markets-will-grow-to-1-trillion-by-2030-bernstein-says.html>
- Kayser, M. A., & Lindstädt, R. (2015). A Cross-National Measure of Electoral Competitiveness. *Political Analysis*, 23(2), 242-253. <https://doi.org/10.1093/pan/mpv001>
- Kennedy, C., Blumenthal, M., Clement, S., Clinton, J. D., Durand, C., Franklin, C., McGeeney, K., Miringoff, L., Olson, K., Rivers, D., Saad, L., Witt, G. E., & Wlezien, C.

- (2018). An Evaluation of the 2016 Election Polls in the United States. *Public Opinion Quarterly*, 82(1), 1-33. <https://doi.org/10.1093/poq/nfx047>
- Lewis-Beck, M. S., Nadeau, R., & Bélanger, É. (2004). General Election Forecasts in the United Kingdom: A Political Economy Model. *Electoral Studies*, 23(2), 279-290. [https://doi.org/10.1016/S0261-3794\(02\)00071-9](https://doi.org/10.1016/S0261-3794(02)00071-9)
- Lewis-Beck, M. S., Nadeau, R., & Bélanger, É. (2011). Nowcasting v. polling: The 2010 UK election trials. *Electoral Studies*, 30(2), 284-287. <https://doi.org/10.1016/j.electstud.2010.09.013>
- Lewis-Beck, M. S., & Tien, C. (2014). Proxy models and nowcasting: U.S. presidential elections in the future. *Presidential Studies Quarterly*, 44(3), 506-521.
- Mughan, A. (1987). General Election Forecasting in Britain: A Comparison of Three Simple Models. *Electoral Studies*, 6(3), 195-207. [https://doi.org/10.1016/0261-3794\(87\)90031-X](https://doi.org/10.1016/0261-3794(87)90031-X)
- Norpoth, H. (2004). Forecasting British Elections: A Dynamic Perspective. *Electoral Studies*, 23(2), 297-305. [https://doi.org/10.1016/S0261-3794\(02\)00070-7](https://doi.org/10.1016/S0261-3794(02)00070-7)
- Ríos Giraldo, M. (2026). Ley de encuestas en Colombia: la polémica norma. *Diario de Occidente*. <https://occidente.co/politica/graffiti/ley-de-encuestas-colombia-derogatoria-cne-investigaciones-2026/>
- Sanders, D. (1991). Government Popularity and the Next General Election. *The Political Quarterly*, 62(2), 235-261. <https://doi.org/10.1111/j.1467-923X.1991.tb00856.x>
- Sigelman, L. (1979). Presidential Popularity and Presidential Elections. *Public Opinion Quarterly*, 43(4), 532-534. <https://www-jstor-org.ez.unisabana.edu.co/stable/2749005>
- Skoric, M. M., Liu, J., & Jaidka, K. (2020). Electoral and Public Opinion Forecasts with Social Media Data: A Meta-Analysis. *Information*, 11(4), 187. <https://doi.org/10.3390/info11040187>
- Stegmaier, M., Jokinsky, S., & Lewis-Beck, M. S. (2023). The Evolution of Election Forecasting Models in the UK. *Electoral Studies*, 86, 102694. <https://doi.org/10.1016/j.electstud.2023.102694>
- Tucker, J. A., Guess, A., Barberá, P., Vaccari, C., Siegel, A., Sanovich, S., Stukal, D., & Nyhan, B. (2018). *Social Media, Political Polarization, and Political Disinformation: A Review of the Scientific Literature* (inf. téc.). SSRN. <https://doi.org/10.2139/ssrn.3144139>
- Tumasjan, A., Sprenger, T. O., Sandner, P. G., & Welp, I. M. (2010). Predicting elections with Twitter: What 140 characters reveal about political sentiment. *Proceedings of the Fourth International AAAI Conference on Weblogs and Social Media*, 178-185.
- Whiteley, P. (1979). Electoral Forecasting from Poll Data: The British Case. *British Journal of Political Science*, 9(2), 219-236. <https://doi.org/10.1017/S0007123400001733>