

MAESTRÍA EN ANALÍTICA APLICADA
FACULTAD DE INGENIERÍA

Diseño e implementación de un modelo de *nowcasting* elección-agnóstico para la intención de voto aplicado a elecciones locales en Colombia 2023

Juan Sotelo Aguilar

DIRECTOR
Prof. PhD. Miguel Uribe Laverde
Universidad de La Sabana

AÑO ACADÉMICO 2026

A María José, mi familia y quienes creyeron en esto antes de que yo mismo creyera.

Índice general

Resumen	1
Abstract	1
1 Introducción	1
1.1 Motivación del problema	1
1.2 Estado del arte: el modelo SOMEN-DC	2
1.3 Hipótesis de trabajo	2
1.4 Estructura del documento	3
2 Pregunta de investigación	3
2.1 Pregunta principal	3
2.2 Preguntas derivadas	4
3 Marco conceptual	5
3.1 <i>Nowcasting</i> electoral y predicción con redes sociales	5
3.1.a Definición de <i>nowcasting</i> en contexto electoral	5
3.2 Modelos elección-agnósticos: definición y ventajas	5
3.3 Interacciones digitales como <i>proxy</i> de intención de voto	6
3.3.a La hipótesis Tumasjan	6
3.3.b Interacciones absolutas vs. dominancia relativa	6
3.4 El problema del histórico de interacciones	6
4 Objetivos	7
4.1 Objetivo general	7
4.2 Objetivos específicos	7
5 Metodología	8
5.1 Diseño general del pipeline	8
5.2 Etapa 1 — Bolivia: Replicación del SOMEN-DC y prueba de concepto . . .	8
5.2.a Caso de estudio y recolección de datos	8
5.2.b Evaluación de modelos	9
5.3 Etapa 2 — Costa Rica: Modelado del crecimiento de interacciones	9
5.3.a El problema estructural	9
5.3.b Metodología y Modelo Weibull	9
5.4 Etapa 3 — Colombia: Construcción del dataset y modelado	10
5.5 Modelado predictivo	11
5.5.a Modelo de regresión	11
5.5.b Modelo de clasificación binaria	12

6	Resultados	12
6.1	Resultados de Bolivia (Etapa 1)	12
6.2	Resultados de Costa Rica (Etapa 2)	13
6.3	Resultados de Colombia (Etapa 3)	14
6.4	Síntesis: contribuciones al estado del arte	14
7	Impacto esperado	15
7.1	Impacto académico	15
7.2	Impacto práctico	15
7.3	Limitaciones y trabajo futuro	16
8	Conclusiones	17
8.1	Respuesta a la pregunta de investigación	17
8.2	Lecciones aprendidas	17
8.3	Próximos pasos	18
	Bibliografía	19

Resumen

En Latinoamérica, las encuestas electorales son la única herramienta disponible para el seguimiento de la intención de voto durante una campaña activa. Este trabajo propone y valida una metodología alternativa para estimar la intención de voto que no depende de encuestas, es elección-agnóstica y puede replicarse con herramientas comerciales accesibles.

Palabras clave: nowcasting electoral, redes sociales, machine learning, Colombia, elecciones locales, elección-agnóstico.

Abstract

In Latin America, electoral polls are the only available tool for tracking voting intention during an active campaign. This work proposes and validates an alternative methodology to estimate voting intention that does not rely on polls, is election-agnostic, and can be replicated with accessible commercial tools. Using social media interactions from candidates' official profiles as the primary signal, and a Weibull growth model for historical interaction reconstruction, the study demonstrates that relative dominance of a candidate's digital engagement is a statistically significant predictor of electoral outcomes in Colombian local elections ($\rho > 0.46, p < 2 \times 10^{-7}$).

Keywords: electoral nowcasting, social media, machine learning, Colombia, local elections, election-agnostic model, Weibull growth.

1

Introducción

1.1. Motivación del problema

El seguimiento de la intención de voto durante una campaña electoral es, en casi todos los países del mundo, una industria dominada por un único instrumento metodológico: la encuesta de opinión pública Brito et al., 2024. En el contexto latinoamericano, y particularmente en Colombia, esta dependencia es todavía más pronunciada. No existen herramientas alternativas consolidadas ni estandarizadas que permitan estimar la opinión del electorado en tiempo real durante una campaña activa de forma sistemática y rigurosa.

A pesar de su ubicuidad, las encuestas electorales en Colombia enfrentan profundos retos estructurales. Como ha señalado Andrés Caballero, director de Cifras y Conceptos **PENDIENTE**, estos instrumentos presentan problemas significativos de sesgo y representatividad. La dificultad logística de abarcar territorios extensos, la alta tasa de no respuesta y los altos costos operativos limitan la frecuencia y el tamaño muestral de los estudios, especialmente en elecciones locales. En este panorama, se hace cada vez más necesario desarrollar herramientas novedosas para el pronóstico electoral que no dependan exclusivamente de las encuestas y que aprovechen fuentes alternativas de datos masivos.

1.2. Estado del arte: el modelo SOMEN-DC

El modelo que representa el estado del arte más relevante para este trabajo es el denominado **SOMEN-DC** (*Social Media Electoral Nowcasting During Campaign*), desarrollado por investigadores de la Universidad Federal de Pernambuco en Brasil Brito y Adeodato, 2023. Este modelo propone un avance metodológico importante al utilizar una combinación de datos de encuestas e interacciones en redes sociales, recopiladas sistemáticamente durante el transcurso de la campaña electoral, para entrenar un algoritmo predictivo específico para cada elección.

Sin embargo, a pesar de sus aportes, el modelo SOMEN-DC presenta tres limitaciones metodológicas fundamentales que restringen su aplicabilidad a gran escala:

1. **Techo encuestocéntrico:** Dado que el modelo utiliza los resultados de las encuestas como variable objetivo (*ground truth*) durante su fase de entrenamiento, su capacidad predictiva se ve estructuralmente limitada. No puede superar la precisión de las encuestas mismas porque está diseñado para replicar su comportamiento.
2. **Dependencia de infraestructura costosa:** La recolección de interacciones en redes sociales exige un proceso de extracción de datos (*scraping*) continuo y en tiempo real a lo largo de toda la campaña, lo cual requiere una infraestructura técnica y computacional de alto costo que no suele estar al alcance de investigadores independientes o medios de comunicación locales.
3. **No transferibilidad:** Los pesos aprendidos por el algoritmo son útiles exclusivamente para la elección en la que fueron entrenados. Al no poder generalizar patrones, el modelo carece de transferibilidad y debe construirse desde cero en cada nuevo contexto electoral.

1.3. Hipótesis de trabajo

El punto de partida conceptual de este proyecto es la hipótesis seminal formulada por Tumasjan et al. (2010), quienes postulan que el volumen de actividad digital y menciones de un candidato en plataformas de microblogging, como Twitter, funciona como un estimador razonable de su capital electoral subyacente.

Este trabajo extiende dicha hipótesis mediante una premisa metodológica propia: dado que la relación entre la tracción digital y el apoyo en las urnas es un fenómeno conductual común que trasciende contextos aislados, es teóricamente posible entrenar un único modelo estadístico utilizando datos de *múltiples elecciones simultáneamente*. Esto permitiría desarrollar una herramienta capaz de modelar la intención de voto de manera independiente, sin la necesidad de integrar encuestas en la ecuación predictiva.

Bajo este marco, el modelo propuesto opera recibiendo como *input* las interacciones digitales (ya sean totales o promediadas por publicación) generadas en una ventana de tiempo específica previa a la jornada electoral. A partir de estas señales, el *output* proyectado es un vector de tamaño C (donde C es el número de candidatos competitivos), que representa el porcentaje estimado de intención de voto para cada contendiente.

1.4. Estructura del documento

Para abordar esta hipótesis, la investigación se estructuró a través de tres etapas empíricas que guían la organización de este documento. El **Capítulo 2** define formalmente la pregunta de investigación y los interrogantes derivados. El **Capítulo 3** presenta el marco conceptual, explorando la literatura sobre *nowcasting* electoral y la viabilidad de los modelos elección-agnósticos. Seguidamente, el **Capítulo 4** detalla los objetivos del estudio.

El **Capítulo 5** desarrolla la metodología, dividida en las tres fases del proyecto:

- **Bolivia (Prueba de concepto):** Donde se replica el modelo SOMEN-DC para evaluar empíricamente sus limitaciones.
- **Costa Rica (Modelado de crecimiento):** Enfocada en resolver el problema del registro histórico mediante la calibración matemática de la curva de crecimiento de las interacciones.
- **Colombia (Construcción y modelado final):** Donde se compila el *dataset* elección-agnóstico de elecciones locales (2023) y se entrenan los algoritmos de clasificación y regresión.

Finalmente, el **Capítulo 6** expone los resultados obtenidos en cada fase, mientras que los **Capítulos 7 y 8** discuten el impacto esperado de la herramienta, sus limitaciones inherentes y las conclusiones definitivas del estudio.

2

Pregunta de investigación

Para abordar las limitaciones metodológicas previamente expuestas relativas a la dependencia de las encuestas y la imposibilidad de transferir los modelos de *nowcasting* a nuevas elecciones, esta investigación se estructura alrededor de un interrogante central y una serie de preguntas derivadas que guían el diseño empírico del estudio.

2.1. Pregunta principal

La inquietud fundamental que motiva este trabajo se sintetiza en la siguiente pregunta de investigación:

*¿Es posible diseñar e implementar un modelo de nowcasting de la intención de voto que sea **elección-agnóstico** —es decir, cuyos parámetros se entrenen con datos de múltiples elecciones simultáneas y sean transferibles a contiendas no vistas—, que no dependa en ninguna etapa de encuestas de opinión pública, y que pueda aplicarse con precisión a elecciones locales en Colombia utilizando únicamente señales extraídas de interacciones en redes sociales?*

Esta pregunta desafía el paradigma establecido en la literatura (representado por modelos como el SOMEN-DC), buscando independizar por completo el pronóstico de las encuestas y evaluar si las huellas digitales por sí solas contienen suficiente información estructural para estimar el apoyo político en un ecosistema electoral altamente fragmentado como el colombiano.

2.2. Preguntas derivadas

Para dar respuesta a la pregunta principal de manera secuencial y estructurada, el estudio plantea cuatro preguntas de investigación derivadas, cada una asociada a un desafío metodológico o empírico específico:

1. **Sobre la capacidad predictiva intrínseca de la red:** ¿Las interacciones en redes sociales de los candidatos (volumen de *likes*, comentarios, visualizaciones, etc.) tienen un poder predictivo estadísticamente significativo sobre el resultado electoral real en el contexto latinoamericano?
2. **Sobre la viabilidad de la reconstrucción de series temporales:** Dado que las plataformas digitales no almacenan un registro público del historial de interacciones de una publicación, ¿es posible reconstruir matemáticamente la curva de crecimiento de las interacciones de publicaciones pasadas sin haber realizado *scraping* en tiempo real durante la campaña original?
3. **Sobre la selección de características (feature engineering):** Entre las múltiples señales disponibles, ¿qué tipo de métricas digitales resultan más informativas para el pronóstico electoral: el volumen absoluto de interacciones de un candidato, su *dominancia relativa* en comparación con sus contrincantes, o su capacidad para generar tracción tardía en los últimos días de la campaña?
4. **Sobre la escalabilidad y el tipo de modelado:** Considerando las limitaciones en el tamaño de muestra de elecciones históricas viables para estudio, ¿con cuántos ejemplos de entrenamiento es estadísticamente factible y robusto entrenar un modelo de **clasificación** (predecir quién gana) versus un modelo de **regresión** (predecir el porcentaje exacto de votos)?

3

Marco conceptual

3.1. *Nowcasting* electoral y predicción con redes sociales

3.1.a. Definición de *nowcasting* en contexto electoral

En ciencia política, *nowcasting* (pronóstico del presente) designa una estimación cuantitativa de “lo que pasaría si la elección se celebrara hoy”. Se diferencia del *forecasting* clásico (predicción a futuro) en que el *nowcasting* busca modelar el estado actual y latente del electorado mediante actualizaciones continuas y en tiempo real, basándose en un modelo cuyos parámetros estructurales se mantienen fijos mientras varían las covariables observadas Lewis-Beck y Tien, 2014; Lewis-Beck et al., 2011.

La primera formulación formal aplicada a elecciones nacionales se consolidó con los modelos *proxy*. Por ejemplo, en el Reino Unido, Lewis-Beck et al. (2011) modelaron el voto del oficialismo a partir de indicadores adelantados, como la aprobación del gobierno, medida con meses de antelación. En épocas más recientes, con el auge del *Big Data*, la literatura empírica se ha volcado al uso de redes sociales como fuente masiva de covariables en tiempo real, transformando el *nowcasting* en una herramienta de minería de datos dinámicos Skoric et al., 2020.

Desde el estudio seminal de Tumasjan et al. (2010), múltiples autores han explorado arquitecturas híbridas. Trabajos recientes como los de Brito y Adeodato (2022, 2023) han sofisticado la técnica combinando recolección de datos durante la campaña (*During Campaign*) y modelos de aprendizaje automático (*Machine Learning*) aplicados a Latinoamérica. Sin embargo, estas aplicaciones mantienen una dependencia crítica: el entrenamiento constante frente a encuestas tradicionales.

3.2. Modelos elección-agnósticos: definición y ventajas

Un modelo **elección-agnóstico** es aquel que se entrena utilizando datos conjuntos de múltiples elecciones simultáneamente, con el propósito de aprender reglas de decisión y pesos paramétricos que representen patrones de comportamiento electoral universales (o regionalmente consistentes), de modo que sean directamente transferibles a elecciones no vistas.

Formalmente, sea $\mathcal{E} = \{e_1, e_2, \dots, e_M\}$ un conjunto de M elecciones históricas diferentes (por ejemplo, alcaldías de distintas ciudades). El objetivo es aprender una función predictiva:

$$f : \mathbb{R}^d \rightarrow [0, 1] \quad (3.1)$$

tal que $\hat{y}_{i,m} = f(\mathbf{x}_{i,m})$, donde $\mathbf{x}_{i,m}$ es el vector de características de d dimensiones (interacciones digitales, tasas de crecimiento, dominancia) del candidato i en la elección m , y

$\hat{y}_{i,m}$ es la cuota de voto estimada o la probabilidad de victoria.

La principal ventaja matemática y operativa de este enfoque frente a arquitecturas específicas de campaña como el SOMEN-DC Brito y Adeodato, 2023 radica en su escalabilidad e independencia. Al abstraer la función f sobre M elecciones, el modelo se desacopla de la necesidad de contar con datos de encuestas como variable dependiente, utilizando directamente los resultados electorales finales como *ground truth*. Asimismo, elimina la dependencia de infraestructura de *scraping* en tiempo real, pues la predicción sobre una elección nueva $\mathcal{E}_{new}$ requiere únicamente extraer los vectores $\mathbf{x}_{new}$ y procesarlos a través del modelo pre-entrenado.

3.3. Interacciones digitales como *proxy* de intención de voto

3.3.a. La hipótesis Tumasjan

El uso de señales digitales como estimador político se sustenta empíricamente en el trabajo fundacional de Tumasjan et al. (2010) sobre las elecciones federales alemanas de 2009. Estos autores demostraron que el simple conteo volumétrico de *tweets* que mencionan a un partido refleja fielmente el resultado electoral, logrando un error absoluto medio (MAE) de 1.65 %. Esta hipótesis sugiere que la atención (reflejada en interacciones y contenido generado) equivale a capital político en la arena digital.

3.3.b. Interacciones absolutas vs. dominancia relativa

Si bien el volumen absoluto de interacciones (por ejemplo, el total de *likes*) ofrece una señal importante, presenta ruido debido a la heterogeneidad de los distritos electorales y la presencia de cuentas atípicamente virales. Para mitigar esto, este estudio introduce y prioriza la métrica de **dominancia relativa**: el porcentaje de interacciones que acumula un candidato sobre el total de interacciones generadas por todos los candidatos competitivos dentro de su misma ciudad o distrito.

Los análisis exploratorios sobre las elecciones locales colombianas de 2023 presentados en este trabajo confirman que la dominancia relativa es significativamente más informativa que el volumen absoluto. La correlación de Spearman entre la dominancia relativa en interacciones y la cuota de voto real alcanza $\rho > 0.46$ con $p < 2 \times 10^{-7}$.

No obstante, se deben reconocer las limitaciones intrínsecas de este *proxy*. Las redes sociales son ecosistemas permeables a la actividad no inorgánica (bots, manipulación coordinada), sesgos demográficos propios de las plataformas y la existencia de candidatos que, por su condición de figuras públicas o *influencers*, generan tracción digital desproporcionada a su verdadera viabilidad electoral.

3.4. El problema del histórico de interacciones

Uno de los mayores desafíos para entrenar modelos predictivos retrospectivos es la opacidad temporal de los datos en redes sociales. Plataformas como Facebook, Twitter/X y TikTok muestran únicamente el total acumulado de interacciones de una publicación en el instante en que es consultada (hoy). No guardan ni exponen públicamente la curva histórica de crecimiento; por lo tanto, es imposible observar directamente cuántos *likes*

tenía una publicación específicamente el día anterior a las elecciones, un dato crucial para el *nowcasting*.

Para sortear este obstáculo metodológico, este trabajo propone modelar matemáticamente la curva de crecimiento acumulado de las interacciones utilizando una distribución de Weibull con parámetro de desplazamiento (*offset*):

$$F(t) = 1 - e^{-k \cdot (t+t_0)^\alpha} \quad (3.2)$$

donde t es el tiempo transcurrido (en días) desde la publicación; k es el parámetro de escala que determina la velocidad general de acumulación; α es el parámetro de forma que captura la rápida deceleración típica del consumo de contenido en redes (decaimiento exponencial); y t_0 modela la asimetría temporal inicial, capturando la explosión masiva de interacciones que ocurre en las primeras horas antes de que t se convierta en 1 día.

Al calibrar estos parámetros (k, α, t_0) de forma diferenciada para cada plataforma, es posible proyectar la curva $F(t)$ hacia el pasado y estimar con alta fidelidad las métricas que tenía cualquier publicación histórica en la víspera electoral.

4

Objetivos

4.1. Objetivo general

Diseñar e implementar un modelo de *nowcasting* de la intención de voto en elecciones locales colombianas que sea elección-agnóstico, no dependa de encuestas, use únicamente interacciones en redes sociales de los perfiles oficiales de los candidatos, y pueda replicarse con herramientas comerciales accesibles.

4.2. Objetivos específicos

1. **OE1.** Replicar y evaluar empíricamente el modelo SOMEN-DC en la segunda vuelta presidencial de Bolivia (octubre de 2025).
2. **OE2.** Modelar el crecimiento temporal de las interacciones en redes sociales mediante una distribución Weibull con *offset*.
3. **OE3.** Construir un *dataset* de entrenamiento elección-agnóstico con datos de las elecciones locales colombianas de 2023.
4. **OE4.** Entrenar y evaluar modelos de clasificación y regresión del resultado electoral.
5. **OE5.** Documentar las condiciones de viabilidad metodológica del modelo propuesto y documentar sus limitaciones.

5 Metodología

5.1. Diseño general del pipeline

La arquitectura metodológica de esta investigación está estructurada como un *pipeline* secuencial dividido en tres etapas empíricas. La Etapa 1 corresponde a una prueba de concepto en Bolivia para replicar y evidenciar los problemas estructurales del modelo base. La Etapa 2 aborda el problema de la asimetría de la información temporal, calibrando un modelo de crecimiento matemático en Costa Rica. Finalmente, la Etapa 3 consolida el modelo elección-agnóstico en Colombia.

La arquitectura general del *pipeline* de predicción propuesto opera bajo la siguiente secuencia lógica: en primer lugar, se extraen los datos acumulados actuales de las redes sociales de los candidatos (restringidos a publicaciones realizadas en los últimos 14 días pre-elección); posteriormente, se procesan mediante un modelo paramétrico de Weibull específico por plataforma para estimar la reconstrucción histórica de la curva de crecimiento diario; con esta información, se construyen las *features* diarias por candidato; y, finalmente, un modelo elección-agnóstico pre-entrenado procesa el vector para proyectar un vector C -dimensional con la intención de voto o la probabilidad de victoria de cada contendor.

Todo el ecosistema de recolección de datos fue diseñado para garantizar su accesibilidad y bajo costo, operando sin requerir infraestructura institucional. Para ello, se integraron herramientas comerciales y *scripts* a medida utilizando la plataforma de automatización Make.com, clientes de *scraping* de Apify, la API oficial de Twitter/X y *scripts* de navegación programática o *headless browsers* desarrollados con Playwright.

5.2. Etapa 1 — Bolivia: Replicación del SOMEN-DC y prueba de concepto

5.2.a. Caso de estudio y recolección de datos

Para confirmar empíricamente las limitaciones inherentes a la literatura de *nowcasting* dependiente de encuestas, se planteó un caso de estudio replicando la metodología SOMEN-DC en el contexto de la segunda vuelta presidencial de Bolivia (programada para el 19 de octubre de 2025). Esta contienda polarizada entre Rodrigo Paz Pereira (PDC) y Jorge “Tuto” Quiroga (Alianza Libre) representó un escenario ideal de prueba. El resultado real proyectado para el estudio determinó a Paz como ganador con el 54.53 % frente al 45.47 % de Quiroga.

Se definió una ventana temporal retrospectiva de 180 días (del 18 de mayo al 18 de octubre de 2025), extrayendo datos diariamente de las cuentas oficiales de ambos candidatos en Facebook, Twitter/X, Instagram y TikTok. Esto generó un vector de 29 características

(*features*) por candidato y por día, incluyendo métricas absolutas (volumen de publicaciones, *likes*, comentarios, compartidos) y métricas relativas (como el *engagement* promedio por publicación), normalizadas posteriormente mediante puntajes Z (*z-scores*).

La variable objetivo se construyó interpolando linealmente los resultados de las principales encuestas publicadas durante ese período (firmas como Ipsos Ciesmori, SPIE, Captura Consulting y Ciemcorp), anclando el último punto de la serie al resultado electoral real. El *dataset* final consolidó 308 registros diarios independientes.

5.2.b. Evaluación de modelos

Siguiendo la arquitectura original, se entrenaron y evaluaron múltiples topologías algorítmicas, incluyendo Regresión Lineal Clásica, Perceptrón Multicapa con *Backpropagation* (MLP-BP) y Redes Neuronales de Regresión Generalizada (GRNN), explorando también variantes con Análisis de Componentes Principales (PCA).

El modelo con mejor desempeño predictivo resultó ser el ensamble MLP-BP + PCA, alcanzando un Error Absoluto Medio (MAE) de 0.0279 y un Error Porcentual Absoluto Medio (MAPE) aproximado del 5.1 %. Este resultado superó considerablemente el *baseline* trivial basado en tomar simplemente el valor de la última encuesta disponible antes de la elección (cuyo MAE en el caso del candidato Paz fue del 0.1803). Cabe destacar que los modelos estrictamente lineales fracasaron sistemáticamente en el ajuste (presentando MAEs entre 0.29 y 0.31), confirmando empíricamente que la relación entre el volumen de interacciones digitales y la tracción en las encuestas exhibe dinámicas fuertemente no lineales.

Los resultados de esta primera etapa confirmaron de manera concluyente los problemas teóricos del SOMEN-DC señalados en la hipótesis: la dependencia estructural de las encuestas para el entrenamiento, el altísimo costo logístico de mantener infraestructura de *scraping* continuo y, más grave aún, la imposibilidad de extrapolar los pesos de la red neuronal a una nueva elección (no generalizabilidad).

5.3. Etapa 2 — Costa Rica: Modelado del crecimiento de interacciones

5.3.a. El problema estructural

Para construir un modelo generalizable a partir de M elecciones pasadas se requiere observar los datos. Sin embargo, las plataformas digitales únicamente muestran el total acumulado de interacciones observables en la fecha actual de la consulta (por ejemplo, si se raspan datos en 2026 sobre una elección de 2023). Este fenómeno imposibilita conocer cuántas de esas interacciones se habían acumulado legítimamente el día de la elección y cuántas correspondieron a tráfico residual o póstumo tras conocerse los resultados electorales. Para resolver esto, es forzoso estimar una curva teórica de crecimiento de interacciones.

5.3.b. Metodología y Modelo Weibull

Se condujo un proceso de recolección intensiva diaria (*panel data*) sobre 2,026 publicaciones únicas correspondientes a los candidatos presidenciales de la campaña de Costa

Rica 2026. Al depurar los registros, se aislaron 1,922 publicaciones aptas para el modelado temporal continuo, generando más de 19,439 observaciones cruzadas.

El modelado del crecimiento orgánico de interacciones se parametrizó bajo una curva de distribución Weibull con *offset* temporal, expresada formalmente en la Ecuación 3.2 (Sección 3.4). Mediante rutinas de optimización no lineal, se calibraron los parámetros óptimos para cada plataforma, como se resume a continuación:

Cuadro 5.1: Parámetros Weibull calibrados por plataforma

Plataforma	Escala (k)	Forma (α)	Offset (t_0) [días]	R^2 Panel
Facebook	0.9480	0.8230	1.93	0.3514
Instagram	1.1369	0.5210	0.04	0.4026
TikTok	1.3272	0.5124	0.79	0.3509
Twitter/X	1.4453	1.1422	0.26	0.6905

Aunque los valores de bondad de ajuste (R^2) del panel parecen matemáticamente discretos, estudios de descomposición de varianza evidenciaron que cerca del 66.8 % del error cuadrático proviene del ruido intrínseco de cada publicación (varianza intra-publicación). Por lo tanto, la verdadera métrica de éxito evaluada fue la precisión proyectiva al último día.

Las validaciones cruzadas determinaron que, si se observaba la publicación al día 3 desde su emisión, entre el 89 % y el 99 % de las inferencias sobre su total asintótico final caían dentro de un margen de error estricto (MAPE < 20 %). Adicionalmente, pruebas T demostraron que, si bien el crecimiento es estadísticamente significativo ($p < 0.0001$) hasta el día 10, desde una óptica empírica el incremento se vuelve marginal a partir del día 5 al 7 (< 2 % diario), justificando sólidamente que una ventana de análisis retrospectivo de 14 días previos a la jornada de votación es matemáticamente suficiente y robusta. Si bien se evaluó la hipótesis cualitativa del “arrastre post-victoria” (por ejemplo, el aceleramiento en las métricas de la ganadora proyectada), este efecto no demostró significancia estadística sobre la muestra analizada, permitiendo que el modelo asuma patrones estacionarios indiferentes al resultado.

5.4. Etapa 3 — Colombia: Construcción del dataset y modelado

Con la solución temporal formalizada, la tercera etapa se concentró en la construcción del *dataset* de entrenamiento masivo. Se estableció un protocolo riguroso de diseño para capturar información exclusiva de las campañas de las elecciones locales de alcaldías en Colombia de octubre de 2023. Se definió un universo geográfico abarcando las 33 ciudades más pobladas de Colombia, procediendo a compilar interacciones generadas estrictamente en la ventana de 14 días previos a los comicios.

Por políticas y restricciones agresivas de la API *Graph* impuestas corporativamente por Meta en sus versiones recientes, Instagram tuvo que ser excluido de la extracción sistematizada. Por tanto, la adquisición de datos de fuentes abiertas iteró sobre tres infraestructuras concurrentes automatizadas a través de un *pipeline* (*scripts* ‘scrapping_general.py’ y ‘unificar_redes.py’): Playwright para automatización de navegadores ocultos (*headless*) contra la interfaz web de Twitter/X (con restricción de hasta 50 *tweets* por actor); y consultas

de alto rendimiento hacia la API privada no documentada de TikTok y las colecciones indexadas de Facebook a través de *Apify*.

Para asegurar la validez inferencial, se aplicaron filtros de exclusión: solo ingresaron al *dataset* actores políticos con más de 10,000 votos confirmados en los escrutinios finales. Se excluyeron deliberadamente dos ciudades, la capital Bogotá (debido al sesgo de representatividad por el perfil de *influencer* de Gustavo Bolívar, cuya masiva tracción general superaba demográficamente la esfera meramente local) y Piedecuesta (debido a que la candidatura ganadora enfrentó problemas legales que resultaron en la desaparición intencional de sus perfiles y rastros de campaña). En casos anómalos como el de Santa Marta, donde la candidatura de mayor votación enfrentó revocatoria legal posterior, el estudio consideró ganador computacional al actor con mayor volumen bruto de votos consignados, para preservar la correlación con la intención ciudadana.

Tras los filtros geográficos y de calidad de datos documentados en el análisis exploratorio preliminar (*'analisi_exploratorio.ipynb'*), el universo hábil final consolidó 5,776 publicaciones únicas distribuidas a través de las tres infraestructuras monitoreadas (2,511 en Facebook, 2,346 en Twitter/X y 919 en TikTok). Estas entradas correspondieron a un censo final de 328 candidatos repartidos a través de 31 ciudades competitivas. Sobre los 112 candidatos que superaban la barrera estadística de los 10,000 votos (cuya cobertura digital era altísima, con 92.6 % de ellos poseyendo publicaciones de red activas en el archivo), los análisis paramétricos confirmaron tempranamente la existencia de señal predictiva: las interacciones totales medias evidenciaban que los ganadores promediaban 44,252 frente a 28,011 de los perdedores, y las pruebas U de Mann-Whitney validaban una superioridad de *engagement* medio por publicación estadísticamente significativa para un 95 % de confianza ($p = 0.0481$). De manera asilada, un pronosticador empírico básico (*baseline*) asumiendo que el ganador fuera siempre aquel con mayor volumen nominal habría acertado en el 57.58 % de las jurisdicciones municipales.

La integración operativa del modelo de crecimiento de la Etapa 2 se ejecutó a través de la rutina *'Reconstruccion_Panel_Historico.ipynb'*. Aplicando los parámetros k, α estáticos y derivando el t_0 dinámico en función del lapso transcurrido desde la creación particular de cada post, la red reconstruyó la matriz histórica produciendo un *super-dataset* validado de 5,776 instancias por 340 campos numéricos (representando las permutaciones correspondientes a 11 subclases de métricas y sus rezagos o sumatorias acumuladas en plazos iterativos de 30 días escalables). Las calibraciones documentales confirmaron que la monotonidad de las curvas sintéticas era impecable (cumplimiento en 5,776 de 5,776 ensayos) y el factor de error mediano inyectado sobre las estimaciones finales se situaba matemáticamente en un 0.000 % absoluto para proyecciones convergentes en el día 14.

5.5. Modelado predictivo

La etapa terminal concentró los análisis econométricos y heurísticos bajo dos grandes paradigmas clásicos de la Inteligencia Artificial.

5.5.a. Modelo de regresión

El enfoque predictivo continuo (*'Modelo_Predictivo_Electoral.ipynb'*) pretendía encontrar un mapeo directo para estimar la magnitud escalar porcentual de votos. Con un

tensor de entrenamiento reducido dimensionalmente (112 individuos por 84 variables explicativas macro), las optimizaciones se condujeron aplicando el protocolo analítico de validación cruzada dejando uno fuera (*Leave-One-Out Cross-Validation*, LOO-CV) para mitigar correlaciones espaciales endógenas. Las arquitecturas de Vectores de Soporte Regresivo (SVR) provistas de *kernel* radial (RBF) lograron los mejores comportamientos topográficos, pero exhibieron resultados mediocres de inferencia (Error Absoluto Medio de 15.22 puntos porcentuales de desviación por estimación y una varianza explicada o R^2 irrisoria del 0.054). La saturación matemática diagnosticó enfáticamente un sobreajuste estructural de la red; la abundancia masiva de variables intervinientes no era asimilable para el pequeño volumen de observaciones empíricas. Se desestimó este enfoque, por ahora, como una ruta viable a corto plazo.

5.5.b. Modelo de clasificación binaria

Tras constatar la asimetría matricial, el análisis se reconceptualizó sobre el paradigma probabilístico discreto ('Clasificacion_Binaria_Electoral.ipynb'), simplificando la tarea del algoritmo a una función discriminatoria simple: adivinar el ganador o vencedor absoluto por distrito (*¿quién gana?*). El hiperplano se centró en priorizar masivamente el constructo analítico de la **dominancia relativa** como entrada primordial. Con un balance de clases nativo de 24.1 % (casos positivos, victoriosos) versus 75.9 % (casos negativos), los clasificadores de Regresión Logística Penalizada (LOO-CV) dominaron ampliamente, registrando niveles de *Accuracy* ponderado de 0.812 y coeficientes AUC-ROC de 0.770, traduciéndose en pronósticos asertivos para el 59.3 % de las municipalidades (16 aciertos en 27 contiendas).

Aunque estas mediciones confirman irreprochablemente que el capital político latente sí se manifiesta y decodifica a través de las interacciones sociales (la señal existe y el ruido no la silencia estadísticamente), un heurístico ingenuo (*baseline*) estipulado al comienzo de la experimentación —pronosticar ciegamente a favor del postulante con el mayor indicador bruto acumulado de *dominancia_engagement* en el ecosistema municipal— ostentaba un nivel de predicción efectiva del 70.4 % (19 aciertos de 27). Por ende, el algoritmo no pudo rebasar este techo estadístico debido a la falta de masa crítica de entrenamiento y volumen electoral comparado en los rangos analíticos; con mayores tamaños y adiciones de contiendas iteradas, la profundidad topológica se revelaría.

6 Resultados

6.1. Resultados de Bolivia (Etapa 1)

La replicación de las técnicas de pronóstico dependientes de encuestas en el contexto de la segunda vuelta boliviana de 2025 arrojó resultados mixtos que confirmaron las sospechas teóricas iniciales sobre la viabilidad de la metodología convencional.

En términos de precisión bruta, la experimentación demostró que la relación entre la acumulación de interacciones y la proyección demoscópica no obedece a dinámicas lineales. Los modelos lineales clásicos fallaron de manera sistemática, pero el ensamble óptimo de Perceptrón Multicapa con Análisis de Componentes Principales (MLP-BP + PCA) logró un Error Absoluto Medio (MAE) de 0.0279 y un MAPE de 5.1 %. Este resultado mejoró abrumadoramente el estimador básico (*baseline*) de predecir basándose únicamente en el valor inercial de la última encuesta publicada (cuyo MAE se disparaba al 0.1803 para el candidato ganador, Paz).

Sin embargo, a nivel operativo y analítico, se evidenciaron falencias críticas que desaconsejaron continuar por esta ruta de *nowcasting*. Primero, se ratificó la absoluta falta de generalización: la topología y los pesos optimizados de la red neuronal carecían de validez semántica fuera de esa elección particular, confinando el esfuerzo computacional a un único evento irrepetible. Segundo, el modelo mostró una preocupante ceguera ante giros súbitos del electorado; los cambios de favorabilidad que ocurrieron en la última semana crítica de campaña no fueron reflejados por las métricas de interacciones acumuladas. Por último, un análisis detallado de importancia de variables identificó que la dinámica de viralidad de TikTok operaba en un plano disociado del resto de plataformas, inyectando varianza espuria en momentos en que la intención de voto real permanecía estacionaria.

6.2. Resultados de Costa Rica (Etapa 2)

El modelado paramétrico de la variable tiempo resolvió satisfactoriamente el obstáculo estructural para la explotación de registros históricos sin depender de infraestructura activa de extracción. A través de la calibración supervisada de 1,922 publicaciones presidenciales del panel costarricense, el sistema logró aislar parámetros k , α universales para cuatro plataformas hegemónicas (Facebook, Instagram, TikTok, Twitter/X).

Las pruebas de precisión y decaimiento del error proyectivo resultaron formidables. Al observar cualquier publicación con apenas tres días ($t = 3$) de vida útil, el modelo matemático de distribución Weibull logró predecir el límite asintótico total final de esa publicación con un error inferior al 20 % para entre el 89 % y el 99 % de los casos de la muestra empírica.

A nivel estadístico descriptivo, aunque las curvas de crecimiento mantenían una gradiente matemáticamente significativa (con $p < 0.0001$) hasta por lo menos 10 días tras el evento de publicación, el estudio demostró que desde una perspectiva pragmática o de negocio, la curva se vuelve plana (crecimiento diario menor al 2 %) a partir de una ventana de 5 a 7 días. Esta dinámica de saturación viral rápida validó metodológicamente la decisión de encapsular los *datasets* de extracción a una ventana móvil o estática de 14 días (holgura de seguridad del doble del tiempo de saturación).

Consecuentemente, se consolidó la herramienta computacional de **reconstrucción histórica temporal**, la cual evidenció una calidad algorítmica intachable: no se documentaron violaciones de monotonidad (una publicación nunca perdía interacciones reconstruidas al retroceder en el tiempo), y el error mediano inyectado a la serie temporal original en el día 14 pre-elección fue matemáticamente cero.

6.3. Resultados de Colombia (Etapa 3)

La evaluación del ecosistema digital de las elecciones de alcaldes 2023 sobre las 31 ciudades competitivas colombianas confirmó irrevocablemente la hipótesis fundacional del estudio empírico: las interacciones en redes sociales sí albergan una señal predictiva real y cuantificable sobre el comportamiento en urnas.

Las pruebas no paramétricas de distribución confirmaron que, en promedio, los candidatos ganadores movilizaron más interacciones globales y poseían un *engagement* marginal por post significativamente más alto ($p < 0.05$) que el resto de contendientes derrotados de sus respectivos tarjetones. Más profundamente, la experimentación estableció un paradigma de extracción de características: la **dominancia relativa** de la conversación digital en el territorio superó con creces al volumen nominal de interacciones como predictor de éxito, logrando índices de correlación monótona de Spearman superiores a 0.46.

Frente a la escalabilidad de modelado en escasez de datos (112 muestras), los resultados fueron contrastantes. El abordaje de **regresión lineal / no-lineal** para adivinar márgenes porcentuales exactos de voto fracasó categóricamente (el máximo techo explicativo o pseudo- R^2 alcanzado fue apenas del 0.118), indicando que el espacio dimensional es excesivamente grande y ruidoso frente a la disponibilidad de observaciones.

Por el contrario, la **clasificación probabilística discreta** (resolver quién es el ganador binario del certamen en cada ciudad) exhibió una convergencia parcial y funcional. Los modelos de ensamble superaron métricas conservadoras con tasas de aciertos ponderadas del 59.3 % en adivinar correctamente el mapa político regional de ganadores por capitales. No obstante, las arquitecturas entrenadas no lograron desbancar al heurístico analítico puro (*baseline*): simplemente asignar como ganador determinista al candidato que en solitario concentró la mayor dominancia de *engagement* en su respectiva ciudad reportó una tasa de acierto del 70.4 %. La señal existe intrínsecamente en el vector espacial, pero la reducida cardinalidad de la matriz actual imposibilita que una red compleja de aprendizaje automatizado abstraiga patrones topológicos multidimensionales que le permitan abatir una simple regla algorítmica descriptiva.

6.4. Síntesis: contribuciones al estado del arte

Los hallazgos empíricos y los desarrollos técnicos documentados a lo largo de este estudio confluyen en cuatro contribuciones sustanciales al dominio de la analítica política y los modelos predictivos heterodoxos:

1. **Elección-Agnosticismo Empírico:** Se establece una ruta metodológica viable (demostrada a través de la clasificación binaria basada en la métrica transversal de dominancia relativa) para romper la asimetría temporal del SOMEN-DC, permitiendo entrenar algoritmos con observaciones de múltiples contiendas de alcaldías paralelas simultáneamente y abstraer reglas de decisión exportables.
2. **Total Independencia Demoscópica:** A diferencia de la inmensa mayoría de la literatura contemporánea en estimación digital electoral, este esquema sustituye la obligatoriedad de usar encuestas como variable dependiente, anclando directamente su optimización sobre la variable *ground truth* universal: el escrutinio final.
3. **Restaurador Temporal de Series (Modelo Weibull):** Se introduce y formaliza una arquitectura matemática de interpolación capaz de retrotraer variables acumulativas

hacia instantes en el pasado. Esto soluciona drásticamente el que quizás sea el mayor obstáculo técnico para la investigación retrospectiva de dinámicas digitales, facultando a los analistas a poblar *datasets* de series temporales históricas partiendo exclusivamente de un raspado actual estático, sin requerir despliegues preventivos costosos.

4. **Democratización del Pipeline:** Se desmitifica la barrera logística del analfabetismo algorítmico, comprobando la total escalabilidad y operatividad de la solución utilizando, de principio a fin, una orquestación ligera ensamblada con herramientas de mercado genéricas (*Make*, *Apify*, API oficiales, librerías *Headless*), demostrando que la predicción y monitoreo algorítmico no es una tecnología que deba residir exclusivamente bajo el control de infraestructuras corporativas, gubernamentales o institucionales avanzadas.

7

Impacto esperado

7.1. Impacto académico

Esta investigación aspira a realizar una aportación fundacional a la literatura de ciencia de datos políticos y estudios electorales cuantitativos en América Latina. A nivel epistemológico, este trabajo documenta la primera metodología estructurada de *nowcasting* electoral elección-agnóstica e independiente de encuestas conceptualizada e implementada para el entorno político altamente fragmentado de Colombia.

Metodológicamente, la formalización matemática del **modelo de crecimiento Weibull** constituye un artefacto científico de exportación. Al proporcionar un marco matemático capaz de reconstruir la evolución temporal de la tracción digital sin depender de registros en tiempo real, el estudio libera a futuras investigaciones académicas de la obligación logística de desplegar sensores de recopilación con meses de antelación al evento electoral de interés.

Adicionalmente, se efectúa una contribución transversal al debate global sobre la viabilidad de la predicción electoral mediante redes sociales, delineando claramente las fronteras de escala empírica: delimitando la inviabilidad estructural de las arquitecturas de regresión volumétrica en escenarios de escasez dimensional (muestras menores a 200 casos), al tiempo que valida matemáticamente la *dominancia relativa* como el estimador heurístico más robusto en elecciones subnacionales.

7.2. Impacto práctico

En una dimensión operativa, el principal aporte aplicativo es la materialización de un sistema orquestado de pronóstico y monitoreo de extremado bajo costo. Al demostrarse la reproducibilidad absoluta del ecosistema metodológico empleando herramientas comerciales de extracción *off-the-shelf* (como *Apify* o integradores *no-code* como *Make.com*)

y prescindiendo por completo de servidores y arquitecturas universitarias dedicadas, la investigación democratiza el análisis de datos políticos complejos.

Este avance abre la puerta para que medios de comunicación regionales, laboratorios de veeduría ciudadana y pequeñas firmas de consultoría estratégica desplieguen capacidades de inteligencia electoral en tiempo real. En el mediano plazo, estas técnicas se proyectan como la alternativa natural y costo-eficiente frente a los oligopolios demoscópicos, especialmente en otras naciones de Latinoamérica donde la carencia de encuestas sistemáticas o la desconfianza pública en sus resultados exigen métodos de estimación paralelos transparentes y auditables.

7.3. Limitaciones y trabajo futuro

La honestidad intelectual obliga a delimitar las fallas orgánicas y los confines de aplicabilidad del estudio. En primer lugar, la calibración de la matriz temporal Weibull, si bien fue exhaustiva a nivel micro de publicaciones, descansó sobre el comportamiento macro de una única elección (Costa Rica 2026). Asumir universalidad conductual exige una validación prospectiva replicando la medición longitudinal sobre certámenes demográficamente disímiles para confirmar la estabilidad inter-elecciones de los parámetros de forma y escala.

En segundo lugar, por determinaciones corporativas restrictivas de la compañía Meta, Instagram quedó excluido del *dataset* colombiano; esta omisión representa una pérdida incalculable de la fotografía generacional y el consumo audiovisual de una gran franja del electorado joven. Asimismo, tanto el modelo de dominancia heurística como los ensambles algorítmicos probaron ser estructuralmente vulnerables a perfiles políticos con audiencias atípicas (como lo demostró la exclusión forzosa del candidato *influencer* Gustavo Bolívar), revelando que las masas críticas interdepartamentales contaminan la medición estrictamente local. Todo esto sin ignorar que el conteo volumétrico peca de ceguera ante la calidad y veracidad de la interacción: las arquitecturas modeladas no están equipadas actualmente para ponderar el efecto adverso o positivo de interacciones manufacturadas artificialmente (granjas de *bots*, perfiles inorgánicos o *astroturfing*).

Por lo tanto, la agenda de ****trabajo futuro**** a desprender de esta investigación es rica y expansiva. Se priorizará escalar el conjunto de datos integrando eventos asimétricos (elecciones legislativas departamentales) y otras geografías de la región andina; investigar el desempeño matricial de agregar ventanas temporales de memoria (*lagged variables*); desarrollar clasificadores semánticos que depuren la señal descartando la actividad inorgánica artificial; e incorporar en el plano explicativo covariables estructuradas *offline* (indicadores económicos territoriales y clima de opinión en la prensa tradicional). Inmediatamente, la prioridad empírica definitiva será la confrontación longitudinal ciega del clasificador binario entrenado contra los resultados de las próximas elecciones territoriales en Colombia del año 2027.

8

Conclusiones

8.1. Respuesta a la pregunta de investigación

Este documento se originó a partir de una inquietud central: evaluar si era metodológicamente posible diseñar un modelo de *nowcasting* electoral elección-agnóstico y emancipado de las encuestas para el complejo entorno local colombiano. A la luz de los hallazgos empíricos, la respuesta global es afirmativa con matices estructurales: el modelo es conceptual y operativamente posible, pero su techo predictivo actual está condicionado por el volumen histórico de entrenamiento.

En primer lugar, se demostró irrefutablemente que las interacciones ciudadanas en plataformas sociales **tienen un poder predictivo real** sobre el comportamiento del electorado colombiano. Las pruebas no paramétricas arrojaron diferencias significativas ($p < 0.05$) entre ganadores y perdedores, y la correlación de rango cruzó un umbral robusto de Spearman $\rho > 0.46$. No obstante, la experimentación también comprobó que, frente a un problema de alta varianza como una elección fragmentada, la señal extraída aislada de la red sin covariables de apoyo es ruidosa e insuficiente para dictar sentencias determinísticas absolutas a nivel nacional.

En segundo término, la viabilidad del modelo descansaba sobre la premisa de la **reconstrucción temporal**. Las pruebas sobre el panel de control validaron que la interpolación matemática mediante distribuciones de Weibull es excepcionalmente precisa (inyectando errores menores al 20 % en más del 89 % del material muestral observado tempranamente). En consecuencia, un marco analítico elección-agnóstico se ha consolidado como un enfoque empírico viable y robusto: el modelo puede abstraer y aplicar reglas universales. Sin embargo, para que las arquitecturas topológicas (como redes neuronales o ensambles complejos) logren trascender el desempeño del algoritmo *baseline* trivial basado en dominancia relativa, se torna imperativo inyectar iteraciones masivas de eventos históricos en la matriz de aprendizaje.

8.2. Lecciones aprendidas

A lo largo del desarrollo computacional y la revisión estadística del proyecto, se decantaron lecciones críticas para la práctica del *nowcasting* digital en el sur global:

- **La supremacía de la dominancia relativa:** Quedó evidenciado que el ecosistema de campaña funciona como un juego de suma cero territorial. La posición de un candidato relativa a la conversación local de su ciudad (*share of voice*) es una métrica inmensamente superior al volumen absoluto de interacciones, pues este último es susceptible de distorsiones poblacionales y mediáticas inherentes a las dinámicas atípicas de los perfiles públicos masivos.

- **El paradigma de clasificación:** Frente a matrices limitadas por la escasez de datos subnacionales etiquetados, plantear la predicción como un problema de clasificación probabilística discreta (*¿quién se lleva la elección?*) probó ser cualitativamente más realista y convergente que pretender establecer márgenes porcentuales directos (*¿cuánto saca?*) a través de regímenes de regresión.
- **El abismo de la última semana:** El obstáculo empírico más resistente para las métricas agregativas continúa siendo el giro coyuntural tardío. La explosión de interacciones preexistentes oculta frecuentemente las volatilidades sutiles de la opinión pública suscitadas por eventos, escándalos o alianzas que acontecen en los tres días anteriores al evento de urnas.
- **Autonomía computacional:** La comprobación de un ciclo de vida completo de análisis —desde la orquestación y el *scraping* (*Make.com*, *Playwright*, API de X, *Apify*) hasta la proyección asintótica y el modelado matricial— probó que este *pipeline* analítico complejo es enteramente ejecutable desde laboratorios comerciales e independientes que operen con un coste logístico nominal o nulo.

8.3. Próximos pasos

La natural prolongación de este cuerpo de investigación consiste en llevar la experimentación a la fase de masificación de datos, integrando *datasets* de contiendas asimétricas de más naciones de América Latina y diferentes marcos temporales, apuntalando así el tamaño de las muestras para destrabar el uso de aprendizaje profundo. Inminentemente, se hace obligatoria la recalibración inter-regional del modelo Weibull, así como el rediseño dimensional para inyectar vectores categóricos de sentimiento. La culminación de este esfuerzo empírico se cristalizará durante la apertura de las urnas de las próximas elecciones territoriales en Colombia de 2027, las cuales fungirán como el juez definitivo ciego (*out-of-time sample*) sobre el cual se medirá, bajo estricto rigor metodológico ex-ante, la madurez proyectiva de la inteligencia desarrollada.

Bibliografía

- Brito, K., & Adeodato, P. J. L. (2022). Measuring the performances of politicians on social media and the correlation with major Latin American election results. *Government Information Quarterly*, 39(4), 101745. <https://doi.org/10.1016/j.giq.2022.101745>
- Brito, K., & Adeodato, P. J. L. (2023). Machine learning for predicting elections in Latin America. *Government Information Quarterly*, 40(2), 101782. <https://doi.org/10.1016/j.giq.2022.101782>
- Brito, K., Silva Filho, T., & Adeodato, P. J. L. (2024). Stop trying to predict elections only with Twitter: There are other data. *Government Information Quarterly*, 41(1), 101899. <https://doi.org/10.1016/j.giq.2023.101899>
- Lewis-Beck, M. S., Nadeau, R., & Bélanger, É. (2011). Nowcasting v. polling: The 2010 UK election trials. *Electoral Studies*, 30(2), 284-287. <https://doi.org/10.1016/j.electstud.2010.09.013>
- Lewis-Beck, M. S., & Tien, C. (2014). Proxy models and nowcasting: U.S. presidential elections in the future. *Presidential Studies Quarterly*, 44(3), 506-521.
- Skoric, M. M., Liu, J., & Jaidka, K. (2020). Electoral and Public Opinion Forecasts with Social Media Data: A Meta-Analysis. *Information*, 11(4), 187. <https://doi.org/10.3390/info11040187>
- Tumasjan, A., Sprenger, T. O., Sandner, P. G., & Welpe, I. M. (2010). Predicting elections with Twitter: What 140 characters reveal about political sentiment. *Proceedings of the Fourth International AAAI Conference on Weblogs and Social Media*, 178-185.