

MAESTRÍA EN ANALÍTICA APLICADA  
FACULTAD DE INGENIERÍA

# **Diseño e implementación del modelo ELA-NOM, un *nowcasting* elección-agnóstico para la intención de voto aplicado a elecciones locales en Colombia 2023**

**Juan Sotelo Aguilar**

DIRECTOR  
**PhD. Miguel Uribe Laverde**  
Universidad de La Sabana

AÑO ACADÉMICO 2026

*A María José, mi familia y quienes creyeron en esto antes de que yo mismo creyera.*

# Índice general

|                                                                                     |             |
|-------------------------------------------------------------------------------------|-------------|
| <b>Resumen</b>                                                                      | <b>v</b>    |
| <b>Abstract</b>                                                                     | <b>v</b>    |
| <b>Índice de figuras</b>                                                            | <b>vii</b>  |
| <b>Índice de cuadros</b>                                                            | <b>viii</b> |
| <b>1 Introducción</b>                                                               | <b>1</b>    |
| 1.1 Motivación del problema . . . . .                                               | 1           |
| 1.2 Estado del arte: de los modelos paramétricos al SOMEN-DC . . . . .              | 2           |
| 1.3 Hipótesis de trabajo . . . . .                                                  | 4           |
| 1.4 Estructura del documento . . . . .                                              | 6           |
| <b>2 Pregunta de investigación</b>                                                  | <b>6</b>    |
| 2.1 Pregunta principal . . . . .                                                    | 6           |
| 2.2 Preguntas derivadas . . . . .                                                   | 7           |
| <b>3 Marco conceptual</b>                                                           | <b>7</b>    |
| 3.1 <i>Nowcasting</i> electoral y predicción con redes sociales . . . . .           | 7           |
| 3.1.a Definición de <i>nowcasting</i> en contexto electoral . . . . .               | 7           |
| 3.2 Modelos elección-agnósticos: definición y ventajas . . . . .                    | 8           |
| 3.3 Interacciones digitales como <i>proxy</i> de intención de voto . . . . .        | 8           |
| 3.3.a La hipótesis Tumasjan . . . . .                                               | 8           |
| 3.3.b Interacciones absolutas vs. dominancia relativa . . . . .                     | 9           |
| 3.4 El problema del histórico de interacciones . . . . .                            | 9           |
| <b>4 Objetivos</b>                                                                  | <b>10</b>   |
| 4.1 Objetivo general . . . . .                                                      | 10          |
| 4.2 Objetivos específicos . . . . .                                                 | 10          |
| <b>5 Metodología</b>                                                                | <b>11</b>   |
| 5.1 Definición formal del problema . . . . .                                        | 11          |
| 5.1.a Definición de la elección . . . . .                                           | 11          |
| 5.1.b Definición de la intención de voto y los resultados . . . . .                 | 11          |
| 5.1.c Definición formal de las publicaciones y su comportamiento temporal . . . . . | 12          |
| 5.1.d Definición del problema . . . . .                                             | 13          |
| 5.2 Diseño general del proceso . . . . .                                            | 14          |
| 5.3 Etapa 1 - Bolivia: Replicación del SOMEN-DC y prueba de concepto . . . . .      | 14          |
| 5.3.a Caso de estudio y recolección de datos . . . . .                              | 14          |

|          |                                                                             |           |
|----------|-----------------------------------------------------------------------------|-----------|
| 5.3.b    | Preparación de datos y variable objetivo . . . . .                          | 15        |
| 5.3.c    | Evaluación de modelos . . . . .                                             | 15        |
| 5.4      | Etapla 2 - Costa Rica: Modelado del crecimiento de interacciones . . . . .  | 16        |
| 5.4.a    | El problema estructural . . . . .                                           | 16        |
| 5.4.b    | Recolección y validación del panel . . . . .                                | 16        |
| 5.4.c    | Análisis de la persistencia de interacciones . . . . .                      | 17        |
| 5.4.d    | Selección y calibración del modelo Weibull . . . . .                        | 18        |
| 5.4.e    | Validación: precisión en la estimación del total final . . . . .            | 20        |
| 5.4.f    | Función de reconstrucción histórica . . . . .                               | 21        |
| 5.5      | Etapla 3 - Colombia: Construcción del dataset y modelado . . . . .          | 21        |
| 5.6      | Modelado predictivo . . . . .                                               | 23        |
| 5.6.a    | Modelo de regresión fraccional (cuota de voto) . . . . .                    | 23        |
| 5.6.b    | Selección de especificación y regularización (ElasticNet) . . . . .         | 24        |
| 5.6.c    | Aplicación prospectiva: Segunda Vuelta Presidencial Colombia 2026 . . . . . | 25        |
| <b>6</b> | <b>Resultados</b>                                                           | <b>26</b> |
| 6.1      | Resultados de Bolivia (Etapla 1) . . . . .                                  | 26        |
| 6.2      | Resultados de Costa Rica (Etapla 2) . . . . .                               | 28        |
| 6.3      | Resultados de Colombia (Etapla 3) . . . . .                                 | 29        |
| 6.3.a    | Señal digital y correlación con el voto . . . . .                           | 29        |
| 6.3.b    | Modelo de regresión fraccional . . . . .                                    | 31        |
| 6.3.c    | Especificación ganadora ElasticNet . . . . .                                | 31        |
| 6.3.d    | Aplicación a la Segunda Vuelta Presidencial 2026 . . . . .                  | 33        |
| 6.3.e    | Análisis complementario: tamaño de muestra y tracción tardía . . . . .      | 34        |
| 6.4      | Síntesis: contribuciones al estado del arte . . . . .                       | 36        |
| <b>7</b> | <b>Impacto esperado</b>                                                     | <b>36</b> |
| 7.1      | Impacto académico . . . . .                                                 | 36        |
| 7.2      | Impacto práctico . . . . .                                                  | 37        |
| 7.3      | Limitaciones y trabajo futuro . . . . .                                     | 38        |
| <b>8</b> | <b>Conclusiones</b>                                                         | <b>38</b> |
| 8.1      | Respuesta a la pregunta de investigación . . . . .                          | 38        |
| 8.2      | Lecciones aprendidas . . . . .                                              | 39        |
| 8.3      | Próximos pasos . . . . .                                                    | 40        |
|          | <b>Bibliografía</b>                                                         | <b>41</b> |

## Resumen

En América Latina, las encuestas electorales son prácticamente la única herramienta disponible para estimar la intención de voto durante una campaña activa. Este trabajo diseña, implementa y valida **ELA-NOM** (*Election-Agnostic Nowcasting Model*), una metodología alternativa de *nowcasting* electoral que prescinde de encuestas, opera de forma agnóstica a la elección y es replicable con herramientas comerciales de bajo costo.

La investigación avanzó en tres etapas empíricas. La **Etapa 1** replicó el modelo SOMENDC en la segunda vuelta presidencial de Bolivia (octubre de 2025), confirmando sus limitaciones estructurales: dependencia de encuestas para el entrenamiento y no generalizabilidad a nuevas elecciones. La **Etapa 2** calibró un modelo de crecimiento Weibull sobre el panel longitudinal de Costa Rica (2026), resolviendo el problema de la asimetría temporal entre la fecha de extracción de datos y la fecha histórica de interés; el modelo estima el total final de interacciones de una publicación con un error menor al 6 % a partir del tercer día de observación en Facebook y Twitter/X. La **Etapa 3** construyó el *dataset* de entrenamiento a partir de las elecciones locales de Colombia (2023), abarcando 120 candidatos en 31 ciudades, y entrenó el modelo final mediante regresión logística fraccional con selección anidada ElasticNet. El modelo completo sobre el *pool* de nueve variables alcanza un MAE de **9,57 puntos porcentuales** y un  $R^2$  fuera de muestra de 0,518; la especificación de dos predictores aplicada prospectivamente logra un MAE de 9,56 pp, mejorando en 3,05 pp frente al *baseline* de proporcionalidad.

La validación prospectiva definitiva se realizó en la segunda vuelta presidencial de Colombia del 21 de junio de 2026, sin reentrenamiento alguno. El modelo pronosticó 60,5 % para Cepeda Castro y 39,5 % para De la Espriella; el resultado real de la Registraduría Nacional fue Abelardo De la Espriella con 50,48 % e Iván Cepeda con 49,52 %, una diferencia de apenas 0,96 pp. El error absoluto de 10,98 pp para el candidato favorito supera en **1,42 pp** el MAE medio del modelo (9,56 pp): el resultado de la elección quedó por fuera del límite de resolución empírico del modelo, lo que confirma que las contiendas de empate técnico, con márgenes inferiores a 1 pp, exceden la precisión de cualquier sistema basado en *engagement* agregado. Lejos de invalidar la metodología, este hallazgo delimita con precisión su espacio de aplicación: ELA-NOM es informativo en contiendas con ventajas digitales amplias; no en empates técnicos.

**Palabras clave:** *nowcasting* electoral, redes sociales, aprendizaje automático, Colombia, elecciones locales, modelo elección-agnóstico, modelo Weibull, regresión logística fraccional, ElasticNet.

## Abstract

In Latin America, electoral polls are virtually the only tool available for tracking voting intention during an active campaign. This work designs, implements, and validates **ELA-NOM** (*Election-Agnostic Nowcasting Model*), an alternative electoral nowcasting methodology that operates independently of polls, is election-agnostic, and can be replicated using low-cost commercial tools.

The research proceeded through three empirical stages. **Stage 1** replicated the SOMENDC model on the Bolivian presidential run-off (October 2025), confirming its structural

limitations: dependence on polls for training and lack of generalizability to new elections. **Stage 2** calibrated a Weibull growth model on a longitudinal panel collected during the Costa Rican election (2026), solving the temporal asymmetry between data extraction and historical reconstruction; the model estimates the final interaction total of a post with a median error below 6 % from the third day of observation on Facebook and Twitter/X. **Stage 3** built the training dataset from the 2023 Colombian local elections, covering 120 candidates across 31 cities, and trained the final model via fractional logistic regression with nested ElasticNet selection. The full nine-variable model achieves a **MAE of 9.57 percentage points** and an out-of-sample  $R^2$  of 0.518; the two-predictor specification applied prospectively achieves a MAE of 9.56 pp, a 3.05 pp improvement over the proportionality baseline.

The definitive prospective validation was conducted on the Colombian presidential run-off of June 21, 2026, without any retraining. The model forecast 60.5 % for Cepeda Castro and 39.5 % for De la Espriella; the actual result certified by the Registraduría Nacional del Estado Civil was Abelardo De la Espriella with 50.48 % and Iván Cepeda with 49.52 %, a margin of only 0.96 pp. The absolute error of 10.98 pp for the digitally dominant candidate exceeds the model's mean out-of-sample MAE (9.56 pp) by **1.42 pp**: this outcome falls outside the model's empirical resolution limit, confirming that near-ties decided by less than 1 pp lie beyond the precision of any aggregate engagement-based system. Far from invalidating the methodology, this finding precisely delineates its scope: ELA-NOM is informative in races with substantial digital advantages; not in statistical ties.

**Keywords:** electoral nowcasting, social media, machine learning, Colombia, local elections, election-agnostic model, Weibull growth, fractional logistic regression, ElasticNet.

## Índice de figuras

|     |                                                                                                                                                                                                                                                                                                                                                                                                                                  |    |
|-----|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----|
| 5.1 | Series de tiempo de la evolución de la intención de voto utilizando el modelo MLP-BP con PCA. . . . .                                                                                                                                                                                                                                                                                                                            | 16 |
| 5.2 | Porcentaje de interacciones acumuladas por Día Relativo (curvas estabilizadas): Laura Fernández, candidata ganadora (línea dorada continua), vs. promedio del resto de candidatos (línea azul discontinua). Ambas curvas son morfológicamente indistinguibles, lo que confirma que el patrón de crecimiento es una propiedad de la plataforma y no del candidato. . . . .                                                        | 18 |
| 5.3 | Distribución de la fracción acumulada de interacciones ( $n_t/n_{\text{máx}}$ ) por Día Relativo, sobre el panel completo de 1.922 publicaciones. La línea roja muestra la mediana: en el Día 0 ya se acumula el 72 % del total final; al Día 3, el 98 %. La dispersión en los días iniciales refleja la heterogeneidad entre publicaciones, razón por la que el $R^2$ global es bajo pero el modelo promedio es válido. . . . . | 19 |

|     |                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                      |    |
|-----|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----|
| 5.4 | Ajuste del modelo Weibull con <i>offset</i> temporal por plataforma. Puntos negros: mediana empírica. Área azul: rango intercuartílico (IQR) empírico. Curva roja: modelo calibrado. Los parámetros $k$ , $\alpha$ y $t_0$ de cada plataforma se detallan en la Tabla 5.2. . . . .                                                                                                                                                                                                                   | 20 |
| 5.5 | Evaluación de la precisión proyectiva del modelo Weibull. <b>Izquierda:</b> MAPE mediano por plataforma y día de observación; la línea discontinua marca el umbral de referencia del 20 %. <b>Derecha:</b> distribución del error por publicación al Día 3. A partir del Día 3, las cuatro plataformas se ubican por debajo del 20 %; Instagram, que en el Día 1 registra el MAPE más alto (20,72 %), converge a 12,06 % en el Día 3. . . . .                                                        | 20 |
| 5.6 | Ejemplos de reconstrucción histórica de interacciones con el modelo Weibull calibrado. <b>Izquierda:</b> publicación de Facebook con 50,000 interacciones totales conocidas; el modelo distribuye las interacciones nuevas por día (barras) y la fracción acumulada (curva roja). <b>Derecha:</b> publicación de Instagram con 43,000 interacciones medidas el Día 10; el modelo infiere el total final y reconstruye la curva completa. . . . .                                                     | 21 |
| 6.1 | Evolución diaria de la intención de voto estimada por el modelo MLP-BP+PCA (líneas continuas) vs. la intención de voto real interpolada desde encuestas (líneas discontinuas) para Paz (verde) y Quiroga (rojo). Las líneas verticales punteadas marcan la fecha de publicación de cada encuesta. El modelo captura la tendencia ascendente de Paz en las últimas semanas, aunque con alta varianza diaria. . . . .                                                                                  | 27 |
| 6.2 | Relación entre la dominancia digital de <i>likes</i> y la cuota de voto real en las elecciones de alcaldes de Colombia 2023 (120 candidatos, 31 contiendas). La correlación de rango de Spearman calculada sobre todos los candidatos (mancomunada) es $\rho = 0,70$ ( $p < 0,001$ ). Los puntos azules corresponden a ganadores y los rojos a perdedores. . . . .                                                                                                                                   | 30 |
| 6.3 | Escalera de desempeño de especificaciones evaluadas (LOCO-CV, 31 contiendas). Cada barra representa el MAE en puntos porcentuales de la cuota de voto. La línea punteada vertical marca el <i>baseline</i> de proporcionalidad. . . . .                                                                                                                                                                                                                                                              | 31 |
| 6.4 | Estabilidad de los coeficientes del modelo de dos variables (GLM fraccional, <i>link</i> logit) estimados entre los 31 pliegues LOCO-CV en escala logit ( $\hat{\beta}_1 \approx 0,780$ para la dominancia de <i>likes</i> y $\hat{\beta}_2 \approx 0,540$ para el moderador de población, barras con media $\pm$ IC 95 %). En escala estandarizada con <i>StandardScaler</i> , corresponden a $\hat{\beta}_1 = 0,111$ y $\hat{\beta}_2 = 0,026$ en la especificación final (Sección 5.6.b). . . . . | 32 |
| 6.5 | Izquierda: predicción vs. resultado real para los 120 candidatos en validación LOCO-CV. La línea discontinua dorada representa la predicción perfecta. Derecha: distribución de residuos (predicho – real, en pp); la línea roja marca el error cero y la dorada la media del error. . . . .                                                                                                                                                                                                         | 32 |
| 6.6 | Comparación entre la señal digital (dominancia de <i>likes</i> ), el pronóstico de ELA-NOM y el resultado certificado por la Registraduría Nacional del Estado Civil en la segunda vuelta presidencial de Colombia (21 jun. 2026). . . . .                                                                                                                                                                                                                                                           | 33 |
| 6.7 | Curva de aprendizaje de ELA-NOM. MAE fuera de muestra (media y banda $\pm 1$ desviación estándar) en función del número de contiendas de entrenamiento. La banda sombreada representa la variabilidad entre las 50 repeticiones de muestreo. . . . .                                                                                                                                                                                                                                                 | 35 |

# Índice de cuadros

|     |                                                                                                                                                                                                                                   |    |
|-----|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----|
| 5.1 | Comparativa de bondad de ajuste ( $R^2$ ) entre familias de funciones de crecimiento acumulado. . . . .                                                                                                                           | 18 |
| 5.2 | Parámetros Weibull calibrados por plataforma y bondad de ajuste ( $R^2$ ) sobre el panel de fracciones. . . . .                                                                                                                   | 19 |
| 5.3 | Métricas fuera de muestra del modelo de regresión fraccional (LOCO-CV sobre 31 contiendas, 120 candidatos). . . . .                                                                                                               | 23 |
| 6.1 | Métricas de predicción en el día de elecciones: candidato Paz (real: 54,53 %)†                                                                                                                                                    | 27 |
| 6.2 | MAPE mediano (%) en la estimación del total final de interacciones, por plataforma y día de observación (panel longitudinal Costa Rica 2026). . . .                                                                               | 29 |
| 6.3 | Escalera de resultados del proceso AutoML acotado: comparativa completa de especificaciones (LOCO-CV, 31 contiendas, 120 candidatos). . . . .                                                                                     | 31 |
| 6.4 | Pronóstico ELA-NOM vs. resultado real de la segunda vuelta presidencial colombiana (21 jun. 2026). Fuente del resultado: Registraduría Nacional del Estado Civil. . . . .                                                         | 33 |
| 6.5 | Curva de aprendizaje: MAE fuera de muestra según el número de contiendas de entrenamiento (50 repeticiones con muestreo aleatorio, semilla 42). Modelo base: regresión lineal sobre dominancia en logit de <i>likes</i> . . . . . | 34 |





## 1.1. Motivación del problema

La industria global de investigación de mercados y opinión pública, que incluye el pronóstico electoral, alcanzó 153.000 millones de dólares en 2024, un crecimiento del 8 % frente al año anterior, según *ESOMAR* (*ESOMAR, 2025*), la asociación mundial del sector. En Colombia, la misma industria facturó 743.058 millones de pesos en 2024 (equivalentes a aproximadamente 208 millones de dólares a la tasa de cambio de mayo de 2026), con un crecimiento del 1 % frente al año anterior, según la *Asociación Colombiana de Empresas de Investigación de Mercados y Opinión Pública* (*ACEI, 2025*).

En paralelo, el auge de los mercados de predicción financiera ilustra que existe un apetito de mercado creciente por pronósticos ágiles y verificables sobre eventos futuros. Plataformas como *Polymarket* y *Kalshi*, que no son competidoras directas de las encuestadoras sino mercados financieros de contratos sobre resultados, proyectan alcanzar un billón de dólares en volumen transado anual para 2030, según estimaciones de Bernstein Research (*Giangiulio, 2026*). Aunque se trata de industrias de naturaleza distinta, este fenómeno revela una demanda no atendida por información predictiva en tiempo real que las encuestas tradicionales, por diseño, no están estructuradas para satisfacer.

A pesar de su ubicuidad, las encuestas electorales en Colombia enfrentan profundos retos estructurales que se han agudizado recientemente. La dificultad logística de abarcar territorios extensos, la alta tasa de no respuesta y los elevados costos operativos limitan la frecuencia y el tamaño muestral de los estudios, especialmente en elecciones locales.

A estos problemas estructurales se suma un nuevo marco regulatorio que ha tensionado aún más el sector: la **Ley 2494 de 2025**, que estableció requisitos metodológicos estrictos para la elaboración y publicación de encuestas electorales, incluyendo una veda de publicación que interrumpió el flujo de información entre julio y noviembre de 2025 (*Congreso de la República de Colombia, 2025*).

La aplicación práctica de esta norma generó tal nivel de fricción entre el *Consejo Nacional Electoral* (CNE) y las firmas encuestadoras, que la consultora española GAD3 suspendió definitivamente sus mediciones en el país en mayo de 2026, argumentando que la interpretación de la Comisión Técnica exige demostrar condiciones de muestreo que “ninguna metodología demoscópica puede satisfacer en la práctica” (*GAD3, 2026*).

La norma, al invalidar encuestas telefónicas, paneles digitales y métodos mixtos en favor de encuestas presenciales domiciliarias, encareció operativamente el sector y concentró el mercado en pocas firmas con suficiente capacidad económica para operar en campo en todo el territorio nacional (*Ríos Giraldo, 2026*). En este panorama, resulta cada vez más urgente desarrollar herramientas de pronóstico electoral que no dependan exclusivamente de encuestas y que aprovechen fuentes alternativas de datos masivos.

## 1.2. Estado del arte: de los modelos paramétricos al SOMEN-DC

La capacidad de anticipar resultados electorales ha sido un reto persistente para la ciencia política desde los años setenta, cuando surgieron los primeros modelos predictivos formales en Estados Unidos y el Reino Unido. Los trabajos pioneros de Sigelman (1979) y Whiteley (1979) demostraron que la popularidad presidencial medida meses antes de una elección era un predictor estadísticamente significativo del resultado electoral, abriendo la puerta a una tradición de modelos formales de pronóstico que hasta entonces era prácticamente inexistente en la ciencia política.

Esta tradición evolucionó rápidamente hacia arquitecturas econométricas más sofisticadas. Mughan (1987) comparó tres modelos simples de pronóstico para elecciones generales en el Reino Unido, concluyendo que las variables macroeconómicas, en particular el desempleo y la aprobación gubernamental, ofrecían mayor poder predictivo que los indicadores de popularidad aislados. Por su parte, Sanders (1991) desarrolló un modelo de función de popularidad para el gobierno británico que incorporaba condiciones económicas y eventos políticos exógenos, anticipando el resultado de las elecciones generales con seis meses de antelación. Durante los años noventa y la primera década del siglo XXI, estos modelos alcanzaron su madurez técnica, apoyándose en herramientas de series de tiempo como VAR y ARMA. En el contexto del Reino Unido, Lewis-Beck et al. (2004) formularon un modelo de economía política que explicaba más del 80 % de la varianza en el apoyo gubernamental usando solo tres variables: aprobación del gobierno, inflación y el número de términos consecutivos en el poder. En paralelo, Norpoth (2004) propuso una perspectiva dinámica que modelaba el retorno del voto al equilibrio histórico mediante un proceso autorregresivo AR(1), demostrando que el partido ganador tiende a perder aproximadamente la mitad de su ventaja en la siguiente elección. En varios ciclos electorales, estos modelos superaban en precisión a las propias encuestadoras.

Sin embargo, desde aproximadamente 2015, la capacidad predictiva de estos enfoques se deterioró de forma pronunciada. En el Reino Unido, ningún modelo establecido logró anticipar la mayoría conservadora de ese año (Stegmaier et al., 2023); un año después, los mismos enfoques fallaron en predecir la victoria de Donald Trump, el Brexit y los resultados de otras consultas populares de ese ciclo (K. Brito et al., 2024; Stegmaier et al., 2023). Esta crisis generalizada no fue accidental: Kennedy et al. (2018) documentaron, en una evaluación exhaustiva encargada por la Asociación Americana de Investigación de Opinión Pública (AAPOR), que los sondeos de 2016 sobreestimaron sistemáticamente el apoyo a Hillary Clinton debido a sesgos de no-respuesta diferencial, especialmente entre votantes de Trump sin estudios universitarios. A esto se sumaron los cambios estructurales en la comunicación política propiciados por las redes sociales (Tucker et al., 2018) y la creciente fragmentación y polarización de los electorados (Barberá, 2020), que volvieron menos predecibles los comportamientos que los modelos paramétricos habían aprendido a capturar.

La crisis impulsó a los investigadores a explorar fuentes de datos alternativas. El auge del *Big Data* y las plataformas digitales abrió una nueva línea de investigación: usar las huellas digitales de los ciudadanos como covariables en tiempo real para el pronóstico electoral. El estudio seminal de Tumasjan et al. (2010) sobre las elecciones federales alemanas de 2009 fue el primer trabajo de referencia en este campo. Analizando más de 104.000 *tweets* publicados en las semanas previas a la elección, los autores encontraron que el

simple volumen de menciones de cada partido replicaba el resultado electoral con un error absoluto medio de apenas 1,65 %, comparable al de las encuestadoras tradicionales. Más allá de la predicción, Tumasjan et al. demostraron que los perfiles de sentimiento de los mensajes correspondían a las posiciones políticas reales de los partidos, y que las menciones conjuntas de dos partidos reflejaban las alianzas políticas existentes. Esta hipótesis, que la atención digital equivale a capital político, abrió una década de investigación intensa.

No obstante, la promesa inicial no se sostuvo en la replicación sistemática. Skoric et al. (2020), en un meta-análisis de 74 estudios publicados entre 2007 y 2018, encontraron que las predicciones basadas en redes sociales quedaban en promedio por debajo de los *benchmarks* de la encuesta tradicional, con alta varianza entre estudios y sin convergencia metodológica. Sus resultados mostraron que las predicciones basadas únicamente en análisis de sentimiento léxico no superaban a las basadas en características estructurales de red, y que la combinación de ambas, usando aprendizaje automático, producía los mejores resultados ( $MAE = 2,14 \%$ ;  $R^2 = 0,818$ ). K. Brito et al. (2024), en una revisión crítica de doce años de investigación, formalizaron el problema: el enfoque de *Twitter* solo, basado en volumen de menciones o sentimiento, no rinde mejor que el azar, con tasas de acierto de entre el 50 % y el 63 %. Los autores identificaron cinco causas estructurales de este fracaso: la imposibilidad de encuestar representativamente a través de *Twitter*, la dependencia de decisiones arbitrarias de recolección, los cambios constantes en el ecosistema de plataformas, la falta de datos históricos comparables, y la repetición de los errores metodológicos de las *straw polls* anteriores a 1936. El problema de fondo es metodológico: rastrear millones de publicaciones abiertas es costoso, ruidoso y difícilmente replicable fuera de entornos universitarios con infraestructura computacional avanzada (Skoric et al., 2020).

La respuesta más sofisticada a estos problemas llegó desde Brasil. K. d. S. Brito y Adeodato (2020) propusieron un cambio fundamental de paradigma: en lugar de rastrear lo que la ciudadanía dice sobre los candidatos, menciones abiertas, *hashtags*, sentimiento, el modelo analiza exclusivamente lo que la ciudadanía hace con el contenido que los propios candidatos publican en sus perfiles oficiales. Combinando datos de Facebook, *Twitter* e *Instagram* de las elecciones presidenciales de Brasil (2018) y Estados Unidos (2016) con encuestas tradicionales como variable objetivo, entrenaron redes neuronales tipo MLP que superaron estadísticamente a las encuestadoras en Brasil, donde los candidatos son muchos y las encuestas son pocas, y fueron competitivos en Estados Unidos. Este enfoque fue posteriormente sistematizado por K. Brito y Adeodato (2022), quienes analizaron más de 67.000 publicaciones de candidatos presidenciales en Argentina, Brasil, Colombia y México (2018–2019), demostrando que las métricas de *engagement* por publicación, en particular los *likes* por *post* en *Instagram*, correlacionaban fuertemente con el resultado electoral ( $r = 0,75\text{--}0,98$ ), mientras que el número absoluto de publicaciones presentaba correlación nula o negativa.

El conjunto de estas contribuciones se formalizó en el marco **SOMEN-DC** (*Social Media Electoral Nowcasting During Campaign*), desarrollado por K. Brito y Adeodato (2023) en la Universidad Federal de Pernambuco. El modelo propone un proceso de cinco pasos: comprensión del evento, recolección de datos, preparación, modelado y evaluación, y una estrategia de ejecución continua (DC) que permite emitir predicciones diarias durante la campaña. Usando datos de más de 65.000 publicaciones y 195 encuestas de cuatro países

latinoamericanos, los ensambles de redes neuronales (MLP y GRNN) entrenados con métricas de *engagement* y encuestas como etiquetas alcanzaron errores absolutos medios frecuentemente inferiores a 3 puntos porcentuales, dentro del umbral histórico de las encuestadoras.

Sin embargo, el SOMEN-DC presenta tres limitaciones estructurales que este trabajo busca superar:

1. **Techo encuestocéntrico.** Al usar las encuestas como variable objetivo de entrenamiento, el modelo no puede superar la capacidad predictiva de las propias encuestas. Es, en esencia, un replicador sofisticado de sondeos: aprende a imitar la señal de las encuestas a partir de datos digitales, sin acceso a una fuente de verdad independiente.
2. **Dependencia de infraestructura costosa.** El modelo requiere *scraping* continuo desde el inicio de la campaña para registrar la evolución temporal de las interacciones, acceso que los autores originales tenían a través de servicios institucionales de la Universidad Federal de Pernambuco, hoy inasequibles o inexistentes para la mayoría de investigadores independientes.
3. **No transferibilidad.** Los pesos aprendidos son válidos exclusivamente para la elección en que se entrenaron. Cada nueva contienda exige repetir desde cero el ciclo completo de recolección y entrenamiento, sin posibilidad de acumular aprendizaje entre elecciones o de generalizar patrones entre contextos electorales distintos.

Estas tres limitaciones definen el espacio de contribución de esta tesis.

### 1.3. Hipótesis de trabajo

El punto de partida conceptual de este proyecto es la hipótesis seminal formulada por Tumasjan et al. (2010), quienes postulan que el volumen de actividad digital de un candidato en plataformas de redes sociales funciona como un estimador de su capital electoral subyacente. Esta intuición ha encontrado respaldo empírico consistente en contextos distintos al original: K. Brito y Adeodato (2022) demostraron que las métricas de *engagement* por publicación en los perfiles oficiales de candidatos presidenciales en Argentina, Brasil, Colombia y México correlacionan fuertemente con el resultado electoral ( $r = 0,75-0,98$ ), mientras que las interacciones absolutas o el volumen de publicaciones presentan correlaciones nulas o negativas.

No obstante, existe un argumento estructural en contra de esta hipótesis que merece atención explícita: la penetración de las redes sociales no es aleatoria. La probabilidad de que un ciudadano tenga presencia activa en redes sociales depende de factores económicos, geográficos y culturales, lo que introduce un sesgo sistemático si se asume que la audiencia digital de un candidato representa fielmente a su electorado potencial (Skoric et al., 2020). Sin embargo, este argumento pierde fuerza en la medida en que la cobertura digital se aproxima a la universalidad. Según DataReportal (2025), el 70,4 % de la población colombiana usa redes sociales al cierre de 2025, cifra que creció en 1,6 millones de personas solo en 2024, con Facebook, TikTok, YouTube, Instagram y LinkedIn alcanzando al 89,3 %, 93,0 %, 74,4 %, 52,3 % y 44,4 % de los usuarios de redes sociales colombianos, respectivamente (porcentajes calculados sobre la base de quienes ya usan redes sociales, no sobre la población adulta total). Significativamente, X/Twitter, la plataforma que

concentra la mayor parte de la literatura de predicción electoral con redes sociales, solo alcanza al 12,0 % de los usuarios de redes sociales en Colombia, lo que compromete estructuralmente cualquier modelo que dependa exclusivamente de esa fuente.

## Formulación del problema

Considérese una elección de ganador único para un cargo ejecutivo: alcalde, gobernador o presidente, con un conjunto finito de  $C$  candidatos competitivos  $\mathcal{C} = \{c_1, c_2, \dots, c_C\}$ . Para cada candidato  $c_i$ , se observa un vector de características digitales:

$$\mathbf{x}_i \in \mathbb{R}^d \quad (1.1)$$

construido a partir de las interacciones acumuladas en sus publicaciones de redes sociales durante una ventana de  $n$  días previos a la jornada electoral. Este vector puede incluir interacciones totales, *engagement* por publicación, dominancia relativa respecto al total de interacciones de la elección, entre otras métricas.

La hipótesis central de este trabajo postula que existe una función:

$$f : \mathbb{R}^d \rightarrow [0, 1] \quad (1.2)$$

tal que  $f(\mathbf{x}_i)$  aproxima la cuota de voto esperada del candidato  $c_i$ . La restricción de coherencia, que las predicciones sumen a la unidad sobre todos los candidatos de la misma elección, no es una propiedad de  $f$  en sí misma, sino una normalización que se impone a posteriori sobre el conjunto de salidas escalares:

$$\sum_{i=1}^C f(\mathbf{x}_i) = 1 \quad (1.3)$$

La contribución metodológica de este trabajo respecto a la literatura previa reside en el mecanismo de aprendizaje de  $f$ . En los modelos existentes, incluyendo el SOMEN-DC (K. Brito & Adeodato, 2023), esta función se aprende de forma independiente para cada elección, usando las encuestas de intención de voto como variable objetivo. En el modelo propuesto,  $f$  se aprende sobre un conjunto de  $M$  elecciones históricas  $\mathcal{E} = \{e_1, e_2, \dots, e_M\}$ , usando directamente el resultado electoral como fuente de verdad. Esto tiene dos implicaciones fundamentales: primero, elimina la dependencia de encuestas en cualquier etapa del proceso; segundo, permite que los parámetros aprendidos capturen patrones que son comunes entre elecciones, la relación estructural entre tracción digital y respaldo electoral, y no los detalles particulares de una campaña en específico. Una vez entrenada,  $f$  puede aplicarse a una elección nueva  $e_{M+1} \notin \mathcal{E}$  sin necesidad de datos de entrenamiento adicionales, lo que constituye la propiedad de **elección-agnosticismo** que da nombre al modelo.

Bajo este marco, el modelo opera recibiendo como *input* el vector  $\mathbf{x}_i$  de interacciones digitales de cada candidato, calculado sobre una ventana de  $n$  días previos a la jornada electoral. El *output* se obtiene aplicando  $f$  individualmente a cada candidato:  $\hat{y}_i = f(\mathbf{x}_i) \in [0, 1]$ , y ensamblando el vector resultante  $\hat{\mathbf{y}} = (\hat{y}_1, \dots, \hat{y}_C) \in [0, 1]^C$ , donde cada componente representa la cuota de voto estimada para el candidato  $c_i$ , respondiendo a la pregunta: *si las elecciones ocurrieran hoy, ¿qué porcentaje de los votantes apoyaría a cada candidato?*

## 1.4. Estructura del documento

Para abordar esta hipótesis, la investigación se estructuró a través de tres etapas empíricas que guían la organización de este documento. El **Capítulo 2** define formalmente la pregunta de investigación y los interrogantes derivados. El **Capítulo 3** presenta el marco conceptual, explorando la literatura sobre *nowcasting* electoral y la viabilidad de los modelos elección-agnósticos. Seguidamente, el **Capítulo 4** detalla los objetivos del estudio.

El **Capítulo 5** desarrolla la metodología, dividida en las tres fases del proyecto:

- **Bolivia (Prueba de concepto):** donde se replica el modelo SOMEN-DC con herramientas comerciales, documentando sus limitaciones metodológicas.
- **Costa Rica (Modelado de crecimiento):** enfocada en resolver el problema del registro histórico mediante la calibración matemática de la curva de crecimiento de las interacciones.
- **Colombia (Construcción y modelado final):** donde se compila el *dataset* elección-agnóstico de elecciones locales (2023) y se entrenan los modelos de regresión fraccional (evaluando la precisión de clasificación del *Top-1* derivado).

Finalmente, el **Capítulo 6** expone los resultados obtenidos en cada fase, mientras que los **Capítulos 7 y 8** discuten el impacto esperado de la herramienta, sus limitaciones inherentes y las conclusiones definitivas del estudio.

## 2

## Pregunta de investigación

Para abordar las limitaciones metodológicas previamente expuestas relativas a la dependencia de las encuestas y la imposibilidad de transferir los modelos de *nowcasting* a nuevas elecciones, esta investigación se estructura alrededor de un interrogante central y una serie de preguntas derivadas que guían el diseño empírico del estudio.

### 2.1. Pregunta principal

La inquietud fundamental que motiva este trabajo se sintetiza en la siguiente pregunta de investigación:

*¿Es posible diseñar e implementar un modelo de nowcasting de la intención de voto que sea **elección-agnóstico**, es decir, cuyos parámetros se entrenen con datos de múltiples elecciones simultáneas y sean transferibles a contiendas no vistas, que no dependa en ninguna etapa de encuestas de opinión pública, y que pueda aplicarse con precisión a elecciones locales en Colombia utilizando únicamente señales extraídas de interacciones en redes sociales?*



Esta pregunta desafía el paradigma establecido en la literatura (representado por modelos como el SOMEN-DC), buscando independizar por completo el pronóstico de las encuestas y evaluar si las huellas digitales por sí solas contienen suficiente información estructural para estimar el apoyo político en un ecosistema electoral altamente fragmentado como el colombiano.

## 2.2. Preguntas derivadas

Para dar respuesta a la pregunta principal de manera secuencial y estructurada, el estudio plantea cuatro preguntas de investigación derivadas, cada una asociada a un desafío metodológico o empírico específico:

1. **Sobre la capacidad predictiva intrínseca de la red:** ¿Las interacciones en redes sociales de los candidatos (volumen de *likes*, comentarios, visualizaciones, etc.) tienen un poder predictivo estadísticamente significativo sobre el resultado electoral real en el contexto latinoamericano?
2. **Sobre la viabilidad de la reconstrucción de series temporales:** Dado que las plataformas digitales no almacenan un registro público del historial de interacciones de una publicación, ¿es posible reconstruir matemáticamente la curva de crecimiento de las interacciones de publicaciones pasadas sin haber realizado *scraping* en tiempo real durante la campaña original?
3. **Sobre la selección de características (feature engineering):** Entre las múltiples señales disponibles, ¿qué tipo de métricas digitales resultan más informativas para el pronóstico electoral: el volumen absoluto de interacciones de un candidato, su *dominancia relativa* en comparación con sus contrincantes, o su capacidad para generar tracción tardía en los últimos días de la campaña?
4. **Sobre el tamaño mínimo de muestra:** Considerando que el volumen de contiendas electorales históricas disponibles es estructuralmente limitado en América Latina, ¿cuántas contiendas de entrenamiento son necesarias para que un modelo de regresión fraccional basado en señales digitales alcance su umbral de rendimiento estable, y qué determina su techo de error residual?

# 3

## Marco conceptual

### 3.1. *Nowcasting* electoral y predicción con redes sociales

#### 3.1.a. Definición de *nowcasting* en contexto electoral

En ciencia política, *nowcasting* (pronóstico del presente) designa una estimación cuantitativa de “lo que pasaría si la elección se celebrara hoy”. Se diferencia del *forecasting* clásico (predicción a futuro) en que el *nowcasting* busca modelar el estado actual y latente del electorado mediante actualizaciones continuas y en tiempo real, basándose en un



modelo cuyos parámetros estructurales se mantienen fijos mientras varían las covariables observadas (Lewis-Beck & Tien, 2014; Lewis-Beck et al., 2011).

La primera formulación formal aplicada a elecciones nacionales se consolidó con los modelos *proxy*. Por ejemplo, en el Reino Unido, Lewis-Beck et al. (2011) modelaron el voto del oficialismo a partir de indicadores adelantados, como la aprobación del gobierno, medida con meses de antelación. En épocas más recientes, con el auge del *Big Data*, la literatura empírica se ha volcado al uso de redes sociales como fuente masiva de covariables en tiempo real, transformando el *nowcasting* en una herramienta de minería de datos dinámicos (Skoric et al., 2020).

Desde el estudio seminal de Tumasjan et al. (2010), múltiples autores han explorado arquitecturas híbridas. Trabajos recientes como los de K. Brito y Adeodato (2022, 2023) han sofisticado la técnica combinando recolección de datos durante la campaña (*During Campaign*) y modelos de aprendizaje automático (*Machine Learning*) aplicados a Latinoamérica. Sin embargo, estas aplicaciones mantienen una dependencia crítica: el entrenamiento constante frente a encuestas tradicionales.

### 3.2. Modelos elección-agnósticos: definición y ventajas

Un modelo **elección-agnóstico** es aquel que se entrena utilizando datos conjuntos de múltiples elecciones simultáneamente, con el propósito de aprender reglas de decisión y pesos paramétricos que representen patrones de comportamiento electoral universales (o regionalmente consistentes), de modo que sean directamente transferibles a elecciones no vistas.

Formalmente, sea  $\mathcal{E} = \{e_1, e_2, \dots, e_M\}$  un conjunto de  $M$  elecciones históricas diferentes (por ejemplo, alcaldías de distintas ciudades). El objetivo es aprender una función predictiva:

$$f : \mathbb{R}^d \rightarrow [0, 1] \quad (3.1)$$

tal que  $\hat{y}_{i,m} = f(\mathbf{x}_{i,m})$ , donde  $\mathbf{x}_{i,m}$  es el vector de características de  $d$  dimensiones (interacciones digitales, tasas de crecimiento, dominancia) del candidato  $i$  en la elección  $m$ , y  $\hat{y}_{i,m}$  es la cuota de voto estimada o la probabilidad de victoria.

La principal ventaja matemática y operativa de este enfoque frente a arquitecturas específicas de campaña como el SOMEN-DC (K. Brito & Adeodato, 2023) radica en su escalabilidad e independencia. Al abstraer la función  $f$  sobre  $M$  elecciones, el modelo se desacopla de la necesidad de contar con datos de encuestas como variable dependiente, utilizando directamente los resultados electorales finales como *ground truth*. Asimismo, elimina la dependencia de infraestructura de *scraping* en tiempo real, pues la predicción sobre una elección nueva  $\mathcal{E}_{new}$  requiere únicamente extraer los vectores  $\mathbf{x}_{new}$  y procesarlos a través del modelo pre-entrenado.

### 3.3. Interacciones digitales como *proxy* de intención de voto

#### 3.3.a. La hipótesis Tumasjan

El uso de señales digitales como estimador político se sustenta empíricamente en el trabajo fundacional de Tumasjan et al. (2010) sobre las elecciones federales alemanas de

2009. Estos autores demostraron que el simple conteo volumétrico de *tweets* que mencionan a un partido refleja fielmente el resultado electoral, logrando un error absoluto medio (MAE) de 1,65 %. Esta hipótesis sugiere que la atención (reflejada en interacciones y contenido generado) equivale a capital político en la arena digital.

### 3.3.b. Interacciones absolutas vs. dominancia relativa

Si bien el volumen absoluto de interacciones (por ejemplo, el total de *likes*) ofrece una señal importante, presenta ruido debido a la heterogeneidad de los distritos electorales y la presencia de cuentas atípicamente virales. Para mitigar esto, este estudio introduce y prioriza la métrica de **dominancia relativa**: el porcentaje de interacciones que acumula un candidato sobre el total de interacciones generadas por todos los candidatos competitivos dentro de su misma ciudad o distrito.

Los análisis exploratorios sobre las elecciones locales colombianas de 2023 presentados en este trabajo confirman que la dominancia relativa es significativamente más informativa que el volumen absoluto.

No obstante, conviene precisar el alcance inferencial de este *proxy*. ELA-NOM no mide intención de voto en sentido estricto, una variable actitudinal y psicológica que requeriría sondeo directo al elector, sino que aproxima la **cuota electoral observada** a partir de señales digitales observables. Además del apoyo electoral genuino, las interacciones en redes sociales pueden reflejar: (i) **visibilidad mediática**, cuando un candidato es cubierto ampliamente por medios que generan reacciones digitales sin que ello equivalga a apoyo; (ii) **polarización y rechazo**, ya que las interacciones negativas (comentarios críticos, *shares* de denuncia) también incrementan los conteos de engagement; (iii) **pauta publicitaria paga**, que infla artificialmente las métricas mediante contenido promovido; y (iv) **militancia digital organizada** (posible actividad coordinada no orgánica, incluyendo bots y *astroturfing*). Las redes sociales son ecosistemas permeables a estos fenómenos, así como a los sesgos demográficos propios de cada plataforma y a la existencia de candidatos cuya tracción digital es desproporcionada a su viabilidad electoral real (como se evidenció con la exclusión de Gustavo Bolívar en el dataset colombiano).

## 3.4. El problema del histórico de interacciones

Uno de los mayores desafíos para entrenar modelos predictivos retrospectivos es la opacidad temporal de los datos en redes sociales. Plataformas como Facebook, Twitter/X y TikTok muestran únicamente el total acumulado de interacciones de una publicación en el instante en que es consultada (hoy). No guardan ni exponen públicamente la curva histórica de crecimiento; por lo tanto, es imposible observar directamente cuántos *likes* tenía una publicación específicamente el día anterior a las elecciones, un dato crucial para el *nowcasting*.

Para sortear este obstáculo metodológico, este trabajo propone modelar matemáticamente la curva de crecimiento acumulado de las interacciones utilizando una distribución de Weibull con parámetro de desplazamiento (*offset*):

$$F(t) = 1 - e^{-k \cdot (t+t_0)^\alpha} \quad (3.2)$$

donde  $t$  es el tiempo transcurrido (en días) desde la publicación;  $k$  es el parámetro de

tasa que determina la velocidad general de acumulación;  $\alpha$  es el parámetro de forma que controla la geometría de la curva de crecimiento acumulado (valores  $\alpha < 1$  producen curvas cóncavas con desaceleración progresiva; valores  $\alpha > 1$  producen curvas convexas con tasa de acumulación creciente, como ocurre con Twitter/X, calibrado con  $\alpha = 1,1422$ ;  $\alpha = 1$  recupera el modelo exponencial simple, descartado por ajuste inferior); y  $t_0 > 0$  adelanta el origen de la acumulación, haciendo que  $F(0) > 0$  y capturando la explosión masiva de interacciones que ocurre en las primeras horas antes de que  $t$  alcance el primer día completo.

Al calibrar estos parámetros  $(k, \alpha, t_0)$  de forma diferenciada para cada plataforma, es posible proyectar la curva  $F(t)$  hacia el pasado y estimar con alta fidelidad las métricas que tenía cualquier publicación histórica en la víspera electoral.

## 4

# Objetivos

### 4.1. Objetivo general

Diseñar e implementar un modelo de *nowcasting* de la cuota electoral (*proxy* de la intención de voto) en elecciones locales colombianas que sea elección-agnóstico, que no dependa de encuestas, que use únicamente interacciones en redes sociales de los perfiles oficiales de los candidatos, y que pueda replicarse con herramientas comerciales accesibles.

### 4.2. Objetivos específicos

1. **OE1.** Replicar y evaluar empíricamente el modelo SOMEN-DC en la segunda vuelta presidencial de Bolivia (octubre de 2025).
2. **OE2.** Modelar el crecimiento temporal de las interacciones en redes sociales usando varios modelos de forma comparativa.
3. **OE3.** Construir un *dataset* de entrenamiento elección-agnóstico con datos de las elecciones locales colombianas de 2023.
4. **OE4.** Entrenar y evaluar modelos de regresión fraccional para predecir la cuota de voto, derivando de sus estimaciones continuas la precisión en clasificación del candidato ganador (*Top-1*).
5. **OE5.** Identificar las condiciones de viabilidad metodológica del modelo propuesto y documentar sus limitaciones.

## 5

# Metodología

## 5.1. Definición formal del problema

### 5.1.a. Definición de la elección

Definimos una elección, llamada **elección-agnóstica** como  $e$  donde  $e \in E$  y  $E$  es el conjunto de todas las elecciones agnósticas que cumplen los siguientes requisitos:

- Es un proceso competitivo no determinístico definido como la participación de dos o más candidatos con posibilidades reales de ganar y condiciones equitativas (Kayser & Lindstädt, 2015).
- Tiene por ganador a un único candidato por elección  $c_{ganador,e} \in C_e$  con  $C_e$  siendo el conjunto de candidatos para la elección  $e$ .
- El candidato ganador  $c_{ganador,e}$  es aquel que obtuvo más votos entre las opciones posibles de la elección  $e$ .
- Se desarrolla en un periodo de tiempo acotado  $t \in [t_0, t_f]$ , con  $t_0$  y  $t_f$  siendo el inicio y fin de la campaña, que sería el día anterior a la elección.
- Se mide mediante los votos de los electores  $v_e \in V_e$ , siendo  $V_e$  el conjunto de todos los electores de la elección  $e$ .
- Todos los candidatos del universo de elecciones  $E$  tienen cuentas oficiales de un conjunto de redes sociales  $R$  con  $r \in R$  y publican activamente en ellas para el momento  $t_0$ . En el ejercicio de Bolivia y Costa Rica estas fueron Facebook, TikTok, X/Twitter e Instagram, mientras que para Colombia se omitió Instagram.

### 5.1.b. Definición de la intención de voto y los resultados

Definimos la intención de voto como el número de votantes  $v_e$  que, en un momento  $t$ , escogerían al candidato  $c_e$ . Esta es una variable subyacente, ya que no todos los votantes tienen definido su voto desde el  $t_0$ , algunos no van a votar o pueden hacerlo en blanco. Las encuestas son estimadores de esta misma variable, pero dado que esta variable solo toma un valor definido el día de las elecciones, no podemos usar una metodología clásica de series de tiempo para modelar la evolución temporal de la intención de voto. Por lo tanto, modelamos la relación entre los vectores de métricas de redes sociales de los candidatos desde una cantidad de días antes de la elección y el valor que sabemos que toma la **intención** de voto el día de las elecciones.

La intención de voto verdadera es, en sentido estricto, una variable latente que evoluciona con  $t$ : distintos momentos de la campaña producirían distintos resultados hipotéticos si la elección ocurriera ese día. Sin embargo, por restricciones de observabilidad, solo conocemos su valor real en el instante terminal  $t = t_f$  (el día de la elección); este trabajo

modela exclusivamente ese valor final, utilizándolo como variable objetivo del entrenamiento supervisado. A partir de aquí, la notación  $i_{e,c_j}$  se refiere siempre a este valor terminal operacionalizado, no a la trayectoria dinámica.

La elección  $e$  tiene una intención de voto asociada, representada por un vector  $i_e \in I_e$ , donde  $I_e$  es el conjunto de intenciones de voto para la elección  $e$ . Este vector está compuesto por una secuencia de intenciones de voto, una por cada candidato, ordenadas de forma idéntica al vector de candidatos  $C_e$ . Es decir,  $i_e = (i_{e,c_1}, i_{e,c_2}, \dots, i_{e,c_{|C_e|}})$ , donde  $i_{e,c_j}$  es la intención de voto del candidato  $c_j$  para la elección  $e$ . Esta intención de voto para el candidato  $c_e$  se calcula como su número de votos porcentual obtenido en la elección  $e$ , es decir:

$$i_{e,c_j} = \frac{v_{e,c_j}}{v_e}$$

donde  $v_{e,c_j}$  es el número de votos del candidato  $c_j$  para la elección  $e$  y  $v_e$  es el número total de votos válidos a candidatos en la elección  $e$ , es decir  $\sum_{j=1}^{|C_e|} v_{e,c_j} = v_e$ . Por construcción de esta fórmula, las cuotas de voto sí suman la unidad:  $\sum_{j=1}^{|C_e|} i_{e,c_j} = 1$ . Es fundamental destacar que  $v_e$  NO incluye votos nulos, en blanco o similares.

Dadas estas condiciones, tenemos que una elección de estas características es un evento que es posible acotar a métricas comparables del conjunto de elecciones sin importar su número de candidatos. De esta forma, pasamos a definir cómo funcionan las publicaciones, interacciones e intención de voto.

### 5.1.c. Definición formal de las publicaciones y su comportamiento temporal

Partimos de una publicación cualquiera, es decir un elemento  $p$ , de un candidato  $c_e$ , en una fecha  $t$ , en una red social  $r_j$ , es decir, un  $p_{e,c,r,t}$ , que simplificamos a  $p_i \forall i \in I$  para un momento de recolección de información  $t$ . Esta publicación posee un conjunto de características que permite su comparación con otras publicaciones:

- Fecha de publicación  $t_{pub}$
- Fecha de recolección de información  $t_{rec}$
- Vector de interacciones a fecha de recolección: me gusta, compartir, comentar, guardar, etc.  $x_{i,t_{rec}}$

Este trabajo parte de la idea fundamental de que el conjunto de vectores  $x_i$  para un candidato  $c$  tiene algún tipo y nivel de correlación con su intención de voto  $i_{e,c}$  y es lo que el trabajo busca modelar. Este vector puede ser apoyado por otras variables microfundamentadas, como la relación gobierno/oposición, variables económicas, entre otras.

Este vector de interacciones  $x_{i,t_{rec}}$  posee una propiedad importante y es que es acumulativo. Con muy notables excepciones causadas por intervención de la plataforma o del candidato, las interacciones de una publicación no caen, por lo que para un momento  $t$ , podemos decir que los elementos del vector  $x_{i,t}$  son monótonamente no decrecientes. Por lo tanto el vector de interacciones se puede modelar mediante una función  $f_j(t_{pub}, t_{rec}, x_i)$  para cada red social, que modela el crecimiento de las interacciones de una publicación a lo largo del tiempo, donde  $t$  está en días desde la fecha de publicación.

### 5.1.d. Definición del problema

Con estos elementos contruidos, postulamos la existencia de una función que tenga como *input* un vector de características de las interacciones en redes sociales junto con otras variables de un conjunto  $\mathcal{C}_e$  de candidatos y que tenga como *output* la intención de voto de los candidatos, como porcentaje del total de los votos a candidatos válidos. Dicho en notación matemática, este trabajo busca encontrar:

$$\mathbf{i}_e = f(\mathbf{x}_e, \mathbf{c}_e, t_{rec}, \mathcal{C}_e) \quad (5.1)$$

donde:

- $i_{e,c}$  es la intención de voto del candidato  $c$  para la elección  $e$ .
- $x_{e,c}$  es el vector de características de las interacciones en redes sociales del candidato  $c$  para la elección  $e$ .
- $c_{e,c}$  es el vector de características del candidato  $c$  para la elección  $e$ .
- $t_{rec}$  es la fecha de recolección de información.
- $\mathcal{C}_e$  es el conjunto de candidatos para la elección  $e$ .

Esta función debería tener un conjunto de características tales que la hagan una alternativa viable para la toma de decisiones en campaña, con una relación costo/calidad similar o mejor a las encuestas. Entre estas: ser elección agnóstica, funcionar independiente del número de candidatos y tener un costo inferior al de una encuesta.

Para poder construir esta función se vuelve necesario solucionar un conjunto de problemas:

- **PM1** *¿El modelo SOMEN-DC es replicable con herramientas comerciales no-académicas?*
- **PM2** *¿Cómo se comporta el modelo SOMEN-DC ante un cambio en su lógica de recolección de datos?*
- **PM3** *¿Cómo se puede construir un conjunto de datos de entrenamiento para este problema?*
- **PM4** *¿Cómo se puede convertir este modelo en una herramienta de nowcasting electoral si es un problema de corte transversal más que un problema de serie de tiempo?*

Para resolver estas preguntas metodológicas se hizo necesario realizar los tres ejercicios definidos en el trabajo; la elección presidencial de Segunda Vuelta en Bolivia del 2025, de Primera Vuelta en Costa Rica del 2026 y las Elecciones locales de Colombia en el 2023. El ejercicio de Bolivia ayudó a solucionar las preguntas PM1 y PM2, mientras que el ejercicio de Costa Rica y de Colombia ayudó a solucionar la pregunta PM3. Por último, la pregunta PM4 se responde **parcialmente** con los resultados del ejercicio con la Segunda Vuelta de las Elecciones presidenciales en Colombia en 2026: se demuestra que el núcleo agnóstico es transferible a un formato electoral diferente (condición necesaria para el *nowcasting* continuo), pero la simulación de cadencia diaria queda como extensión natural del trabajo.

## 5.2. Diseño general del proceso

La arquitectura metodológica de esta investigación está estructurada como un proceso secuencial dividido en cuatro etapas empíricas interdependientes, cada una diseñada para responder preguntas de investigación específicas (P1–P4, Capítulo 2) y resolver obstáculos técnicos que habilitan la siguiente etapa:

- **Etapas 1 - Bolivia (2025):** Replica el enfoque de *nowcasting* basado en encuestas del SOMEN-DC sobre la segunda vuelta presidencial boliviana. Su objetivo es confirmar empíricamente que la señal digital es informativa (**P1**) y documentar los tres problemas estructurales del paradigma encuestocéntrico que motivan el diseño de ELA-NOM (**PM1 Y PM2**).
- **Etapas 2 - Costa Rica (2026):** Resuelve el obstáculo de la asimetría temporal de la información: dado que las plataformas solo muestran el total acumulado actual de interacciones, no su valor histórico, se calibra un modelo de crecimiento Weibull que permite reconstruir el estado de cualquier publicación en una fecha pasada (P2). Esto habilita la construcción del *dataset* de entrenamiento retrospectivo.
- **Etapas 3 - Colombia (2023):** Con el restaurador temporal operativo, se construye el *dataset* histórico de 31 elecciones de alcaldes y se entrena y valida el modelo elección-agnóstico final (ElasticNet regularizado, LOCO-CV). Responde **P3** (*¿qué métricas son más informativas?*) y **P4** (*¿cuántas contiendas bastan para estabilizar el rendimiento?*), además de **PM3** (*construcción del dataset*).
- **Validación prospectiva - Colombia (2026):** El núcleo agnóstico entrenado en elecciones locales se aplica sin reentrenamiento a la segunda vuelta presidencial, un formato diferente, para explorar la transferibilidad del modelo (**PM4**).

## 5.3. Etapas 1 - Bolivia: Replicación del SOMEN-DC y prueba de concepto

### 5.3.a. Caso de estudio y recolección de datos

Para confirmar empíricamente las limitaciones inherentes a la literatura de *nowcasting* dependiente de encuestas, se planteó un caso de estudio replicando la metodología SOMEN-DC en el contexto de la segunda vuelta presidencial de Bolivia (programada para el 19 de octubre de 2025). Esta contienda polarizada entre Rodrigo Paz Pereira y Jorge “Tuto” Quiroga representó un escenario ideal de prueba por ser una elección presidencial en un país latinoamericano no tratado por los autores (Brito y Andeoato) en su producción científica. El resultado real proyectado para el estudio determinó a Paz como ganador con el 54,53 % frente al 45,47 % de Quiroga.

Se definió como ventana temporal retrospectiva 153 días (del 18 de mayo al 18 de octubre de 2025). Para extraer los datos se usaron herramientas como Apify operando como *scrapers* web y Make.com como orquestador lógico, programados para extraer diariamente las interacciones a las 10:00 p.m. hora de La Paz de las cuentas oficiales de ambos candidatos en Facebook, Twitter/X, Instagram y TikTok durante la semana anterior a la elección. Los datos crudos se agregaron a nivel diario, garantizando continuidad temporal al imputar con cero (0) aquellos días sin publicaciones. El procesamiento incluyó el



cálculo de promedios de interacción por publicación (ej. *likes* por post) para medir tanto el volumen bruto como la calidad del *engagement*, consolidando un vector final de **26 características** explicativas numéricas en un *dataset* de 308 registros independientes.

### 5.3.b. Preparación de datos y variable objetivo

El preprocesamiento de la información digital fue exhaustivo para lidiar con el ruido de las redes sociales. Primero, se aplicó una estandarización intra-plataforma mediante puntajes *Z* (*z-scores*) para equiparar el peso relativo de redes con distintos niveles de masividad. Seguidamente, se normalizaron de forma independiente los indicadores numéricos de cada candidato a una escala  $[0, 1]$  utilizando escalado *Min-Max*, y para mitigar la alta variabilidad diaria inherente a las publicaciones, se aplicó un filtro de suavizado temporal consistente en una media móvil de dos períodos (*window=2*).

La generación de la variable dependiente o variable objetivo (*IntencionVotoReal*) es uno de los pasos más críticos. Se extrajeron los resultados de 14 encuestas de diversas firmas (Ipsos Ciesmori, SPIE, Captura Consulting y Ciemcorp) divulgadas durante la ventana de análisis. Los porcentajes declarados fueron normalizados matemáticamente para que la intención de ambos contendientes sumara estrictamente 1 (o 100 %). Posteriormente, se ancló el último valor de la serie temporal al resultado electoral real del día de los comicios y se generó una serie de tiempo diaria ininterrumpida utilizando métodos de interpolación lineal matemática.

El modelo de entrenamiento (*train*) consumió únicamente los datos abarcados desde la primera hasta la última encuesta pública, reservando la porción final para la ventana de proyección predictiva (*pred*) hasta el día cero de las elecciones. Con este corte, las normalizaciones de validación (*StandardScaler*) se calibraron sobre el conjunto de entrenamiento para imposibilitar fugas de información futura (*data leakage*).


### 5.3.c. Evaluación de modelos

Siguiendo la arquitectura original, se entrenaron y evaluaron múltiples topologías algorítmicas bajo un esquema determinista de aprendizaje supervisado, comparando algoritmos lineales versus no lineales y validando el impacto de la reducción de dimensionalidad (*Principal Component Analysis*, PCA). El portafolio de modelos evaluados incluyó Regresión Lineal Clásica, Redes Neuronales de Regresión Generalizada (GRNN) ajustando el *sigma* mediante la mediana de las distancias euclidianas, y Perceptrón Multicapa con *Backpropagation* (MLP-BP) configurado con capas ocultas de 48 y 24 neuronas, función de activación *ReLU*, optimizador Adam y una tasa de aprendizaje iterativo. Adicionalmente, las salidas predictivas de las redes neuronales fueron filtradas con medias móviles exponenciales algorítmicas ( $\beta$  asimétrico dependiendo del cambio de tendencia) para suavizar la intención predictiva final.

El modelo con mejor desempeño predictivo resultó ser el ensamble MLP-BP acoplado con PCA, tal como se observa de manera suavizada en la Figura 5.1, alcanzando un Error Absoluto Medio (MAE) de 0,0279 y un Error Porcentual Absoluto Medio (MAPE) aproximado del 5,1 %. Este resultado superó al *baseline* basado en tomar el valor de la última encuesta disponible antes de la elección (cuyo MAE en el caso del candidato Paz fue de 0,1803). Cabe destacar que los modelos estrictamente lineales fracasaron sistemáticamente en el ajuste (presentando MAEs entre 0,29 y 0,31), confirmando empíricamente que la



relación entre el volumen de interacciones digitales y la tracción en las encuestas exhibe dinámicas fuertemente no lineales.



**Figura 5.1:** Series de tiempo de la evolución de la intención de voto utilizando el modelo MLP-BP con PCA.

Los resultados de esta primera etapa confirmaron de manera concluyente los problemas teóricos del SOMEN-DC señalados en la hipótesis: la dependencia estructural de las encuestas para el entrenamiento, el altísimo costo logístico de mantener infraestructura de *scraping* continuo y, más grave aún, la imposibilidad de extrapolar los pesos de la red neuronal a una nueva elección (no generalizabilidad).

## 5.4. Etapa 2 - Costa Rica: Modelado del crecimiento de interacciones

### 5.4.a. El problema estructural

Para construir un modelo generalizable a partir de  $M$  elecciones pasadas se requiere observar datos históricos. Sin embargo, las plataformas digitales únicamente muestran el total acumulado de interacciones en la fecha actual de la consulta: si se extrajesen datos en 2026 sobre una elección de 2023, sería imposible saber cuántas interacciones se habían acumulado el día de la elección y cuántas corresponden a tráfico residual o póstumo generado tras conocerse los resultados. Para resolver esto, es necesario estimar una curva teórica de crecimiento de interacciones que permita reconstruir el estado del post en cualquier momento pasado.

### 5.4.b. Recolección y validación del panel

Se recolectaron datos con una cadencia de extracción **diaria** durante un período de **30 días**: los 15 días previos a la primera vuelta presidencial del 1 de febrero de 2026 y los 15 días posteriores. Esta ventana simétrica garantizó capturar tanto el pico de actividad de

campana como la curva de decaimiento posterior, cubriendo así el ciclo de vida completo de las publicaciones más recientes. El proceso abarcó **cuatro plataformas** (Facebook, Instagram, TikTok y Twitter/X) y **4 candidatos presidenciales**.

Durante la validación de integridad se detectó que Twitter presentaba ausencia masiva de identificadores de publicación (*postIds*). Para solucionar esto, se generaron identificadores únicos calculando un hash MD5 sobre el contenido textual de cada *tweet*, permitiendo agrupar correctamente las observaciones longitudinales de una misma publicación. Se documentaron 765 publicaciones únicas de Facebook, 603 de Instagram, 344 de TikTok y 210 de Twitter/X.

La estandarización temporal se realizó calculando el **Día Relativo**: el tiempo transcurrido en días desde la fecha de publicación hasta el momento de extracción, siendo el día de publicación el Día 0. Sobre el panel bruto se observó el denominado **Sesgo de Composición**: cuando publicaciones de crecimiento rápido alcanzan su máximo y dejan de observarse, el promedio global cae artificialmente porque solo permanecen en la muestra las publicaciones con crecimiento más lento. Para corregirlo, se aplicó:

- **Forzado monótono** (*cummax*): las interacciones solo pueden crecer o mantenerse, nunca bajar.
- **Interpolación lineal**: los días sin observación dentro del período de vida de un *post* se rellenan por interpolación entre los puntos conocidos.
- **Forward Fill**: si un post alcanza el 100 % y deja de observarse, su valor se mantiene en los días siguientes para no deprimir el promedio.
- **Normalización a fracción**: las interacciones absolutas se convierten en fracción del máximo observado ( $\in [0, 1]$ ), haciendo comparables publicaciones de distinto volumen.


Tras aplicar estos filtros, se retuvieron las publicaciones con al menos dos observaciones y con máximo alcanzado en el Día 3 o posterior. El resultado final del panel fue de **1.922 publicaciones únicas** (765 de Facebook, 603 de Instagram, 344 de TikTok y 210 de Twitter/X, que suman exactamente 1.922), generando **19.439 pares** (día, fracción) aptos para el modelado.

#### 5.4.c. Análisis de la persistencia de interacciones

El primer objetivo del análisis fue cuantificar cuánto tiempo persiste la actividad de una publicación y si la candidata ganadora mostraba un patrón diferente al resto. Se aplicaron pruebas T de una muestra para cada Día Relativo: el crecimiento es estadísticamente significativo ( $p < 0,0001$ ) hasta el día 10, pero desde una perspectiva empírica se vuelve marginal a partir del día 5–7 ( $< 2\%$  diario). Esto justifica que una ventana de 14 días previos a la jornada de votación es suficiente y robusta para capturar el *engagement* relevante de una publicación.

La Figura 5.2 compara la curva promedio de interacciones acumuladas (estabilizada con *Forward Fill*) de la candidata ganadora Laura Fernández versus el promedio del resto de candidatos. Ambas curvas exhiben una forma de saturación prácticamente idéntica: en los primeros 2–3 días se acumula más del 80 % del total de interacciones, y a partir del Día 7 ambas han alcanzado el 100 % para fines prácticos. Esta convergencia morfológica confirma que los factores de crecimiento orgánico son propiedades de la plataforma, no

del candidato, validando el supuesto de estacionariedad del modelo y que el resultado electoral no altera la forma de la curva.



**Figura 5.2:** Porcentaje de interacciones acumuladas por Día Relativo (curvas estabilizadas): Laura Fernández, candidata ganadora (línea dorada continua), vs. promedio del resto de candidatos (línea azul discontinua). Ambas curvas son morfológicamente indistinguibles, lo que confirma que el patrón de crecimiento es una propiedad de la plataforma y no del candidato.

#### 5.4.d. Selección y calibración del modelo Weibull

Para modelar la curva de crecimiento acumulado de interacciones se evaluaron cuantitativamente tres familias de funciones: exponencial simple, logística y Weibull con *offset* temporal  $t_0$ . La Tabla 5.1 resume la evaluación empírica comparativa entre estas familias. El modelo exponencial simple  $F(t) = 1 - e^{-kt}$  fue descartado por presentar un ajuste deficiente ( $R^2$  promedio de 0,182), ya que asume una tasa de decaimiento rígida ( $\alpha = 1$ ) e imposibilita capturar la acumulación inicial diferenciada por plataforma. El modelo logístico  $F(t) = \frac{1}{1+e^{-k(t-t_0)}}$  mejoró levemente el ajuste ( $R^2 \approx 0,245$ ), pero su punto de inflexión simétrico fuerza a que la mitad de la acumulación ocurra en un instante fijo, contradiciendo la asimetría observada en los datos reales. La distribución Weibull con *offset* ( $R^2$  promedio de 0,449):

**Cuadro 5.1:** Comparativa de bondad de ajuste ( $R^2$ ) entre familias de funciones de crecimiento acumulado.

| Modelo                    | Ecuación                           | $R^2$        | Diagnóstico metodológico                                                               |
|---------------------------|------------------------------------|--------------|----------------------------------------------------------------------------------------|
| Exponencial simple        | $F(t) = 1 - e^{-kt}$               | 0,182        | Rígido ( $\alpha = 1, t_0 = 0$ ); subestima acumulación inicial.                       |
| Logístico                 | $F(t) = \frac{1}{1+e^{-k(t-t_0)}}$ | 0,245        | Inflexión simétrica forzada; inadecuado para asimetría.                                |
| <b>Weibull con offset</b> | $F(t) = 1 - e^{-k(t+t_0)^\alpha}$  | <b>0,449</b> | <b>Geometría flexible (<math>\alpha</math>) y adelanto inicial (<math>t_0</math>).</b> |


fue seleccionada por tres razones: (i) está acotada en  $[0, 1]$ , lo que la hace matemáticamente compatible con la fracción de interacciones acumuladas; (ii) el parámetro de forma  $\alpha$  controla la geometría de la curva (valores  $\alpha < 1$  producen curvas cóncavas con desaceleración progresiva, valores  $\alpha > 1$  producen curvas convexas con aceleración creciente, y  $\alpha = 1$  recupera el caso exponencial simple que fue descartado); y (iii) el *offset*  $t_0 > 0$  adelanta el origen de la acumulación, haciendo que  $F(0) > 0$  y capturando así la explosión masiva de interacciones que ocurre en las primeras horas antes de que  $t$  alcance el primer día completo.

Los parámetros  $k$  (tasa de crecimiento),  $\alpha$  (forma) y  $t_0$  (adelanto inicial) se calibraron por plataforma mediante optimización no lineal por mínimos cuadrados (*curve\_fit*), ensayando múltiples puntos de partida para evitar mínimos locales. Los parámetros óptimos se presentan en la Tabla 5.2.

**Cuadro 5.2:** Parámetros Weibull calibrados por plataforma y bondad de ajuste ( $R^2$ ) sobre el panel de fracciones.

| Plataforma | $k$    | $\alpha$ | $t_0$ [días] | $t_0$ [horas] | $R^2$ |
|------------|--------|----------|--------------|---------------|-------|
| Facebook   | 0,9480 | 0,8230   | 1,93         | 46h           | 0,351 |
| Instagram  | 1,1369 | 0,5210   | 0,04         | 1h            | 0,403 |
| TikTok     | 1,3272 | 0,5124   | 0,79         | 19h           | 0,351 |
| Twitter/X  | 1,4453 | 1,1422   | 0,26         | 6h            | 0,691 |


Los  $R^2$  del panel resultan matemáticamente bajos en Facebook y TikTok. Un análisis de descomposición de varianza reveló que la varianza *intra-publicación* (ruido de medición dentro de un mismo *post*: hora de publicación, viralidad puntual, algoritmo de la plataforma) representa el 66,8 % de la varianza total, frente al 29,2 % de varianza *inter-publicaciones* (diferencias entre publicaciones distintas). Esto implica que un  $R^2$  bajo es matemáticamente irreducible para cualquier modelo de curva promedio, y que el modelo captura correctamente la forma global de la curva. El diagnóstico se ilustra en la Figura 5.3: la mediana de las fracciones se concentra rápidamente cerca del 100 % (72 % en el día 0, 87 % al día 1, 98 % al día 3), pero la dispersión es alta en los primeros días, reflejando la heterogeneidad entre publicaciones.



**Figura 5.3:** Distribución de la fracción acumulada de interacciones ( $n_t/n_{\text{máx}}$ ) por Día Relativo, sobre el panel completo de 1.922 publicaciones. La línea roja muestra la mediana: en el Día 0 ya se acumula el 72 % del total final; al Día 3, el 98 %. La dispersión en los días iniciales refleja la heterogeneidad entre publicaciones, razón por la que el  $R^2$  global es bajo pero el modelo promedio es válido.

La Figura 5.4 muestra el ajuste del modelo Weibull para cada plataforma. Cada panel presenta la mediana empírica (puntos negros), el rango intercuartílico empírico (área


azul) y la curva del modelo calibrado (roja). Twitter/X exhibe el mejor ajuste ( $R^2 = 0.691$ ) dado que sus publicaciones alcanzan el 100 % muy rápidamente y con poca dispersión.



**Figura 5.4:** Ajuste del modelo Weibull con *offset* temporal por plataforma. Puntos negros: mediana empírica. Área azul: rango intercuartílico (IQR) empírico. Curva roja: modelo calibrado. Los parámetros  $k$ ,  $\alpha$  y  $t_0$  de cada plataforma se detallan en la Tabla 5.2.

#### 5.4.e. Validación: precisión en la estimación del total final

La Figura 5.5 muestra visualmente estos resultados. En el panel izquierdo se observa que el MAPE decae con el día de observación: a partir del Día 1, todas las plataformas salvo Instagram se ubican por debajo del umbral de referencia del 20 %, y a partir del Día 3 las cuatro plataformas lo hacen (Instagram alcanza un MAPE mediano de 12,06 % en ese punto, Tabla 6.2). El umbral del 20 % se adopta como criterio orientador porque en aplicaciones de reconstrucción histórica un error inferior a un quinto del total estimado permite calcular la dominancia relativa entre candidatos con margen de error suficientemente acotado; no es un estándar de la literatura sino una referencia pragmática que puede ajustarse según el contexto. El panel derecho ilustra la distribución completa del error al Día 3, mostrando que la gran mayoría de las publicaciones se estima con alta precisión. Instagram presenta el MAPE más alto en días muy tempranos (Día 0 y Día 1) debido a la fuerte concentración de interacciones en las primeras horas, que el modelo no captura completamente con el offset  $t_0 = 0,04$  días.




**Figura 5.5:** Evaluación de la precisión proyectiva del modelo Weibull. **Izquierda:** MAPE mediano por plataforma y día de observación; la línea discontinua marca el umbral de referencia del 20 %. **Derecha:** distribución del error por publicación al Día 3. A partir del Día 3, las cuatro plataformas se ubican por debajo del 20 %; Instagram, que en el Día 1 registra el MAPE más alto (20,72 %), converge a 12,06 % en el Día 3.

#### 5.4.f. Función de reconstrucción histórica

Con los parámetros calibrados, se implementó una función de reconstrucción que, dada la fecha de publicación, las interacciones observadas en un día  $t$  y la plataforma, estima el total final de interacciones y genera la curva diaria completa. Formalmente:

$$\hat{N} = \frac{n_t}{F(t; k, \alpha, t_0)} \quad (5.2)$$

donde  $n_t$  son las interacciones observadas en el Día  $t$  y  $F(t; k, \alpha, t_0) = 1 - e^{-k(t+t_0)^\alpha}$  es la fracción acumulada predicha. Los parámetros exportados a un archivo de configuración garantizan consistencia entre las dos fases del estudio.



**Figura 5.6:** Ejemplos de reconstrucción histórica de interacciones con el modelo Weibull calibrado. **Izquierda:** publicación de Facebook con 50,000 interacciones totales conocidas; el modelo distribuye las interacciones nuevas por día (barras) y la fracción acumulada (curva roja). **Derecha:** publicación de Instagram con 43,000 interacciones medidas el Día 10; el modelo infiere el total final y reconstruye la curva completa.

### 5.5. Etapa 3 - Colombia: Construcción del dataset y modelado

Con la solución temporal formalizada, la tercera etapa se concentró en la construcción del *dataset* de entrenamiento masivo. El código fuente completo de esta etapa (scraping, procesamiento, modelos y cuadernos de análisis) está disponible en el repositorio público de la investigación (Sotelo Aguilar, 2026), junto con el archivo `requirements_tesis.txt` que especifica las versiones de las dependencias Python utilizadas. Se estableció un protocolo de diseño para capturar información exclusiva de las campañas de las elecciones locales de alcaldías en Colombia de octubre de 2023. Se definió un universo geográfico abarcando las 33 ciudades más pobladas de Colombia, procediendo a compilar interacciones generadas estrictamente en la ventana de 14 días previos a los comicios.

Por políticas y restricciones agresivas de la API *Graph* impuestas corporativamente por Meta en sus versiones recientes, Instagram tuvo que ser excluido de la extracción sistematizada. Por tanto, la adquisición de datos de fuentes abiertas iteró sobre tres infraestructuras concurrentes automatizadas a través de un *pipeline*: Playwright para automatización de navegadores ocultos (*headless*) contra la interfaz web de Twitter/X; y consultas de alto rendimiento hacia la API privada no documentada de TikTok y las colecciones indexadas de Facebook a través de *Apify*.



Para delimitar el universo de análisis, se aplicaron filtros de exclusión con criterios explícitos que se documentan a continuación junto con sus implicaciones metodológicas. Solo ingresaron al *dataset* actores políticos con más de 10.000 votos confirmados en los escrutinios finales.<sup>1</sup> De las 33 ciudades iniciales se excluyeron dos: la capital Bogotá<sup>2</sup> y Piedecuesta (porque la candidatura ganadora eliminó intencionalmente sus perfiles digitales ante procesos legales en curso), dejando **31 ciudades competitivas**. En casos anómalos como el de Santa Marta, donde la candidatura de mayor votación enfrentó revocatoria legal posterior, el estudio consideró ganador computacional al actor con mayor volumen bruto de votos consignados, para preservar la correlación con la intención ciudadana.

Tras los filtros geográficos y de calidad de datos documentados en el análisis exploratorio preliminar, el universo hábil final consolidó 5.776 publicaciones únicas distribuidas a través de las tres infraestructuras monitoreadas (2.511 en Facebook, 2.346 en Twitter/X y 919 en TikTok). Estas entradas correspondieron a un censo final de 328 candidatos repartidos a través de 31 ciudades competitivas. Sobre los 120 candidatos que superaban la barrera estadística de los 10.000 votos (cuya cobertura digital era altísima, con el 92,6 % de ellos poseyendo publicaciones de red activas en el archivo), los análisis paramétricos confirmaron tempranamente la existencia de señal predictiva: las interacciones totales medias evidenciaban que los ganadores promediaban 44.252 frente a 28.011 de los perdedores, y las pruebas U de Mann-Whitney validaban una superioridad de *engagement* medio por publicación estadísticamente significativa para un 95 % de confianza ( $p = 0,0481$ ).

Para contextualizar la capacidad predictiva de las señales digitales, conviene contrastarlas con tres referencias escalonadas. Con un promedio de 3,84 candidatos por contienda, un pronosticador puramente aleatorio acertaría al ganador en  $1/3,84 \approx 26,0\%$  de las jurisdicciones por puro azar. Un *baseline* empírico básico que asignara la victoria al candidato con mayor **volumen nominal** de interacciones acertó en el **57,58 %** de las 31 contiendas: más del doble que el azar, pero muy lejos de ser un predictor fiable. En cambio, cuando la señal se reexpresa como **dominancia relativa**, es decir, la cuota de *likes* de un candidato sobre el total de la contienda, que es la variable central de ELA-NOM, el heurístico de asignar la victoria al candidato con mayor dominancia acertó en el **71,0 %** de los casos

<sup>1</sup> Este umbral es una decisión de diseño pragmática para eliminar candidatos «testimoniales» sin campaña digital activa real, es decir, candidaturas que acumulan escasas interacciones en redes y votos mínimos, cuya presencia degradaría la señal colectiva del modelo. El valor de 10.000 votos se definió por criterio del investigador; no existe una regla técnica que lo determine de forma única, y un umbral distinto (p. ej., 5.000 o 20.000) habría generado un corpus diferente. El principal riesgo metodológico de este filtro es que introduce un **sesgo de selección sobre la variable dependiente**: la muestra de entrenamiento y validación excluye exactamente a los candidatos con peor desempeño electoral, sesgando las métricas de desempeño ( $MAE=9,56$  pp,  $R^2_{oos}=0,518$ ) hacia el subconjunto más predecible. En ausencia de un criterio de exclusión que no dependa de los resultados electorales, por ejemplo, un umbral basado exclusivamente en actividad digital, esta limitación es inherente al diseño y debe considerarse al interpretar las métricas reportadas.

<sup>2</sup> La exclusión de Bogotá responde a la violación del **supuesto de localidad geográfica** que sustenta el modelo: que la mayoría de las interacciones de un candidato en redes sociales provienen de votantes potenciales de su circunscripción electoral. En las elecciones de alcaldía de Bogotá (2023), el candidato Gustavo Bolívar, quien ocupó el tercer lugar en votos, acumuló varios millones de interacciones, superando con holgura a todos los demás candidatos del panel colombiano. Sin embargo, Gustavo Bolívar es simultáneamente un reconocido libretista y escritor con audiencia en toda Latinoamérica y el mundo, lo que implica que una fracción indeterminada, y probablemente mayoritaria, de sus interacciones digitales no proviene de electores bogotanos. Incluirlo habría asignado una señal digital masiva a una cuota de voto moderada (tercer lugar), rompiendo la función de mapeo que el modelo intenta aprender. El diagnóstico de influencia no se calculó formalmente, pero la escala de la distorsión, órdenes de magnitud por encima del siguiente candidato del panel, hacía su exclusión justificada. Esta decisión implica que el modelo no está calibrado para candidatos con audiencias digitales supranacionales.

(22 de 31 contiendas), casi tres veces la referencia aleatoria. Esta progresión (del 26,0 % al 57,6 % y finalmente al 71,0 %) ilustra por qué el diseño del modelo prioriza la dominancia relativa sobre el volumen nominal como predictor de la cuota electoral.

## 5.6. Modelado predictivo

La etapa de modelado concentró los análisis econométricos bajo dos grandes paradigmas: regresión continua para estimar la cuota de voto, y clasificación binaria para identificar al ganador por contienda.

### 5.6.a. Modelo de regresión fraccional (cuota de voto)

El objetivo central de la tesis requiere estimar la **cuota de voto** de cada candidato dentro de su contienda, no identificar al ganador. Al estar la cuota acotada en  $(0, 1)$ , se empleó una **regresión logística fraccional** (Papke & Wooldridge, 1996): un GLM con familia binomial y *link* logit, que respeta los límites naturales sin transformaciones adicionales y conecta con la escala log-odds donde la señal digital es más limpia.

La señal digital principal es el **logit de la dominancia relativa de likes**:

$$\text{logit}(\text{dom}_{likes,c}) = \log\left(\frac{\text{dom}_{likes,c}/100}{1 - \text{dom}_{likes,c}/100}\right) \quad (5.3)$$

donde  $\text{dom}_{likes,c}$  es la cuota porcentual de *likes* del candidato  $c$  sobre el total de la contienda.<sup>3</sup> El modelo ajustado con errores agrupados por contienda sobre los 120 candidatos arrojó:

$$\hat{\beta}_{\text{logit\_likes}} = 0,4231 \quad (z = 5,90, p < 0,001) \quad (5.4)$$

Lo que implica que un incremento de una unidad en el logit de la cuota de *likes* multiplica los *odds* de la cuota de voto por  $e^{0,42} \approx 1,53$ . La validación *leave-one-contest-out* (LOCO-CV) sobre las 31 contiendas produjo los resultados resumidos en la Tabla 5.3.

**Cuadro 5.3:** Métricas fuera de muestra del modelo de regresión fraccional (LOCO-CV sobre 31 contiendas, 120 candidatos).

| Modelo                                                | MAE (pp) | $R^2_{oos}$ | Top-1 |
|-------------------------------------------------------|----------|-------------|-------|
| Regresión fraccional (solo logit_likes)               | 11,52    | 0,460       | 71 %  |
| Baseline proporcionalidad (cuota likes = cuota votos) | 12,61    | 0,185       | 71 %  |
| Baseline uniforme ( $1/k$ candidatos)                 | 12,49    | 0,306       | 39 %  |

<sup>3</sup>Para los candidatos sin actividad digital registrada (dominancia = 0 %), el logit es matemáticamente indefinido. En la implementación se aplicó un recorte (*clipping*) con  $\varepsilon = 10^{-3}$  (0,1 %), de modo que  $\text{dom}_{likes,c}$  se evaluó en el intervalo  $[10^{-3}, 1 - 10^{-3}]$  antes de aplicar el logit. Esto asigna  $\text{logit}(0,001) \approx -6,91$  a los aproximadamente 9 candidatos sin publicaciones activas (el 7,4 % del panel). A modo de análisis de sensibilidad: con  $\varepsilon = 10^{-2}$  (1 %) el logit imputado sería  $\approx -4,60$ , una diferencia de 2,31 unidades en logit que, multiplicada por el coeficiente estimado del modelo núcleo ( $\hat{\beta} \approx 0,111$ ), desplazaría la predicción del candidato en  $\approx 0,26$  unidades de cuota ( $\approx 26$  pp). Esta sensibilidad confirma que la declaración del valor de  $\varepsilon$  es esencial para la replicabilidad. El valor  $\varepsilon = 10^{-3}$  se estableció como convención en el código de procesamiento (`generar_figuras_colombia.py`, función `to_logit`), y es el mismo utilizado en todos los cálculos reportados en este documento.



El modelo supera en MAE y  $R_{oos}^2$  a ambos *baselines*, confirmando que la señal digital es informativa más allá de la proporcionalidad directa. El *top-1* coincide con el del *baseline* de proporcionalidad (71 %), lo cual es esperable: ambos usan la misma variable ordinal. Sin embargo, el modelo fraccional aporta estimaciones de magnitud más calibradas.

### 5.6.b. Selección de especificación y regularización (ElasticNet)

Para determinar si añadir variables al modelo reduce el MAE fuera de muestra o solo produce sobreajuste, se realizó un proceso de selección honesta con las siguientes reglas:

1. Toda métrica se calcula **fuera de muestra** mediante validación *leave-one-contest-out*. Ninguna decisión se toma por el ajuste en entrenamiento.
2. La **métrica única de selección** es el MAE de la cuota de voto (en puntos porcentuales), siempre comparado contra el *baseline* de proporcionalidad.
3. La **regularización** (ElasticNet) realiza la selección de variables automáticamente, eliminando las redundantes por multicolinealidad.
4. La selección es **anidada**: un CV interno elige los hiperparámetros; un CV externo mide el desempeño real, evitando el sesgo de selección.

Para la regularización se empleó un modelo **ElasticNet**, que combina las ventajas de la penalización Lasso ( $L_1$ , para selección automática de características ajustando a cero los coeficientes redundantes) y Ridge ( $L_2$ , para la contracción suave de coeficientes ante multicolinealidad). La función de pérdida minimizada es:

$$\min_{\beta} \left\{ \mathcal{L}_{\text{fraccional}}(\beta) + \alpha \left[ \gamma \|\beta\|_1 + \frac{1-\gamma}{2} \|\beta\|_2^2 \right] \right\} \quad (5.5)$$

donde  $\alpha$  ajusta la intensidad de regularización y  $\gamma \in [0, 1]$  (*l1\_ratio*) balancea entre selección estricta y contracción suave. En la calibración anidada sobre las 31 contiendas,  $\gamma = 0,10$  y  $\alpha = 0,0475$  resultaron óptimos.

La estructura de validación fuera de muestra (*out-of-sample*) del estudio opera en dos niveles definidos:

1. **Nivel 1 - Fuera de muestra por contienda (LOCO-CV anidado)**: El proceso se ejecuta en dos fases. En la **Fase 1** (evaluación honesta), se realiza un ciclo de 31 pliegues externos: en cada uno se bloquea una ciudad completa como conjunto de prueba y se reservan las 30 ciudades restantes para entrenamiento. Dentro de cada pliegue externo, un *grid search* interno evalúa 120 combinaciones de hiperparámetros ( $\alpha \in [10^{-3}, 10]$  con 30 valores en escala logarítmica;  $\gamma \in \{0,3, 0,5, 0,8, 1,0\}$ ) mediante un CV adicional sobre las 30 ciudades de entrenamiento, sin acceder en ningún momento a la ciudad bloqueada. La combinación ganadora de cada pliegue externo se utiliza para entrenar el ElasticNet definitivo de ese pliegue, que luego predice la ciudad bloqueada. El MAE fuera de muestra se obtiene como promedio de los 31 errores individuales. En la **Fase 2** (modelo final), los hiperparámetros más frecuentes a lo largo de los 31 pliegues ( $\hat{\alpha} = 0,0475$ ,  $\hat{\gamma} = 0,10$ ) se utilizan para entrenar el ElasticNet sobre las 31 ciudades completas, produciendo los coeficientes definitivos del modelo.
2. **Nivel 2 - Fuera de muestra por formato de elección (Evaluación prospectiva 2026)**: Evalúa la transferibilidad aplicando el núcleo agnóstico entrenado en elecciones municipales a una elección nacional bipolar sin reentrenamiento.

El *pool* inicial de nueve variables candidatas incluyó seis cuotas digitales en logit ( $f_{likes\_dom}$ ,  $f_{coment\_dom}$ ,  $f_{compart\_dom}$ ,  $f_{likes\_pp}$ ,  $f_{coment\_pp}$ ,  $f_{compart\_pp}$ ), dos variables territoriales ( $n_{candidatos}$ ,  $\log(pob)$ ) y un moderador de interacción ( $f_{likes\_dom} \times (\log(pob) - \overline{\log(pob)})$ ). El análisis de factor de inflación de la varianza (VIF) reveló alta multicolinealidad entre las cuotas digitales, respaldando el uso de ElasticNet.

La **especificación ganadora** retuvo únicamente dos variables:

$$\hat{y}_c = \beta_0 + \beta_1 \cdot f_{likes\_dom,c} + \beta_2 \cdot (f_{likes\_dom,c} \times (\log pob - \overline{\log pob})) \quad (5.6)$$

con  $\hat{\beta}_1 = 0,111$  y  $\hat{\beta}_2 = 0,026$  ( $\alpha$  óptimo = 0,0475,  $L1$  ratio = 0,10, intercepto = 0,258). Esta especificación logró el menor MAE fuera de muestra entre todas las combinaciones evaluadas, y fue seleccionada como modelo definitivo para la aplicación prospectiva.

### 5.6.c. Aplicación prospectiva: Segunda Vuelta Presidencial Colombia 2026

El 21 de junio de 2026 se celebró la segunda vuelta de las elecciones presidenciales de Colombia, enfrentando a **Iván Cepeda Castro** y **Abelardo De la Espriella**. Esta contienda constituyó el escenario de prueba definitivo del modelo ELA-NOM: por primera vez, el modelo entrenado en elecciones de alcaldes 2023 se aplicaba a una elección distinta, presidencial y de alcance nacional, sin reentrenamiento alguno.

El proceso de *feature engineering* replicó exactamente la metodología de entrenamiento. Se calculó la dominancia de *likes* de cada candidato sobre el total de la contienda presidencial (444 publicaciones en total: 255 de Cepeda y 189 de De la Espriella). Iván Cepeda acumuló 17.087.679 *likes* (77,6 % de dominancia) frente a 4.926.361 de Abelardo De la Espriella (22,4 %).

Una corrección metodológica fue necesaria para esta aplicación: el modelo fue entrenado en contiendas con un promedio de 3,84 candidatos (intercepto  $\approx 0,258$ , equivalente a una cuota media del 26 % aproximadamente), mientras que una segunda vuelta tiene exactamente dos candidatos y una cuota base del 50 %. Se eliminó por tanto el intercepto multi-candidato y se re-centró la señal sobre la línea base del 50 %:

$$\hat{p}_c^{(2)} = 0,50 + (\hat{\beta} \cdot \mathbf{x}_c) \quad (5.7)$$

donde  $\hat{\beta} \cdot \mathbf{x}_c$  es la contribución pura de las *features* sin el intercepto. Los pronósticos finales normalizados suman exactamente 1. El modelo otorgó a Cepeda Castro una señal digital de +0,2294 en logit, traducándose en un pronóstico de **60,5 %** frente al **39,5 %** de De la Espriella.

El resultado real de la elección fue aproximadamente 50 %–50 %, con victoria de Abelardo De la Espriella. El modelo erró **10,98 pp** en esta predicción, superando en **1,42 pp** su MAE histórico de validación (9,56 pp sobre las 31 contiendas municipales de entrenamiento): un desempeño ligeramente inferior al observado en la muestra de referencia, coherente con el salto de formato (de elecciones de alcaldías locales con 3,84 candidatos en promedio a una segunda vuelta presidencial nacional y binaria). La dominancia digital de Cepeda Castro (77,6 % de los *likes*) generó una señal robusta pero insuficiente para predecir con precisión el resultado en una contienda excepcionalmente reñida (margen real: 0,96 pp). Este hallazgo es consistente con la literatura: los giros electorales de última semana, frecuentemente asociados a eventos exógenos o movilización diferencial,

constituyen el límite empírico más resistente de cualquier modelo basado en métricas de *engagement* agregadas.

## 6 Resultados

### 6.1. Resultados de Bolivia (Etapas 1)

La replicación del enfoque de *nowcasting* electoral basado en encuestas sobre la segunda vuelta presidencial boliviana (Paz vs. Quiroga, octubre de 2025) arrojó resultados mixtos que confirmaron las limitaciones estructurales de este paradigma y justificaron el viraje metodológico hacia la Etapa 2.

#### Datos y configuración experimental

Se construyó un *dataset* de 308 observaciones diarias (26 columnas de características) que combinaba métricas diarias de interacción, *posts*, *likes*, *shares* y comentarios, de Facebook, Instagram, TikTok y Twitter/X para ambos candidatos. La variable objetivo fue la intención de voto real interpolada a partir de las encuestas publicadas entre la primera y la última medición demoscópica disponible. El resultado real del 19 de octubre de 2025 fue: **Paz: 54,53 %**, **Quiroga: 45,47 %**.

#### Comparativa de modelos

Se evaluaron seis modelos (más el *baseline* de última encuesta) sobre su predicción en el día de elecciones. La Tabla 6.1 resume las métricas para el candidato Paz (el ganador), que son las más relevantes para la predicción. La Figura 6.1 ilustra la evolución temporal del mejor modelo.

El modelo **MLP-BP + PCA** fue el único que superó al *baseline*: predijo un 51,74 % para Paz (error absoluto de solo 2,79 puntos porcentuales frente al resultado real de 54,53 %), mejorando más de seis veces al estimador inercial de última encuesta ( $MAE = 0,1803$ ). Los modelos de regresión lineal fallaron de manera categórica, incluso invirtiendo el resultado (prediciendo a Quiroga como ganador con 75,15 %), lo que confirma que la relación entre interacciones digitales e intención de voto no es lineal. El GRNN quedó sistemáticamente “atascado” sobreestimando a Quiroga durante toda la serie temporal (véase Figura 6.1).

#### Limitaciones estructurales identificadas


A pesar del resultado numérico del MLP-BP+PCA, el análisis reveló tres falencias críticas que desaconsejaron continuar esta ruta:

1. **Falta de generalización:** Los pesos y la topología de la red neuronal son específicos de este evento electoral. No existe mecanismo para transferir el aprendizaje a otra contienda sin reentrenamiento completo, haciendo el modelo irreplicable.

**Cuadro 6.1:** Métricas de predicción en el día de elecciones: candidato Paz (real: 54,53 %)†

| Modelo                     | Predicción Paz | MAE           | MAPE         |
|----------------------------|----------------|---------------|--------------|
| Baseline (última encuesta) | 36,50 %        | 0,1803        | 33,1 %       |
| Regresión Lineal           | 24,85 %        | 0,2968        | 54,4 %       |
| Regresión Lineal + PCA     | 23,38 %        | 0,3115        | 57,1 %       |
| MLP-BP                     | 46,91 %        | 0,0762        | 14,0 %       |
| <b>MLP-BP + PCA</b>        | <b>51,74 %</b> | <b>0,0279</b> | <b>5,1 %</b> |
| GRNN                       | 34,67 %        | 0,1986        | 36,4 %       |
| GRNN + PCA                 | 34,48 %        | 0,2005        | 36,8 %       |

† Las métricas se calcularon sobre el único punto observable fuera de muestra: la predicción del día de la elección vs. el resultado certificado. Por construcción matemática, MAE = RMSE cuando  $n = 1$ ; la columna RMSE se omite por ser redundante. A modo de referencia heurística, el error de predicción en el día de la elección (2,79 pp) es aproximadamente 1,2 veces el error medio del modelo sobre las 14 fechas de encuesta disponibles ( $\approx 6,2$  pp). Este cociente sugiere que la predicción puntual no fue atípicamente precisa respecto a la calibración general del modelo; sin embargo, dado que el conjunto de prueba consta de un único punto, esta comparación tiene carácter ilustrativo y no constituye una medida formal de generalización.



**Figura 6.1:** Evolución diaria de la intención de voto estimada por el modelo MLP-BP+PCA (líneas continuas) vs. la intención de voto real interpolada desde encuestas (líneas discontinuas) para Paz (verde) y Quiroga (rojo). Las líneas verticales punteadas marcan la fecha de publicación de cada encuesta. El modelo captura la tendencia ascendente de Paz en las últimas semanas, aunque con alta varianza diaria.

2. **Ceguera ante giros súbitos:** Los cambios de favorabilidad ocurridos en la última semana de campaña, cuando Paz remontó significativamente en las encuestas, no fueron capturados por las métricas de interacciones acumuladas. El modelo operó con un rezago estructural irrecuperable.
3. **Disociación de la señal TikTok:** Un análisis de importancia de variables identificó que la dinámica de viralidad de TikTok operaba en un plano desacoplado del resto de plataformas. Los picos de interacción en TikTok inyectaban varianza espuria en momentos en que la intención de voto real permanecía estacionaria, degradando la señal agregada.

Un experimento adicional con *lag features* (memorias de 1, 2 y 3 días) y ponderación temporal exponencial (mayor peso a días recientes) buscó dotar al modelo de capacidad para detectar cambios de tendencia. Si bien este enfoque redujo el sesgo en períodos de alta actividad, amplificó el ruido diario y no logró resolver la inestabilidad en los días de elección. Estos hallazgos consolidaron la decisión de redirigir el enfoque hacia un modelo de regresión fraccional elección-agnóstico, independiente de las dinámicas específicas de un único evento.

## 6.2. Resultados de Costa Rica (Etapa 2)

El modelado paramétrico del crecimiento de interacciones resolvió satisfactoriamente el obstáculo estructural que impide explotar registros históricos sin infraestructura activa de extracción. El panel de 30 días (15 antes y 15 después del día de elecciones), recogido con cadencia diaria sobre las cuatro plataformas hegemónicas, produjo **1.922 publicaciones válidas** y **19.439 observaciones** con las que se calibraron los parámetros del modelo Weibull.

### Morfología del crecimiento: ganadores y no ganadores

Un hallazgo central del análisis es que la **curva de crecimiento acumulado de interacciones es morfológicamente idéntica entre la candidata ganadora y el resto de los competidores** (véase Figura 5.2 en la sección de metodología). En ambos grupos, más del 80 % de las interacciones totales se acumulan en los primeros 2–3 días desde la publicación, y a partir del Día 7 la curva es prácticamente plana. Las pruebas T día a día confirman que el crecimiento es estadísticamente significativo ( $p < 0,0001$ ) hasta el Día 10, pero empíricamente irrelevante ( $< 2\%$  diario) a partir del Día 5–7.

Este resultado tiene una implicación metodológica crítica: **el patrón de crecimiento orgánico es una propiedad de la plataforma, no del candidato ni del resultado electoral**. Esto valida el supuesto de estacionariedad del modelo Weibull y permite aplicar los mismos parámetros calibrados en Costa Rica 2026 para reconstruir históricamente las interacciones de cualquier otra elección.

### Precisión proyectiva del modelo Weibull

Los parámetros calibrados ( $k, \alpha, t_0$ ) para cada plataforma se detallan en la Tabla 5.2. La evaluación de precisión se realizó simulando el escenario real de uso: tomando la medición de un día  $t$  y estimando el total final como  $\hat{N} = n_t / F(t; k, \alpha, t_0)$ . Los resultados del MAPE mediano se resumen en la Tabla 6.2 y se visualizan en la Figura 5.5.

Los resultados son robustos en la mayoría de las plataformas. Al observar una publicación en su **Día 3**:

- **Facebook**: MAPE mediano de **2,12 %** – prácticamente sin error desde el día 3.
- **TikTok**: MAPE mediano de **5,94 %** – muy por debajo del umbral de referencia del 20 %.
- **Twitter/X**: MAPE mediano de **0,38 %** – error casi nulo; las publicaciones de Twitter se saturan en horas.
- **Instagram**: MAPE mediano de **12,06 %** – el más alto, explicado por la extrema concentración de interacciones en las primeras horas (offset  $t_0 = 0,04$  días = 1 hora).

En términos globales, entre el 89 % y el 99 % de las publicaciones (según la plataforma) se estiman con un error inferior al 20 % al observarlas en el Día 3. A partir del **Día 7**, el error mediano cae por debajo del 4 % en todas las plataformas.

**Cuadro 6.2:** MAPE mediano (%) en la estimación del total final de interacciones, por plataforma y día de observación (panel longitudinal Costa Rica 2026).

| Plataforma | Día 0   | Día 1   | Día 2   | Día 3   | Día 7  |
|------------|---------|---------|---------|---------|--------|
| Facebook   | 11,27 % | 6,92 %  | 3,73 %  | 2,12 %  | 0,32 % |
| Instagram  | 64,77 % | 20,72 % | 15,67 % | 12,06 % | 3,76 % |
| TikTok     | 25,36 % | 14,20 % | 8,35 %  | 5,94 %  | 2,29 % |
| Twitter/X  | 56,37 % | 11,09 % | 2,55 %  | 0,38 %  | 0,00 % |

### Función de reconstrucción histórica

Con los parámetros calibrados se implementó y validó la **función de reconstrucción histórica** (véase Figura 5.6), que dado el total de interacciones observado en un día  $t$  y la plataforma, genera la curva diaria completa de interacciones nuevas e infiere el estado del post en cualquier fecha pasada. No se documentaron violaciones de monotonicidad (una publicación nunca pierde interacciones al retroceder en el tiempo), y el error mediano inyectado a la serie temporal en el Día 14 pre-elección es matemáticamente cero para Facebook y Twitter/X.

## 6.3. Resultados de Colombia (Etapa 3)


### 6.3.a. Señal digital y correlación con el voto

La evaluación del ecosistema digital de las elecciones de alcaldes de 2023 sobre las 31 ciudades competitivas colombianas confirmó la hipótesis fundacional del estudio: las interacciones en redes sociales albergan una señal predictiva real y cuantificable sobre el comportamiento en urnas.

Los candidatos ganadores evidenciaron una mayor mediana de *engagement* por publicación que sus contendientes derrotados ( $p = 0,0481$ , prueba U de Mann-Whitney sobre la muestra mancomunada). Para controlar la dependencia intra-contienda derivada del anidamiento de los 120 candidatos en las 31 ciudades, se evaluó una prueba de permutación dentro de contienda intercambiando las etiquetas de ganador/perdedor dentro



de cada municipio en 10.000 iteraciones (semilla = 42). El estadístico observado fue una diferencia de medianas de 112 puntos de *engagement*; ninguna de las 10.000 permutaciones igualó o superó ese valor, arrojando un p-valor empírico  $p < 0,0001$ , lo que ratificó la significancia de la ventaja digital con mayor contundencia que el test mancomunado. Asimismo, la **dominancia relativa** de *likes* ( $\rho = 0,70$  mancomunado sobre todos los candidatos, véase la Figura 6.2) superó ampliamente al volumen nominal de interacciones ( $\rho \approx 0,45$ ) como predictor de la cuota electoral. Un heurístico ingenuo basado en asignar la victoria al candidato con mayor dominancia de *engagement* acertó en el 71,0 % de las 31 contiendas (22 de 31 aciertos, IC 95 % de Wilson: 53,4 %–83,9 %). Dado que dominancia y cuota son variables composicionales que comparten denominador dentro de cada contienda, se cuantificó la inflación mecánica del coeficiente de Spearman mediante una segunda prueba de permutación: en 10.000 iteraciones se redistribuyeron aleatoriamente los *likes* entre candidatos dentro de cada municipio, preservando el total de *likes* por ciudad pero eliminando la relación entre *likes* y votos. El  $\rho$  promedio bajo esa hipótesis nula composicional fue  $\rho_{mec.} = 0,261$  (IC empírico al 95 %: hasta 0,397), lo que implica que aproximadamente el 39 % del  $\rho$  observado se debe a la mecánica composicional y el 61 % restante ( $\rho_{real} \approx 0,41$ ) constituye señal predictiva genuina entre *likes* y votos. Ninguna de las 10.000 permutaciones de *likes* alcanzó el  $\rho$  observado ( $p < 0,0001$ ). Esta descomposición confirma que la advertencia composicional reduce la magnitud del  $\rho$  pero no invalida la relación; la validez predictiva fuera de muestra la establece el protocolo LOCO-CV.



**Figura 6.2:** Relación entre la dominancia digital de *likes* y la cuota de voto real en las elecciones de alcaldes de Colombia 2023 (120 candidatos, 31 contiendas). La correlación de rango de Spearman calculada sobre todos los candidatos (mancomunada) es  $\rho = 0,70$  ( $p < 0,001$ ). Los puntos azules corresponden a ganadores y los rojos a perdedores.




### 6.3.b. Modelo de regresión fraccional

El modelo de regresión logística fraccional entrenado sobre los 120 candidatos (31 contiendas) produjo, mediante validación *leave-one-contest-out* (LOCO-CV), los resultados que se resumen junto al resto de especificaciones evaluadas en la Tabla 6.3.

**Cuadro 6.3:** Escalera de resultados del proceso AutoML acotado: comparativa completa de especificaciones (LOCO-CV, 31 contiendas, 120 candidatos).

| Modelo                                                 | MAE (pp)    | $R^2_{oos}$  | Top-1  |
|--------------------------------------------------------|-------------|--------------|--------|
| Baseline proporcionalidad                              | 12,61       | 0,185        | 71,0 % |
| Núcleo digital (solo logit_likes)                      | 11,52       | 0,460        | 71,0 % |
| <b>Modelo completo (ElasticNet, selección anidada)</b> | <b>9,56</b> | <b>0,518</b> | 64,5 % |
| Gradient boosting superficial (control)                | 9,91        | 0,515        | 67,7 % |

El modelo completo con selección anidada ElasticNet reduce el MAE en 3,05 pp respecto al *baseline* de proporcionalidad y en 1,96 pp respecto al núcleo digital, alcanzando un MAE de **9,56 pp** y un  $R^2_{oos}$  de 0,518. La Figura 6.3 ilustra la escalera de mejora entre especificaciones. El *gradient boosting* de control (MAE 9,91) no logra superar a la regresión regularizada, confirmando que con 31 contiendas la no-linealidad adicional solo añade varianza. El descenso del *top-1* al 64,5% es teóricamente coherente: optimizar para la cuota de voto de *todos* los candidatos y acertar quién es el #1 son objetivos distintos, y el modelo sacrifica algo de exactitud de ranking a cambio de estimaciones de magnitud más calibradas.




**Figura 6.3:** Escalera de desempeño de especificaciones evaluadas (LOCO-CV, 31 contiendas). Cada barra representa el MAE en puntos porcentuales de la cuota de voto. La línea punteada vertical marca el *baseline* de proporcionalidad.

### 6.3.c. Especificación ganadora ElasticNet

La selección anidada de especificación por LOCO-CV identificó como modelo óptimo el ElasticNet regularizado con dos predictores: la dominancia en logit de *likes* ( $f_{likes\_dom}$ ) y


su interacción con el logaritmo de la población municipal ( $f_{\text{likes\_dom}} \times (\log \text{pob} - \overline{\log \text{pob}})$ ). Los coeficientes estimados fueron  $\hat{\beta}_1 = 0,111$  y  $\hat{\beta}_2 = 0,026$ , con intercepto 0,258 e hiperparámetros  $\alpha = 0,0475$  y  $L1 \text{ ratio} = 0,10$ .

La interpretación del moderador de población es teóricamente coherente: en municipios grandes, dominar las redes se traduce con más fuerza en votos que en municipios pequeños, porque la población no actúa como efecto directo (es constante dentro de la contienda y se diluye) sino como **moderador** de cuánto pesan las interacciones. En la especificación ganadora de dos predictores, los coeficientes en escala estandarizada son  $\hat{\beta}_1 = 0,111$  (dominancia) y  $\hat{\beta}_2 = 0,026$  (moderador), retenidos en el 100 % de los pliegues. La Figura 6.4 ilustra la magnitud y la estabilidad inter-pliegue de los coeficientes en la especificación final.



**Figura 6.4:** Estabilidad de los coeficientes del modelo de dos variables (GLM fraccional, *link* logit) estimados entre los 31 pliegues LOCO-CV en escala logit ( $\hat{\beta}_1 \approx 0,780$  para la dominancia de *likes* y  $\hat{\beta}_2 \approx 0,540$  para el moderador de población, barras con media  $\pm$  IC 95 %). En escala estandarizada con *StandardScaler*, corresponden a  $\hat{\beta}_1 = 0,111$  y  $\hat{\beta}_2 = 0,026$  en la especificación final (Sección 5.6.b).

La Figura 6.5 compara las predicciones del modelo con los resultados reales y muestra la distribución de residuos, confirmando que el error es aproximadamente simétrico y centrado en cero.



**Figura 6.5:** Izquierda: predicción vs. resultado real para los 120 candidatos en validación LOCO-CV. La línea discontinua dorada representa la predicción perfecta. Derecha: distribución de residuos (predicho – real, en pp); la línea roja marca el error cero y la dorada la media del error.


El modelo final tiene en la práctica **dos versiones complementarias**: (i) la **especificación de dos predictores** ( $f_{\text{likes\_dom}}$  más el moderador de interacción con la población), que es la que se entrenó sobre las 31 contiendas y se validó prospectivamente en la presidencial 2026, con MAE fuera de muestra de **9,56 pp** (LOCO-CV); y (ii) el **ElasticNet sobre el pool completo** de nueve variables, que con selección anidada alcanza un MAE de 9,57 pp pero retiene variables territoriales específicas del nivel municipal (población, número de candidatos) que no son directamente transferibles a una elección nacional de dos candidatos.

### 6.3.d. Aplicación a la Segunda Vuelta Presidencial 2026

El 21 de junio de 2026 se celebró la segunda vuelta presidencial de Colombia, enfrentando a Iván Cepeda Castro y Abelardo De la Espriella. El modelo ELA-NOM, sin reentrenamiento, produjo el pronóstico que resume la Tabla 6.4.

**Cuadro 6.4:** Pronóstico ELA-NOM vs. resultado real de la segunda vuelta presidencial colombiana (21 jun. 2026). Fuente del resultado: Registraduría Nacional del Estado Civil.

| Candidato                | Likes totales | Dom. likes | Pronóstico | Resultado real |
|--------------------------|---------------|------------|------------|----------------|
| Iván Cepeda Castro       | 17.087.679    | 77,6 %     | 60,5 %     | 49,52 %        |
| Abelardo De la Espriella | 4.926.361     | 22,4 %     | 39,5 %     | 50,48 %        |



**Figura 6.6:** Comparación entre la señal digital (dominancia de *likes*), el pronóstico de ELA-NOM y el resultado certificado por la Registraduría Nacional del Estado Civil en la segunda vuelta presidencial de Colombia (21 jun. 2026).

El modelo apuntó correctamente la dirección de la señal digital (Cepeda acumuló 3,5 veces más *likes*), pero sobreestimó la ventaja resultante. El pronóstico del 60,5 % se obtuvo aplicando la fórmula de re-centrado para segunda vuelta: se calculó la señal estandarizada ( $\hat{s} = \hat{\beta}_1 \cdot z_{\text{dom}} + \hat{\beta}_2 \cdot z_{\text{mod}} = 0,2294$ ), se sumó a la base de 50 % ( $0,50 + 0,2294 = 0,729$ ) y se normalizó entre los dos candidatos ( $0,729 / (0,729 + 0,477) = 60,5 \%$ ). El error absoluto fue

de **10,98 pp** (60,5 % pronóstico vs. 49,52 % real), superando el MAE medio fuera de muestra del modelo de dos predictores aplicado (9,56 pp sobre las 31 contiendas municipales de entrenamiento).

El dato definitivo para contextualizar el error es el margen real de la elección: De la Espriella ganó por **apenas 0,96 puntos porcentuales** (50,48 % vs. 49,52 %), es decir, una contienda de empate técnico. Predecir correctamente el ganador en semejante escenario excede la resolución de cualquier modelo basado en métricas de *engagement* agregado y, de hecho, excede la resolución de la mayoría de las encuestas publicadas durante la campaña. El error observado (10,98 pp) supera en **1,42 pp** el MAE medio del modelo (9,56 pp): este caso queda por fuera del límite de resolución empírico del modelo, lo que confirma que la contienda se encontraba en un territorio donde ningún sistema basado en *engagement* agregado tiene precisión suficiente para determinar el ganador.

Este hallazgo delimita con precisión el espacio donde ELA-NOM es informativo: contiendas con ventajas digitales netas superiores a 20 pp, donde la señal digital traslada más fuerza a las urnas. En contiendas de empate técnico como la segunda vuelta de 2026, las métricas de *engagement* agregado capturan movilización simbólica pero no la movilización efectiva diferencial, los giros de última semana ni la estructura organizativa territorial. Lejos de invalidar el modelo, este resultado es el límite estructural mejor documentado que la investigación puede reportar.

### 6.3.e. Análisis complementario: tamaño de muestra y tracción tardía

Las dos preguntas derivadas evaluadas computacionalmente arrojan conclusiones que merecen una lectura honesta y calibrada.


#### P4: ¿Cuántas contiendas de entrenamiento son necesarias para estabilizar el rendimiento del modelo?

Para responder esta pregunta se realizó un experimento de curva de aprendizaje: se repitió 50 veces la estimación del MAE fuera de muestra variando el número de contiendas de entrenamiento entre 5 y 30 (con semilla aleatoria fija *seed*=42). Los resultados se muestran en la Tabla 6.5 y en la Figura 6.7.

**Cuadro 6.5:** Curva de aprendizaje: MAE fuera de muestra según el número de contiendas de entrenamiento (50 repeticiones con muestreo aleatorio, semilla 42). Modelo base: regresión lineal sobre dominancia en logit de *likes*.

| Contiendas de entrenamiento | MAE medio (pp) | Desv. estándar (pp) |
|-----------------------------|----------------|---------------------|
| 5                           | 12,82          | 1,37                |
| 10                          | 12,53          | 1,07                |
| 15                          | 12,45          | 0,94                |
| 20                          | 12,22          | 0,84                |
| 25                          | 12,25          | 1,77                |
| 30                          | 12,05          | 0,00                |

La reducción total del MAE entre el escenario de menor muestra (5 contiendas) y la muestra completa (30 contiendas) es de apenas **0,77 pp** (de 12,82 a 12,05 pp). La curva es prácticamente plana: con tan solo 10 contiendas se alcanza un MAE de 12,53 pp, y los



**Figura 6.7:** Curva de aprendizaje de ELA-NOM. MAE fuera de muestra (media y banda  $\pm 1$  desviación estándar) en función del número de contiendas de entrenamiento. La banda sombreada representa la variabilidad entre las 50 repeticiones de muestreo.

incrementos marginales siguientes son de décimas de punto porcentual. Adicionalmente, a  $N = 25$  la desviación estándar sube a 1,77 pp, lo que indica inestabilidad en algunos subconjuntos específicos de esa talla, probablemente derivada del pequeño universo de 30 municipios disponibles.

La interpretación más honesta de este resultado es que el piso de error del modelo (12 pp) no está determinado por la insuficiencia de datos de entrenamiento, sino por el nivel de ruido intrínseco de la señal digital como predictor de cuota de voto. Esto tiene una consecuencia metodológica positiva: el modelo no requiere grandes acervos históricos para funcionar, siendo viable desde tamaños de muestra moderados; y una consecuencia negativa: agregar más elecciones del mismo tipo no resolverá el error residual observado.

### P3 (complementario): ¿La tracción tardía aporta información predictiva adicional sobre la dominancia relativa?

Se comparó la correlación de Spearman entre la cuota de voto real y dos versiones de la señal digital: (i) la dominancia acumulada durante la ventana completa de 14 días antes de la elección, y (ii) la dominancia de crecimiento tardío (últimos días de campaña, reportada como *late\_growth* en las plataformas disponibles).

Los resultados fueron:

- Dominancia acumulada 14 días:  $\rho = 0,7036$
- Dominancia de tracción tardía:  $\rho = 0,6655$

La diferencia entre ambos coeficientes es de  $\Delta\rho = 0,038$ . Con  $n = 109$  candidatos no se realizó un test de Steiger formal, pero la magnitud de la diferencia es pequeña en términos prácticos. Esta evidencia sugiere que la tracción tardía **no aporta información predictiva adicional** sobre la señal acumulada: la dominancia relativa de *likes* en la ventana de 14 días ya captura la mayor parte de la señal disponible. La decisión de diseño de ELA-NOM de

trabajar con la ventana acumulada en lugar de ponderar de forma diferencial los días finales queda así respaldada empíricamente, aunque los datos disponibles no permiten una verificación estadística concluyente dada la escala de la muestra.

## 6.4. Síntesis: contribuciones al estado del arte

Los hallazgos empíricos y los desarrollos técnicos documentados a lo largo de este estudio confluyen en cuatro contribuciones sustanciales al dominio de la analítica política y los modelos predictivos heterodoxos:

1. **Elección-Agnosticismo Empírico:** Se establece una ruta metodológica viable, demostrada a través de la regresión fraccional basada en la métrica transversal de dominancia relativa, para superar la limitación de no transferibilidad del SOMENDC (tercera limitación identificada en la Sección 1.2), permitiendo entrenar algoritmos con observaciones de múltiples contiendas de alcaldías simultáneas y abstraer reglas de decisión exportables a elecciones de distinto formato.
2. **Total Independencia Demoscópica:** A diferencia de la inmensa mayoría de la literatura contemporánea en estimación digital electoral, este esquema sustituye la obligatoriedad de usar encuestas como variable dependiente, anclando directamente su optimización sobre la variable *ground truth* universal: el escrutinio final.
3. **Restaurador Temporal de Series (Modelo Weibull):** Se introduce y formaliza una arquitectura matemática de interpolación capaz de retrotraer variables acumulativas hacia instantes en el pasado. Esto resuelve el que quizás sea el mayor obstáculo técnico para la investigación retrospectiva de dinámicas digitales, facultando a los analistas a poblar *datasets* de series temporales históricas partiendo exclusivamente de una extracción actual estática, sin requerir despliegues preventivos costosos. La solución está calibrada sobre el panel de Costa Rica 2026 y su generalización a otras elecciones debe verificarse empíricamente.
4. **Democratización del Pipeline:** Se verifica la operatividad de la solución utilizando, de principio a fin, una orquestación ligera ensamblada con herramientas de mercado genéricas (*Make*, *Apify*, API oficiales, librerías *Headless*), mostrando que la predicción y monitoreo algorítmico no requiere necesariamente infraestructuras corporativas, gubernamentales o institucionales avanzadas.

# 7

## Impacto esperado

### 7.1. Impacto académico

Esta investigación aspira a realizar una aportación fundacional a la literatura de ciencia de datos políticos y estudios electorales cuantitativos en América Latina. A nivel epistemológico, este trabajo documenta la primera metodología estructurada de *nowcasting* electoral elección-agnóstica e independiente de encuestas conceptualizada e implementada para el entorno político altamente fragmentado de Colombia.

Metodológicamente, la formalización matemática del **modelo de crecimiento Weibull** constituye un artefacto científico de exportación. Al proporcionar un marco matemático capaz de reconstruir la evolución temporal de la tracción digital sin depender de registros en tiempo real, el estudio libera a futuras investigaciones académicas de la obligación logística de desplegar sensores de recopilación con meses de antelación al evento electoral de interés.

Adicionalmente, se efectúa una contribución transversal al debate global sobre la viabilidad de la predicción electoral mediante redes sociales. El trabajo delimita con evidencia empírica las fronteras de aplicabilidad del enfoque: valida matemáticamente la *dominancia relativa* de *likes* como el predictor digital más robusto en elecciones subnacionales, y demuestra que la regularización ElasticNet con selección anidada es el marco estadístico adecuado para extraer señal de un problema con alta multicolinealidad y muestra moderada (31 contiendas). El resultado, un MAE de **9,56 pp** fuera de muestra, constituye la primera estimación honesta y replicable del techo predictivo actual de esta familia de modelos para el caso colombiano.

## 7.2. Impacto práctico

En una dimensión operativa, el principal aporte aplicativo es la materialización de un sistema orquestado de pronóstico y monitoreo de bajo costo. El ecosistema metodológico está documentado y es reproducible: el código fuente, los cuadernos de análisis y el entorno de dependencias Python se encuentran disponibles en el repositorio público (Sotelo Aguilar, 2026). La solución emplea herramientas comerciales de extracción *off-the-shelf* (como *Apify* o integradores *no-code* como *Make.com*), lo que reduce la barrera de entrada frente a arquitecturas de investigación que requieren infraestructura dedicada.

Este avance abre la puerta para que medios de comunicación regionales, laboratorios de veeduría ciudadana y pequeñas firmas de consultoría estratégica desplieguen capacidades de inteligencia electoral en tiempo real. En el mediano plazo, estas técnicas se proyectan como una alternativa complementaria frente a los instrumentos demoscópicos, especialmente en naciones de Latinoamérica donde la carencia de encuestas sistemáticas o la desconfianza pública en sus resultados exigen métodos de estimación paralelos transparentes y auditables.

Una consideración regulatoria relevante es si la publicación de estimaciones de ELA-NOM durante campaña estaría sujeta a la **Ley 2494 de 2025**, que regula la elaboración y divulgación de encuestas electorales en Colombia (Congreso de la República de Colombia, 2025). La Ley define “encuesta electoral” en términos vinculados a sondeos directos de intención de voto; ELA-NOM, al derivar sus estimaciones exclusivamente de métricas de interacción digital (no de consulta directa a electores), podría no encuadrar en esa definición. Sin embargo, dado que el resultado del modelo es funcionalmente análogo (una estimación de la cuota de voto de cada candidato), es prudente consultar con asesoría jurídica especializada antes de cualquier despliegue público durante campaña. Esta indefinición regulatoria no invalida el valor académico o exploratorio de la herramienta, pero sí debe tenerse en cuenta en su aplicación práctica.



### 7.3. Limitaciones y trabajo futuro

La honestidad intelectual obliga a delimitar las limitaciones intrínsecas y los confines de aplicabilidad del estudio. En primer lugar, la calibración del modelo Weibull, si bien fue exhaustiva a nivel micro de publicaciones, descansó sobre el comportamiento macro de una única elección (Costa Rica 2026). Asumir universalidad conductual exige una validación prospectiva replicando la medición longitudinal sobre certámenes demográficamente disímiles para confirmar la estabilidad inter-elecciones de los parámetros de forma y escala.

En segundo lugar, por determinaciones corporativas restrictivas de la compañía Meta, Instagram quedó excluido del *dataset* colombiano; esta omisión representa una pérdida de la fotografía generacional y el consumo audiovisual de una gran franja del electorado joven. Asimismo, el modelo probó ser estructuralmente vulnerable a perfiles políticos con audiencias atípicas (como lo demostró la exclusión forzosa del candidato *influencer* Gustavo Bolívar), revelando que las masas críticas interdepartamentales contaminan la medición estrictamente local. Todo esto sin ignorar que el conteo volumétrico peca de ceguera ante la calidad y veracidad de la interacción: las arquitecturas modeladas no están equipadas actualmente para ponderar el efecto adverso o positivo de interacciones generadas artificialmente (granjas de *bots*, perfiles inorgánicos o *astroturfing*).

En tercer lugar, la validación prospectiva en la segunda vuelta presidencial de 2026 confirmó el límite más resistente del modelo: en contiendas bipolares excepcionalmente reñidas, la dominancia digital sobreestima la ventaja resultante, porque el *engagement* agrega ruido acumulado sin capturar los giros de opinión de la última semana ni la movilización territorial diferencial.

Por lo tanto, la agenda de **trabajo futuro** es rica y expansiva. Se priorizará escalar el conjunto de datos integrando eventos de más naciones de la región andina; investigar el desempeño de ventanas temporales de memoria (*lagged variables*); desarrollar clasificadores semánticos que depuren la señal descartando la actividad inorgánica artificial; e incorporar covariables estructuradas *offline* (indicadores económicos territoriales y clima de opinión en prensa). La prioridad empírica inmediata será la confrontación longitudinal ciega del modelo entrenado contra los resultados de las próximas elecciones territoriales en Colombia de 2027, que fungirán como el juez definitivo *out-of-time* sobre la madurez proyectiva de ELA-NOM.

## 8

## Conclusiones

### 8.1. Respuesta a la pregunta de investigación

Este documento se originó a partir de una inquietud central: evaluar si era metodológicamente posible diseñar un modelo de *nowcasting* electoral elección-agnóstico y

emancipado de las encuestas para el complejo entorno local colombiano. A la luz de los hallazgos empíricos, la respuesta global es **afirmativa con matices estructurales**: el modelo es conceptual y operativamente posible, y su desempeño fuera de muestra, un MAE de **9,56 puntos porcentuales** sobre 31 contiendas, supera al *baseline* de proporcionalidad, aunque su techo predictivo actual está condicionado principalmente por el nivel de ruido intrínseco de la señal digital, y no por la insuficiencia de datos de entrenamiento.

En primer lugar, se demostró que las interacciones ciudadanas en plataformas sociales **tienen un poder predictivo real** sobre el comportamiento del electorado colombiano. Las pruebas no paramétricas arrojaron diferencias significativas ( $p < 0,05$ ) entre ganadores y perdedores, y la correlación de rango de Spearman fue  $\rho = 0,70$  (mancomunada sobre todos los candidatos). Sin embargo, la experimentación también confirmó que la señal extraída de la red sin covariables de apoyo es ruidosa: el modelo de regresión fraccional con un solo predictor (dominancia de *likes*) alcanza un MAE de 11,52 pp, y solo al incorporar el moderador de población mediante ElasticNet anidado el error desciende a **9,56 pp**.

En segundo término, la viabilidad del modelo descansaba sobre la premisa de la **reconstrucción temporal**. Las pruebas sobre el panel de Costa Rica validaron que la interpolación matemática mediante distribuciones de Weibull es precisa: el MAPE mediano cae por debajo del 6 % a partir del tercer día de observación en Facebook, Twitter/X y TikTok, y en torno al 12 % en Instagram. En consecuencia, un marco analítico elección-agnóstico se ha mostrado como un enfoque empíricamente viable: el modelo puede abstraer reglas del contexto colombiano y aplicarlas, como *núcleo agnóstico*, a una elección de formato diferente, como se exploró prospectivamente en la segunda vuelta presidencial de 2026, donde el error fue de 10,98 pp y no se acertó el candidato ganador (véase Sección 6.3.d y la discusión en 7.3).

## 8.2. Lecciones aprendidas

A lo largo del desarrollo computacional y la revisión estadística del proyecto, se decantaron lecciones críticas para la práctica del *nowcasting* digital en el sur global:

- **La supremacía de la dominancia relativa:** El ecosistema de campaña funciona como un juego de suma cero territorial. La posición de un candidato relativa a la conversación local de su ciudad (*share of voice*) es una métrica inmensamente superior al volumen absoluto de interacciones, pues este último es susceptible de distorsiones poblacionales y mediáticas inherentes a los perfiles públicos masivos. La dominancia de *likes* en logit, presente en el 100 % de los pliegues de validación, es el predictor más estable del modelo final.
- **La población como moderador, no como efecto directo:** El hallazgo más sorprendente de la selección de variables fue que la interacción entre dominancia digital y tamaño de la ciudad es el segundo predictor retenido en la especificación final, con un coeficiente de  $\hat{\beta}_2 = 0,026$  en escala estandarizada. En municipios grandes, dominar las redes se traduce en votos con más fuerza que en municipios pequeños; la población no diferencia candidatos de la misma contienda, pero amplifica o amortigua el efecto de la señal digital.
- **La regularización como árbitro honesto:** Frente a matrices con alta multicolinealidad entre métricas digitales, la selección manual de variables introduce sesgo de selección. El protocolo ElasticNet con validación anidada, eligiendo hiperparámetros en CV interno y midiendo desempeño en CV externo, es el único procedimiento

que paga honestamente el costo del sobreajuste de selección y produce estimaciones reportables.

- **El abismo de la última semana:** El obstáculo empírico más resistente para las métricas agregativas continúa siendo el giro coyuntural tardío. La explosión de interacciones preexistentes oculta frecuentemente las volatilidades sutiles de la opinión pública suscitadas por eventos, escándalos o alianzas que acontecen en los tres días anteriores al evento de urnas. La segunda vuelta presidencial de 2026 es el ejemplo paradigmático de este límite estructural.
- **Autonomía computacional:** La comprobación de un ciclo de vida completo de análisis, desde la orquestación y el *scraping* (*Make.com*, *Playwright*, API de X, *Apify*) hasta la proyección asintótica y el modelado con regularización, probó que este *pipeline* analítico complejo es enteramente ejecutable desde laboratorios comerciales e independientes que operen con un coste logístico nominal o nulo.

### 8.3. Próximos pasos

La natural prolongación de este cuerpo de investigación consiste en llevar la experimentación a la fase de masificación de datos, integrando *datasets* de contiendas asimétricas de más naciones de América Latina y diferentes marcos temporales, apuntalando así el tamaño de las muestras para explorar arquitecturas más expresivas. En el corto plazo, es prioritario recalibrar el modelo Weibull inter-regionalmente (Colombia, México, Ecuador) y reentrenar ELA-NOM con los datos de la segunda vuelta de 2026, que constituyen observaciones cuya verdad de campo ahora se conoce.

La culminación de este esfuerzo empírico se cristalizará durante la apertura de las urnas de las próximas elecciones territoriales en Colombia de 2027, las cuales fungirán como el juez definitivo ciego (*out-of-time sample*) sobre el cual se medirá, bajo estricto rigor metodológico ex-ante, la madurez proyectiva de ELA-NOM. A diferencia de la validación de 2026, prospectiva pero presidencial y binaria, las elecciones de 2027 replican el contexto multi-candidato subnacional para el cual el modelo fue diseñado y entrenado, ofreciendo la comparación más directa y exigente posible.

Finalmente, la pregunta metodológica PM4, respondida en este trabajo solo en su dimensión de transferibilidad, tiene una extensión natural no implementada: el **nowcasting continuo de cadencia diaria**. La arquitectura técnica ya lo habilita: dado que el restaurador Weibull puede proyectar el total final de interacciones de una publicación desde cualquier día de la campaña, es posible correr ELA-NOM cada 24 horas durante una campaña en curso, simulando en cada iteración el resultado “si la elección fuera hoy”. Graficando esas predicciones en el tiempo se obtendría una trayectoria continua de la intención de voto estimada, actualizando en tiempo casi-real el pronóstico conforme se acumulan interacciones. Esta implementación requeriría únicamente datos de extracción diaria durante la campaña, lo que la convierte en la extensión de mayor valor práctico para un despliegue operativo de ELA-NOM.

# Bibliografía

- ACEI. (2025). Perspectivas de la Industria de Investigación de Mercados en Colombia 2025 [Asociación Colombiana de Empresas de Investigación de Mercados y Opinión Pública].
- Barberá, P. (2020). Social Media, Echo Chambers, and Political Polarization. En N. Persily & J. A. Tucker (Eds.), *Social Media and Democracy: The State of the Field and Prospects for Reform*. Cambridge University Press. <https://www.researchgate.net/publication/343996442>
- Brito, K., & Adeodato, P. J. L. (2022). Measuring the performances of politicians on social media and the correlation with major Latin American election results. *Government Information Quarterly*, 39(4), 101745. <https://doi.org/10.1016/j.giq.2022.101745>
- Brito, K., & Adeodato, P. J. L. (2023). Machine learning for predicting elections in Latin America. *Government Information Quarterly*, 40(2), 101782. <https://doi.org/10.1016/j.giq.2022.101782>
- Brito, K., Silva Filho, T., & Adeodato, P. J. L. (2024). Stop trying to predict elections only with Twitter: There are other data. *Government Information Quarterly*, 41(1), 101899. <https://doi.org/10.1016/j.giq.2023.101899>
- Brito, K. d. S., & Adeodato, P. J. L. (2020). Predicting Brazilian and U.S. Elections with Machine Learning and Social Media Data. *Proceedings of the 2020 International Joint Conference on Neural Networks (IJCNN)*.
- Congreso de la República de Colombia. (2025). Ley 2494 de 2025, por la cual se regula la elaboración, publicación y divulgación de encuestas electorales [Diario Oficial de Colombia].
- DataReportal. (2025, noviembre). Digital 2026: Colombia [Datos de octubre 2025. Publicado por Kepios / We Are Social / Meltwater]. <https://datareportal.com/reports/digital-2026-colombia>
- ESOMAR. (2025). *Global Market Research 2025*. ESOMAR. <https://esomar.org/publications/global-market-research-2025>
- GAD3. (2026, mayo). Comunicado: Suspensión de publicación de encuestas electorales en Colombia. <https://www.lasillavacia.com/en-vivo/por-ley-mordaza-gad3-suspende-publicacion-de-encuestas-en-colombia/>
- Giangiulio, D. (2026, abril). Prediction Markets: On Pace for \$1 Trillion by 2030 [Citado en CNBC, 14 de abril de 2026]. <https://www.cnbc.com/2026/04/14/prediction-markets-will-grow-to-1-trillion-by-2030-bernstein-says.html>
- Kayser, M. A., & Lindstädt, R. (2015). A Cross-National Measure of Electoral Competitiveness. *Political Analysis*, 23(2), 242-253. <https://doi.org/10.1093/pan/mpv001>
- Kennedy, C., Blumenthal, M., Clement, S., Clinton, J. D., Durand, C., Franklin, C., McGeeney, K., Miringoff, L., Olson, K., Rivers, D., Saad, L., Witt, G. E., & Wlezien, C.

- (2018). An Evaluation of the 2016 Election Polls in the United States. *Public Opinion Quarterly*, 82(1), 1-33. <https://doi.org/10.1093/poq/nfx047>
- Lewis-Beck, M. S., Nadeau, R., & Bélanger, É. (2004). General Election Forecasts in the United Kingdom: A Political Economy Model. *Electoral Studies*, 23(2), 279-290. [https://doi.org/10.1016/S0261-3794\(02\)00071-9](https://doi.org/10.1016/S0261-3794(02)00071-9)
- Lewis-Beck, M. S., Nadeau, R., & Bélanger, É. (2011). Nowcasting v. polling: The 2010 UK election trials. *Electoral Studies*, 30(2), 284-287. <https://doi.org/10.1016/j.electstud.2010.09.013>
- Lewis-Beck, M. S., & Tien, C. (2014). Proxy models and nowcasting: U.S. presidential elections in the future. *Presidential Studies Quarterly*, 44(3), 506-521.
- Mughan, A. (1987). General Election Forecasting in Britain: A Comparison of Three Simple Models. *Electoral Studies*, 6(3), 195-207. [https://doi.org/10.1016/0261-3794\(87\)90031-X](https://doi.org/10.1016/0261-3794(87)90031-X)
- Norpoth, H. (2004). Forecasting British Elections: A Dynamic Perspective. *Electoral Studies*, 23(2), 297-305. [https://doi.org/10.1016/S0261-3794\(02\)00070-7](https://doi.org/10.1016/S0261-3794(02)00070-7)
- Papke, L. E., & Wooldridge, J. M. (1996). Econometric Methods for Fractional Response Variables with an Application to 401(k) Plan Participation Rates. *Journal of Applied Econometrics*, 11(6), 619-632. [https://doi.org/10.1002/\(SICI\)1099-1255\(199611\)11:6<619::AID-JAE418>3.0.CO;2-1](https://doi.org/10.1002/(SICI)1099-1255(199611)11:6<619::AID-JAE418>3.0.CO;2-1)
- Ríos Giraldo, M. (2026). Ley de encuestas en Colombia: la polémica norma. *Diario de Occidente*. <https://occidente.co/politica/graffiti/ley-de-encuestas-colombia-derogatoria-cne-investigaciones-2026/>
- Sanders, D. (1991). Government Popularity and the Next General Election. *The Political Quarterly*, 62(2), 235-261. <https://doi.org/10.1111/j.1467-923X.1991.tb00856.x>
- Sigelman, L. (1979). Presidential Popularity and Presidential Elections. *Public Opinion Quarterly*, 43(4), 532-534. <https://www-jstor-org.ez.unisabana.edu.co/stable/2749005>
- Skoric, M. M., Liu, J., & Jaidka, K. (2020). Electoral and Public Opinion Forecasts with Social Media Data: A Meta-Analysis. *Information*, 11(4), 187. <https://doi.org/10.3390/info11040187>
- Sotelo Aguilar, J. (2026). ELA-NOM: Election-Agnostic Nowcasting Model Código fuente, datos y cuadernos de análisis [Repositorio público. Entorno Python reproducible]. [https://github.com/Juansotag/Avances\\_tesis](https://github.com/Juansotag/Avances_tesis)
- Stegmaier, M., Jokinsky, S., & Lewis-Beck, M. S. (2023). The Evolution of Election Forecasting Models in the UK. *Electoral Studies*, 86, 102694. <https://doi.org/10.1016/j.electstud.2023.102694>
- Tucker, J. A., Guess, A., Barberá, P., Vaccari, C., Siegel, A., Sanovich, S., Stukal, D., & Nyhan, B. (2018). *Social Media, Political Polarization, and Political Disinformation: A Review of the Scientific Literature* (inf. téc.). SSRN. <https://doi.org/10.2139/ssrn.3144139>
- Tumasjan, A., Sprenger, T. O., Sandner, P. G., & Welpe, I. M. (2010). Predicting elections with Twitter: What 140 characters reveal about political sentiment. *Proceedings of the Fourth International AAAI Conference on Weblogs and Social Media*, 178-185.
- Whiteley, P. (1979). Electoral Forecasting from Poll Data: The British Case. *British Journal of Political Science*, 9(2), 219-236. <https://doi.org/10.1017/S0007123400001733>