

MAESTRÍA EN ANALÍTICA APLICADA
FACULTAD DE INGENIERÍA

Diseño e implementación de un modelo de *nowcasting* elección-agnóstico para la intención de voto aplicado a elecciones locales en Colombia 2023

Juan Sotelo Aguilar

DIRECTOR
Prof. PhD. Miguel Uribe Laverde
Universidad de La Sabana

AÑO ACADÉMICO 2026

A María José, mi familia y quienes creyeron en esto antes de que yo mismo creyera.

Índice general

Resumen	1
Abstract	1
1 Introducción	1
1.1 Motivación del problema	1
1.2 Estado del arte: de los modelos paramétricos al SOMEN-DC	2
1.3 Hipótesis de trabajo	5
1.4 Estructura del documento	6
2 Pregunta de investigación	7
2.1 Pregunta principal	7
2.2 Preguntas derivadas	7
3 Marco conceptual	8
3.1 <i>Nowcasting</i> electoral y predicción con redes sociales	8
3.1.a Definición de <i>nowcasting</i> en contexto electoral	8
3.2 Modelos elección-agnósticos: definición y ventajas	8
3.3 Interacciones digitales como <i>proxy</i> de intención de voto	9
3.3.a La hipótesis Tumasjan	9
3.3.b Interacciones absolutas vs. dominancia relativa	9
3.4 El problema del histórico de interacciones	10
4 Objetivos	10
4.1 Objetivo general	10
4.2 Objetivos específicos	10
5 Metodología	11
5.1 Definición formal del problema	11
5.1.a Definición de la elección	11
5.1.b Definición de la intención de voto y los resultados	11
5.1.c Definición formal de las publicaciones y su comportamiento temporal	12
5.2 Diseño general del pipeline	12
5.3 Etapa 1 — Bolivia: Replicación del SOMEN-DC y prueba de concepto	13
5.3.a Caso de estudio y recolección de datos	13
5.3.b Evaluación de modelos	14
5.4 Etapa 2 — Costa Rica: Modelado del crecimiento de interacciones	14
5.4.a El problema estructural	14
5.4.b Metodología y Modelo Weibull	14

5.5	Etapa 3 — Colombia: Construcción del dataset y modelado	15
5.6	Modelado predictivo	16
5.6.a	Modelo de regresión	16
5.6.b	Modelo de clasificación binaria	17
6	Resultados	17
6.1	Resultados de Bolivia (Etapa 1)	17
6.2	Resultados de Costa Rica (Etapa 2)	18
6.3	Resultados de Colombia (Etapa 3)	18
6.4	Síntesis: contribuciones al estado del arte	19
7	Impacto esperado	20
7.1	Impacto académico	20
7.2	Impacto práctico	20
7.3	Limitaciones y trabajo futuro	21
8	Conclusiones	21
8.1	Respuesta a la pregunta de investigación	21
8.2	Lecciones aprendidas	22
8.3	Próximos pasos	23
	Bibliografía	24

Resumen

En Latinoamérica, las encuestas electorales son la única herramienta disponible para el seguimiento de la intención de voto durante una campaña activa. Este trabajo propone y valida una metodología alternativa para estimar la intención de voto que no depende de encuestas, es elección-agnóstica y puede replicarse con herramientas comerciales accesibles.

Palabras clave: nowcasting electoral, redes sociales, machine learning, Colombia, elecciones locales, elección-agnóstico.

Abstract

In Latin America, electoral polls are the only available tool for tracking voting intention during an active campaign. This work proposes and validates an alternative methodology to estimate voting intention that does not rely on polls, is election-agnostic, and can be replicated with accessible commercial tools. Using social media interactions from candidates' official profiles as the primary signal, and a Weibull growth model for historical interaction reconstruction, the study demonstrates that relative dominance of a candidate's digital engagement is a statistically significant predictor of electoral outcomes in Colombian local elections ($\rho > 0.46, p < 2 \times 10^{-7}$).

Keywords: electoral nowcasting, social media, machine learning, Colombia, local elections, election-agnostic model, Weibull growth.

1

Introducción

1.1. Motivación del problema

La industria global de investigación de mercados y opinión pública, que incluye el pronóstico electoral, alcanzó 153.000 millones de dólares en 2024, un crecimiento del 8 % frente al año anterior, según *ESOMAR* (2025), la asociación mundial del sector. En Colombia, la misma industria facturó 743.058 millones de pesos en 2024 (equivalentes a aproximadamente 208.000 dólares a la tasa de cambio de mayo de 2026), con un crecimiento del 1 % frente al año anterior, según la *Asociación Colombiana de Empresas de Investigación de Mercados y Opinión Pública* (ACEI, 2025).

Este crecimiento contrasta con el de los mercados alternativos de pronóstico: plataformas como *Polymarket* y *Kalshi* registraron en conjunto cerca de 60.000 millones de dólares en volumen de operaciones en los primeros meses de 2026, superando ya el total de 2025, y se proyecta que alcancen un billón de dólares anuales para 2030, según estimaciones de Bernstein Research (Giangiulio, 2026). Esta divergencia sugiere que la demanda por información predictiva sobre resultados futuros crece a un ritmo que las encuestas tradicionales no están capturando.

A pesar de su ubicuidad, las encuestas electorales en Colombia enfrentan profundos retos estructurales que se han agudizado recientemente. La dificultad logística de abarcar territorios extensos, la alta tasa de no respuesta y los elevados costos operativos limitan la frecuencia y el tamaño muestral de los estudios, especialmente en elecciones locales.

A estos problemas estructurales se suma un nuevo marco regulatorio que ha tensionado aún más el sector: la **Ley 2494 de 2025**, que estableció requisitos metodológicos estrictos para la elaboración y publicación de encuestas electorales, incluyendo una veda de publicación que interrumpió el flujo de información entre julio y noviembre de 2025 (Congreso de la República de Colombia, 2025).

La aplicación práctica de esta norma generó tal nivel de fricción entre el *Consejo Nacional Electoral* (CNE) y las firmas encuestadoras, que la consultora española GAD3 suspendió definitivamente sus mediciones en el país en mayo de 2026, argumentando que la interpretación de la Comisión Técnica exige demostrar condiciones de muestreo que “ninguna metodología demoscópica puede satisfacer en la práctica” (GAD3, 2026).

La norma, al invalidar encuestas telefónicas, paneles digitales y métodos mixtos en favor de encuestas presenciales domiciliarias, encareció operativamente el sector y concentró el mercado en pocas firmas con suficiente capacidad económica para operar en campo en todo el territorio nacional (Ríos Giraldo, 2026). En este panorama, resulta cada vez más urgente desarrollar herramientas de pronóstico electoral que no dependan exclusivamente de encuestas y que aprovechen fuentes alternativas de datos masivos.

1.2. Estado del arte: de los modelos paramétricos al SOMEN-DC

La capacidad de anticipar resultados electorales ha sido un reto persistente para la ciencia política desde los años setenta, cuando surgieron los primeros modelos predictivos formales en Estados Unidos y el Reino Unido. Los trabajos pioneros de Sigelman (1979) y Whiteley (1979) demostraron que la popularidad presidencial medida meses antes de una elección era un predictor estadísticamente significativo del resultado electoral, abriendo la puerta a una tradición de modelos formales de pronóstico que hasta entonces era prácticamente inexistente en la ciencia política.

Esta tradición evolucionó rápidamente hacia arquitecturas econométricas más sofisticadas. Mughan (1987) comparó tres modelos simples de pronóstico para elecciones generales en el Reino Unido, concluyendo que las variables macroeconómicas, en particular el desempleo y la aprobación gubernamental, ofrecían mayor poder predictivo que los indicadores de popularidad aislados. Por su parte, Sanders (1991) desarrolló un modelo de función de popularidad para el gobierno británico que incorporaba condiciones económicas y eventos políticos exógenos, anticipando el resultado de las elecciones generales con seis meses de antelación. Durante los años noventa y la primera década del siglo XXI, estos modelos alcanzaron su madurez técnica, apoyándose en herramientas de series de

tiempo como VAR y ARMA. En el contexto del Reino Unido, ()Lewis-Beck et al. (2004) formularon un modelo de economía política que explicaba más del 80 % de la varianza en el apoyo gubernamental usando solo tres variables: aprobación del gobierno, inflación y el número de términos consecutivos en el poder. En paralelo, Norpoth (2004) propuso una perspectiva dinámica que modelaba el retorno del voto al equilibrio histórico mediante un proceso autorregresivo AR(1), demostrando que el partido ganador tiende a perder aproximadamente la mitad de su ventaja en la siguiente elección. En varios ciclos electorales, estos modelos superaban en precisión a las propias encuestadoras.

Sin embargo, desde aproximadamente 2015, la capacidad predictiva de estos enfoques se deterioró de forma pronunciada. En el Reino Unido, ningún modelo establecido logró anticipar la mayoría conservadora de ese año (Stegmaier et al., 2023); un año después, los mismos enfoques fallaron en predecir la victoria de Donald Trump, el Brexit y la salida del Reino Unido de la Unión Europea (K. Brito et al., 2024; Stegmaier et al., 2023). Esta crisis generalizada no fue accidental: Kennedy et al. (2018) documentaron, en una evaluación exhaustiva encargada por la Asociación Americana de Investigación de Opinión Pública (AAPOR), que los sondeos de 2016 sobreestimaron sistemáticamente el apoyo a Hillary Clinton debido a sesgos de no-respuesta diferencial, especialmente entre votantes de Trump sin estudios universitarios. A esto se sumaron los cambios estructurales en la comunicación política propiciados por las redes sociales (Tucker et al., 2018) y la creciente fragmentación y polarización de los electorados (Barberá, 2020), que volvieron menos predecibles los comportamientos que los modelos paramétricos habían aprendido a capturar.

La crisis impulsó a los investigadores a explorar fuentes de datos alternativas. El auge del *Big Data* y las plataformas digitales abrió una nueva línea de investigación: usar las huellas digitales de los ciudadanos como covariables en tiempo real para el pronóstico electoral. El estudio seminal de Tumasjan et al. (2010) sobre las elecciones federales alemanas de 2009 fue el primer trabajo de referencia en este campo. Analizando más de 104.000 *tweets* publicados en las semanas previas a la elección, los autores encontraron que el simple volumen de menciones de cada partido replicaba el resultado electoral con un error absoluto medio de apenas 1,65 %, comparable al de las encuestadoras tradicionales. Más allá de la predicción, Tumasjan et al. demostraron que los perfiles de sentimiento de los mensajes correspondían a las posiciones políticas reales de los partidos, y que las menciones conjuntas de dos partidos reflejaban las alianzas políticas existentes. Esta hipótesis, que la atención digital equivale a capital político, abrió una década de investigación intensa.

No obstante, la promesa inicial no se sostuvo en la replicación sistemática. Skoric et al. (2020), en un meta-análisis de 74 estudios publicados entre 2007 y 2018, encontraron que las predicciones basadas en redes sociales quedaban en promedio por debajo de los *benchmarks* de la encuesta tradicional, con alta varianza entre estudios y sin convergencia metodológica. Sus resultados mostraron que las predicciones basadas únicamente en análisis de sentimiento léxico no superaban a las basadas en características estructurales de red, y que la combinación de ambas, usando aprendizaje automático, producía los mejores resultados ($MAE = 2,14 \%$; $R^2 = 0,818$). K. Brito et al. (2024), en una revisión crítica de doce años de investigación, formalizaron el problema: el enfoque de *Twitter* solo, basado en volumen de menciones o sentimiento, no rinde mejor que el azar, con tasas de acierto de entre el 50 % y el 63 %. Los autores identificaron cinco causas estructurales

de este fracaso: la imposibilidad de encuestar representativamente a través de Twitter, la dependencia de decisiones arbitrarias de recolección, los cambios constantes en el ecosistema de plataformas, la falta de datos históricos comparables, y la repetición de los errores metodológicos de las *straw polls* anteriores a 1936. El problema de fondo es metodológico: rastrear millones de publicaciones abiertas es costoso, ruidoso y difícilmente replicable fuera de entornos universitarios con infraestructura computacional avanzada (Skoric et al., 2020).

La respuesta más sofisticada a estos problemas llegó desde Brasil. K. d. S. Brito y Adeodato (2020) propusieron un cambio fundamental de paradigma: en lugar de rastrear lo que la ciudadanía dice sobre los candidatos, menciones abiertas, *hashtags*, sentimiento, el modelo analiza exclusivamente lo que la ciudadanía hace con el contenido que los propios candidatos publican en sus perfiles oficiales. Combinando datos de Facebook, Twitter e Instagram de las elecciones presidenciales de Brasil (2018) y Estados Unidos (2016) con encuestas tradicionales como variable objetivo, entrenaron redes neuronales tipo MLP que superaron estadísticamente a las encuestadoras en Brasil, donde los candidatos son muchos y las encuestas son pocas, y fueron competitivos en Estados Unidos. Este enfoque fue posteriormente sistematizado por K. Brito y Adeodato (2022), quienes analizaron más de 67.000 publicaciones de candidatos presidenciales en Argentina, Brasil, Colombia y México (2018–2019), demostrando que las métricas de *engagement* por publicación, en particular los *likes* por *post* en Instagram, correlacionaban fuertemente con el resultado electoral ($r = 0,75\text{--}0,98$), mientras que el número absoluto de publicaciones presentaba correlación nula o negativa.

El conjunto de estas contribuciones se formalizó en el marco **SOMEN-DC** (*Social Media Electoral Nowcasting During Campaign*), desarrollado por K. Brito y Adeodato (2023) en la Universidad Federal de Pernambuco. El modelo propone un proceso de cinco pasos, comprensión del evento, recolección de datos, preparación, modelado y evaluación, y una estrategia de ejecución continua (DC) que permite emitir predicciones diarias durante la campaña. Usando datos de más de 65.000 publicaciones y 195 encuestas de cuatro países latinoamericanos, los ensambles de redes neuronales (MLP y GRNN) entrenados con métricas de *engagement* y encuestas como etiquetas alcanzaron errores absolutos medios frecuentemente inferiores a 3 puntos porcentuales, dentro del umbral histórico de las encuestadoras.

Sin embargo, el SOMEN-DC presenta tres limitaciones estructurales que este trabajo busca superar:

1. **Techo encuestocéntrico.** Al usar las encuestas como variable objetivo de entrenamiento, el modelo no puede superar la capacidad predictiva de las propias encuestas. Es, en esencia, un replicador sofisticado de sondeos: aprende a imitar la señal de las encuestas a partir de datos digitales, sin acceso a una fuente de verdad independiente.
2. **Dependencia de infraestructura costosa.** El modelo requiere *scraping* continuo desde el inicio de la campaña para registrar la evolución temporal de las interacciones, acceso que los autores originales tenían a través de servicios institucionales de la Universidad Federal de Pernambuco, hoy inasequibles o inexistentes para la mayoría de investigadores independientes.
3. **No transferibilidad.** Los pesos aprendidos son válidos exclusivamente para la elección en que se entrenaron. Cada nueva contienda exige repetir desde cero el ciclo

completo de recolección y entrenamiento, sin posibilidad de acumular aprendizaje entre elecciones o de generalizar patrones entre contextos electorales distintos.

Estas tres limitaciones definen el espacio de contribución de esta tesis.

1.3. Hipótesis de trabajo

El punto de partida conceptual de este proyecto es la hipótesis seminal formulada por Tumasjan et al. (2010), quienes postulan que el volumen de actividad digital de un candidato en plataformas de redes sociales funciona como un estimador de su capital electoral subyacente. Esta intuición ha encontrado respaldo empírico consistente en contextos distintos al original: K. Brito y Adeodato (2022) demostraron que las métricas de *engagement* por publicación en los perfiles oficiales de candidatos presidenciales en Argentina, Brasil, Colombia y México correlacionan fuertemente con el resultado electoral ($r = 0,75-0,98$), mientras que las interacciones absolutas o el volumen de publicaciones presentan correlaciones nulas o negativas.

No obstante, existe un argumento estructural en contra de esta hipótesis que merece atención explícita: la penetración de las redes sociales no es aleatoria. La probabilidad de que un ciudadano tenga presencia activa en redes sociales depende de factores económicos, geográficos y culturales, lo que introduce un sesgo sistemático si se asume que la audiencia digital de un candidato representa fielmente a su electorado potencial (Skoric et al., 2020). Sin embargo, este argumento pierde fuerza en la medida en que la cobertura digital se aproxima a la universalidad. Según DataReportal (2025), el 70,4 % de la población colombiana usa redes sociales al cierre de 2025, cifra que creció en 1,6 millones de personas solo en 2024, con Facebook, TikTok, YouTube, Instagram y LinkedIn alcanzando al 89,3 %, 93,0 %, 74,4 %, 52,3 % y 44,4 % de los adultos colombianos, respectivamente. Significativamente, X/Twitter, la plataforma que concentra la mayor parte de la literatura de predicción electoral con redes sociales, solo alcanza al 12,0 % de los adultos en Colombia, lo que compromete estructuralmente cualquier modelo que dependa exclusivamente de esa fuente.

Formulación del problema

Considérese una elección de ganador único para un cargo ejecutivo ; alcalde, gobernador o presidente con un conjunto finito de C candidatos competitivos $\mathcal{C} = \{c_1, c_2, \dots, c_C\}$. Para cada candidato c_i , se observa un vector de características digitales:

$$\mathbf{x}_i \in \mathbb{R}^d \tag{1.1}$$

construido a partir de las interacciones acumuladas en sus publicaciones de redes sociales durante una ventana de n días previos a la jornada electoral. Este vector puede incluir interacciones totales, *engagement* por publicación, dominancia relativa respecto al total de interacciones de la elección, entre otras métricas.

La hipótesis central de este trabajo postula que existe una función:

$$f : \mathbb{R}^d \rightarrow [0, 1]^C \tag{1.2}$$

tal que $f(\mathbf{x}_i)$ aproxima la cuota de voto esperada del candidato c_i , con la restricción natural de que las predicciones sumen a la unidad sobre todos los candidatos de la misma elección:

$$\sum_{i=1}^C f(\mathbf{x}_i) = 1 \quad (1.3)$$

La contribución metodológica de este trabajo respecto a la literatura previa reside en el mecanismo de aprendizaje de f . En los modelos existentes, incluyendo el SOMEN-DC (K. Brito & Adeodato, 2023), esta función se aprende de forma independiente para cada elección, usando las encuestas de intención de voto como variable objetivo. En el modelo propuesto, f se aprende sobre un conjunto de M elecciones históricas $\mathcal{E} = \{e_1, e_2, \dots, e_M\}$, usando directamente el resultado electoral como fuente de verdad. Esto tiene dos implicaciones fundamentales: primero, elimina la dependencia de encuestas en cualquier etapa del proceso; segundo, permite que los parámetros aprendidos capturen patrones que son comunes entre elecciones, la relación estructural entre tracción digital y respaldo electoral, y no los detalles particulares de una campaña en específico. Una vez entrenada, f puede aplicarse a una elección nueva $e_{M+1} \notin \mathcal{E}$ sin necesidad de datos de entrenamiento adicionales, lo que constituye la propiedad de **elección-agnosticismo** que da nombre al modelo.

Bajo este marco, el modelo opera recibiendo como *input* el vector $\mathbf{x}_i$ de interacciones digitales de cada candidato, calculado sobre una ventana de n días previos a la jornada electoral. El *output* es un vector $\hat{\mathbf{y}} \in [0, 1]^C$ donde cada componente $\hat{y}_i = f(\mathbf{x}_i)$ representa la cuota de voto estimada para el candidato c_i , respondiendo a la pregunta: *si las elecciones ocurrieran hoy, ¿Qué porcentaje de los votantes apoyaría a cada candidato?*

1.4. Estructura del documento

Para abordar esta hipótesis, la investigación se estructuró a través de tres etapas empíricas que guían la organización de este documento. El **Capítulo 2** define formalmente la pregunta de investigación y los interrogantes derivados. El **Capítulo 3** presenta el marco conceptual, explorando la literatura sobre *nowcasting* electoral y la viabilidad de los modelos elección-agnósticos. Seguidamente, el **Capítulo 4** detalla los objetivos del estudio.

El **Capítulo 5** desarrolla la metodología, dividida en las tres fases del proyecto:

- **Bolivia (Prueba de concepto):** Donde se replica el modelo SOMEN-DC para evaluar empíricamente sus limitaciones.
- **Costa Rica (Modelado de crecimiento):** Enfocada en resolver el problema del registro histórico mediante la calibración matemática de la curva de crecimiento de las interacciones.
- **Colombia (Construcción y modelado final):** Donde se compila el *dataset* elección-agnóstico de elecciones locales (2023) y se entrenan los algoritmos de clasificación y regresión.

Finalmente, el **Capítulo 6** expone los resultados obtenidos en cada fase, mientras que los **Capítulos 7 y 8** discuten el impacto esperado de la herramienta, sus limitaciones inherentes y las conclusiones definitivas del estudio.

2

Pregunta de investigación

Para abordar las limitaciones metodológicas previamente expuestas relativas a la dependencia de las encuestas y la imposibilidad de transferir los modelos de *nowcasting* a nuevas elecciones, esta investigación se estructura alrededor de un interrogante central y una serie de preguntas derivadas que guían el diseño empírico del estudio.

2.1. Pregunta principal

La inquietud fundamental que motiva este trabajo se sintetiza en la siguiente pregunta de investigación:

*¿Es posible diseñar e implementar un modelo de nowcasting de la intención de voto que sea **elección-agnóstico**, es decir, cuyos parámetros se entrenen con datos de múltiples elecciones simultáneas y sean transferibles a contiendas no vistas, que no dependa en ninguna etapa de encuestas de opinión pública, y que pueda aplicarse con precisión a elecciones locales en Colombia utilizando únicamente señales extraídas de interacciones en redes sociales?*

Esta pregunta desafía el paradigma establecido en la literatura (representado por modelos como el SOMEN-DC), buscando independizar por completo el pronóstico de las encuestas y evaluar si las huellas digitales por sí solas contienen suficiente información estructural para estimar el apoyo político en un ecosistema electoral altamente fragmentado como el colombiano.

2.2. Preguntas derivadas

Para dar respuesta a la pregunta principal de manera secuencial y estructurada, el estudio plantea cuatro preguntas de investigación derivadas, cada una asociada a un desafío metodológico o empírico específico:

1. **Sobre la capacidad predictiva intrínseca de la red:** ¿Las interacciones en redes sociales de los candidatos (volumen de *likes*, comentarios, visualizaciones, etc.) tienen un poder predictivo estadísticamente significativo sobre el resultado electoral real en el contexto latinoamericano?
2. **Sobre la viabilidad de la reconstrucción de series temporales:** Dado que las plataformas digitales no almacenan un registro público del historial de interacciones de una publicación, ¿Es posible reconstruir matemáticamente la curva de crecimiento de las interacciones de publicaciones pasadas sin haber realizado *scraping* en tiempo real durante la campaña original?
3. **Sobre la selección de características (feature engineering):** Entre las múltiples señales disponibles, ¿Qué tipo de métricas digitales resultan más informativas para el

pronóstico electoral: el volumen absoluto de interacciones de un candidato, su *dominancia relativa* en comparación con sus contrincantes, o su capacidad para generar tracción tardía en los últimos días de la campaña?

4. **Sobre la escalabilidad y el tipo de modelado:** Considerando las limitaciones en el tamaño de muestra de elecciones históricas viables para estudio, ¿Con cuántos ejemplos de entrenamiento es estadísticamente factible y robusto entrenar un modelo de **clasificación** (predecir quién gana) versus un modelo de **regresión** (predecir el porcentaje exacto de votos)?

3

Marco conceptual

3.1. *Nowcasting* electoral y predicción con redes sociales

3.1.a. Definición de *nowcasting* en contexto electoral

En ciencia política, *nowcasting* (pronóstico del presente) designa una estimación cuantitativa de “lo que pasaría si la elección se celebrara hoy”. Se diferencia del *forecasting* clásico (predicción a futuro) en que el *nowcasting* busca modelar el estado actual y latente del electorado mediante actualizaciones continuas y en tiempo real, basándose en un modelo cuyos parámetros estructurales se mantienen fijos mientras varían las covariables observadas Lewis-Beck y Tien, 2014; Lewis-Beck et al., 2011.

La primera formulación formal aplicada a elecciones nacionales se consolidó con los modelos *proxy*. Por ejemplo, en el Reino Unido, Lewis-Beck et al. (2011) modelaron el voto del oficialismo a partir de indicadores adelantados, como la aprobación del gobierno, medida con meses de antelación. En épocas más recientes, con el auge del *Big Data*, la literatura empírica se ha volcado al uso de redes sociales como fuente masiva de covariables en tiempo real, transformando el *nowcasting* en una herramienta de minería de datos dinámicos Skoric et al., 2020.

Desde el estudio seminal de Tumasjan et al. (2010), múltiples autores han explorado arquitecturas híbridas. Trabajos recientes como los de K. Brito y Adeodato (2022, 2023) han sofisticado la técnica combinando recolección de datos durante la campaña (*During Campaign*) y modelos de aprendizaje automático (*Machine Learning*) aplicados a Latinoamérica. Sin embargo, estas aplicaciones mantienen una dependencia crítica: el entrenamiento constante frente a encuestas tradicionales.

3.2. Modelos elección-agnósticos: definición y ventajas

Un modelo **elección-agnóstico** es aquel que se entrena utilizando datos conjuntos de múltiples elecciones simultáneamente, con el propósito de aprender reglas de decisión y pesos paramétricos que representen patrones de comportamiento electoral universales

(o regionalmente consistentes), de modo que sean directamente transferibles a elecciones no vistas.

Formalmente, sea $\mathcal{E} = \{e_1, e_2, \dots, e_M\}$ un conjunto de M elecciones históricas diferentes (por ejemplo, alcaldías de distintas ciudades). El objetivo es aprender una función predictiva:

$$f : \mathbb{R}^d \rightarrow [0, 1] \quad (3.1)$$

tal que $\hat{y}_{i,m} = f(\mathbf{x}_{i,m})$, donde $\mathbf{x}_{i,m}$ es el vector de características de d dimensiones (interacciones digitales, tasas de crecimiento, dominancia) del candidato i en la elección m , y $\hat{y}_{i,m}$ es la cuota de voto estimada o la probabilidad de victoria.

La principal ventaja matemática y operativa de este enfoque frente a arquitecturas específicas de campaña como el SOMEN-DC K. Brito y Adeodato, 2023 radica en su escalabilidad e independencia. Al abstraer la función f sobre M elecciones, el modelo se desacopla de la necesidad de contar con datos de encuestas como variable dependiente, utilizando directamente los resultados electorales finales como *ground truth*. Asimismo, elimina la dependencia de infraestructura de *scraping* en tiempo real, pues la predicción sobre una elección nueva $\mathcal{E}_{new}$ requiere únicamente extraer los vectores $\mathbf{x}_{new}$ y procesarlos a través del modelo pre-entrenado.

3.3. Interacciones digitales como *proxy* de intención de voto

3.3.a. La hipótesis Tumasjan

El uso de señales digitales como estimador político se sustenta empíricamente en el trabajo fundacional de Tumasjan et al. (2010) sobre las elecciones federales alemanas de 2009. Estos autores demostraron que el simple conteo volumétrico de *tweets* que mencionan a un partido refleja fielmente el resultado electoral, logrando un error absoluto medio (MAE) de 1.65 %. Esta hipótesis sugiere que la atención (reflejada en interacciones y contenido generado) equivale a capital político en la arena digital.

3.3.b. Interacciones absolutas vs. dominancia relativa

Si bien el volumen absoluto de interacciones (por ejemplo, el total de *likes*) ofrece una señal importante, presenta ruido debido a la heterogeneidad de los distritos electorales y la presencia de cuentas atípicamente virales. Para mitigar esto, este estudio introduce y prioriza la métrica de **dominancia relativa**: el porcentaje de interacciones que acumula un candidato sobre el total de interacciones generadas por todos los candidatos competitivos dentro de su misma ciudad o distrito.

Los análisis exploratorios sobre las elecciones locales colombianas de 2023 presentados en este trabajo confirman que la dominancia relativa es significativamente más informativa que el volumen absoluto. La correlación de Spearman entre la dominancia relativa en interacciones y la cuota de voto real alcanza $\rho > 0.46$ con $p < 2 \times 10^{-7}$.

No obstante, se deben reconocer las limitaciones intrínsecas de este *proxy*. Las redes sociales son ecosistemas permeables a la actividad no inorgánica (bots, manipulación coordinada), sesgos demográficos propios de las plataformas y la existencia de candidatos que, por su condición de figuras públicas o *influencers*, generan tracción digital

desproporcionada a su verdadera viabilidad electoral.

3.4. El problema del histórico de interacciones

Uno de los mayores desafíos para entrenar modelos predictivos retrospectivos es la opacidad temporal de los datos en redes sociales. Plataformas como Facebook, Twitter/X y TikTok muestran únicamente el total acumulado de interacciones de una publicación en el instante en que es consultada (hoy). No guardan ni exponen públicamente la curva histórica de crecimiento; por lo tanto, es imposible observar directamente cuántos *likes* tenía una publicación específicamente el día anterior a las elecciones, un dato crucial para el *nowcasting*.

Para sortear este obstáculo metodológico, este trabajo propone modelar matemáticamente la curva de crecimiento acumulado de las interacciones utilizando una distribución de Weibull con parámetro de desplazamiento (*offset*):

$$F(t) = 1 - e^{-k \cdot (t+t_0)^\alpha} \quad (3.2)$$

donde t es el tiempo transcurrido (en días) desde la publicación; k es el parámetro de escala que determina la velocidad general de acumulación; α es el parámetro de forma que captura la rápida deceleración típica del consumo de contenido en redes (decaimiento exponencial); y t_0 modela la asimetría temporal inicial, capturando la explosión masiva de interacciones que ocurre en las primeras horas antes de que t se convierta en 1 día.

Al calibrar estos parámetros (k, α, t_0) de forma diferenciada para cada plataforma, es posible proyectar la curva $F(t)$ hacia el pasado y estimar con alta fidelidad las métricas que tenía cualquier publicación histórica en la víspera electoral.

4 Objetivos

4.1. Objetivo general

Diseñar e implementar un modelo de *nowcasting* de la intención de voto en elecciones locales colombianas que sea elección-agnóstico, no dependa de encuestas, use únicamente interacciones en redes sociales de los perfiles oficiales de los candidatos, y pueda replicarse con herramientas comerciales accesibles.

4.2. Objetivos específicos

1. **OE1.** Replicar y evaluar empíricamente el modelo SOMEN-DC en la segunda vuelta presidencial de Bolivia (octubre de 2025).
2. **OE2.** Modelar el crecimiento temporal de las interacciones en redes sociales usando varios modelos de forma comparativa.

3. **OE3.** Construir un *dataset* de entrenamiento elección-agnóstico con datos de las elecciones locales colombianas de 2023.
4. **OE4.** Entrenar y evaluar modelos de clasificación y regresión del resultado electoral.
5. **OE5.** Documentar las condiciones de viabilidad metodológica del modelo propuesto y documentar sus limitaciones.

5

Metodología

5.1. Definición formal del problema

5.1.a. Definición de la elección

Definimos una elección, llamada **elección agnóstica** como e donde $e \in E$ y E es el conjunto de todas las elecciones agnósticas que cumplen los siguientes requisitos:

- Es un proceso competitivo no determinístico definido como la participación de dos o más candidatos con posibilidades reales de ganar y condiciones equitativas **kayser2015**.
- Tiene por ganador a un único candidato por elección $c_{ganador,e} \in C_e$ con C_e siendo el conjunto de candidatos para la elección e .
- El candidato ganador $c_{ganador,e}$ es aquel que obtuvo más votos entre las opciones posibles de la elección e .
- Se desarrolla en un periodo de tiempo acotado $t \in [t_0, t_f]$, con t_0 y t_f siendo el inicio y fin de la campaña, que sería el día anterior a la elección.
- Se mide mediante los votos de los electores $v_e \in V_e$, siendo V_e el conjunto de todos los electores de la elección e .
- Todos los candidatos del universo de elecciones E tienen cuentas oficiales de un conjunto de redes sociales R con $r \in R$ y publican activamente en ellas para el momento t_0 . En el ejercicio de Bolivia y Costa Rica estas fueron Facebook, TikTok, X/Twitter e Instagram mientras que para Colombia se omitió Instagram.

5.1.b. Definición de la intención de voto y los resultados

Definimos la intención de voto como el número de votantes v_e que, en un momento t , escogerían al candidato c_e . Esta es una variable subyacente, ya que no todos los votantes tienen definido su voto desde el t_0 , algunos no van a votar o pueden hacerlo en blanco. Las encuestas son estimadores de esta misma variable, pero dado que esta variable solo toma un valor definido el día de las elecciones, no podemos usar una metodología clásica de series de tiempo para modelar la evolución temporal de la intención de voto. Por lo tanto,

modelamos la relación entre los vectores de métricas de redes sociales de los candidatos desde una cantidad de días antes de la elección y el valor que sabemos que toma la intención de voto el día de las elecciones.

La elección e tiene una intención de voto asociada, representada por un vector $i_e \in I_e$, donde I_e es el conjunto de intenciones de voto para la elección e . Este vector está compuesto por una secuencia de intenciones de voto, una por cada candidato, ordenadas de forma idéntica al vector de candidatos C_e . Es decir, $i_e = (i_{e,c_1}, i_{e,c_2}, \dots, i_{e,c_{|C_e|}})$, donde i_{e,c_j} es la intención de voto del candidato c_j para la elección e . Esta intención de voto para el candidato c_e se calcula como su número de votos porcentual obtenido en la elección e , es decir:

$$i_{e,c_j} = \frac{v_{e,c_j}}{v_e}$$

donde v_{e,c_j} es el número de votos del candidato c_j para la elección e y v_e es el número total de votos para cualquiera de los candidatos de la elección e , es decir $\sum_{j=1}^{|C_e|} v_{e,c_j} = 1$. Es muy importante denotar que esta suma NO incluye votos nulos, en blanco o similares.

Dadas estas condiciones, tenemos que una elección de estas características es un evento que es posible acotar a métricas comparables del conjunto de elecciones sin importar su número de candidatos. De esta forma, pasamos a definir como funcionan las publicaciones, interacciones e intención de voto.

5.1.c. Definición formal de las publicaciones y su comportamiento temporal

Partimos de una publicación cualquiera, es decir un elemento p , de un candidato c_e , en una fecha t , en una red social r_j , es decir, un $p_{e,c,r,t}$, que simplificamos a $p_i \forall i \in I$ para un momento de recolección de información t . Esta publicación posee un conjunto de características que permite su comparación con otras publicaciones:

- Fecha de publicación t_{pub}
- Fecha de recolección de información t_{rec}
- Vector de interacciones a fecha de recolección: me gusta, compartir, comentar, guardar, etc. $x_{i,t_{rec}}$

Este trabajo parte de la idea fundamental que el conjunto de vectores x_i para un candidato c tiene algún tipo y nivel de correlación con su intención de voto $i_{e,c}$ y es lo que el trabajo busca modelar. Este vector puede ser apoyado por otras variables microfundamentadas, como la relación gobierno/oposición, variables económicas, entre otras.

Este vector de interacciones $x_{i,t_{rec}}$ posee una propiedad importante y es que es acumulativo. Con muy notables excepciones causadas por intervención de la plataforma o del candidato, las interacciones de una publicación no caen, por lo que para un momento t , podemos decir que los elementos del vector $x_{i,t}$ son monótonamente no decrecientes. Por lo tanto el vector de interacciones se puede modelar mediante una función $f_j(t_{pub}, t_{rec}, x_i)$ para cada red social, que modela el crecimiento de las interacciones de una publicación a lo largo del tiempo, donde t está en días desde la fecha de publicación.

5.2. Diseño general del pipeline

La arquitectura metodológica de esta investigación está estructurada como un *pipeline* secuencial dividido en tres etapas no continuas. La Etapa 1 corresponde al levantamiento

de los datos de entrenamiento

La arquitectura metodológica de esta investigación está estructurada como un *pipeline* secuencial dividido en tres etapas empíricas. La Etapa 1 corresponde a una prueba de concepto en Bolivia para replicar y evidenciar los problemas estructurales del modelo base. La Etapa 2 aborda el problema de la asimetría de la información temporal, calibrando un modelo de crecimiento matemático en Costa Rica. Finalmente, la Etapa 3 consolida el modelo elección-agnóstico en Colombia.

La arquitectura general del *pipeline* de predicción propuesto opera bajo la siguiente secuencia lógica: en primer lugar, se extraen los datos acumulados actuales de las redes sociales de los candidatos (restringidos a publicaciones realizadas en los últimos 14 días pre-elección); posteriormente, se procesan mediante un modelo paramétrico de Weibull específico por plataforma para estimar la reconstrucción histórica de la curva de crecimiento diario; con esta información, se construyen las *features* diarias por candidato; y, finalmente, un modelo elección-agnóstico pre-entrenado procesa el vector para proyectar un vector C -dimensional con la intención de voto o la probabilidad de victoria de cada contendor.

Todo el ecosistema de recolección de datos fue diseñado para garantizar su accesibilidad y bajo costo, operando sin requerir infraestructura institucional. Para ello, se integraron herramientas comerciales y *scripts* a medida utilizando la plataforma de automatización Make.com, clientes de *scraping* de Apify, la API oficial de Twitter/X y *scripts* de navegación programática o *headless browsers* desarrollados con Playwright.

5.3. Etapa 1 — Bolivia: Replicación del SOMEN-DC y prueba de concepto

5.3.a. Caso de estudio y recolección de datos

Para confirmar empíricamente las limitaciones inherentes a la literatura de *nowcasting* dependiente de encuestas, se planteó un caso de estudio replicando la metodología SOMEN-DC en el contexto de la segunda vuelta presidencial de Bolivia (programada para el 19 de octubre de 2025). Esta contienda polarizada entre Rodrigo Paz Pereira (PDC) y Jorge “Tuto” Quiroga (Alianza Libre) representó un escenario ideal de prueba. El resultado real proyectado para el estudio determinó a Paz como ganador con el 54.53 % frente al 45.47 % de Quiroga.

Se definió una ventana temporal retrospectiva de 180 días (del 18 de mayo al 18 de octubre de 2025), extrayendo datos diariamente de las cuentas oficiales de ambos candidatos en Facebook, Twitter/X, Instagram y TikTok. Esto generó un vector de 29 características (*features*) por candidato y por día, incluyendo métricas absolutas (volumen de publicaciones, *likes*, comentarios, compartidos) y métricas relativas (como el *engagement* promedio por publicación), normalizadas posteriormente mediante puntajes Z (*z-scores*).

La variable objetivo se construyó interpolando linealmente los resultados de las principales encuestas publicadas durante ese período (firmas como Ipsos Ciesmori, SPIE, Captura Consulting y Ciemcorp), anclando el último punto de la serie al resultado electoral real. El *dataset* final consolidó 308 registros diarios independientes.

5.3.b. Evaluación de modelos

Siguiendo la arquitectura original, se entrenaron y evaluaron múltiples topologías algorítmicas, incluyendo Regresión Lineal Clásica, Perceptrón Multicapa con *Backpropagation* (MLP-BP) y Redes Neuronales de Regresión Generalizada (GRNN), explorando también variantes con Análisis de Componentes Principales (PCA).

El modelo con mejor desempeño predictivo resultó ser el ensamble MLP-BP + PCA, alcanzando un Error Absoluto Medio (MAE) de 0.0279 y un Error Porcentual Absoluto Medio (MAPE) aproximado del 5.1 %. Este resultado superó considerablemente el *baseline* trivial basado en tomar simplemente el valor de la última encuesta disponible antes de la elección (cuyo MAE en el caso del candidato Paz fue del 0.1803). Cabe destacar que los modelos estrictamente lineales fracasaron sistemáticamente en el ajuste (presentando MAEs entre 0.29 y 0.31), confirmando empíricamente que la relación entre el volumen de interacciones digitales y la tracción en las encuestas exhibe dinámicas fuertemente no lineales.

Los resultados de esta primera etapa confirmaron de manera concluyente los problemas teóricos del SOMEN-DC señalados en la hipótesis: la dependencia estructural de las encuestas para el entrenamiento, el altísimo costo logístico de mantener infraestructura de *scraping* continuo y, más grave aún, la imposibilidad de extrapolar los pesos de la red neuronal a una nueva elección (no generalizabilidad).

5.4. Etapa 2 — Costa Rica: Modelado del crecimiento de interacciones

5.4.a. El problema estructural

Para construir un modelo generalizable a partir de M elecciones pasadas se requiere observar los datos. Sin embargo, las plataformas digitales únicamente muestran el total acumulado de interacciones observables en la fecha actual de la consulta (por ejemplo, si se raspan datos en 2026 sobre una elección de 2023). Este fenómeno imposibilita conocer cuántas de esas interacciones se habían acumulado legítimamente el día de la elección y cuántas correspondieron a tráfico residual o póstumo tras conocerse los resultados electorales. Para resolver esto, es forzoso estimar una curva teórica de crecimiento de interacciones.

5.4.b. Metodología y Modelo Weibull

Se condujo un proceso de recolección intensiva diaria (*panel data*) sobre 2,026 publicaciones únicas correspondientes a los candidatos presidenciales de la campaña de Costa Rica 2026. Al depurar los registros, se aislaron 1,922 publicaciones aptas para el modelado temporal continuo, generando más de 19,439 observaciones cruzadas.

El modelado del crecimiento orgánico de interacciones se parametrizó bajo una curva de distribución Weibull con *offset* temporal, expresada formalmente en la Ecuación 3.2 (Sección 3.4). Mediante rutinas de optimización no lineal, se calibraron los parámetros óptimos para cada plataforma, como se resume a continuación:

Aunque los valores de bondad de ajuste (R^2) del panel parecen matemáticamente discretos, estudios de descomposición de varianza evidenciaron que cerca del 66.8 % del error

Cuadro 5.1: Parámetros Weibull calibrados por plataforma

Plataforma	Escala (k)	Forma (α)	Offset (t_0) [días]	R^2 Panel
Facebook	0.9480	0.8230	1.93	0.3514
Instagram	1.1369	0.5210	0.04	0.4026
TikTok	1.3272	0.5124	0.79	0.3509
Twitter/X	1.4453	1.1422	0.26	0.6905

cuadrático proviene del ruido intrínseco de cada publicación (varianza intra-publicación). Por lo tanto, la verdadera métrica de éxito evaluada fue la precisión proyectiva al último día.

Las validaciones cruzadas determinaron que, si se observaba la publicación al día 3 desde su emisión, entre el 89 % y el 99 % de las inferencias sobre su total asintótico final caían dentro de un margen de error estricto ($\text{MAPE} < 20\%$). Adicionalmente, pruebas T demostraron que, si bien el crecimiento es estadísticamente significativo ($p < 0.0001$) hasta el día 10, desde una óptica empírica el incremento se vuelve marginal a partir del día 5 al 7 ($< 2\%$ diario), justificando sólidamente que una ventana de análisis retrospectivo de 14 días previos a la jornada de votación es matemáticamente suficiente y robusta. Si bien se evaluó la hipótesis cualitativa del “arrastre post-victoria” (por ejemplo, el aceleramiento en las métricas de la ganadora proyectada), este efecto no demostró significancia estadística sobre la muestra analizada, permitiendo que el modelo asuma patrones estacionarios indiferentes al resultado.

5.5. Etapa 3 — Colombia: Construcción del dataset y modelado

Con la solución temporal formalizada, la tercera etapa se concentró en la construcción del *dataset* de entrenamiento masivo. Se estableció un protocolo riguroso de diseño para capturar información exclusiva de las campañas de las elecciones locales de alcaldías en Colombia de octubre de 2023. Se definió un universo geográfico abarcando las 33 ciudades más pobladas de Colombia, procediendo a compilar interacciones generadas estrictamente en la ventana de 14 días previos a los comicios.

Por políticas y restricciones agresivas de la API *Graph* impuestas corporativamente por Meta en sus versiones recientes, Instagram tuvo que ser excluido de la extracción sistematizada. Por tanto, la adquisición de datos de fuentes abiertas iteró sobre tres infraestructuras concurrentes automatizadas a través de un *pipeline* (scripts ‘scrapping_general.py’ y ‘unificar_redes.py’): Playwright para automatización de navegadores ocultos (*headless*) contra la interfaz web de Twitter/X (con restricción de hasta 50 *tweets* por actor); y consultas de alto rendimiento hacia la API privada no documentada de TikTok y las colecciones indexadas de Facebook a través de *Apify*.

Para asegurar la validez inferencial, se aplicaron filtros de exclusión: solo ingresaron al *dataset* actores políticos con más de 10,000 votos confirmados en los escrutinios finales. Se excluyeron deliberadamente dos ciudades, la capital Bogotá (debido al sesgo de representatividad por el perfil de *influencer* de Gustavo Bolívar, cuya masiva tracción general superaba demográficamente la esfera meramente local) y Piedecuesta (debido a que la candidatura ganadora enfrentó problemas legales que resultaron en la desaparición intencional de sus perfiles y rastros de campaña). En casos anómalos como el de Santa

Marta, donde la candidatura de mayor votación enfrentó revocatoria legal posterior, el estudio consideró ganador computacional al actor con mayor volumen bruto de votos consignados, para preservar la correlación con la intención ciudadana.

Tras los filtros geográficos y de calidad de datos documentados en el análisis exploratorio preliminar ('`analisis_exploratorio.ipynb`'), el universo hábil final consolidó 5,776 publicaciones únicas distribuidas a través de las tres infraestructuras monitoreadas (2,511 en Facebook, 2,346 en Twitter/X y 919 en TikTok). Estas entradas correspondieron a un censo final de 328 candidatos repartidos a través de 31 ciudades competitivas. Sobre los 112 candidatos que superaban la barrera estadística de los 10,000 votos (cuya cobertura digital era altísima, con 92.6 % de ellos poseyendo publicaciones de red activas en el archivo), los análisis paramétricos confirmaron tempranamente la existencia de señal predictiva: las interacciones totales medias evidenciaban que los ganadores promediaban 44,252 frente a 28,011 de los perdedores, y las pruebas U de Mann-Whitney validaban una superioridad de *engagement* medio por publicación estadísticamente significativa para un 95 % de confianza ($p = 0.0481$). De manera asilada, un pronosticador empírico básico (*baseline*) asumiendo que el ganador fuera siempre aquel con mayor volumen nominal habría acertado en el 57.58 % de las jurisdicciones municipales.

La integración operativa del modelo de crecimiento de la Etapa 2 se ejecutó a través de la rutina '`Reconstruccion_Panel_Historico.ipynb`'. Aplicando los parámetros k , α estáticos y derivando el t_0 dinámico en función del lapso transcurrido desde la creación particular de cada post, la red reconstruyó la matriz histórica produciendo un super-*dataset* validado de 5,776 instancias por 340 campos numéricos (representando las permutaciones correspondientes a 11 subclases de métricas y sus rezagos o sumatorias acumuladas en plazos iterativos de 30 días escalables). Las calibraciones documentales confirmaron que la monotonicidad de las curvas sintéticas era impecable (cumplimiento en 5,776 de 5,776 ensayos) y el factor de error mediano inyectado sobre las estimaciones finales se situaba matemáticamente en un 0.000 % absoluto para proyecciones convergentes en el día 14.

5.6. Modelado predictivo

La etapa terminal concentró los análisis econométricos y heurísticos bajo dos grandes paradigmas clásicos de la Inteligencia Artificial.

5.6.a. Modelo de regresión

El enfoque predictivo continuo ('`Modelo_Predictivo_Electoral.ipynb`') pretendía encontrar un mapeo directo para estimar la magnitud escalar porcentual de votos. Con un tensor de entrenamiento reducido dimensionalmente (112 individuos por 84 variables explicativas macro), las optimizaciones se condujeron aplicando el protocolo analítico de validación cruzada dejando uno fuera (*Leave-One-Out Cross-Validation*, LOO-CV) para mitigar correlaciones espaciales endógenas. Las arquitecturas de Vectores de Soporte Regresivo (SVR) provistas de *kernel* radial (RBF) lograron los mejores comportamientos topográficos, pero exhibieron resultados mediocres de inferencia (Error Absoluto Medio de 15.22 puntos porcentuales de desviación por estimación y una varianza explicada o R^2 irrisoria del 0.054). La saturación matemática diagnosticó enfáticamente un sobreajuste estructural de la red; la abundancia masiva de variables intervinientes no era asimilable

para el pequeño volumen de observaciones empíricas. Se desestimó este enfoque, por ahora, como una ruta viable a corto plazo.

5.6.b. Modelo de clasificación binaria

Tras constatar la asimetría matricial, el análisis se reconceptualizó sobre el paradigma probabilístico discreto ('Clasificacion_Binaria_Electoral.ipynb'), simplificando la tarea del algoritmo a una función discriminatoria simple: adivinar el ganador o vencedor absoluto por distrito (*¿quién gana?*). El hiperplano se centró en priorizar masivamente el constructo analítico de la **dominancia relativa** como entrada primordial. Con un balance de clases nativo de 24.1 % (casos positivos, victoriosos) versus 75.9 % (casos negativos), los clasificadores de Regresión Logística Penalizada (LOO-CV) dominaron ampliamente, registrando niveles de *Accuracy* ponderado de 0.812 y coeficientes AUC-ROC de 0.770, traducándose en pronósticos asertivos para el 59.3 % de las municipalidades (16 aciertos en 27 contiendas).

Aunque estas mediciones confirman irreprochablemente que el capital político latente sí se manifiesta y decodifica a través de las interacciones sociales (la señal existe y el ruido no la silencia estadísticamente), un heurístico ingenuo (*baseline*) estipulado al comienzo de la experimentación —pronosticar ciegamente a favor del postulante con el mayor indicador bruto acumulado de *dominancia_engagement* en el ecosistema municipal— ostentaba un nivel de predicción efectiva del 70.4 % (19 aciertos de 27). Por ende, el algoritmo no pudo rebasar este techo estadístico debido a la falta de masa crítica de entrenamiento y volumen electoral comparado en los rangos analíticos; con mayores tamaños y adiciones de contiendas iteradas, la profundidad topológica se revelaría.

6

Resultados

6.1. Resultados de Bolivia (Etapa 1)

La replicación de las técnicas de pronóstico dependientes de encuestas en el contexto de la segunda vuelta boliviana de 2025 arrojó resultados mixtos que confirmaron las sospechas teóricas iniciales sobre la viabilidad de la metodología convencional.

En términos de precisión bruta, la experimentación demostró que la relación entre la acumulación de interacciones y la proyección demoscópica no obedece a dinámicas lineales. Los modelos lineales clásicos fallaron de manera sistemática, pero el ensamble óptimo de Perceptrón Multicapa con Análisis de Componentes Principales (MLP-BP + PCA) logró un Error Absoluto Medio (MAE) de 0.0279 y un MAPE de 5.1 %. Este resultado mejoró abrumadoramente el estimador básico (*baseline*) de predecir basándose únicamente en el valor inercial de la última encuesta publicada (cuyo MAE se disparaba al 0.1803 para el candidato ganador, Paz).

Sin embargo, a nivel operativo y analítico, se evidenciaron falencias críticas que des-

aconsejaron continuar por esta ruta de *nowcasting*. Primero, se ratificó la absoluta falta de generalización: la topología y los pesos optimizados de la red neuronal carecían de validez semántica fuera de esa elección particular, confinando el esfuerzo computacional a un único evento irrepetible. Segundo, el modelo mostró una preocupante ceguera ante giros súbitos del electorado; los cambios de favorabilidad que ocurrieron en la última semana crítica de campaña no fueron reflejados por las métricas de interacciones acumuladas. Por último, un análisis detallado de importancia de variables identificó que la dinámica de viralidad de TikTok operaba en un plano disociado del resto de plataformas, inyectando varianza espuria en momentos en que la intención de voto real permanecía estacionaria.

6.2. Resultados de Costa Rica (Etapa 2)

El modelado paramétrico de la variable tiempo resolvió satisfactoriamente el obstáculo estructural para la explotación de registros históricos sin depender de infraestructura activa de extracción. A través de la calibración supervisada de 1,922 publicaciones presidenciales del panel costarricense, el sistema logró aislar parámetros k, α universales para cuatro plataformas hegemónicas (Facebook, Instagram, TikTok, Twitter/X).

Las pruebas de precisión y decaimiento del error proyectivo resultaron formidables. Al observar cualquier publicación con apenas tres días ($t = 3$) de vida útil, el modelo matemático de distribución Weibull logró predecir el límite asintótico total final de esa publicación con un error inferior al 20 % para entre el 89 % y el 99 % de los casos de la muestra empírica.

A nivel estadístico descriptivo, aunque las curvas de crecimiento mantenían una gradiente matemáticamente significativa (con $p < 0.0001$) hasta por lo menos 10 días tras el evento de publicación, el estudio demostró que desde una perspectiva pragmática o de negocio, la curva se vuelve plana (crecimiento diario menor al 2 %) a partir de una ventana de 5 a 7 días. Esta dinámica de saturación viral rápida validó metodológicamente la decisión de encapsular los *datasets* de extracción a una ventana móvil o estática de 14 días (holgura de seguridad del doble del tiempo de saturación).

Consecuentemente, se consolidó la herramienta computacional de **reconstrucción histórica temporal**, la cual evidenció una calidad algorítmica intachable: no se documentaron violaciones de monotonía (una publicación nunca perdía interacciones reconstruidas al retroceder en el tiempo), y el error mediano inyectado a la serie temporal original en el día 14 pre-elección fue matemáticamente cero.

6.3. Resultados de Colombia (Etapa 3)

La evaluación del ecosistema digital de las elecciones de alcaldes 2023 sobre las 31 ciudades competitivas colombianas confirmó irrevocablemente la hipótesis fundacional del estudio empírico: las interacciones en redes sociales sí albergan una señal predictiva real y cuantificable sobre el comportamiento en urnas.

Las pruebas no paramétricas de distribución confirmaron que, en promedio, los candidatos ganadores movilizaban más interacciones globales y poseían un *engagement* marginal por post significativamente más alto ($p < 0.05$) que el resto de contendientes derrotados de sus respectivos tarjetones. Más profundamente, la experimentación estableció

un paradigma de extracción de características: la **dominancia relativa** de la conversación digital en el territorio superó con creces al volumen nominal de interacciones como predictor de éxito, logrando índices de correlación monótona de Spearman superiores a 0.46.

Frente a la escalabilidad de modelado en escasez de datos (112 muestras), los resultados fueron contrastantes. El abordaje de **regresión lineal / no-lineal** para adivinar márgenes porcentuales exactos de voto fracasó categóricamente (el máximo techo explicativo o pseudo- R^2 alcanzado fue apenas del 0.118), indicando que el espacio dimensional es excesivamente grande y ruidoso frente a la disponibilidad de observaciones.

Por el contrario, la **clasificación probabilística discreta** (resolver quién es el ganador binario del certamen en cada ciudad) exhibió una convergencia parcial y funcional. Los modelos de ensamble superaron métricas conservadoras con tasas de aciertos ponderadas del 59.3 % en adivinar correctamente el mapa político regional de ganadores por capitales. No obstante, las arquitecturas entrenadas no lograron desbancar al heurístico analítico puro (*baseline*): simplemente asignar como ganador determinista al candidato que en solitario concentró la mayor dominancia de *engagement* en su respectiva ciudad reportó una tasa de acierto del 70.4 %. La señal existe intrínsecamente en el vector espacial, pero la reducida cardinalidad de la matriz actual imposibilita que una red compleja de aprendizaje automatizado abstraiga patrones topológicos multidimensionales que le permitan abatir una simple regla algorítmica descriptiva.

6.4. Síntesis: contribuciones al estado del arte

Los hallazgos empíricos y los desarrollos técnicos documentados a lo largo de este estudio confluyen en cuatro contribuciones sustanciales al dominio de la analítica política y los modelos predictivos heterodoxos:

1. **Elección-Agnosticismo Empírico:** Se establece una ruta metodológica viable (demostrada a través de la clasificación binaria basada en la métrica transversal de dominancia relativa) para romper la asimetría temporal del SOMEN-DC, permitiendo entrenar algoritmos con observaciones de múltiples contiendas de alcaldías paralelas simultáneamente y abstraer reglas de decisión exportables.
2. **Total Independencia Demoscópica:** A diferencia de la inmensa mayoría de la literatura contemporánea en estimación digital electoral, este esquema sustituye la obligatoriedad de usar encuestas como variable dependiente, anclando directamente su optimización sobre la variable *ground truth* universal: el escrutinio final.
3. **Restaurador Temporal de Series (Modelo Weibull):** Se introduce y formaliza una arquitectura matemática de interpolación capaz de retrotraer variables acumulativas hacia instantes en el pasado. Esto soluciona drásticamente el que quizás sea el mayor obstáculo técnico para la investigación retrospectiva de dinámicas digitales, facultando a los analistas a poblar *datasets* de series temporales históricas partiendo exclusivamente de un raspado actual estático, sin requerir despliegues preventivos costosos.
4. **Democratización del Pipeline:** Se desmitifica la barrera logística del analfabetismo algorítmico, comprobando la total escalabilidad y operatividad de la solución utilizando, de principio a fin, una orquestación ligera ensamblada con herramientas de mercado genéricas (*Make*, *Apify*, API oficiales, librerías *Headless*), demostrando que la predicción y monitoreo algorítmico no es una tecnología que deba residir exclusivamente bajo el control de infraestructuras corporativas, gubernamentales o institucionales avanzadas.

7 Impacto esperado

7.1. Impacto académico

Esta investigación aspira a realizar una aportación fundacional a la literatura de ciencia de datos políticos y estudios electorales cuantitativos en América Latina. A nivel epistemológico, este trabajo documenta la primera metodología estructurada de *nowcasting* electoral elección-agnóstica e independiente de encuestas conceptualizada e implementada para el entorno político altamente fragmentado de Colombia.

Metodológicamente, la formalización matemática del **modelo de crecimiento Weibull** constituye un artefacto científico de exportación. Al proporcionar un marco matemático capaz de reconstruir la evolución temporal de la tracción digital sin depender de registros en tiempo real, el estudio libera a futuras investigaciones académicas de la obligación logística de desplegar sensores de recopilación con meses de antelación al evento electoral de interés.

Adicionalmente, se efectúa una contribución transversal al debate global sobre la viabilidad de la predicción electoral mediante redes sociales, delineando claramente las fronteras de escala empírica: delimitando la inviabilidad estructural de las arquitecturas de regresión volumétrica en escenarios de escasez dimensional (muestras menores a 200 casos), al tiempo que valida matemáticamente la *dominancia relativa* como el estimador heurístico más robusto en elecciones subnacionales.

7.2. Impacto práctico

En una dimensión operativa, el principal aporte aplicativo es la materialización de un sistema orquestado de pronóstico y monitoreo de extremado bajo costo. Al demostrarse la reproducibilidad absoluta del ecosistema metodológico empleando herramientas comerciales de extracción *off-the-shelf* (como *Apify* o integradores *no-code* como *Make.com*) y prescindiendo por completo de servidores y arquitecturas universitarias dedicadas, la investigación democratiza el análisis de datos políticos complejos.

Este avance abre la puerta para que medios de comunicación regionales, laboratorios de veeduría ciudadana y pequeñas firmas de consultoría estratégica desplieguen capacidades de inteligencia electoral en tiempo real. En el mediano plazo, estas técnicas se proyectan como la alternativa natural y costo-eficiente frente a los oligopolios demoscópicos, especialmente en otras naciones de Latinoamérica donde la carencia de encuestas sistemáticas o la desconfianza pública en sus resultados exigen métodos de estimación paralelos transparentes y auditables.

7.3. Limitaciones y trabajo futuro

La honestidad intelectual obliga a delimitar las fallas orgánicas y los confines de aplicabilidad del estudio. En primer lugar, la calibración de la matriz temporal Weibull, si bien fue exhaustiva a nivel micro de publicaciones, descansó sobre el comportamiento macro de una única elección (Costa Rica 2026). Asumir universalidad conductual exige una validación prospectiva replicando la medición longitudinal sobre certámenes demográficamente disímiles para confirmar la estabilidad inter-elecciones de los parámetros de forma y escala.

En segundo lugar, por determinaciones corporativas restrictivas de la compañía Meta, Instagram quedó excluido del *dataset* colombiano; esta omisión representa una pérdida incalculable de la fotografía generacional y el consumo audiovisual de una gran franja del electorado joven. Asimismo, tanto el modelo de dominancia heurística como los ensambles algorítmicos probaron ser estructuralmente vulnerables a perfiles políticos con audiencias atípicas (como lo demostró la exclusión forzosa del candidato *influencer* Gustavo Bolívar), revelando que las masas críticas interdepartamentales contaminan la medición estrictamente local. Todo esto sin ignorar que el conteo volumétrico peca de ceguera ante la calidad y veracidad de la interacción: las arquitecturas modeladas no están equipadas actualmente para ponderar el efecto adverso o positivo de interacciones manufacturadas artificialmente (granjas de *bots*, perfiles inorgánicos o *astroturfing*).

Por lo tanto, la agenda de ****trabajo futuro**** a desprender de esta investigación es rica y expansiva. Se priorizará escalar el conjunto de datos integrando eventos asimétricos (elecciones legislativas departamentales) y otras geografías de la región andina; investigar el desempeño matricial de agregar ventanas temporales de memoria (*lagged variables*); desarrollar clasificadores semánticos que depuren la señal descartando la actividad inorgánica artificial; e incorporar en el plano explicativo covariables estructuradas *offline* (indicadores económicos territoriales y clima de opinión en la prensa tradicional). Inmediatamente, la prioridad empírica definitiva será la confrontación longitudinal ciega del clasificador binario entrenado contra los resultados de las próximas elecciones territoriales en Colombia del año 2027.

8

Conclusiones

8.1. Respuesta a la pregunta de investigación

Este documento se originó a partir de una inquietud central: evaluar si era metodológicamente posible diseñar un modelo de *nowcasting* electoral elección-agnóstico y emancipado de las encuestas para el complejo entorno local colombiano. A la luz de los hallazgos empíricos, la respuesta global es afirmativa con matices estructurales: el modelo es conceptual y operativamente posible, pero su techo predictivo actual está condicionado

por el volumen histórico de entrenamiento.

En primer lugar, se demostró irrefutablemente que las interacciones ciudadanas en plataformas sociales **tienen un poder predictivo real** sobre el comportamiento del electorado colombiano. Las pruebas no paramétricas arrojaron diferencias significativas ($p < 0.05$) entre ganadores y perdedores, y la correlación de rango cruzó un umbral robusto de Spearman $\rho > 0.46$. No obstante, la experimentación también comprobó que, frente a un problema de alta varianza como una elección fragmentada, la señal extraída aislada de la red sin covariables de apoyo es ruidosa e insuficiente para dictar sentencias determinísticas absolutas a nivel nacional.

En segundo término, la viabilidad del modelo descansaba sobre la premisa de la **reconstrucción temporal**. Las pruebas sobre el panel de control validaron que la interpolación matemática mediante distribuciones de Weibull es excepcionalmente precisa (inyectando errores menores al 20 % en más del 89 % del material muestral observado tempranamente). En consecuencia, un marco analítico elección-agnóstico se ha consolidado como un enfoque empírico viable y robusto: el modelo puede abstraer y aplicar reglas universales. Sin embargo, para que las arquitecturas topológicas (como redes neuronales o ensambles complejos) logren trascender el desempeño del algoritmo *baseline* trivial basado en dominancia relativa, se torna imperativo inyectar iteraciones masivas de eventos históricos en la matriz de aprendizaje.

8.2. Lecciones aprendidas

A lo largo del desarrollo computacional y la revisión estadística del proyecto, se decantaron lecciones críticas para la práctica del *nowcasting* digital en el sur global:

- **La supremacía de la dominancia relativa:** Quedó evidenciado que el ecosistema de campaña funciona como un juego de suma cero territorial. La posición de un candidato relativa a la conversación local de su ciudad (*share of voice*) es una métrica inmensamente superior al volumen absoluto de interacciones, pues este último es susceptible de distorsiones poblacionales y mediáticas inherentes a las dinámicas atípicas de los perfiles públicos masivos.
- **El paradigma de clasificación:** Frente a matrices limitadas por la escasez de datos subnacionales etiquetados, plantear la predicción como un problema de clasificación probabilística discreta (*¿quién se lleva la elección?*) probó ser cualitativamente más realista y convergente que pretender establecer márgenes porcentuales directos (*¿cuánto saca?*) a través de regímenes de regresión.
- **El abismo de la última semana:** El obstáculo empírico más resistente para las métricas agregativas continúa siendo el giro coyuntural tardío. La explosión de interacciones preexistentes oculta frecuentemente las volatilidades sutiles de la opinión pública suscitadas por eventos, escándalos o alianzas que acontecen en los tres días anteriores al evento de urnas.
- **Autonomía computacional:** La comprobación de un ciclo de vida completo de análisis —desde la orquestación y el *scraping* (*Make.com*, *Playwright*, API de X, *Apify*) hasta la proyección asintótica y el modelado matricial— probó que este *pipeline* analítico complejo es enteramente ejecutable desde laboratorios comerciales e independientes que operen con un coste logístico nominal o nulo.

8.3. Próximos pasos

La natural prolongación de este cuerpo de investigación consiste en llevar la experimentación a la fase de masificación de datos, integrando *datasets* de contiendas asimétricas de más naciones de América Latina y diferentes marcos temporales, apuntalando así el tamaño de las muestras para destrabar el uso de aprendizaje profundo. Inminentemente, se hace obligatoria la recalibración inter-regional del modelo Weibull, así como el rediseño dimensional para inyectar vectores categóricos de sentimiento. La culminación de este esfuerzo empírico se cristalizará durante la apertura de las urnas de las próximas elecciones territoriales en Colombia de 2027, las cuales fungirán como el juez definitivo ciego (*out-of-time sample*) sobre el cual se medirá, bajo estricto rigor metodológico ex-ante, la madurez proyectiva de la inteligencia desarrollada.

Bibliografía

- ACEI. (2025). Perspectivas de la Industria de Investigación de Mercados en Colombia 2025 [Asociación Colombiana de Empresas de Investigación de Mercados y Opinión Pública].
- Barberá, P. (2020). Social Media, Echo Chambers, and Political Polarization. En N. Persily & J. A. Tucker (Eds.), *Social Media and Democracy: The State of the Field and Prospects for Reform*. Cambridge University Press. <https://www.researchgate.net/publication/343996442>
- Brito, K., & Adeodato, P. J. L. (2022). Measuring the performances of politicians on social media and the correlation with major Latin American election results. *Government Information Quarterly*, 39(4), 101745. <https://doi.org/10.1016/j.giq.2022.101745>
- Brito, K., & Adeodato, P. J. L. (2023). Machine learning for predicting elections in Latin America. *Government Information Quarterly*, 40(2), 101782. <https://doi.org/10.1016/j.giq.2022.101782>
- Brito, K., Silva Filho, T., & Adeodato, P. J. L. (2024). Stop trying to predict elections only with Twitter: There are other data. *Government Information Quarterly*, 41(1), 101899. <https://doi.org/10.1016/j.giq.2023.101899>
- Brito, K. d. S., & Adeodato, P. J. L. (2020). Predicting Brazilian and U.S. Elections with Machine Learning and Social Media Data. *2020 IEEE International Conference on Big Data (Big Data)*.
- Congreso de la República de Colombia. (2025). Ley 2494 de 2025, por la cual se regula la elaboración, publicación y divulgación de encuestas electorales [Diario Oficial de Colombia].
- DataReportal. (2025, noviembre). Digital 2026: Colombia [Datos de octubre 2025. Publicado por Kepios / We Are Social / Meltwater]. <https://datareportal.com/reports/digital-2026-colombia>
- ESOMAR. (2025). *Global Market Research 2025*. ESOMAR. <https://esomar.org/publications/global-market-research-2025>
- GAD3. (2026, mayo). Comunicado: Suspensión de publicación de encuestas electorales en Colombia. <https://www.lasillavacia.com/en-vivo/por-ley-mordaza-gad3-suspende-publicacion-de-encuestas-en-colombia/>
- Giangiulio, D. (2026, abril). Prediction Markets: On Pace for \$1 Trillion by 2030 [Citado en CNBC, 14 de abril de 2026]. <https://www.cnbc.com/2026/04/14/prediction-markets-will-grow-to-1-trillion-by-2030-bernstein-says.html>
- Kennedy, C., Blumenthal, M., Clement, S., Clinton, J. D., Durand, C., Franklin, C., McGeeney, K., Miringoff, L., Olson, K., Rivers, D., Saad, L., Witt, G. E., & Wlezien, C. (2018). An Evaluation of the 2016 Election Polls in the United States. *Public Opinion Quarterly*, 82(1), 1-33. <https://doi.org/10.1093/poq/nfx047>

- Lewis-Beck, M. S., Nadeau, R., & Bélanger, É. (2004). General Election Forecasts in the United Kingdom: A Political Economy Model. *Electoral Studies*, 23(2), 279-290. [https://doi.org/10.1016/S0261-3794\(02\)00071-9](https://doi.org/10.1016/S0261-3794(02)00071-9)
- Lewis-Beck, M. S., Nadeau, R., & Bélanger, É. (2011). Nowcasting v. polling: The 2010 UK election trials. *Electoral Studies*, 30(2), 284-287. <https://doi.org/10.1016/j.electstud.2010.09.013>
- Lewis-Beck, M. S., & Tien, C. (2014). Proxy models and nowcasting: U.S. presidential elections in the future. *Presidential Studies Quarterly*, 44(3), 506-521.
- Mughan, A. (1987). General Election Forecasting in Britain: A Comparison of Three Simple Models. *Electoral Studies*, 6(3), 195-207. [https://doi.org/10.1016/0261-3794\(87\)90031-X](https://doi.org/10.1016/0261-3794(87)90031-X)
- Norpoth, H. (2004). Forecasting British Elections: A Dynamic Perspective. *Electoral Studies*, 23(2), 297-305. [https://doi.org/10.1016/S0261-3794\(02\)00070-7](https://doi.org/10.1016/S0261-3794(02)00070-7)
- Ríos Giraldo, M. (2026). Ley de encuestas en Colombia: la polémica norma. *Diario de Occidente*. <https://occidente.co/politica/graffiti/ley-de-encuestas-colombia-derogatoria-cne-investigaciones-2026/>
- Sanders, D. (1991). Government Popularity and the Next General Election. *The Political Quarterly*, 62(2), 235-261. <https://doi.org/10.1111/j.1467-923X.1991.tb00856.x>
- Sigelman, L. (1979). Presidential Popularity and Presidential Elections. *Public Opinion Quarterly*, 43(4), 532-534. <https://www-jstor-org.ez.unisabana.edu.co/stable/2749005>
- Skoric, M. M., Liu, J., & Jaidka, K. (2020). Electoral and Public Opinion Forecasts with Social Media Data: A Meta-Analysis. *Information*, 11(4), 187. <https://doi.org/10.3390/info11040187>
- Stegmaier, M., Jokinsky, S., & Lewis-Beck, M. S. (2023). The Evolution of Election Forecasting Models in the UK. *Electoral Studies*, 86, 102694. <https://doi.org/10.1016/j.electstud.2023.102694>
- Tucker, J. A., Guess, A., Barberá, P., Vaccari, C., Siegel, A., Sanovich, S., Stukal, D., & Nyhan, B. (2018). *Social Media, Political Polarization, and Political Disinformation: A Review of the Scientific Literature* (inf. téc.). SSRN. <https://doi.org/10.2139/ssrn.3144139>
- Tumasjan, A., Sprenger, T. O., Sandner, P. G., & Welpe, I. M. (2010). Predicting elections with Twitter: What 140 characters reveal about political sentiment. *Proceedings of the Fourth International AAAI Conference on Weblogs and Social Media*, 178-185.
- Whiteley, P. (1979). Electoral Forecasting from Poll Data: The British Case. *British Journal of Political Science*, 9(2), 219-236. <https://doi.org/10.1017/S0007123400001733>