

ELA-NOM

Election-Agnostic Nowcasting Model

Un modelo de predicción electoral sin encuestas
para el entorno local latinoamericano

Juan Sotelo Aguilar

Universidad de La Sabana · Maestría en Analítica e Inteligencia de Negocios

Junio 2026

Agenda

1. **Motivación** y gap empírico
2. **Pregunta** e hipótesis
3. **Etapas 1 — Bolivia**
SOMEN-DC: límites del estado del arte
4. **Etapas 2 — Costa Rica**
Reconstrucción temporal Weibull
5. **Etapas 3 — Colombia**
Dataset, modelado, ElasticNet
6. **Resultados** Colombia 2023
7. **Validación prospectiva** 2026
8. **Conclusiones** y trabajo futuro

Duración: 30 min presentación + preguntas del jurado

Motivación

El problema: dependencia estructural de las encuestas

- ▶ En América Latina, las encuestas son **virtualmente el único** instrumento de seguimiento de intención de voto
- ▶ **Tres fallas estructurales** documentadas en la literatura:
 - ▷ **Sesgo de respuesta**: tasas de participación en declive estructural
 - ▷ **Dependencia de entrenamiento**: modelos no generalizables entre elecciones
 - ▷ **Costo**: una encuesta de calidad puede superar los COP 300 millones
- ▶ Las **redes sociales** ofrecen señal digital continua, gratuita y pública

América Latina: cobertura de encuestas

País	Casas encuestadoras
Brasil	12
México	8
Colombia	4
Ecuador	2
Bolivia	1
Costa Rica	3

Mercados pequeños: sin encuestas

¿Por qué es difícil usar redes sociales para predicción?

Problema 1: Asimetría temporal

Las plataformas solo exponen el conteo *actual* de interacciones.

Si scrapeas hoy una publicación de hace 30 días, ves el total acumulado, no el estado que tenía el día que importaba.

Problema 2: Escala y agregación

Un candidato nacional con 2M de seguidores tiene más *likes* absolutos que cualquier candidato local, aunque pierda en su ciudad.

Problema 3: Generalización

Modelos entrenados en elecciones presidenciales no predicen elecciones locales y viceversa.

Soluciones propuestas en ELA-NOM

- ✓ Modelo de crecimiento Weibull
reconstruye el historial de interacciones
- ✓ Dominancia relativa (share of voice)
normaliza dentro de cada contienda
- ✓ Diseño election-agnóstico
un núcleo transferible entre elecciones

Pregunta e Hipótesis

*“¿Es metodológicamente posible diseñar un modelo de nowcasting electoral **election-agnóstico** y **emancipado de encuestas** para el entorno local colombiano?”*

Hipótesis operacionales

- H1 Las interacciones en redes contienen señal predictiva real ($\rho > 0$, $p < 0,05$)
- H2 La *dominancia relativa* supera al volumen absoluto como predictor
- H3 Un modelo entrenado en Colombia puede transferirse a elecciones presidenciales sin reentrenamiento

Diseño en 3 etapas

- E1 **Bolivia**: replicar SOMEN-DC y documentar sus límites
- E2 **Costa Rica**: resolver el problema de la asimetría temporal
- E3 **Colombia**: construir ELA-NOM y validarlo prospectivamente

Variable objetivo: dominancia digital

Definición formal

Sea $\mathcal{C}_d$ el conjunto de candidatos en la contienda d .


La **dominancia digital** del candidato c es:

$$\delta_c^{(d)} = \frac{\sum_{p \in P_c} \text{likes}_p}{\sum_{c' \in \mathcal{C}_d} \sum_{p \in P_{c'}} \text{likes}_p}$$

donde P_c son las publicaciones del candidato c en la ventana de 14 días previos.

Propiedad clave: $\sum_{c \in \mathcal{C}_d} \delta_c^{(d)} = 1$ (suma cero dentro de contienda)

Cuota de likes vs. cuota de votos



$\rho = 0,70$ sobre 120 candidatos (31 contiendas)

Etapa 1 — Bolivia

Contexto: Segunda vuelta presidencial Bolivia 2025

Escenario

- ▶ Contienda: **Rodrigo Paz vs. Jorge “Tuto” Quiroga**
- ▶ Fecha: 19 octubre 2025
- ▶ Resultado real: Paz **54.53 %** · Quiroga 45.47 %
- ▶ Ventana: 153 días (18 mayo – 18 octubre 2025)
- ▶ Plataformas: Facebook, Twitter/X, Instagram, TikTok
- ▶ Dataset: **308 registros diarios**, 26 características


Metodología base: SOMEN-DC

Brito & Andeato (2024): red neuronal entrenada con encuestas + señal digital.


Limitación: requiere encuestas históricas para el entrenamiento.

6 modelos evaluados		
Modelo	MAE	MAPE
Baseline (últ. encuesta)	0.180	33.1 %
Regresión Lineal	0.297	54.4 %
Regresión Lin.+PCA	0.312	57.1 %
GRNN	0.199	36.4 %
MLP-BP	0.076	14.0 %
MLP-BP+PCA	0.028	5.1 %

SOMEN-DC: modelo ganador MLP-BP + PCA



Comparación de los 6 modelos evaluados



GRNN como referencia: captura tendencia pero incapaz de converger al resultado real

Limitación estructural identificada

Lo que SOMEN-DC NO puede hacer

- × Predecir elecciones **sin encuestas históricas** del mismo país
- × Transferirse a elecciones de **formato diferente** (local → presidencial)
- × Operar sobre datos digitales **reconstruidos históricamente**

Lo que ELA-NOM resuelve

- ✓ Entrena exclusivamente en **datos digitales**
- ✓ Usa **dominancia relativa** transferible entre elecciones
- ✓ Reconstrucción temporal **Weibull**

⇒ La Etapa 2 ataca directamente el problema de la reconstrucción temporal.

Etapas 2 — Costa Rica

El problema de la asimetría temporal

¿Cuál es el problema?

Si extraemos datos el 18 de octubre, una publicación del 1 de septiembre ya acumuló 47 días de interacciones adicionales. Necesitamos saber **cuántas interacciones tenía el día de la elección**, no hoy.


Solución: modelo de crecimiento Weibull

La fracción acumulada de interacciones en el día t sigue:

$$F(t; k, \alpha, t_0) = 1 - e^{-k(t+t_0)^\alpha}$$

donde k = velocidad, α = forma, t_0 = offset inicial.


El total final estimado dado n_t interacciones al día t : $\hat{N} = n_t / F(t; k, \alpha, t_0)$



Panel longitudinal: 1.922 publicaciones · 4 plataformas · elecciones


Costa Rica 2026

Calibración Weibull por plataforma



MAPE mediano Día 0 (peor caso): Facebook 11.3% · Twitter/X 56.4% · Instagram 64.8% · TikTok 25.1%

Precisión proyectiva: MAPE por plataforma y día




MAPE mediano al Día 3

Plataforma	MAPE D3
Facebook	2.12 %
Twitter/X	0.38 %
TikTok	5.94 %
Instagram	12.06 %

A partir del **Día 3**, Facebook, Twitter/X y TikTok tienen error $< 6\%$. Instagram concentra sus interacciones en las primeras horas ($t_0 = 0,04$ días).

Ejemplos de reconstrucción histórica



Izquierda: Facebook · 50,000 interacciones totales · reconstrucción desde Día 5

Derecha: Instagram · 43,000 medidas el Día 10

Output: función de reconstrucción exportada

¿Qué se exporta a la Etapa 3?

Un archivo de configuración con los parámetros $\{k, \alpha, t_0\}$ calibrados por plataforma, listo para ser consumido por el pipeline de Colombia:

$$\hat{n}_{\text{hist}}(\tau) = \hat{N} \cdot [F(\tau) - F(\tau - 1)]$$

donde $\tau < t_{\text{scrape}}$ es el día histórico de interés.

Impacto

El error mediano inyectado a la serie temporal en el Día 14 pre-elección es **matemáticamente cero** para Facebook y Twitter/X.

Parámetros calibrados

Red	k	α	t_0
FB	0.31	0.62	0.12
IG	0.89	0.44	0.04
TT	0.44	0.58	0.08
X	0.97	0.38	0.01

⇒ Error de reconstrucción ≈ 0 al Día 14

Etapa 3 — Colombia

Construcción del dataset

- ▶ Universo: 33 ciudades más pobladas
- ▶ Excluidas: Bogotá (sesgo influencer) + Piedecuesta (sin datos digitales)
- ▶ Universo final: **31 ciudades competitivas**
- ▶ Candidatos con >10,000 votos: **120 candidatos**
- ▶ Publicaciones únicas: **5,776**
 - Facebook: 2,511
 - Twitter/X: 2,346
 - TikTok: 919
- ▶ Ventana de captura: **14 días** previos a los comicios
- ▶ Cobertura digital: **92.6 %** de candidatos con publicaciones activas


Pipeline de extracción

Facebook	Apify scraper
Twitter/X	Playwright headless
TikTok	API privada (Apify)
Instagram	Excluido (API restrictions)

Reconstrucción Weibull

aplicada a todas las publicaciones

Evidencia descriptiva: dominancia digital y votos



Modelado predictivo: regresión logística fraccional

Especificación del modelo

La variable objetivo es la **cuota de voto real**
 $v_c \in (0, 1)$.

Dado que v_c es una proporción, usamos regresión logística fraccional (Papke & Wooldridge, 1996):

$$\mathbb{E}[v_c | X] = \frac{1}{1 + e^{-(\beta_0 + X^\top \beta)}}$$

con predictor central:

$$\text{logit}(\delta_c) = \log\left(\frac{\delta_c}{1 - \delta_c}\right)$$

Selección de variables: ElasticNet anidado

$$\hat{\beta} = \arg \min_{\beta} \{L(\beta) + \lambda_1 \|\beta\|_1 + \lambda_2 \|\beta\|_2^2\}$$

Comparativa de modelos


Métricas LOCO-CV (31 contiendas)

Modelo	MAE	R^2	T1
Base uniforme	12.49	0.306	39 %
Base proporcional	12.61	0.185	71 %
Reg. fraccional	11.52	0.460	71 %
ELA-NOM	9.43	0.518	64.5 %
Grad. Boosting	9.91	0.515	67.7 %

Validación: LOCO-CV


Leave-One-Contest-Out CV: en cada pliegue se excluye una contienda completa y el modelo predice **fuera de muestra**. 31 pliegues · unidad = contienda.

Coeficientes: estabilidad inter-pliegue (bootstrap)



Estabilidad: `logit_likes` e `interacción` presentes en el 100 % de los pliegues de validación


Residuales LOCO-CV: distribución del error



MAE = 9.43 pp · $R^2_{\text{os}} = 0,518$ · Top-1 = 64.5 % (20/31) · sin patrones sistemáticos de sesgo

Resultados Colombia 2023

Escalera de MAE: progresión de modelos



ELA-NOM: MAE — 9.43 pp - Base 12.61 pp - Núcleo digital 11.52 pp - ELA-NOM 9.43 pp - GBT 9.91 pp

Modelo	MAE	R^2_{oos}	Top-1
Baseline uniforme	12.49	0.306	39 %
Baseline proporcional	12.61	0.185	71 %
Regresión fraccional	11.52	0.460	71 %
ELA-NOM	9.43	0.518	64.5 %
Gradient Boosting	9.91	0.515	67.7 %

ELA-NOM: ElasticNet con moderador de población. GBT como benchmark no-lineal.

Hallazgos clave

- 1 La **dominancia relativa** ($\rho = 0,70$) supera al volumen absoluto
- 2 La **interacción** dominancia $\times$ población es el coeficiente más fuerte ($\hat{\beta} = 0,557$)
- 3 ELA-NOM mejora **3.18 pp** sobre el baseline de proporcionalidad
- 4 Top-1 accuracy = **64.5 %** (20/31 contiendas correctas)

Interpretación del moderador de población

¿Por qué interactúa la población?

En municipios grandes, dominar las redes se traduce con más fuerza en votos porque:


- ▶ La población actúa como **amplificador** de la señal digital
- ▶ En ciudades pequeñas, la red personal y el cacicazgo local dominan sobre la señal digital
- ▶ La dominancia digital captura la **movilización urbana** diferencial

Interpretación matemática:

$$\frac{\partial \mathbb{E}[v_c]}{\partial \delta_c} = (\hat{\beta}_1 + \hat{\beta}_{\text{mod}} \cdot \log N_d) \cdot v_c(1 - v_c)$$

El efecto marginal de la dominancia **crece** con el tamaño N_d de la ciudad.

Efecto marginal por tamaño de ciudad




Validación Prospectiva 2026

Segunda vuelta presidencial: 21 junio 2026

Contexto de la validación

- ▶ Candidatos: **Iván Cepeda Castro** vs. **Abelardo De la Espriella**
- ▶ Modelo: ELA-NOM *sin ningún reentrenamiento*
- ▶ Señal digital: Cepeda acumuló **3.5× más likes** que De la Espriella
- ▶ Resultado de la Registraduría Nacional:
 - ▷ De la Espriella: **50.48 %**
 - ▷ Cepeda Castro: 49.52 %
 - ▷ Margen: **0.96 pp** — empate técnico



Dominancia de likes: Cepeda 77.8 % vs. De la Espriella 22.2 %

Pronóstico ELA-NOM vs. resultado real

Candidato	Pronóstico ELA-NOM	Real
Cepeda Castro	60.5 %	49.52 %
De la Espriella	39.5 %	50.48 %

Error absoluto: 10.98 pp

(para el candidato digitalmente dominante)

Ganador predicho: incorrecto

Margen real: 0.96 pp — dentro del ruido del modelo

Análisis del intervalo de incertidumbre

Con $MAE \approx 9.4$ pp, el rango plausible para Cepeda es:

$$[60,5 - 9,43, 60,5 + 9,43] = [51,07 \%, 69,93 \%]$$

El resultado real (49.52 %) queda:

$$51,07 - 49,52 = 1.55 \text{ pp}$$

por debajo del límite inferior.

El resultado real cae a ≈ 1.5 pp del rango plausible del modelo.

En un empate de 0.96 pp, **ninguna** metodología basada en engagement agregado tiene resolución suficiente.

¿Qué capturó y qué no capturó el modelo?

Lo que ELA-NOM capturó correctamente

- ✓ La contienda era **extremadamente competitiva**
- ✓ Cepeda tenía **ventaja digital neta** ($3.5 \times$ likes)
- ✓ El rango plausible (51 %–70 %) era informativo

Fuera del alcance del modelo

- ✗ Giros de **última semana** (movilización diferencial)
- ✗ Estructura organizativa **territorial** de campaña
- ✗ Eventos exógenos de impacto electoral

Límite estructural documentado: ELA-NOM es informativo en contiendas con ventajas digitales >20 pp. En empates <1 pp, ningún modelo de engagement tiene resolución suficiente.

Conclusiones

Tres hallazgos fundamentales

Hallazgo 1

La **señal predictiva** en redes sociales es **real** y cuantificable.

$$\rho = 0,70, \rho < 0,001$$

Mann-Whitney confirma diferencias significativas entre ganadores y perdedores.

Hallazgo 2

El **moderador de población** amplifica la señal.

$$\hat{\beta}_{\text{mod}} = 0,557$$

En ciudades grandes, dominar las redes pesa más en urnas.

Hallazgo 3

ELA-NOM es **transferible** sin reentrenamiento.

Colombia → 2026 presidencial

Límite estructural documentado:
empates de < 1 pp exceden la resolución del modelo.

Agenda de trabajo futuro

Corto plazo (2026–2027)

- ▶ Recalibrar Weibull inter-regionalmente (Colombia, México, Ecuador)
- ▶ Reentrenar ELA-NOM con datos de la segunda vuelta 2026
- ▶ Validar en **elecciones locales Colombia 2027** (juez definitivo ciego)

Largo plazo

- ▶ Integrar datasets de contiendas asimétricas de más países de AL
- ▶ Explorar arquitecturas expresivas (GBT, XGBoost, SHAP interpretability)
- ▶ Publicación en revista indexada

Comparativa ELA-NOM vs. estado del arte

Caracter.	SOMEN-DC	ELA-NOM
Sin encuestas	×	✓
Agnóstico	×	✓
Recon. temporal	×	✓
Val. prospectiva	×	✓
Costo herram.	Alto	Bajo

$$\text{MAE} = 9.43 \text{ pp} \cdot R^2 = 0,518$$

Gracias

¿Preguntas?

Juan Sotelo Aguilar · Universidad de La Sabana · 2026

9.43 pp

MAE

0.518

R^2

64.5 %

Top-1

31

ciudades

120

candidatos