

ELA-NOM

Election-Agnostic Nowcasting Model

Un modelo de predicción electoral sin encuestas
para el entorno local latinoamericano

Juan Soage

Universidad de La Sabana · Maestría en Analítica e Inteligencia de Negocios

Junio 2026

Agenda

1. **Motivación** y gap empírico
2. **Pregunta** e hipótesis
3. **Etapas 1 — Bolivia**
SOMEN-DC: límites del estado del arte
4. **Etapas 2 — Costa Rica**
Reconstrucción temporal Weibull
5. **Etapas 3 — Colombia**
Dataset, modelado, ElasticNet
6. **Resultados** Colombia 2023
7. **Validación prospectiva** 2026
8. **Conclusiones** y trabajo futuro

Duración: 30 min presentación + preguntas del jurado

Motivación

El problema: dependencia estructural de las encuestas

- ▶ En América Latina, las encuestas son **virtualmente el único** instrumento de seguimiento de intención de voto
- ▶ **Tres fallas estructurales** documentadas en la literatura:
 - ▷ **Sesgo de respuesta** creciente (tasa de respuesta $< 15\%$)
 - ▷ **Dependencia de entrenamiento:** modelos no generalizables entre elecciones
 - ▷ **Costo:** una encuesta de calidad cuesta USD 15,000–80,000
- ▶ Las **redes sociales** ofrecen señal digital continua, gratuita y pública

América Latina: cobertura de encuestas

País	Casas encuestadoras
Brasil	12
México	8
Colombia	4
Ecuador	2
Bolivia	1
Costa Rica	3

Mercados pequeños: sin encuestas

¿Por qué es difícil usar redes sociales para predicción?

Problema 1: Asimetría temporal

Las plataformas solo exponen el conteo *actual* de interacciones.

Si scrapeas hoy una publicación de hace 30 días, ves el total acumulado, no el estado que tenía el día que importaba.

Problema 2: Escala y agregación

Un candidato nacional con 2M de seguidores tiene más *likes* absolutos que cualquier candidato local, aunque pierda en su ciudad.

Problema 3: Generalización

✓ Soluciones propuestas en ELA-NOM

✓ Modelo de crecimiento Weibull
reconstruye el historial de interacciones

✓ Dominancia relativa (share of voice)
normaliza dentro de cada contienda

✓ Diseño election-agnóstico
un núcleo transferible entre elecciones

Pregunta e Hipótesis

Pregunta de investigación

“¿Es metodológicamente posible diseñar un modelo de nowcasting electoral election-agnóstico y emancipado de encuestas para el entorno local colombiano?”

Hipótesis operacionales

- H1 Las interacciones en redes contienen señal predictiva real ($\rho > 0, p < 0,05$)
- H2 La *dominancia relativa* supera al volumen absoluto como predictor
- H3 Un modelo entrenado en Colombia puede transferirse a

Diseño en 3 etapas

- E1 **Bolivia**: replicar SOMEN-DC y documentar sus límites
- E2 **Costa Rica**: resolver el problema de la asimetría temporal
- E3 **Colombia**: construir ELA-NOM y validarlo prospectivamente

Variable objetivo: dominancia digital

Definición formal

Sea $\mathcal{C}_d$ el conjunto de candidatos en la contienda d .

La **dominancia digital** del candidato c es:


$$\delta_c^{(d)} = \frac{\sum_{p \in P_c} \text{likes}_p}{\sum_{c' \in \mathcal{C}_d} \sum_{p \in P_{c'}} \text{likes}_p}$$

donde P_c son las publicaciones del candidato c en la ventana de 14 días previos.

Propiedad clave: $\sum_{c \in \mathcal{C}_d} \delta_c^{(d)} = 1$

(suma cero dentro de contienda)

Cuota de likes vs. cuota de votos



$\rho = 0,70$ sobre 120 candidatos (31 contiendas)

Etapa 1 — Bolivia

Contexto: Segunda vuelta presidencial Bolivia 2025

Escenario


- ▶ Contienda: **Rodrigo Paz vs. Jorge “Tuto” Quiroga**
- ▶ Fecha: 19 octubre 2025
- ▶ Resultado real: Paz **54.53 %** · Quiroga 45.47 %
- ▶ Ventana: 153 días (18 mayo – 18 octubre 2025)
- ▶ Plataformas: Facebook, Twitter/X, Instagram, TikTok
- ▶ Dataset: **308 registros diarios**, 26 características

6 modelos evaluados


Modelo	MAE	RMSE
Última encuesta (base)	8.2	9.1
Regresión lineal	12.4	14.1
Random Forest	10.8	12.3
SVR	11.2	13.0
GRNN	9.7	11.2
MLP-BP+PCA	7.3	8.6

Metodología base: SOMEN-DC

SOMEN-DC: modelo ganador MLP-BP + PCA



Comparación de los 6 modelos evaluados



GRNN como referencia: captura tendencia pero incapaz de converger al resultado real

Limitación estructural identificada

Lo que SOMEN-DC NO puede hacer

- × Predecir elecciones **sin encuestas históricas** del mismo país
- × Transferirse a elecciones de **formato diferente** (local → presidencial)
- × Operar sobre datos digitales **reconstruidos históricamente**

Lo que ELA-NOM resuelve

- ✓ Entrena exclusivamente en **datos digitales**
- ✓ Usa **dominancia relativa** transferible entre elecciones
- ✓ ~~Reconstrucción temporal~~
Weibull

⇒ La Etapa 2 ataca directamente el problema de la reconstrucción temporal.

Etapa 2 — Costa Rica

El problema de la asimetría temporal


¿Cuál es el problema?

Si extraemos datos el 18 de octubre, una publicación del 1 de septiembre ya acumuló 47 días de interacciones adicionales. Necesitamos saber **cuántas interacciones tenía el día de la elección**, no hoy.


Solución: modelo de crecimiento Weibull

La fracción acumulada de interacciones en el día t sigue:

$$F(t; k, \alpha, t_0) = 1 - e^{-k(t+t_0)^\alpha}$$




Calibración Weibull por plataforma



Ajuste R^2 : Facebook 0.94 · TikTok 0.88 · Instagram 0.79 · Twitter/X 0.96

Precisión proyectiva: MAPE por plataforma y día




MAPE mediano al Día 3

Plataforma	MAPE D3
Facebook	2.12 %
Twitter/X	0.38 %
TikTok	5.94 %
Instagram	12.06 %

A partir del **Día 3**, Facebook, Twitter/X y TikTok tienen error $< 6\%$. Instagram concentra sus interacciones en las primeras horas ($t_0 = 0,04$ días).

Ejemplos de reconstrucción histórica



Izquierda: Facebook · 50,000 interacciones totales · reconstrucción desde Día 5

Derecha

Output: función de reconstrucción exportada

¿Qué se exporta a la Etapa 3?

Un archivo de configuración con los parámetros $\{k, \alpha, t_0\}$ calibrados por plataforma, listo para ser consumido por el pipeline de Colombia:

$$\hat{n}_{\text{hist}}(\tau) = \hat{N} \cdot [F(\tau) - F(\tau - 1)]$$

donde $\tau < t_{\text{srape}}$ es el día histórico de interés.

Impacto

El error mediano inyectado a la serie temporal en el Día 14 pre-elección es **matemáticamente cero** para Facebook y

Parámetros calibrados

Red	k	α	t_0
FB	0.31	0.62	0.12
IG	0.89	0.44	0.04
TT	0.44	0.58	0.08
X	0.97	0.38	0.01

⇒ Error de reconstrucción ≈ 0 al Día 14

Etapa 3 — Colombia

Dataset: elecciones locales Colombia 2023

Construcción del dataset


- ▶ Universo: 33 ciudades más pobladas
- ▶ Excluidas: Bogotá (sesgo influencer) + Piedecuesta (sin datos digitales)
- ▶ Universo final: **31 ciudades competitivas**
- ▶ Candidatos con $>10,000$ votos: **120 candidatos**
- ▶ Publicaciones únicas: **5,776**
 - Facebook: 2,511
 - Twitter/X: 2,346
 - TikTok: 919
- ▶ Ventana de captura: **14 días**

Pipeline de extracción

Facebook	Apify scraper
Twitter/X	Playwright headless
TikTok	API privada (Apify)
Instagram	Excluido (API restrictions)

Reconstrucción Weibull
aplicada a todas las publicaciones

Evidencia descriptiva: dominancia digital y votos



Modelado predictivo: regresión logística fraccional

Especificación del modelo

La variable objetivo es la **cuota de voto real** $v_c \in (0, 1)$.

Dado que v_c es una proporción, usamos regresión logística fraccional (Papke & Wooldridge, 1996):

$$\mathbb{E}[v_c \mid X] = \frac{1}{1 + e^{-(\beta_0 + X^\top \beta)}}$$

con predictor central:

$$\text{logit}(\delta_c) = \log\left(\frac{\delta_c}{1 - \delta_c}\right)$$

Variables del modelo final

Variable	$\hat{\beta}$
logit(dominancia_likes)	0,431
log(población)	-0,012
interacción	0,557


El coeficiente más fuerte del modelo

es la **interacción** entre dominancia digital y tamaño de ciudad: en municipios grandes la señal digital se amplifica.

Validación: LOCO-CV


Selección de variables: ElasticNet

Coeficientes: estabilidad inter-pliegue (bootstrap)



Estabilidad: logit_likes e interacción presentes en el 100 % de los pliegues de validación


Residuales LOCO-CV: distribución del error



MAE = 9.43 pp · $R^2_{\text{os}} = 0,518$ · Top-1 accuracy = 71 % · sin patrones sistemáticos de

Resultados Colombia 2023

Escalera de MAE: progresión de modelos



Resumen cuantitativo de resultados

Hallazgos clave

Modelo	MAE	R^2_{oos}	Top-1
Baseline uniforme	12.49	0.306	39 %
Baseline proporcional	12.61	0.185	71 %
Regresión fraccional	11.52	0.460	71 %
ELA-NOM	9.43	0.518	71 %
Gradient Boosting	9.91	0.490	71 %

ELA-NOM: ElasticNet con moderador de población. GBT como benchmark no-lineal.

- 1 La **dominancia relativa** ($\rho = 0,70$) supera al volumen absoluto
- 2 La **interacción** dominancia $\times$ población es el coeficiente más fuerte ($\hat{\beta} = 0,557$)
- 3 ELA-NOM mejora **3.18 pp** sobre el baseline de proporcionalidad
- 4 Top-1 accuracy = **71 %** (22/31 tiendas correctas)

Interpretación del moderador de población

¿Por qué interactúa la población?

En municipios grandes, dominar las redes se traduce con más fuerza en votos porque:

- ▶ La población actúa como **amplificador** de la señal digital
- ▶ En ciudades pequeñas, la red personal y el cacicazgo local dominan sobre la señal digital
- ▶ La dominancia digital captura la **movilización urbana** diferencial

Interpretación matemática:

$$\frac{\partial \mathbb{E}[v_c]}{\partial \delta_-} = (\hat{\beta}_1 + \hat{\beta}_{\text{mod}} \cdot \log N_d) \cdot v_c(1 - v_c)$$

Efecto marginal por tamaño de ciudad




Validación Prospectiva 2026

Segunda vuelta presidencial: 21 junio 2026

Contexto de la validación

- ▶ Candidatos: Iván Cepeda Castro vs. Abelardo De la Espriella
- ▶ Modelo: ELA-NOM *sin ningún reentrenamiento*
- ▶ Señal digital: Cepeda acumuló $3.5\times$ más *likes* que De la Espriella
- ▶ Resultado de la Registraduría Nacional:
 - ▶ De la Espriella: **50.48 %**
 - ▶ Cepeda Castro: 49.52 %
 - ▶ Margen: **0.96 pp** — empate



Dominancia de likes: Cepeda 77.8 % vs. De la Espriella 22.2 %

Pronóstico ELA-NOM vs. resultado real

Candidato	Pronóstico ELA-NOM	Real
Cepeda Castro	60.5 %	49.52 %
De la Espriella	39.5 %	50.48 %

Error absoluto: 10.98 pp

(para el candidato digitalmente dominante)

Ganador predicho: incorrecto

Margen real: 0.96 pp — dentro del ruido del modelo

Análisis del intervalo de incertidumbre

Con $MAE \approx 9.4$ pp, el rango plausible para Cepeda es:

$$[60,5 - 9,43, 60,5 + 9,43] = [51,07 \%, 69,93 \%$$

El resultado real (49.52 %) queda:

$$51,07 - 49,52 = \mathbf{1.55 \text{ pp}}$$

por debajo del límite inferior.

El resultado real cae a ≈ 1.5 pp del rango plausible del modelo.

En un empate de 0.96 pp, **ninguna**

¿Qué capturó y qué no capturó el modelo?

Lo que ELA-NOM capturó correctamente

- ✓ La contienda era **extremadamente competitiva**
- ✓ Cepeda tenía **ventaja digital neta** ($3.5\times$ likes)
- ✓ El rango plausible (51 %–70 %) era informativo

Fuera del alcance del modelo

- ✗ Giros de **última semana** (movilización diferencial)
- ✗ Estructura organizativa **territorial** de campaña
- ✗ Eventos exógenos de impacto electoral

Límite estructural documentado: ELA-NOM es informativo en contiendas con ventajas

Conclusiones

Tres hallazgos fundamentales

Hallazgo 1

La **señal predictiva** en redes sociales es **real** y cuantificable.

$$\rho = 0,70, p < 0,001$$

Mann-Whitney confirma diferencias significativas entre ganadores y perdedores.

Hallazgo 2

El **moderador de población** amplifica la señal.

$$\hat{\beta}_{\text{mod}} = 0,557$$

En ciudades grandes, dominar las redes pesa más en urnas.

Hallazgo 3

ELA-NOM es **transferible** sin reentrenamiento.

Colombia → 2026
presidencial

Límite estructural documentado: empates de < 1 pp exceden la resolución del modelo.

Agenda de trabajo futuro

Corto plazo (2026–2027)

- ▶ Recalibrar Weibull inter-regionalmente (Colombia, México, Ecuador)
- ▶ Reentrenar ELA-NOM con datos de la segunda vuelta 2026
- ▶ Validar en **elecciones locales Colombia 2027** (juez definitivo ciego)

Largo plazo

- ▶ Integrar datasets de contiendas asimétricas de más países de AL
- ▶ Explorar arquitecturas expresivas

Comparativa ELA-NOM vs. estado del a

Característica	SOMEN
Sin encuestas	×
Agnóstico	×
Reconstrucción temporal	×
Validación prospectiva	×
Costo herramientas	Alto

$$\text{MAE} = 9.43 \text{ pp} \cdot R^2 = 0,518$$

Gracias

¿Preguntas?

Juan Soage · Universidad de La Sabana · 2026

9.43 pp	0.518	71 %	31	120
MAE	R^2	Top-1	ciudades	candidatos