
ELA-NOM

Diseño e implementación del modelo ELA-NOM:
un *nowcasting* elección-agnóstico para la intención de voto
aplicado a elecciones locales en Colombia 2023

Juan Sotelo Aguilar

Maestría en Analítica Aplicada, Universidad de La Sabana

Agosto 2026

Jurado: César Caballero, Andrés Cruz, Adrián Santana

Director de tesis: Miguel Uribe Laverde

Contexto y motivación

- ▶ El problema: mercado y regulación
- ▶ Literatura: de VAR/GARCH a redes sociales
- ▶ SOMEN-DC y sus limitaciones

Pregunta e hipótesis

- ▶ Pregunta central y preguntas derivadas P1-P4
- ▶ Diseño de tres etapas

Etapas 1: Bolivia

- ▶ Replicación SOMEN-DC, PM1, PM2

Etapas 2: Costa Rica

- ▶ Restaurador temporal Weibull, P2

Etapas 3: Colombia

- ▶ Dataset, señal, modelado: P1, P3, P4
- ▶ Especificación ElasticNet (2 variables)
- ▶ Escalera de modelos y curva de aprendizaje

Validación 2026

- ▶ Segunda vuelta presidencial, PM4

Conclusiones e impacto

La industria de pronósticos electorales

- ▶ Industria global de opinión pública: **\$153 mil millones** facturados en 2024
- ▶ Colombia: más de **\$700 mil millones COP** (2024)
- ▶ Plataformas predictivas alternativas: Polymarket mueve más de **1 billón USD** en contratos de predicción

Tres retos del sector en Colombia

- ▶ **Regulatorio:** Ley 2494/2025 endureció divulgación. **GAD3** se retiró del país en 2026
- ▶ **Cobertura:** más de **1.100 municipios**; encuestadoras cubren solo 10-12 ciudades
- ▶ **Costo:** una encuesta multimuestra es inviable para elecciones subnacionales

La pregunta natural

¿La actividad ciudadana en redes sociales dice algo sobre cómo va a votar el colombiano?

Definición: *Nowcasting*

Estimación del valor **actual** de una variable subyacente difícil de observar directamente, a partir de señales disponibles en tiempo real.

- ▶ **1970s-2000s:** primeros modelos de nowcasting electoral con variables económicas y de aprobación (VAR, ARCH/GARCH): alta precisión histórica
- ▶ **2016:** golpe de gracia. Ningún modelo predijo **Trump** ni el **Brexit**
- ▶ **2009:** Tumasjan *et al.*: menciones en Twitter como estimador insesgado de participación electoral; MAE inferior al 2 % con millones de tweets
- ▶ **2010s-2020s:** modelos híbridos (redes más variables económicas) mejoran resultados pero requieren infraestructura de extracción masiva, inviable fuera de academia
- ▶ **Brito & Andeato (2020s): SOMEN-DC:** *Social Media Electoral Nowcasting During Campaign*. Promete superar encuestadoras con interacciones de candidatos

Problema identificado en SOMEN-DC

Tres limitaciones estructurales que los autores no resuelven:

- ▶ **Techo encuestocéntrico:** la variable objetivo **son las encuestas**, no los resultados
- ▶ **During-Campaign:** requiere scraping diario desde el primer día de campaña
- ▶ **No transferibilidad:** pesos específicos a cada elección; imposible generalizar

Pregunta central


¿Es posible diseñar un modelo de *nowcasting* electoral **elección-agnóstico**, cuyos parámetros se entrenen con múltiples contiendas pasadas y sean **transferibles** a elecciones nuevas, que opere **sin encuestas**, usando exclusivamente señales de redes sociales?

Preguntas derivadas (P)

- P1** ¿Tienen las interacciones digitales poder predictivo real sobre el comportamiento electoral en Colombia?
- P2** ¿Es posible reconstruir matemáticamente el historial de interacciones sin haber recolectado datos en tiempo real?
- P3** ¿Qué métrica digital es el predictor más informativo y robusto?
- P4** ¿Cuántas contiendas de entrenamiento son necesarias para que el modelo alcance desempeño estable?

Preguntas metodológicas (PM)

- PM1** ¿Es posible replicar el SOMEN-DC en una elección no tratada por sus autores?
- PM2** ¿Se confirman empíricamente las tres limitaciones estructurales del SOMEN-DC?
- PM3** ¿Es posible reconstruir el historial de interacciones con precisión suficiente para construir un dataset de entrenamiento retroactivo?
- PM4** ¿Es el modelo transferible a un formato electoral diferente al de entrenamiento?



Variable objetivo:

$$\hat{y}_c = f(\mathbf{x}_c) \in (0, 1) \quad \text{con} \quad \sum_{j \in \mathcal{C}_e} \hat{y}_{c_j} = 1$$

$f: \mathbb{R}^d \rightarrow (0, 1)$, escalar por candidato. La restricción de suma se aplica por normalización posterior.

Supuesto central:

- ▶ Los parámetros de f se aprenden con **múltiples** elecciones pasadas $\mathcal{E}$
- ▶ Se aplican **sin reentrenamiento** a elecciones nuevas
- ▶ Variable objetivo: **cuota electoral observada** (no intención de voto latente)

Elección seleccionada


- ▶ Bolivia, 2.ª vuelta presidencial, 19 oct. 2025
- ▶ Rodrigo Paz Pereira vs. Jorge “Tuto” Quiroga
- ▶ Elección bipolar, no tratada previamente por SOMEN-DC

Dataset

- ▶ **153** días de campaña (18 may. al 18 oct. 2025)
- ▶ Plataformas: Facebook, Instagram, TikTok, Twitter/X
- ▶ **308** observaciones, **26** características
- ▶ Variable objetivo: interpolación de **14** encuestas anclada al resultado real: Paz **54,53 %**, Quiroga **45,47 %**

Modelos entrenados: 6 especificaciones (lineal, lineal más PCA, MLP-BP, MLP-BP más PCA, GRNN)

Etapa 1: Bolivia – evolución de la predicción



Evolución predicha vs. encuestas – MLP-BP+PCA (modelo ganador)

Modelo	Pred. Paz	MAE	MAPE
Baseline (última encuesta)	36,50 %	0,1803	33,1 %
Regresión lineal	24,85 %	0,2968	54,4 %
Regresión lineal + PCA	23,38 %	0,3115	57,1 %
MLP-BP	46,91 %	0,0762	14,0 %
MLP-BP + PCA	51,74 %	0,0279	5,1 %
GRNN	34,67 %	0,1986	36,4 %
Resultado real	54,53 %	-	-

Observación metodológica: MAE y RMSE son idénticos porque $n = 1$ (un solo punto de evaluación). Se reporta MAE y MAPE; la tabla eliminó la columna RMSE redundante.
[[Corrección 1.9](#)]

PM1: Respondida

La replicación es posible.
MLP-BP+PCA supera 6 veces al baseline.

Las tres limitaciones se verificaron empíricamente:

- ▶ **No transferibilidad confirmada:**
Los pesos del MLP-BP son específicos de Bolivia.
No existe mecanismo para exportarlos a Colombia.
- ▶ **Rezago estructural:**
En la última semana Paz remontó en encuestas.
El modelo, con interacciones acumuladas, no lo capturó.
- ▶ **Disociación TikTok:**
Picos de TikTok inyectaban varianza espuria
cuando la intención de voto estaba estacionaria.

PM2: Respondida

El paradigma *During-Campaign* no escala:
requiere infraestructura desde el día 1 y
produce pesos no exportables.

Conclusión: necesitamos un enfoque
fuera de campaña y agnóstico a la elección.

Siguiente paso: resolver el problema del histórico.
¿Cómo conocer el estado de las interacciones en
el pasado sin haber recolectado datos en tiempo
real?

Obstáculo técnico central:

- ▶ Las plataformas solo muestran el **total acumulado hoy**
- ▶ Una publicación de oct. 2023 tiene hoy los likes de ago. 2026
- ▶ El tráfico póstumo (post-elección) **contamina** cualquier extracción retrospectiva estática

Solución propuesta:

Modelar la función de crecimiento acumulado $F(t)$ de cada plataforma. Si conocemos la forma de la curva, podemos estimar cuántas interacciones tenía cualquier publicación en cualquier momento pasado.

Panel de calibración: 1.^a vuelta Costa Rica, 1 feb. 2026

- ▶ 30 días de observación (15 antes, 15 después)
- ▶ 4 candidatos, 4 plataformas
- ▶ **1.922** publicaciones, **19.439** pares (t, F)

Intuición

Las reacciones llegan masivamente en las primeras horas y luego decaen. La curva es asimétrica: arranque explosivo, caída rápida, estabilización.

Tres familias comparadas:

- ▶ Exponencial simple
- ▶ Logística (inflexión simétrica)
- ▶ **Weibull con offset**, ganadora

Modelo	Ecuación	$\bar{R}^2$	Diagnóstico
Exponencial simple	$F(t) = 1 - e^{-kt}$	0,182	Rígido; $\alpha \equiv 1$; subestima acumulación inicial
Logístico	$F(t) = \frac{1}{1 + e^{-k(t-t_0)}}$	0,245	Inflexión simétrica forzada; inadecuado para asimetría real
Weibull con offset	$F(t) = 1 - e^{-k(t+t_0)^\alpha}$	0,449	Geometría flexible (α); adelanto inicial (t_0); acotada en $[0, 1]$

Interpretación correcta de los parámetros [Corr. 1.6]

- ▶ k : **tasa** de acumulación (no parámetro de escala clásico)
- ▶ $\alpha < 1$: acumulación desacelera (Facebook, Instagram, TikTok)
- ▶ $\alpha > 1$: tasa de acumulación **crece** (Twitter/X: $\alpha = 1,14$)
- ▶ $t_0 > 0$: **adelanto de origen**; $F(0) > 0$; modela interacciones previas al primer día de observación completo

Nota sobre R^2 moderado

El **66,8 %** de la varianza total es intra-publicación (ruido irreducible). El modelo captura la **forma global** de la curva, suficiente para la reconstrucción histórica.

Plataforma	k	α	t_0 (h)	R^2
Facebook	0,948	0,823	46	0,351
Instagram	1,137	0,521	1	0,403
TikTok	1,327	0,512	19	0,351
Twitter/X	1,445	1,142	6	0,691

Twitter/X: $\alpha > 1$, tasa creciente (retweet acumulativo)


Hallazgo clave para la validez del diseño:

- ▶ La curva de la candidata **ganadora** (Laura Fernández) es morfológicamente **idéntica** a la del resto
- ▶ Sin diferencia estadísticamente significativa entre ganadores y perdedores en ningún día del panel
- ▶ El patrón de crecimiento es propiedad de la **plataforma**, no del candidato ni del resultado

P2: Respondida

Los parámetros calibrados en Costa Rica 2026 son transferibles para reconstruir el histórico de interacciones de *cualquier* elección colombiana pasada.

Etap 2: La ganadora es indistinguible del resto



Laura Fernández (ganadora) vs. resto de candidatos. Sin diferencia estadísticamente significativa en ningún día del panel. El patrón de crecimiento es una propiedad de la **plataforma**, no del candidato.

MAPE mediano por plataforma y día de observación

Plataforma	Día 0	Día 1	Día 2	Día 3	Día 7
Facebook	11,27 %	6,92 %	3,73 %	2,12 %	0,32 %
Instagram	64,77 %	20,72 %*	15,67 %	12,06 %	3,76 %
TikTok	25,36 %	14,20 %	8,35 %	5,94 %	2,29 %
Twitter/X	56,37 %	11,09 %	2,55 %	0,38 %	0,00 %

* Instagram Día 1 = 20,72 %: único que supera el 20 %. A partir del **Día 3**, las cuatro plataformas están por debajo del 13 %.

[Corr. 1.10]



Criterio adoptado: día 3 de observación por publicación.

Instagram en Día 3: **12,06 %**; la excepción fue Día 1, no Día 3.

PM3: Respondida

La reconstrucción es suficientemente precisa. Los parámetros Weibull son transferibles para construir datasets de entrenamiento retroactivos.





Etapa 2: Convergencia del error por día de observación



Izquierda: MAPE mediano por plataforma y día de observación. Derecha: distribución de errores individuales en Día 3. El 85 % de las publicaciones tiene MAPE $< 20\%$ en Día 3.

Etap 2: Ajuste del restaurador por plataforma

Modelos Weibull con offset por plataforma



Universo: alcaldes oct. 2023, 33 ciudades; 31 competitivas

- ▶ **Bogotá** excluida: Gustavo Bolívar tiene audiencia supranacional que viola el supuesto de localidad [1.12]
- ▶ **Piedecuesta:** ganador eliminó perfiles por procesos legales

Filtro mayor de 10.000 votos [1.12]

- ▶ Criterio sobre v. dependiente; sesgo de selección documentado
- ▶ MAE y R^2 reflejan el subconjunto más predecible del panel
- ▶ Inaplicable antes del escrutinio; inconsistencia con 2026

Imputación ε [1.13] Aprox. 9 candidatos sin publicaciones: $\varepsilon=10^{-3}$, $\text{logit}(0,001) \approx -6,91$. Variar ε de 0,1 % a 1 % implica $\Delta \hat{y} \approx 26$ pp sobre ese candidato.

Resultado

31 ciudades competitivas

Elecciones de alcaldías, octubre 2023.

Solo candidatos con > 10.000 votos confirmados y presencia digital activa.

Tres plataformas monitoreadas

- ▶ **Facebook y TikTok:** Apify (infraestructura comercial de scraping)
- ▶ **Twitter/X:** scraper propio con Playwright (navegador *headless*)
- ▶ **Instagram excluida:** Meta cerró su API pública para investigadores independientes desde 2023

Ventana temporal: 15 días anteriores al 29 oct. 2023
Restauración Weibull:

Las interacciones brutas se convierten en estimaciones al **día de la elección**, descontando el tráfico póstumo acumulado desde oct. 2023 hasta la extracción.

Dataset final

- ▶ **5.776** publicaciones únicas
- ▶ Facebook: **2.511**
- ▶ Twitter/X: **2.346**
- ▶ TikTok: **919**

- ▶ 31 ciudades, **120 candidatos** (más de 10k votos)
- ▶ 92,6 % con publicaciones activas

Mann-Whitney + permutación intra-contienda [Corr. 1.16/2.2]

- ▶ $p = 0,0481$ para **engagement por publicación** (no para diferencia de medias 44.252 vs. 28.011)
- ▶ Candidatos anidados en 31 contiendas; se barajaron etiquetas ganador/perdedor **dentro** de cada ciudad (10.000 iter.)
- ▶ $\Delta\tilde{x} = 112$ eng/publicación observado; ninguna permutación lo igualó:
 $p < 0,0001$ **empírico**

Correlación de Spearman [Corr. 2.2]


- ▶ $\rho = 0,70$ dominancia relativa; $\rho \approx 0,45$ volumen absoluto
- ▶ Composicionalidad cuantificada: $\rho_{mec.} = 0,261$ (39 %), señal real $\rho_{real} \approx 0,41$ (61 %), $p < 0,0001$

Heurístico de dominancia:

$$\Pr(\text{Top-1}) = \frac{22}{31} = 71,0 \% \quad \text{IC}_{95\%} \text{Wilson: } [53,4 \%, 83,9 \%]$$

P1: Respondida

La señal existe. El 61 % del ρ es señal real ($\rho_{real} \approx 0,41$); el 39 % es inflación composicional. La validez predictiva definitiva: LOCO-CV, MAE = 9,56 pp.



$\rho = 0,70$, 120 candidatos, 31 ciudades [Corr. 2.2]

Pool inicial: más de 22 variables (interacciones reconstruidas con el restaurador Weibull)

1. Nominales absolutas

Likes, comentarios, compartidos totales por plataforma.

Problema: quien más publica, más acumula. Señal ruidosa.

2. Por publicación

Likes, comentarios y compartidos **promedio por post**.

Normalizan la actividad editorial. Más estables, pero dependen del tamaño de la contienda.

3. Dominancia relativa ✓

Cuota de likes sobre el total de la contienda.

Elimina el efecto de tamaño absoluto. Clasificador naive: **71 %**; $\rho = 0,70$.

Intento descartado: normalizar por número de seguidores

VIF elevado. El número de seguidores es inestable, colineal con el volumen de publicaciones, y no disponible históricamente en todas las plataformas.

Pool de 9 variables (tras filtro VIF sobre 22 candidatas)

1. Logit dominancia de *likes*
2. Logit dominancia de comentarios
3. Logit dominancia de compartidos
4. Logit *likes* por publicación
5. Logit comentarios por publicación
6. Logit compartidos por publicación
7. Log-población del municipio
8. Número de candidatos en la contienda
9. Moderador: (1) por (log-pob. centrada)

ElasticNet ($L_1 + L_2$): selección automática.
 $\hat{\alpha} = 0,0475$, $\lambda = 0,10$, StandardScaler.

Selección del modelo (AutoML)

- Familias evaluadas: GLM fraccional, gradient boosting, redes neuronales, SVM, random forests
- Criterio único: MAE fuera de muestra (LOCO-CV)
- **Ganador: GLM fraccional + ElasticNet**

¿Por qué GLM sobre gradient boosting?

(1) Cuota $\in (0, 1)$: GLM binomial+logit garantiza $\hat{y} \in (0, 1)$ (Papke & Wooldridge, 1996). (2) Interpretabilidad: coeficientes en log-odds. MAE similar (9,56 vs. 9,91 pp).

Dos fases del proceso:

- ▶ **Fase 1 (evaluación):** ciclo de 31 pliegues. En cada uno se bloquea una ciudad completa, se hace grid search interno (120 combinaciones de $\hat{\alpha}$ y λ) sobre las 30 ciudades restantes, se elige la mejor combinación, se entrena el ElasticNet y se predice la ciudad bloqueada. Resultado: 31 errores cuyo promedio es el MAE.
- ▶ **Fase 2 (modelo final):** con la combinación ganadora ($\hat{\alpha} = 0,0475$, $\lambda = 0,10$) se entrena el ElasticNet sobre las 31 ciudades completas. Los betas resultantes son los definitivos.

Por qué no CV estándar

Mezclar candidatos entre ciudades genera fuga de información: las cuotas de una tienda suman 1, por lo que ver un candidato de Medellín en entrenamiento adelanta información sobre los demás.

Resultado LOCO-CV

$$\text{MAE}_{\text{oos}} = 9,56 \text{ pp}$$

$$R^2_{\text{oos}} = 0,518$$

Grid search anidado

El CV interno elige $\hat{\alpha}$ y λ **sin ver** la ciudad de prueba. La Fase 1 mide el MAE; la Fase 2 entrega los betas para aplicar en 2026.

ElasticNet retuvo **2 variables** del pool de 9, las 7 restantes penalizadas a cero:

$$\hat{y}_c = \underbrace{0,258}_{\beta_0} + \underbrace{0,111}_{\beta_1} \cdot f_\ell + \underbrace{0,026}_{\beta_2} \cdot f_\ell \cdot (\ln P - \overline{\ln P})$$

$f_\ell = \text{logit}(\text{dominancia de likes})$; $P = \text{población municipal}$

Interpretación de los coeficientes:

- ▶ $\beta_0 = 0,258$: cuota del candidato promedio en ciudad promedio ($\approx 1/3,84$ candidatos)
- ▶ $\beta_1 = 0,111$: por cada unidad adicional en $\text{logit}(\text{dominancia})$, la cuota aumenta aprox. 10 pp
- ▶ $\beta_2 = 0,026$: en ciudades grandes la señal digital pesa más electoralmente

P3: Respondida

La dominancia relativa de *likes* en logit es el predictor más estable y robusto. Población modera el efecto (no predice directamente).

Criterio único de selección: MAE fuera de muestra (LOCO-CV).

Ninguna decisión tomada por ajuste en entrenamiento.

Especificación	β_0	β_1	β_2	MAE LOCO	Transferible 2026
Regresión fraccional simple (Fig. 6.4)	N/A	0,423	N/A	11,52 pp	Sí
ElasticNet 2 vars. (modelo final)	0,258	0,111	0,026	9,56 pp	Sí
ElasticNet 9 vars. (pool completo)	0,258	0,111	0,557*	9,57 pp	No


* $\beta_2 = 0,557$: coeficiente del moderador cuando ElasticNet opera sobre el pool completo de 9 variables, con variables territoriales como efectos directos.

¿Por qué el modelo de 9 vars. no es transferible a 2026?



- ▶ Retiene «número de candidatos» como efecto directo
- ▶ En una 2.^a vuelta: exactamente 2 candidatos; constante sin poder discriminador
- ▶ El modelo de 2 vars. retiene solo señal digital pura más moderador de población

Aclaración proactiva

Los tres juegos de coeficientes corresponden a **tres especificaciones distintas**, no a inconsistencias. La tesis incluye una tabla unificada de reconciliación.




Media $\pm$ IC 95 % del coeficiente en escala logit a través de los 31 pliegues LOCO-CV. La dominancia de *likes* ($\beta_1 \approx 0,78$) y el moderador ($\beta_2 \approx 0,54$) son estables. Ningún pliegue invierte el signo de ningún coeficiente.



Izquierda: predicción vs. cuota real (MAE = 9,56 pp). Derecha: distribución de residuos centrada en cero (sesgo medio = 0,00 pp). El modelo no sobreestima ni subestima sistemáticamente.

Modelo	MAE	R^2_{oos}	Top-1
Baseline proporcionalidad	12,61 pp	0,185	71,0 %
Núcleo digital (f_ℓ solo)	11,52 pp	0,460	71,0 %
ElasticNet 2 variables	9,56 pp	0,518	64,5 %
Gradient boosting (ctrl)	9,91 pp	0,515	67,7 %


Top-1 al 64,5 %: cuota de magnitud y acierto de orden son objetivos distintos. Top-1 es métrica derivada de la regresión, no un clasificador entrenado [\[1.20\]](#).



Ciudades	MAE medio	DE
5	12,82 pp	1,37
10	12,53 pp	1,07
15	12,45 pp	0,94
20	12,22 pp	0,84
30	12,05 pp	0,00

P4: Respondida

Con 10 ciudades se alcanza el 95 % del rendimiento final. El piso de error es **estructural** (ruido de señal), no insuficiencia de datos.



Cepeda Castro vs. De la Espriella, 21 jun. 2026

Candidato	Total likes	Dom.
Cepeda Castro	17.087.679	77,6 %
De la Espriella	4.926.361	22,4 %

Corrección metodológica:

Modelo entrenado: base aprox. 26 % (3,84 candidatos prom.)


2.ª vuelta: base = 50 %; se elimina intercepto:

$$\hat{p}_c^{(2)} = 0,50 + \hat{\beta}_1 \cdot f_\ell(c)$$

Pronósticos: $\hat{p}_{\text{Cepeda}} = 60,5 \%$, $\hat{p}_{\text{Espriella}} = 39,5 \%$

Trazabilidad [Corr. 1.15]: 14 días previos,
FB+TW+TikTok, 444 publicaciones, ElasticNet 2v.
(random_state=42)

Segunda vuelta presidencial Colombia 2026
Señal digital, pronóstico ELA-NOM y resultado real



Dominancia de likes, 444 publicaciones

PM4: Respondida

El modelo es **transferible** a un formato electoral diferente: elección presidencial bipolar vs. alcaldías multicandidate.

Resultado real (21 jun. 2026):

De la Espriella: 50,48 % Cepeda: 49,52 %

Margen real: **0,96 pp**, empate técnico.

$$MAE_{2026} = |60,5 \% - 49,52 \%| = \mathbf{10,98\ pp}$$

Supera el MAE medio de entrenamiento en +1,42 pp.

Corrección conceptual: $\pm MAE$ no es intervalo

El MAE mide exactitud promedio, no dispersión.

“ $\hat{p} \pm MAE$ ” **no tiene cobertura estadística declarada**. Un intervalo formal requiere percentiles de los residuos de LOCO-CV o supuestos distribucionales explícitos.

Límite estructural:

- ▶ Cepeda acumuló 3,5 veces más *likes*; señal real y robusta
- ▶ Ningún modelo de engagement resuelve contiendas menores a 1 pp
- ▶ Las encuestadoras colombianas tampoco lo lograron
- ▶ Factores no capturados: movilización territorial, giros de última semana

Uso práctico adecuado del modelo

ELA-NOM es informativo para ordenar tendencias y detectar ventajas mayores a 20 pp. **No** está diseñado para predecir empates técnicos.

PM4: Delimitado

El fallo es una condición de borde (margen menor a 1 pp), no una falsación del modelo.

Sí, es posible. Con matices estructurales bien documentados.

$MAE_{\text{oos}} = 9,56$ pp $R^2_{\text{oos}} = 0,518$ Top-1 = 64,5 % Mejora de 3,05 pp sobre baseline Costo: 20–30 USD/ejercicio

Preguntas respondidas:

- ▶ **PM1:** Replicación SOMEN-DC posible. MLP-BP+PCA supera 6× al baseline
- ▶ **PM2:** Las tres limitaciones estructurales confirmadas empíricamente
- ▶ **PM3:** Restaurador Weibull – MAPE Día 3 menor al 13 % en las 4 plataformas
- ▶ **P1:** $\rho = 0,70$, $p = 0,0481$ – señal predictiva validada
- ▶ **P2:** Reconstrucción histórica precisa con parámetros por plataforma
- ▶ **P3:** Logit(dominancia *likes*), predictor más robusto y parsimonioso
- ▶ **P4:** Con 10 ciudades se alcanza el 95 % del rendimiento final
- ▶ **PM4:** Transferible a elección presidencial bipolar sin reentrenamiento

Limitaciones estructurales:

- ▶ MAE 9,56 pp: adecuado para tendencias y ventajas mayores a 20 pp; no para empates técnicos
- ▶ Weibull calibrado en una sola elección (Costa Rica 2026)
- ▶ Filtro de 10k votos: sesgo de selección sobre v. dependiente
- ▶ Instagram excluida por restricción de API desde 2023
- ▶ Proxy digital mezcla apoyo, visibilidad, polarización y pauta paga [\[2.1\]](#)

1. Elección-agnosticismo empírico

Primera ruta metodológica demostrada para superar la no-transferibilidad del SOMEN-DC: entrenamiento multi-contienda y exportación del núcleo a formatos electorales distintos.

2. Independencia demoscópica total

Único modelo de esta familia que ancla la optimización directamente sobre el escrutinio final (el único *ground truth* universal) sin depender de encuestas como variable objetivo.

3. Restaurador temporal de series (Weibull)

Arquitectura matemática para poblar datasets históricos desde una extracción estática actual.

$F(t) = 1 - e^{-k(t+t_0)^\alpha}$, parámetros calibrados por plataforma.

4. Democratización del pipeline analítico

Todo el ciclo (scraping, restauración, modelado con regularización) es ejecutable por **20–30 USD**, varios órdenes de magnitud por debajo de una encuesta tradicional.

Validación definitiva, 2027

- ▶ Elecciones territoriales de Colombia 2027
- ▶ Mismo contexto multi-candidato subnacional
- ▶ Modelo ya entrenado; evaluación **ex-ante** estricta
- ▶ Permitirá aislar el desempeño sin sesgos del filtro retrospectivo

Extensión: nowcasting continuo

- ▶ Ejecutar ELA-NOM cada 24 horas durante la campaña
- ▶ Arquitectura técnica ya resuelta con el restaurador Weibull
- ▶ Solo requiere datos de extracción diaria

Líneas de investigación futura

- ▶ Validación del modelo Weibull en elecciones con distintos perfiles demográficos
- ▶ Diseño de umbral de inclusión basado en información pre-elección
- ▶ Inclusión de Instagram cuando Meta reabra el acceso para investigadores
- ▶ Logit condicional de McFadden como clasificador complementario *[Corr. 1.20]*
- ▶ Análisis de sensibilidad completo sobre la imputación ϵ *[Corr. 1.13]*

Objetivo general – Cumplido

Diseñar, implementar y validar un modelo de *nowcasting* electoral elección-agnóstico e independiente de encuestas para el entorno colombiano.

Objetivos específicos:

Objetivo específico	Estado	Evidencia
OE1. Replicar SOMEN-DC y documentar sus limitaciones	Cumplido	Bolivia 2025 – PM1, PM2
OE2. Diseñar restaurador temporal para datos históricos	Cumplido	Weibull por plataforma – PM3, P2
OE3. Construir dataset y validar señal digital en Colombia	Cumplido	31 ciudades, $\rho = 0,70$, $p = 0,048$ – P1
OE4. Seleccionar el modelo de mejor desempeño predictivo	Cumplido	ElasticNet 2v., MAE=9,56 pp, $R^2 = 0,518$ – P3
OE5. Validar transferibilidad a elección no vista	Cumplido	2.ª vuelta 2026, MAE=10,98 pp – PM4

Gracias

Juan Sotelo Aguilar
Maestría en Analítica Aplicada
Universidad de La Sabana